



Wahrscheinlichkeitstheorie und frequentistische Inferenz

Dirk Ostwald

Wintersemester 2026/2027

Inhaltsverzeichnis

Vorbemerkungen	4
Zitation	4
Lizenz	4
1 Wahrscheinlichkeitstheorie	5
2 Wahrscheinlichkeitsräume	10
2.1 Definition und erste Eigenschaften	10
2.2 Wahrscheinlichkeitsfunktionen	16
2.3 Beispiele bei endlichem Ergebnisraum	17
2.4 Literaturhinweise	21
3 Elementare Wahrscheinlichkeiten	23
3.1 Gemeinsame Wahrscheinlichkeiten	23
3.2 Bedingte Wahrscheinlichkeiten	26
3.3 Unabhängige Ereignisse	32
3.4 Literaturhinweise	35
4 Zufallsvariablen	37
4.1 Definition	37
4.2 Wahrscheinlichkeitsmassefunktionen	42
4.3 Wahrscheinlichkeitsdichtefunktionen	45
4.4 Kumulative Verteilungsfunktionen	50
4.5 Zufallsergebnisse und Zufallsvariablen	55
4.6 Literaturhinweise	56
5 Zufallsvektoren	58
5.1 Definition und multivariate Verteilungen	58
5.2 Marginalverteilungen	62
5.3 Bedingte Verteilungen	64
5.4 Unabhängige Zufallsvariablen	66
6 Erwartungswerte	70
6.1 Definitionen	70
6.2 Eigenschaften	74
6.3 Bedingter Erwartungswert	76
7 Varianzen	79
7.1 Definition	79
7.2 Eigenschaften	83
7.3 Bedingte Varianz	85

8	Kovarianzen	88
8.1	Definitionen	88
8.2	Eigenschaften	89
8.3	Bedingte Kovarianz	96
8.4	Kovarianzmatrizen	97
9	Ungleichungen	101
9.1	Wahrscheinlichkeitsungleichungen	101
9.2	Erwartungswertungleichungen	103
10	Grenzwerte	107
10.1	Gesetze der großen Zahlen	107
10.2	Zentrale Grenzwertsätze	109
10.3	Literaturhinweise	112
11	Transformationen	113
11.1	Univariate Transformationstheoreme	115
11.2	Multivariate Transformationstheoreme	117
12	Normalverteilungen	120
12.1	Konstruktion multivariater Normalverteilungen	120
12.2	Definition multivariater Normalverteilungen	122
12.3	Sphärizität	124
12.4	Marginale, bedingte und gemeinsame Verteilungen	125
12.5	Marginale Normalverteilungen	126
12.6	Multivariate Transformationen	128
12.7	Transformationen normalverteilter Zufallsvariablen	130
12.8	Literaturhinweise	144
	Referenzen	145

Vorbemerkungen

Dieses Vorlesungsskript begleitet die Veranstaltung *Wahrscheinlichkeitstheorie und frequentistische Inferenz* am Institut für Psychologie der Otto-von-Guericke-Universität Magdeburg im Wintersemester 2026/2027. Die Kapitel dieses Skripts sind unverändert dem Lehrbuch *Probabilistische Datenwissenschaft für die Psychologie (PDWP)* entnommen.

Zitation

Ostwald, D. (2024) Probabilistische Datenwissenschaft für die Psychologie. [10.5281/zenodo.10730199](https://doi.org/10.5281/zenodo.10730199)

Lizenz

Dieses Werk ist lizenziert unter einer Creative Commons Namensnennung 4.0 International Lizenz (CC BY 4.0).

Verweise auf Abschnitte außerhalb dieses Skripts führen zu den entsprechenden Stellen im PDWP-Onlinelehrbuch.

1 Wahrscheinlichkeitstheorie

Vorbemerkungen

Die Wahrscheinlichkeitstheorie ist ein mathematisches Modell zur Beschreibung von und zum quantitativen Schlussfolgern über *Zufallsvorgänge* der Wirklichkeit (Abbildung 1.1). Unter Zufallsvorgängen verstehen wir dabei alle Phänomene, die von uns nicht mit absoluter Sicherheit vorhergesagt werden können, deren Ergebnis also mit Unsicherheit behaftet ist. Offensichtliche und vertraute Beispiele für Zufallsvorgänge sind das Werfen eines Würfels oder einer Münze. Allerdings ist der Begriff des Zufallsvorgangs und damit der Anwendungsbereich der Wahrscheinlichkeitstheorie als sehr viel weiter gefasst zu verstehen. Nicht mit vollständiger Sicherheit vorhersagbar und damit mit Unsicherheit behaftet sind zum Beispiel auch der Ausgang einer Wahl, das morgige Wetter, der Messwert einer Elektroenzephalographie-Elektrode zu einem bestimmten Zeitpunkt oder der Effekt einer Psychotherapieintervention auf den Gesundheitszustand einer Patientin. Beginnt man darüber nachzudenken, welche Phänomene der Wirklichkeit mit Unsicherheit behaftet sind, so fällt es schwer, nichttriviale Phänomene anzugeben hinsichtlich deren Ergebnis man vollständige Sicherheit besitzt.

Als mathematisches Modell von Zufallsvorgängen erlaubt die Wahrscheinlichkeitstheorie insbesondere das vernunftbasierte, quantitative Schlussfolgern über Zufallsvorgänge. Dies schlägt sich primär in der sogenannten *Wahrscheinlichkeitsrechnung* nieder. Quantitative Schlussfolgerungen der Wahrscheinlichkeitsrechnung haben beispielsweise folgende Form: Wenn ich annehme, dass das Ereignis A mit Wahrscheinlichkeit p_1 und das Ereignis B mit Wahrscheinlichkeit p_2 eintritt, dann ergibt sich ein Ereignis C eine Wahrscheinlichkeit von p_3 . Dabei ist der Schluss auf die Wahrscheinlichkeit von C logisch-mathematisch abgesichert, in dem gleichen Sinn, wie zum Beispiel logisch-mathematisch abgesichert ist, dass $1 + 1 = 2$ ist. Ob die Annahmen hinsichtlich der Wahrscheinlichkeiten von A und B aber den Gegebenheiten des Zufallsvorgangs in der Wirklichkeit entsprechen, darüber macht die Wahrscheinlichkeitstheorie keine Aussagen.

Die Wahrscheinlichkeitstheorie selbst bedient sich dabei der mathematischen Theorie der Mengen und Funktionen. Spätestens seit Kolmogoroff (1933) herrscht dabei ein axiomatischer Zugang vor: Man fragt in der Wahrscheinlichkeitstheorie selbst nicht, was denn eine Wahrscheinlichkeit sei oder inwieweit die Vorhersagen der Wahrscheinlichkeitstheorie mit der Wirklichkeit übereinstimmen, sondern versucht, ein in sich schlüssiges formal-mathematisches System von unbegründeten, aber intuitiv plausiblen, Grundannahmen und ihren Folgerungen zu entwickeln. Ausgangspunkt dieser Entwicklung ist das *Wahrscheinlichkeitsraummodell* eines Zufallsvorgangs, das wir in Kapitel 2 einführen werden. In der Tat gibt es neben dem formal-mathematischen System der Wahrscheinlichkeitstheorie bis heute mathematisch-philosophische Diskussionen darüber, was genau denn unter dem Begriff der “Wahrscheinlichkeit eines Ereignisses” zu verstehen ist. Dabei sind grob gesagt zwei etwas gegensätzliche Interpretationen vorherrschend,




Abbildung 1.1 *Wahrscheinlichkeitstheorie als Modell von Zufallsvorgängen.* Ausgangspunkt der Wahrscheinlichkeitstheorie ist die Absicht, über einen Zufallsvorgang, also ein mit Unsicherheit behaftetes Phänomen der Wirklichkeit, logisch-quantitative Schlüsse zu ziehen. Die Repräsentation zentraler Aspekte des Zufallsvorgangs mithilfe wahrscheinlichkeitstheoretischer Begrifflichkeiten bezeichnet man als *Modellierung*. Das wahrscheinlichkeitstheoretische Modell selbst garantiert dann im Sinne der Wahrscheinlichkeitsrechnung die Korrektheit logisch-quantitativer Schlussfolgerungen, welche zur Vorhersage von Aspekten des Zufallsvorgangs genutzt werden können.

zum einen die sogenannte *Frequentistische Interpretation* als prototypisches Beispiel *realistischer Interpretationen*, zum anderen die sogenannte *Bayesianische Interpretation* als allgemeine Form sogenannter *evidenzieller Interpretationen*. Für eine genauere Übersicht verschiedener Interpretationen des Wahrscheinlichkeitsbegriffs, siehe Tabelle 1.1 nach Hájek (2019).

Tabelle 1.1 Interpretationen von Wahrscheinlichkeit nach Hájek (2019). Die *Frequentistische Interpretation* entspricht in ihren wesentlichen Zügen der in der Tabelle skizzierten *unendlich Frequentistischen realistischen Interpretation*, die *Bayesianische Interpretation* entspricht in ihren wesentlichen Zügen den in der Tabelle skizzierten *subjektiven evidentiellen* und *epistemisch evidentiellen Interpretationen*.

Interpretation	Intuition	Anwendungsfeld	Probleme	Referenzen
Endlich Frequentistisch	Die Wahrscheinlichkeit einer Münze, Kopf zu zeigen, entspricht der relativen Häufigkeit der Münze, bei endlich vielen Beobachtungen Kopf zu zeigen.	–	Bei einmaligem Münzwurf ergibt sich keine sinnvolle Prädiktion, Wahrscheinlichkeiten ändern sich je nach Beobachtungsreihe, sind also nicht eindeutig definiert.	Venn (1876)
Unendlich Frequentistisch	Die Wahrscheinlichkeit einer Münze, Kopf zu zeigen, entspricht der relativen Häufigkeit der Münze, bei unendlich vielen Beobachtungen Kopf zu zeigen.	Frequentistische Inferenz	Es gibt keine unendlichen Beobachtungsreihen, bei endlich vielen Münzwürfen ist die Wahrscheinlichkeit eines Ereignisses nicht definiert.	Reichenbach (1949) von Mises (1951)
Propensitär	Die Wahrscheinlichkeit einer Münze, Kopf zu zeigen, entspricht ihrer inhärenten physischen Neigung im Schwerefeld der Erde Kopf zeigend zu landen.	Kausale Inferenz	Zusammenhang zu relativen Häufigkeiten oder physikalischen Theorien nicht unmittelbar klar.	Peirce (1957) Popper (1959) Gillies (2000)
Klassisch	In Abwesenheit weiterer Information sind die Wahrscheinlichkeiten einer Münze, Kopf oder Zahl zu zeigen, gleich.	Glücksspiele, Lehrbücher	Beschränkung auf endliche Ergebnisräume	Laplace (1814) Jaynes (1968)

Interpretation	Intuition	Anwendungsfeld	Probleme	Referenzen
Subjektiv	Die Wahrscheinlichkeit einer Münze, Kopf zu zeigen, entspricht dem subjektiven Grad der Unsicherheit, dem ein Beobachter dem Ausgang eines Münzwurfs zuweist.	Bayesianische Inferenz	Keine prinzipielle Beschränkung auf axiomatisch valide Wahrscheinlichkeiten	De Finetti (1975)
Epistemisch	Die Wahrscheinlichkeit einer Münze, Kopf zu zeigen, entspricht dem subjektiven Grad der Unsicherheit, dem ein rationaler Beobachter dem Ausgang eines Münzwurfs zuweist.	Bayesianische Inferenz	Zusammenhang zu relativen Häufigkeiten oder physikalischen Theorien nicht unmittelbar klar	Ramsey (1926) Jeffreys (1939) Savage (1954)

Nach der *Frequentistischen Interpretation* ist die Wahrscheinlichkeit eines Ereignisses die idealisierte relative Häufigkeit, mit der ein Ereignis unter den gleichen äußeren Bedingungen eintreten pflegt. Zum Beispiel ist die Frequentistische Interpretation der Aussage “Mit einer Wahrscheinlichkeit von $1/6$ zeigt der Würfel im nächsten Wurf eine 2” die folgende: “Wenn man einen Würfel unendlich oft werfen würde und dabei die relative Häufigkeit des Ereignisses, dass der Würfel eine 2 zeigt, bestimmen würde, dann wäre diese relative Häufigkeit gleich $1/6$ ”. Man beachte bei dieser Interpretation, dass man de-facto die Wahrscheinlichkeit eines Ereignisses nicht empirisch bestimmen kann, da man einen Würfel nicht unendlich oft werfen kann. Natürlich kann man die Wahrscheinlichkeit in dieser Interpretation aber empirisch schätzen. Schätzvorgänge selbst wiederum sind allerdings kein Teil der Wahrscheinlichkeitstheorie, sondern der *Inferenz*.

Nach der *Bayesianischen Interpretation* ist die Wahrscheinlichkeit eines Ereignisses der Grad der Sicherheit, den eine Beobachterin aufgrund ihrer subjektiven Einschätzung der Lage dem Eintreten des Ereignisses zuschreibt. Zum Beispiel ist die Bayesianische Interpretation der Aussage “Mit einer Wahrscheinlichkeit von $1/6$ zeigt der Würfel im nächsten Wurf eine Zwei” dann etwa die folgende: “Basierend auf meiner eigenen und der tradierten Erfahrung mit dem Werfen eines Würfels bin ich mir zu 16.6% sicher, dass der Würfel beim nächsten Wurf eine Zwei zeigt.”

In Modellen von tatsächlich zumindest unter ähnlichen Umständen wiederholbaren Zufallsvorgängen wie dem Werfen eines Würfels ist der Unterschied zwischen Frequentistischer und Bayesianischer Interpretation oft eher subtil. Es gibt aber wie oben angedeutet viele Zufallsvorgänge, die mit Wahrscheinlichkeiten beschrieben werden können, bei denen aufgrund ihrer Einmaligkeit eine Frequentistische Interpretation nicht angemessen ist. Zum Beispiel machen Aussagen der Form “Die Wahrscheinlichkeit dafür, dass die weltweiten Hitzerekorde im Jahr 2023 nicht auf den Klimawandel zurückzuführen sind, ist kleiner als 0.01” (vgl. Philip et al. (2020)) nur unter der Bayesianischen Interpretation Sinn, da es

sich bei den Wetteraufzeichnungen des Jahres 2023 um ein einmaliges, nicht wiederholbares Ereignis handelt.

Obwohl also die Interpretation des Begriffes der Wahrscheinlichkeit durchaus nicht eindeutig ist, unterscheiden sich die formalen Definitionen und Rechenregeln für Wahrscheinlichkeiten nicht. Sowohl die Frequentistische als auch die Bayesianische Inferenz haben mit der Wahrscheinlichkeitstheorie ein identisches mathematisches Bezugssystem und gemeinsames Fundament. Im Wesentlichen unterscheidet sich diese Tatsache nicht so sehr von vielen anderen Formen der mathematischen Modellierung. Beispielsweise kann die Ableitung einer Funktion als die Geschwindigkeit eines Objekts oder als die Wachstumsrate einer Bakterienpopulation interpretiert werden. Obwohl sich diese Phänomene intuitiv sehr stark in Bezug auf die Realität unterscheiden, ist das logische Schlussfolgern über beide Phänomene im Bereich der Mathematik identisch.

2 Wahrscheinlichkeitsräume

Ein *Wahrscheinlichkeitsraum* ist ein sehr allgemein gehaltenes formal-mathematisches Modell eines Zufallsvorgangs. Die zentrale Bedeutung dieses Modells für die Wahrscheinlichkeitstheorie und probabilistische Inferenz ergibt sich daraus, dass das Wahrscheinlichkeitsraummodell eine Anleitung dafür gibt, wie man beliebige Zufallsvorgänge, über die man quantitativ schlussfolgern möchte, in das formal-mathematische System der Wahrscheinlichkeitstheorie übersetzen kann. Gleichzeitig garantiert das Wahrscheinlichkeitsraummodell und die auf ihm aufgebauten Konzepte, dass die Mechanik der Wahrscheinlichkeitsrechnung zu logisch sinnvollen quantitativen Schlüssen über Zufallsvorgänge führt. In diesem Kapitel führen wir den Begriff des Wahrscheinlichkeitsraums ein (Kapitel 2.1) und geben dann mithilfe von Wahrscheinlichkeitsfunktionen (Kapitel 2.2) erste Beispiele für die Modellierung von Zufallsvorgängen (Kapitel 2.3).

2.1 Definition und erste Eigenschaften

Wir beginnen mit der Definition des Wahrscheinlichkeitsraummodells nach Kolmogoroff (1933), das wir dann nachfolgend in seinen Einzelteilen aus Frequentistischer Perspektive erläutern wollen.

Definition 2.1 (Wahrscheinlichkeitsraum). Ein *Wahrscheinlichkeitsraum* ist ein Triple $(\Omega, \mathcal{A}, \mathbb{P})$, wobei

- Ω eine beliebige nichtleere Menge von *Ergebnissen* ω ist und *Ergebnismenge* heißt,
- $\mathcal{A}$ eine Menge von Teilmengen von Ω mit den Eigenschaften
 - $\Omega \in \mathcal{A}$,
 - für alle $A \in \mathcal{A}$ gilt, dass auch $A^c := \Omega \setminus A \in \mathcal{A}$,
 - aus $A_1, A_2, \dots \in \mathcal{A}$ folgt, dass auch $\bigcup_{i=1}^{\infty} A_i \in \mathcal{A}$

ist, σ -Algebra auf Ω genannt wird und *Ereignissystem* heißt,

- $\mathbb{P}$ eine Abbildung der Form $\mathbb{P} : \mathcal{A} \rightarrow [0, 1]$ mit den Eigenschaften
 - $\mathbb{P}(A) \geq 0$ für alle $A \in \mathcal{A}$ (*Nicht-Negativität*),
 - $\mathbb{P}(\Omega) = 1$ (*Normiertheit*),
 - $\mathbb{P}(\bigcup_{i=1}^{\infty} A_i) = \sum_{i=1}^{\infty} \mathbb{P}(A_i)$ für paarweise disjunkte $A_i \in \mathcal{A}$ (σ -Additivität)

ist und *Wahrscheinlichkeitsmaß* heißt.

•

Ergebnismenge und Mechanik

Wir beginnen mit Erläuterungen zum Begriff der *Ergebnismenge* Ω und der impliziten Mechanik des Wahrscheinlichkeitsraummodells. Um den Einstieg zu erleichtern, betrachten wir im Folgenden zunächst vor allem *endliche Wahrscheinlichkeitsräume*, bei denen die Kardinalität von Ω nicht unendlich groß ist. Es sei also $|\Omega| < \infty$, Ω habe also nur endlich viele Elemente. Zum Modellieren des Werfens eines Würfels könnte man zum Beispiel $\Omega := \{1, 2, 3, 4, 5, 6\}$ definieren.

Hinter der formalen Definition des Wahrscheinlichkeitsraummodells stehen folgende Frequentistisch-geprägten Annahmen über seine Mechanik als Modell eines Zufallsvorgangs. Wir stellen uns zunächst sequentielle Durchgänge eines Zufallsvorgangs vor, also zum Beispiel das wiederholte Werfen eines Würfels. Nach Annahme des Wahrscheinlichkeitsraummodells wird in jedem dieser Durchgänge genau ein ω aus Ω *realisiert*, also als tatsächlich vorliegend ausgewählt. Wirft man zum Beispiel einen Würfel und fällt eine Zwei, so sagt man, dass eine Zwei realisiert wurde. Die Wahrscheinlichkeit, mit der ein ω aus Ω in einem Durchgang realisiert wird, wird durch den Wert $\mathbb{P}(\{\omega\}) \in [0, 1]$ beschrieben. Ist zum Beispiel $\mathbb{P}(\{\omega\}) = 1$, so wird dieses ω in jedem Durchgang des Zufallsvorgangs realisiert, ist $\mathbb{P}(\{\omega\}) = 0$, so wird dieses ω in keinem Durchgang des Zufallsvorgangs realisiert, und ist $\mathbb{P}(\{\omega\}) = 1/2$, so wird ω in etwa der Hälfte der Durchgänge des Zufallsvorgangs realisiert. Beim Modell des Werfens eines fairen Würfels nimmt man üblicherweise $\mathbb{P}(\{\omega\}) = 1/6$ für alle $\omega \in \Omega$ an. Hier könnte zum Beispiel im ersten Durchgang eine Vier realisiert werden, im zweiten Durchgang eine Eins, im dritten Durchgang eine Fünf, dann vielleicht wieder eine Vier und so weiter.

Ereignisse und Ereignissystem

Den Begriff des *Ereignisses* $A \in \mathcal{A}$ stellt man sich am besten als konzeptionelle Zusammenfassung ein oder mehrerer Ergebnisse vor. Beim Werfen eines Würfels sind mögliche Ereignisse zum Beispiel “Es fällt eine gerade Augenzahl”, das heißt $\omega \in \{2, 4, 6\}$, “Es fällt eine Augenzahl größer als zwei”, das heißt $\omega \in \{3, 4, 5, 6\}$, oder etwa “Es fällt eine Eins oder eine Fünf”, das heißt $\omega \in \{1, 5\}$. Man beachte, dass zum Beispiel das Ereignis “Es fällt eine gerade Augenzahl” vor dem Hintergrund der Mechanik des Wahrscheinlichkeitsraums genau dann eintritt, wenn in einem Durchgang des Zufallsvorgangs *Werfen eines Würfels* das realisierte ω ein Element der Menge $\{2, 4, 6\}$ ist, wenn also zum Beispiel eine Vier fällt. Man mag das Eintreten des Ereignisses “Es fällt eine Augenzahl größer als zwei” also auch lesen als “In einem Durchgang des Zufallsvorgangs *Werfen eines Würfels* wird ein Element von $\{3, 4, 5, 6\}$ realisiert”, da heißt, konkret fällt entweder eine Drei, eine Vier, eine Fünf oder eine Sechs. Natürlich sind auch die Ergebnisse $\omega \in \Omega$ selbst mögliche Ereignisse, sodass zum Beispiel folgende Interpretationen gelten: Das Ereignis “Es fällt eine Eins” entspricht der Realisation $\omega \in \{1\}$ und das Ereignis “Es fällt eine Sechs” entspricht der Realisation $\omega \in \{6\}$. Betrachtet man in diesem Zusammenhang ein Ergebnis $\omega \in \Omega$ als Ereignis, so nennt man es *Elementarereignis* und schreibt es als einelementige Menge $\{\omega\}$.

Insgesamt entspricht dieses Vorgehen zur Beschreibung zufälliger Ereignisse dem inhärenten Ziel der Definition des Wahrscheinlichkeitsraums. Kolmogoroff (1933) schreibt dazu “Wir haben die eigentlichen Objekte unserer weiteren Betrachtungen - die zufälligen Ereignisse - als Mengen definiert.” Dies hat den Vorteil, dass Mengen mathematische Objekte sind, mit denen mathematisch gearbeitet werden kann und damit ein Aspekt der

Wirklichkeit, ein “zufälliges Ereignis”, in den Modellbereich der Mathematik übersetzt wurde.

Alleiniger Sinn des *Ereignissystems* $\mathcal{A}$ ist es nun, alle Ereignisse, die sich basierend auf einer gegebenen Ergebnismenge bei Auswahl eines $\omega \in \Omega$ ergeben können, mathematisch zu repräsentieren. Es soll also keine Ereignisse in der Wirklichkeit geben, die nicht im Vorhinein im Wahrscheinlichkeitsraummodells des Zufallsvorgangs mitgedacht wurden. Wäre dies der Fall, so wäre das Modell defizitär, da es für bestimmte, in der Wirklichkeit eintretende Ereignisse keine Wahrscheinlichkeiten angeben könnte. Das Ereignissystem $\mathcal{A}$ soll also die vollständige Menge aller möglichen Ereignisse bei vorgegebenem Ω sein. Die Forderung, dass $\mathcal{A}$ zu diesem Zweck die sogenannten σ -Algebra Kriterien erfüllen soll, begründet sich dabei intuitiv wie folgt.

- Es soll zunächst einmal sichergestellt sein, dass $\omega \in \Omega$ für ein beliebiges ω , dass also irgendein Ergebnis realisiert wird, eines der möglichen Ereignisse ist. Dies entspricht der Eigenschaft $\Omega \in \mathcal{A}$.
- Zu jedem Ereignis soll es weiterhin auch möglich sein, dass dieses Ereignis gerade nicht eintritt. Dies entspricht der Eigenschaft, dass aus $A \in \mathcal{A}$ folgen soll, dass $A^c := \Omega \setminus A$ auch in $\mathcal{A}$ ist. Dies impliziert insbesondere auch, dass $\emptyset = \Omega \setminus \Omega \in \mathcal{A}$. Ein Ereignis ist also, dass kein Elementarereignis eintritt, allerdings passiert dies nur mit Wahrscheinlichkeit Null, $\mathbb{P}(\emptyset) = 0$. Es tritt also sicher immer zumindest ein Elementarereignis ein.
- Schließlich soll die Kombination von Ereignissen auch immer ein Ereignis sein. Bei der Modellierung des Werfens eines Würfels soll also zum Beispiel neben den Ereignissen “Es fällt eine gerade Zahl” und “Es fällt eine Zahl größer Zwei” auch das Ereignis “Es fällt eine gerade Zahl und/oder diese Zahl ist größer als zwei” ein Ereignis sein. Dies entspricht, in allgemeiner Form, dass aus $A_1, A_2, \dots \in \mathcal{A}$ folgen soll, dass auch $\bigcup_{i=1}^{\infty} A_i \in \mathcal{A}$ ist.

Wenn auch die Begriffe des Ereignissystems und der σ -Algebra etwas abstrakt anmuten mögen, so stellt ihre Definition in der praktischen Modellierung von Zufallsvorgängen meist keine große Herausforderung dar, da sowohl für endliche Ergebnismengen als auch für unendliche abzählbare und überabzählbare Ergebnismengen passende Ereignissysteme schon lange bekannt sind. So erfüllt bei Ergebnismengen mit endlicher Kardinalität die Potenzmenge der Ergebnismenge immer die Anforderungen eines Ereignissystems und kann immer zur Modellformulierung eines Zufallsvorgangs mit endlicher Ergebnismenge genutzt werden. Dies ist die Aussage folgenden Theorems.

Theorem 2.1 (Ereignissystem bei endlicher Ergebnismenge). $\Omega := \{\omega_1, \omega_2, \dots, \omega_n\}$ mit $n \in \mathbb{N}$ sei eine endliche Menge. Dann ist die Potenzmenge $\mathcal{P}(\Omega)$ von Ω eine σ -Algebra auf Ω und damit ein geeignetes Ereignissystem im Wahrscheinlichkeitsraummodell.

◦

Beweis. Die Potenzmenge von Ω ist die Menge aller Teilmengen von Ω . Wir überprüfen die σ -Algebra Eigenschaften. Zunächst gilt, dass Ω selbst eine der Teilmengen von Ω ist, also ist die erste σ -Algebra Eigenschaft erfüllt. Sei nun A eine Teilmenge von Ω . Dann ist auch $A^c = \Omega \setminus A$ eine Teilmenge von Ω und somit ist auch die zweite σ -Algebra Eigenschaft erfüllt. Schließlich betrachten wir die Vereinigung von k Teilmengen $A_1, A_2, \dots, A_k \subseteq \Omega$. Dann ist $\bigcup_{i=1}^k A_i$ die Menge der $\omega \in \Omega$ für die gilt, dass $\omega \in A_1$ und/oder $\omega \in A_2 \dots$ und/oder $\omega \in A_k$. Da für alle diese ω gilt, dass $\omega \in \Omega$ ist also auch $\bigcup_{i=1}^k A_i$ eine Teilmenge von Ω und damit auch die dritte σ -Algebra Eigenschaft erfüllt. Die Potenzmenge erfüllt also die geforderten Eigenschaften an ein Ereignissystem. $\square$

Bei überabzählbaren Ergebnismengen wie den reellen Zahlen $\mathbb{R}$ oder dem n -dimensionalen reellen Raum $\mathbb{R}^n$ ist die Konstruktion eines geeigneten Ereignissystems komplexer, sodass wir in dieser Hinsicht für formale Entwicklungen auf die weiterführende Literatur verweisen wollen (vgl. Meintrup & Schäffler (2005), Schmidt (2009)). Mit der auf Borel (1898) zurückgehenden sogenannten *Borelschen σ -Algebra* ist jedoch ein Mengensystem bekannt, das den Anforderungen einer σ -Algebra auf überabzählbaren Ergebnismengen genügt. Wir bezeichnen die Borelsche σ -Algebra auf $\mathbb{R}$ mit $\mathcal{B}(\mathbb{R})$ und die Borelsche σ -Algebra auf $\mathbb{R}^n$ mit $\mathcal{B}(\mathbb{R}^n)$. Als Menge von Teilmengen von $\mathbb{R}$ bzw. $\mathbb{R}^n$ enthalten $\mathcal{B}(\mathbb{R})$ bzw. $\mathcal{B}(\mathbb{R}^n)$ alle Mengen, an denen man hinsichtlich ihrer durch $\mathbb{P}$ zugeordneten Wahrscheinlichkeit interessiert sein mag. Intuitiv mag man sich die Borelschen σ -Algebren $\mathcal{B}(\mathbb{R})$ und $\mathcal{B}(\mathbb{R}^n)$ also als die Potenzmengen von $\mathbb{R}$ bzw. $\mathbb{R}^n$ denken, auch wenn dies formal falsch ist. Tatsächlich enthält die Borelsche σ -Algebra nur Teilmengen, die durch abzählbare Mengenoperationen generiert werden, nicht aber durch überabzählbare.

Insgesamt ergibt sich also folgendes Vorgehen zur Auswahl von Ereignissystemen in Abhängigkeit von der Ergebnismenge Ω . Ist Ω endlich, so wählt man als Ereignissystem $\mathcal{A}$ die Potenzmenge $\mathcal{P}(\Omega)$ von Ω . Ist Ω gegeben durch $\mathbb{R}$, so wählt man als Ereignissystem $\mathcal{A}$ die Borelsche σ -Algebra $\mathcal{B}(\mathbb{R})$. Ist Ω schließlich gegeben durch $\mathbb{R}^n$, so wählt man für $\mathcal{A}$ die Borelsche σ -Algebra $\mathcal{B}(\mathbb{R}^n)$. In Spezialfällen und für sehr spezielle Ergebnismengen Ω mag man von diesem Vorgehen abweichen wollen, allgemein decken die drei betrachteten Fälle jedoch die meisten Anwendungen ab.

Wahrscheinlichkeitsmaß $\mathbb{P}$

Mit Ω und $\mathcal{A}$, die in Tupleform $(\Omega, \mathcal{A})$ auch als *Messraum* bezeichnet werden, haben wir bisher die *strukturelle Basis* eines Wahrscheinlichkeitsraummodells genauer betrachtet. Viele Wahrscheinlichkeitsräume, zum Beispiel für Zufallsvorgänge die reellen Zahlen betreffend, sind hinsichtlich ihres Messraums identisch. Das *Wahrscheinlichkeitsmaß* $\mathbb{P}$ nun repräsentiert die probabilistischen Charakteristika eines Wahrscheinlichkeitsraummodells und formt damit die *funktionelle Basis* eines solchen. Wir werden im Folgenden, insbesondere nach Einführung der Begriffe der Zufallsvariablen und Zufallsvektoren, sehr viele verschiedene Wahrscheinlichkeitsmaße kennenlernen. An dieser Stelle wollen wir zunächst nur allgemeine Eigenschaften von Wahrscheinlichkeitsmaßen betrachten.

Mit der Definition

$$\mathbb{P} : \mathcal{A} \rightarrow [0, 1], A \mapsto \mathbb{P}(A) \quad (2.1)$$

gilt zunächst einmal, dass ein Wahrscheinlichkeitsmaß auf einer Menge von Mengen definiert ist und den Elementen dieser Menge, also den Mengen $A \in \mathcal{A}$, Wahrscheinlichkeiten, also Werte im Intervall $[0, 1]$, zuordnet. Natürlich gilt mit $\{\omega\} \in \mathcal{A}$ für alle $\omega \in \Omega$, dass $\mathbb{P}$ auch den Elementareignissen Wahrscheinlichkeiten zuordnet, aber eben nicht nur. Wir betonen auch, dass nach Definition die Wahrscheinlichkeit $\mathbb{P}(A)$ eines Ereignisses $A \in \mathcal{A}$ eine Zahl im Intervall $[0, 1]$ ist und nicht etwa eine Prozentzahl oder ein Verhältnis. Wir wollen nachfolgend die definierenden Eigenschaften der *Nicht-Negativität*, der *Normiertheit* und der σ -*Additivität* von $\mathbb{P}$ näher beleuchten.

Die *Nicht-Negativität* $\mathbb{P}(A) \geq 0$ für alle $A \in \mathcal{A}$ ist natürlich in der Definition $[0, 1]$ der Zielmenge von $\mathbb{P}$ implizit. Tatsächlich ist die Abbildungsform von $\mathbb{P}$ eine von uns vorgenommene Ergänzung der Formulierung von Kolmogoroff (1933), die der Klarheit dienen soll. Formal folgt die Form der Zielmenge von $\mathbb{P}$ eigentlich aus den definierenden Eigenschaften der Nicht-Negativität, Normiertheit und σ -Additivität von $\mathbb{P}$.

Die *Normiertheit* $\mathbb{P}(\Omega) = 1$ entspricht der Tatsache, dass in jedem Durchgang eines Zufallsvorgangs sicher gilt, dass ein realisiertes ω ein Element von Ω ist. In jedem Durchgang eines Zufallsvorgangs tritt also ein Elementarereignis ein und, je nach Beschaffenheit des Messraums, noch viele weitere. Beim Modell des Werfens eines Würfels gilt also, dass das in einem Durchgang des Zufallsvorgangs realisierte Ergebnis/Elementarereignis mit Wahrscheinlichkeit 1 ein Element von $\Omega := \{1, 2, 3, 4, 5, 6\}$ ist. Ist das realisierte Ergebnis zum Beispiel eine Eins, so treten neben dem Ereignis “Es fällt eine Eins” auch noch die Ereignisse “Eine ungerade Zahl fällt”, “Eine Zahl kleiner als drei fällt”, “Eine ungerade Zahl kleiner als drei fällt” und viele weitere ein.

Die σ -Additivität des Wahrscheinlichkeitsmaßes $\mathbb{P}$ schließlich bildet das Fundament der *Wahrscheinlichkeitsrechnung*, also die Grundlage für das Rechnen mit Wahrscheinlichkeiten. Die σ -Additivität von $\mathbb{P}$ erlaubt es nämlich, aus bereits bekannten Ereigniswahrscheinlichkeiten die Wahrscheinlichkeiten anderer Ereignisse zu berechnen. Man kann damit basierend auf einer Definition von Ω , $\mathcal{A}$ und $\mathbb{P}$ also Wahrscheinlichkeiten für alle möglichen Ereignisse eines Wahrscheinlichkeitsraummodells berechnen. Ob diese Wahrscheinlichkeiten nun aber tatsächlich etwas mit den realen Ereignissen bezüglich eines Zufallsvorgangs der Wirklichkeit zu tun haben, kommt darauf an, ob die Modellierung einigermaßen gelungen ist oder nicht. Dabei werden berechnete Wahrscheinlichkeiten aber zumindest rational, also nach den Regeln der Vernunft, das heißt der Logik und der Mathematik, bestimmt. Insgesamt erlaubt das Wahrscheinlichkeitsmodell damit das schlussfolgernde Nachdenken über Zufallsvorgänge, also mit Unsicherheit behaftete Phänomene.

Wir wollen abschließend das auf der σ -Additivität von $\mathbb{P}$ beruhende Rechnen mit Wahrscheinlichkeiten noch an zwei grundlegenden Beispielen verdeutlichen. Das erste Beispiel besagt, dass die Wahrscheinlichkeit dafür, dass das in einem Durchgang eines Zufallsvorgangs realisierte ω kein Element der Ergebnismenge ist, gleich null ist.

Theorem 2.2 (Wahrscheinlichkeit des unmöglichen Ereignisses). *$(\Omega, \mathcal{A}, \mathbb{P})$ sei ein Wahrscheinlichkeitsraum. Dann gilt*

$$\mathbb{P}(\emptyset) = 0. \quad (2.2)$$

◦

Beweis. Für $i = 1, 2, \dots$ sei $A_i := \emptyset$. Dann ist $A_1, A_2, \dots$ eine Folge disjunkter Ereignisse, weil gilt, dass $\emptyset \cap \emptyset = \emptyset$ und es ist $\cup_{i=1}^{\infty} A_i = \emptyset$. Mit der σ -Additivität von $\mathbb{P}$ folgt dann, dass

$$\mathbb{P}(\emptyset) = \mathbb{P}(\cup_{i=1}^{\infty} A_i) = \sum_{i=1}^{\infty} \mathbb{P}(A_i) = \sum_{i=1}^{\infty} \mathbb{P}(\emptyset). \quad (2.3)$$

Das unendliche Aufaddieren der Zahl $\mathbb{P}(\emptyset) \in [0, 1]$ soll also wieder $\mathbb{P}(\emptyset)$ ergeben. Dies ist aber nur möglich, wenn $\mathbb{P}(\emptyset) = 0$. $\square$

Man beachte, dass hier intuitiv natürlich eine mögliche Unzulänglichkeit des Wahrscheinlichkeitsraums als Modell für Zufallsvorgänge in der Wirklichkeit auftritt: Fällt beim Würfelspiel der Würfel zum Beispiel unerreichbar unter das Sofa, so ist ein Elementarereignis $\omega \notin \Omega$ eingetreten, obwohl seine modellierte Wahrscheinlichkeit gleich null ist.

Als zweites Beispiel wollen wir zeigen, dass die σ -Additivität, die in der Definition des Wahrscheinlichkeitsraums (nur) für die Vereinigung unendlich vieler disjunkter Ereignisse definiert ist, die σ -Additivität endlich vieler disjunkter Ereignisse, wie sie in der Anwendung oft vorkommen, impliziert.

Theorem 2.3 (σ -Additivität bei endlichen Folgen disjunkter Ereignisse). $(\Omega, \mathcal{A}, \mathbb{P})$ sei ein Wahrscheinlichkeitsraum und $A_1, \dots, A_n$ sei eine endliche Folge paarweise disjunkter Ereignisse. Dann gilt

$$\mathbb{P}(\cup_{i=1}^n A_i) = \sum_{i=1}^n \mathbb{P}(A_i). \quad (2.4)$$

◦

Beweis. Wir betrachten eine unendliche Folge von paarweise disjunkten Ereignissen $A_1, A_2, \dots$ wobei für ein $n \in \mathbb{N}$ gelten soll, dass $A_i := \emptyset$ für $i > n$. Dann gilt mit der σ -Additivität von $\mathbb{P}$ zunächst, dass

$$\mathbb{P}(\cup_{i=1}^n A_i) = \mathbb{P}(\cup_{i=1}^{\infty} A_i) = \sum_{i=1}^{\infty} \mathbb{P}(A_i) = \sum_{i=1}^n \mathbb{P}(A_i) + \sum_{i=n+1}^{\infty} \mathbb{P}(A_i). \quad (2.5)$$

Mit $\mathbb{P}(A_i) = \mathbb{P}(\emptyset) = 0$ für $i = n+1, n+2, \dots$ folgt dann direkt

$$\mathbb{P}(\cup_{i=1}^n A_i) = \sum_{i=1}^n \mathbb{P}(A_i) + 0 = \sum_{i=1}^n \mathbb{P}(A_i). \quad (2.6)$$

□

Zur Vorbereitung des Begriffs der gemeinsamen Wahrscheinlichkeit von Ereignissen wollen wir abschließend noch eine weitere wichtige Eigenschaft von σ -Algebren betrachten: neben der Abgeschlossenheit von $\mathcal{A}$ unter der Bildung von abzählbaren Vereinigungen ist $\mathcal{A}$ auch unter der Bildung von abzählbaren Durchschnitten abgeschlossen. Dies ist eine direkte Konsequenz der Abgeschlossenheit von $\mathcal{A}$ unter der Bildung von Komplementärmengen und abzählbaren Vereinigungen und wird in folgendem Theorem festgehalten.

Theorem 2.4 (Abgeschlossenheit von σ -Algebren bezüglich Durchschnitten). $\mathcal{A}$ sei eine σ -Algebra auf einer Menge Ω . Dann folgt aus $A, B \in \mathcal{A}$, dass auch $A \cap B \in \mathcal{A}$. Allgemein gilt für $A_1, A_2, \dots \in \mathcal{A}$, dass auch $\cap_{i=1}^{\infty} A_i \in \mathcal{A}$.

◦

Beweis. Wir zeigen exemplarisch die erste Aussage. Dazu halten wir zunächst fest, dass mit der ersten De Morganschen Regel und den Eigenschaften von Komplementen gilt, dass

$$(A \cap B)^c = A^c \cup B^c \Leftrightarrow ((A \cap B)^c)^c = (A^c \cup B^c)^c \Leftrightarrow A \cap B = (A^c \cup B^c)^c. \quad (2.7)$$

Ferner gilt mit den definierenden Eigenschaften von σ -Algebren, dass für $A, B \in \mathcal{A}$ gilt, dass auch $(A^c \cup B^c)^c \in \mathcal{A}$. Denn aus der Abgeschlossenheit von $\mathcal{A}$ unter der Bildung von Komplementärmengen folgt zunächst, dass auch $A^c \in \mathcal{A}$ und $B^c \in \mathcal{A}$. Weiterhin folgt aus der Abgeschlossenheit von $\mathcal{A}$ unter der abzählbaren Vereinigung auch $A^c \cup B^c \in \mathcal{A}$. Mit der Abgeschlossenheit von $\mathcal{A}$ unter der Bildung von Komplementärmengen folgt schließlich $(A^c \cup B^c)^c \in \mathcal{A}$. Insgesamt gilt also, dass aus $A, B \in \mathcal{A}$ folgt, dass $A \cap B \in \mathcal{A}$. Die Verallgemeinerung auf abzählbare Durchschnitte $A_1, A_2, \dots \in \mathcal{A}$ □

Nach Theorem 2.4 ist neben den Wahrscheinlichkeiten $\mathbb{P}(A), \mathbb{P}(B)$ und $\mathbb{P}(A \cup B)$ mit $A, B \in \mathcal{A}$ also auch die Wahrscheinlichkeit $\mathbb{P}(A \cap B)$ wohldefiniert.

2.2 Wahrscheinlichkeitsfunktionen

In diesem Abschnitt wollen wir mit den *Wahrscheinlichkeitsfunktionen* eine Möglichkeit kennenlernen, für Wahrscheinlichkeitsräume mit endlicher Ergebnismenge Wahrscheinlichkeitsmaße festzulegen. In Kapitel 4 und Kapitel 5 werden wir Wahrscheinlichkeitsfunktionen unter der Bezeichnung *Wahrscheinlichkeitsmassefunktionen* erneut begegnen. Wir definieren hier den Begriff der Wahrscheinlichkeitsfunktion zunächst wie folgt.

Definition 2.2 (Wahrscheinlichkeitsfunktion). Ω sei eine endliche Menge. Dann heißt eine Funktion $\pi : \Omega \rightarrow [0, 1]$ *Wahrscheinlichkeitsfunktion*, wenn gilt, dass

$$\sum_{\omega \in \Omega} \pi(\omega) = 1. \quad (2.8)$$

Sei weiterhin $\mathbb{P}$ ein Wahrscheinlichkeitsmaß. Dann heißt die durch

$$\pi : \Omega \rightarrow [0, 1], \omega \mapsto \pi(\omega) := \mathbb{P}(\{\omega\}) \quad (2.9)$$

definierte Funktion *Wahrscheinlichkeitsfunktion von $\mathbb{P}$ auf Ω* .

•

Wir merken an, dass weil $\mathbb{P}$ definitionsgemäß σ -additiv ist, insbesondere auch gilt, dass

$$\mathbb{P}(\Omega) = \mathbb{P}(\cup_{\omega \in \Omega} \{\omega\}) = \sum_{\omega \in \Omega} \mathbb{P}(\{\omega\}) = \sum_{\omega \in \Omega} \pi(\omega) = 1. \quad (2.10)$$

Zur Konstruktion von Wahrscheinlichkeitsmaßen durch Wahrscheinlichkeitsfunktionen stellt folgendes Theorem die formale Basis bereit. Es besagt insbesondere, dass bei endlichem Ω die Wahrscheinlichkeiten *aller* möglichen Ereignisse aus den Wahrscheinlichkeiten der Elementarereignisse $\pi(\omega)$ berechnet werden können.

Theorem 2.5. $(\Omega, \mathcal{A}, \mathbb{P})$ sei ein Wahrscheinlichkeitsraum mit endlicher Ergebnismenge und $\pi : \Omega \rightarrow [0, 1]$ sei eine Wahrscheinlichkeitsfunktion. Dann existiert ein Wahrscheinlichkeitsmaß $\mathbb{P}$ auf Ω mit π als Wahrscheinlichkeitsfunktion von $\mathbb{P}$. Dieses Wahrscheinlichkeitsmaß ist definiert als

$$\mathbb{P} : \mathcal{A} \rightarrow [0, 1], A \mapsto \mathbb{P}(A) := \sum_{\omega \in A} \pi(\omega). \quad (2.11)$$

◦

Beweis. Wir überprüfen zunächst die Wahrscheinlichkeitsmaßeigenschaften von $\mathbb{P}$. Weil $\pi(\omega) \in [0, 1]$ für alle $\omega \in \Omega$, gilt auch immer $\sum_{\omega \in A} \pi(\omega) \geq 0$ und damit die Nicht-Negativität von $\mathbb{P}$. Ferner folgt wie oben gesehen mit der Normiertheit von π direkt die Normiertheit von $\mathbb{P}$. Seien nun $A_1, A_2, \dots \in \mathcal{A}$. Dann gilt

$$\mathbb{P}(\cup_{i=1}^{\infty} A_i) = \sum_{\omega \in \cup_{i=1}^{\infty} A_i} \pi(\omega) = \sum_{i=1}^{\infty} \sum_{\omega \in A_i} \pi(\omega) = \sum_{i=1}^{\infty} \mathbb{P}(A_i) \quad (2.12)$$

und damit die σ -Additivität von $\mathbb{P}$. □

Definiert man also für eine gegebene Ergebnismenge Ω eine Funktion $\pi : \Omega \rightarrow [0, 1]$ und stellt sicher, dass sich ihre Funktionswerte $\pi(\omega)$ über alle $\omega \in \Omega$ hinweg zu 1 summieren und interpretiert den einzelnen Funktionswert $\pi(\omega)$ dann als die Wahrscheinlichkeit $\mathbb{P}(\{\omega\})$ des Elementarereignisses $\{\omega\} \in \mathcal{A}$, so hat man ein Wahrscheinlichkeitsmaß konstruiert. Definiert man andersherum bei einer endlichen Ergebnismenge Ω für alle Elementarereignisse $\{\omega\} \in \mathcal{A}$ eine Wahrscheinlichkeit $\mathbb{P}(\{\omega\}) \in [0, 1]$ und stellt sicher, dass $\mathbb{P}(\Omega) = 1$ gilt, so erfüllt man implizit natürlich auch die Anforderungen an eine Wahrscheinlichkeitsfunktion. Man kann in diesem Fall die σ -Additivität von $\mathbb{P}$ für die paarweise disjunkten Elementarereignisse direkt zur Berechnung zusammengesetzter Ereignisse nutzen. Wir verdeutlichen dieses und das Vorgehen mithilfe einer Wahrscheinlichkeitsfunktion in Kapitel 2.3 durch Beispiele.

2.3 Beispiele bei endlichem Ergebnisraum

Aus dem bis hierin Gesagtem lässt sich nun zusammenfassend folgendes Vorgehen zur Modellierung eines Zufallsvorganges mithilfe eines Wahrscheinlichkeitsraums $(\Omega, \mathcal{A}, \mathbb{P})$ festhalten:

- (1) In einem ersten Schritt überlegt man sich eine sinnvolle Definition der Ergebnismenge Ω , also der Ergebnisse bzw. Elementarereignisse, die in jedem Durchgang des Zufallsvorgangs realisiert werden sollen.
- (2) In einem zweiten Schritt wählt man dann ein geeignetes Ereignissystem. Im Fall einer endlichen Ergebnismenge bietet sich die Potenzmenge $\mathcal{P}(\Omega)$ an, im Fall der überabzählbaren Ergebnismenge $\Omega := \mathbb{R}$ bietet sich die Borelsche σ -Algebra $\mathcal{B}(\mathbb{R})$ an.
- (3) Schließlich definiert man ein Wahrscheinlichkeitsmaß $\mathbb{P}$, das die Wahrscheinlichkeiten für das Auftreten aller möglichen Ereignisse repräsentiert. Im Falle einer endlichen Ergebnismenge gelingt dies insbesondere durch Definition der Wahrscheinlichkeiten der Elementarereignisse. In der Folge verdeutlichen wir dieses Vorgehen anhand von Beispielen. Für die überabzählbare Ergebnismenge $\Omega := \mathbb{R}$ bietet sich die Definition von $\mathbb{P}$ mithilfe von *Wahrscheinlichkeitsdichtefunktionen* an, wie wir später sehen werden.

Würfeln mit einem Würfel

Wir modellieren das Würfeln mit einem Würfel. Es ist sicherlich sinnvoll, die Ergebnismenge als $\Omega := \{1, 2, 3, 4, 5, 6\}$ zu definieren. Allerdings wäre auch die Definition von $\Omega := \{\cdot, \cdot, \cdot, \cdot, \cdot, \cdot\}$ in äquivalenter Weise möglich.

Da es sich um eine endliche Ergebnismenge handelt, wählen wir als σ -Algebra $\mathcal{A}$ die Potenzmenge $\mathcal{P}(\Omega)$. $\mathcal{A}$ enthält dann automatisch alle möglichen Ereignisse. Die Kardinalität von $\mathcal{A} := \mathcal{P}(\Omega)$ ist $|\mathcal{P}(\Omega)| = 2^{|\Omega|} = 2^6 = 64$. In Tabelle 2.1 listen wir sechs dieser 64 Ereignisse in ihrer verbalen Beschreibung und als Teilmenge A von Ω auf.

Tabelle 2.1 Ausgewählte Ereignisse beim Modell des Werfens eines Würfels.

Beschreibung	Mengenform
Es fällt eine beliebige Augenzahl	$\omega \in A = \Omega$
Keine Augenzahl fällt	$\omega \in A = \emptyset$
Es fällt eine Augenzahl größer als 4	$\omega \in A = \{5, 6\}$
Es fällt eine gerade Augenzahl	$\omega \in A = \{2, 4, 6\}$
Es fällt eine Sechs	$\omega \in A = \{6\}$
Eine Eins, eine Drei oder eine Sechs fällt	$\omega \in A = \{1, 3, 6\}$

Damit ist die Definition des Messraum $(\Omega, \mathcal{A})$ in der Modellierung des Werfens eines Würfels abgeschlossen.

Wie in Kapitel 2.2 beschrieben, kann ein Wahrscheinlichkeitsmaß $\mathbb{P}$ durch Festlegung von $\mathbb{P}(\{\omega\})$ für alle $\omega \in \Omega$ definiert werden. Für das Modell eines unverfälschten Würfels würde man

$$\mathbb{P}(\{\omega\}) := \frac{1}{|\Omega|} := 1/6 \text{ für alle } \omega \in \Omega \quad (2.13)$$

wählen. Für ein Modell eines verfälschten Würfels, der das Werfen einer Sechs bevorzugt, könnte man zum Beispiel definieren, dass

$$\mathbb{P}(\{\omega\}) := \frac{1}{8} \text{ für } \omega \in \{1, 2, 3, 4, 5\} \text{ und } \mathbb{P}(\{6\}) := \frac{3}{8}. \quad (2.14)$$

Im Fall des unverfälschten Würfels ergibt sich zum Beispiel die Wahrscheinlichkeit für das Ereignis “Es fällt eine gerade Augenzahl” mit der σ -Additivität von $\mathbb{P}$ dann zu

$$\mathbb{P}(\{2, 4, 6\}) = \mathbb{P}(\{2\} \cup \{4\} \cup \{6\}) = \mathbb{P}(\{2\}) + \mathbb{P}(\{4\}) + \mathbb{P}(\{6\}) = \frac{1}{6} + \frac{1}{6} + \frac{1}{6} = \frac{3}{6}. \quad (2.15)$$

Im Fall des obigen Modells eines verfälschten Würfels ergibt sich die Wahrscheinlichkeit für das gleiche Ereignis dagegen zu

$$\mathbb{P}(\{2, 4, 6\}) = \mathbb{P}(\{2\} \cup \{4\} \cup \{6\}) = \mathbb{P}(\{2\}) + \mathbb{P}(\{4\}) + \mathbb{P}(\{6\}) = \frac{1}{8} + \frac{1}{8} + \frac{3}{8} = \frac{5}{8}. \quad (2.16)$$

Das betrachtete Ereignis hat im Modell des verfälschten Würfels eine höhere Wahrscheinlichkeit als im Modell des unverfälschten Würfels, was intuitiv sinnvoll ist, da die Sechs eine gerade Zahl ist.

Gleichzeitiges Würfeln mit einem blauem und einem roten Würfel

Wir wollen nun das gleichzeitige Werfen eines blauen und eines roten Würfels modellieren. Dazu ist es sinnvoll, die Ergebnismenge als

$$\Omega := \{(r, b) | r \in \{1, 2, 3, 4, 5, 6\}, b \in \{1, 2, 3, 4, 5, 6\}\} \quad (2.17)$$

mit Kardinalität $|\Omega| = 36$ zu definieren, wobei r die Augenzahl des blauen Würfels und b die Augenzahl des roten Würfels repräsentieren soll.

Wiederum bietet sich die Wahl der Potenzmenge von Ω als σ -Algebra an, wir definieren also wieder $\mathcal{A} := \mathcal{P}(\Omega)$. Die Anzahl der in diesem Modell möglichen Ereignisse ergibt sich zu $|\mathcal{A}| = 2^{|\Omega|} = 2^{36} = 68.719.476.736$. In Tabelle 2.2 listen wir sechs dieser Ereignisse in ihrer verbalen Beschreibung und als Teilmenge A von Ω auf.

Tabelle 2.2 Ausgewählte Ereignisse beim Modell des Werfens eines roten und eines blauen Würfels.

Beschreibung	Mengenform
Auf dem roten Würfel fällt eine Drei	$\omega \in A = \{(3, 1), (3, 2), (3, 3), (3, 4), (3, 5), (3, 6)\}$
Auf dem blauen Würfel fällt eine Drei	$\omega \in A = \{(1, 3), (2, 3), (3, 3), (4, 3), (5, 3), (6, 3)\}$
Auf beiden Würfeln fällt eine Drei	$\omega \in A = \{(3, 3)\}$
Es fällt eine Pasch	$\omega \in A = \{(1, 1), (2, 2), (3, 3), (4, 4), (5, 5), (6, 6)\}$
Die Summe der gefallen Zahlen ist vier	$\omega \in A = \{(1, 3), (3, 1), (2, 2)\}$

Die Definition des Messraum $(\Omega, \mathcal{A})$ ist damit abgeschlossen. Ein Wahrscheinlichkeitsmaß $\mathbb{P}$ kann wiederum durch Definition von $\mathbb{P}(\{\omega\})$ für alle $\omega \in \Omega$ festgelegt werden. Für das Modell zweier unverfälschter Würfel würde man

$$\mathbb{P}(\{\omega\}) := \frac{1}{|\Omega|} = \frac{1}{36} \text{ für alle } \omega \in \Omega \quad (2.18)$$

wählen. Unter diesem Wahrscheinlichkeitsmaß ergibt sich dann beispielsweise die Wahrscheinlichkeit für das Ereignis “Die Summe der gefallen Zahlen ist vier” mit der σ -Additivität von $\mathbb{P}$ zu

$$\begin{aligned}
 \mathbb{P}(\{(1, 3), (3, 1), (2, 2)\}) &= \mathbb{P}(\{(1, 3)\} \cup \{(3, 1)\} \cup \{(2, 2)\}) \\
 &= \mathbb{P}(\{(1, 3)\}) + \mathbb{P}(\{(3, 1)\}) + \mathbb{P}(\{(2, 2)\}) \\
 &= 1/36 + 1/36 + 1/36 \\
 &= 1/12.
 \end{aligned}$$

Werfen einer Münze

Wir modellieren das Werfen einer Münze, deren eine Seite Kopf (Heads) und deren andere Seite Zahl (Tails) zeigt. Es ist sinnvoll, die Ergebnismenge als $\Omega := \{H, T\}$ zu definieren, wobei H “Heads” und T “Tails” repräsentiert. Allerdings wäre auch jede andere binäre Definition von Ω möglich, z.B. $\Omega := \{0, 1\}$, $\Omega := \{-1, 1\}$ oder $\Omega := \{1, 2\}$.

Die Potenzmenge $\mathcal{A} := \mathcal{P}(\Omega)$ enthält alle möglichen Ereignisse. In diesem Fall können wir das gesamte Mengensystem $\mathcal{A}$ leicht, wie in Tabelle 2.3 gezeigt, komplett auflisten.

Tabelle 2.3 Ereignissystem $\mathcal{A}$ beim Modell des Werfens einer Münze.

Beschreibung	Mengenform
Weder Kopf noch Zahl fällt	$\omega \in A = \emptyset$
Kopf fällt	$\omega \in A = \{H\}$
Zahl fällt	$\omega \in A = \{T\}$
Kopf oder Zahl fällt	$\omega \in A = \{H, T\}$

Die Definition des Messraums $(\Omega, \mathcal{A})$ ist damit abgeschlossen.

Ein Wahrscheinlichkeitsmaß $\mathbb{P}$ kann wiederum durch Definition von $\mathbb{P}(\{\omega\})$ für alle $\omega \in \Omega$ festgelegt werden. Die Normiertheit von Ω bedingt hier insbesondere, dass

$$\mathbb{P}(\Omega) = 1 \Leftrightarrow \mathbb{P}(\{H\}) + \mathbb{P}(\{T\}) = 1 \Leftrightarrow \mathbb{P}(\{T\}) = 1 - \mathbb{P}(\{H\}). \quad (2.19)$$

Bei Festlegung der Wahrscheinlichkeit des Elementarereignisses $\{H\}$ wird also die Wahrscheinlichkeit des Elementarereignis $\{T\}$ sofort mit festgelegt, andersherum gilt dies

natürlich ebenso. Für das Modell einer fairen Münze würde man $\mathbb{P}(\{H\}) = \mathbb{P}(\{T\}) := 1/2$ wählen. Die Wahrscheinlichkeiten aller möglichen Ereignisse ergeben sich in diesem Fall zu

$$\mathbb{P}(\emptyset) = 0, \mathbb{P}(\{H\}) = 1/2, \mathbb{P}(\{T\}) = 1/2 \text{ und } \mathbb{P}(\{H, T\}) = 1. \quad (2.20)$$

Zweifaches Werfen einer Münze

Wir modellieren das zweifache Werfen einer Münze. Basierend auf dem Modell des einfachen Münzwurfs ist es sinnvoll, die Ergebnismenge als $\Omega := \{HH, HT, TH, TT\}$ zu definieren. Die Potenzmenge $\mathcal{A} := \mathcal{P}(\Omega)$ enthält wiederum alle $2^{|\Omega|} = 2^4 = 16$ möglichen Ereignisse. In untenstehender Tabelle listen wir vier davon.

Tabelle 2.4 Ausgewählte Ereignisse beim Modell des zweifachen Werfens einer Münze.

Beschreibung	Mengenform
Kopf fällt im ersten Wurf	$\omega \in A = \{HH, HT\}$
Kopf fällt im zweiten Wurf	$\omega \in A = \{HH, TH\}$
Kopf fällt nicht	$\omega \in A = \{TT\}$
Zahl fällt mindestens einmal	$\omega \in A = \{HT, TH, TT\}$

Die Definition des Messraum $(\Omega, \mathcal{A})$ ist damit abgeschlossen. Ein Wahrscheinlichkeitsmaß $\mathbb{P}$ kann wiederum durch Definition von $\mathbb{P}(\{\omega\})$ für alle $\omega \in \Omega$ festgelegt werden. Für das Modell des zweifachen Werfens einer fairen Münze würde man

$$\mathbb{P}(\{HH\}) = \mathbb{P}(\{HT\}) = \mathbb{P}(\{TH\}) = \mathbb{P}(\{TT\}) := \frac{1}{4} \quad (2.21)$$

definieren.

Wert eines BDI-II Items

Wir modellieren den Wert einer Patient:in für das Item “Traurigkeit” der deutschen Version des Beck Depression Inventory II (Hautzinger et al. (2006)),

- (0) Ich bin nicht traurig.
- (1) Ich bin oft traurig.
- (2) In bin ständig traurig.
- (3) In bin so traurig oder unglücklich, dass ich es nicht aushalte.

Der betrachtete Zufallsvorgang sei also die Antwort einer Patient:in für dieses Item. Dabei bietet sich zur Modellierung dann die Ergebnismenge $\Omega := \{0, 1, 2, 3\}$ an. Für eine erste Patient:in ergibt sich beispielsweise die Realisierung $3 \in \Omega$, für eine zweite Patient:in die Realisierung $0 \in \Omega$, für eine dritte Patient:in $1 \in \Omega$ und so weiter. Als Ereignissystem $\mathcal{A}$ bietet sich wiederum die Potenzmenge an. Diese hat im vorliegenden Fall die Kardinalität

$$|\mathcal{P}(\Omega)| = 2^{|\Omega|} = 2^4 = 16 \quad (2.22)$$

und kann wie in Tabelle 2.5 gezeigt leicht vollständig hingeschrieben werden.

Tabelle 2.5 Ausgewählte Ereignisse beim Modell der Beantwortung eines BDI-II Items.

Angegebene Antwort	Mengenform
Keine	$\emptyset$
“Ich bin nicht traurig”	$\{0\}$
“Ich bin oft traurig”	$\{1\}$
“Ich bin ständig traurig”	$\{2\}$
“Ich bin so traurig oder unglücklich, dass ich es nicht aushalte”	$\{3\}$
“Ich bin nicht traurig” oder “Ich bin oft traurig”	$\{0, 1\}$
“Ich bin nicht traurig” oder “Ich bin ständig traurig”	$\{0, 2\}$
“Ich bin nicht traurig” oder “Ich bin so traurig oder unglücklich, dass ich es nicht aushalte”	$\{0, 3\}$
“Ich bin oft traurig” oder “Ich bin ständig traurig”	$\{1, 2\}$
“Ich bin oft traurig” oder “Ich bin so traurig oder unglücklich, dass ich es nicht aushalte”	$\{1, 3\}$
“Ich bin ständig traurig” oder “Ich bin so traurig oder unglücklich, dass ich es nicht aushalte”	$\{2, 3\}$
Nicht “Ich bin so traurig oder unglücklich, dass ich es nicht aushalte”	$\{0, 1, 2\}$
Nicht “Ich bin ständig traurig”	$\{0, 1, 3\}$
Nicht “Ich bin oft traurig”	$\{0, 2, 3\}$
Nicht “Ich bin nicht traurig”	$\{1, 2, 3\}$
Eine beliebige Antwortmöglichkeit	$\{0, 1, 2, 3\}$

Gehen wir nun davon aus, dass die Wahrscheinlichkeiten der Itemantworten als

$$\mathbb{P}(\{0\}) := \frac{2}{10}, \quad \mathbb{P}(\{1\}) := \frac{3}{10}, \quad \mathbb{P}(\{2\}) := \frac{4}{10}, \quad \mathbb{P}(\{3\}) := \frac{1}{10} \quad (2.23)$$

bekannt sind. Dann definieren diese Wahrscheinlichkeiten im Sinne einer Wahrscheinlichkeitsfunktion

$$\pi : \Omega \rightarrow [0, 1], \omega \mapsto \pi(\omega) =: \mathbb{P}(\{\omega\}) \quad (2.24)$$

ein Wahrscheinlichkeitsmaß und die Definition des Wahrscheinlichkeitsraummodells $(\Omega, \mathcal{A}, \mathbb{P})$ für das betrachtete Szenario ist abgeschlossen. Mithilfe der σ -Additivität von $\mathbb{P}$ lässt sich nun beispielsweise die Wahrscheinlichkeit für eine Itemantwort größer als 1 bestimmen:

$$\mathbb{P}(\{2, 3\}) = \mathbb{P}(\{2\} \cup \{3\}) = \mathbb{P}(\{2\}) + \mathbb{P}(\{3\}) = \frac{4}{10} + \frac{1}{10} = \frac{5}{10} = \frac{1}{2} \quad (2.25)$$

Ebenso ergibt sich beispielsweise die Wahrscheinlichkeit dafür, dass eine Patient:in eine der beiden Itemantworten “(0) Ich bin nicht traurig” oder “(3) Ich bin so traurig oder unglücklich, dass ich es nicht aushalte” angibt, zu

$$\mathbb{P}(\{0, 3\}) = \mathbb{P}(\{0\} \cup \{3\}) = \mathbb{P}(\{0\}) + \mathbb{P}(\{3\}) = \frac{2}{10} + \frac{1}{10} = \frac{3}{10}. \quad (2.26)$$

2.4 Literaturhinweise

Die Monographie “Grundbegriffe der Wahrscheinlichkeitsrechnung” von Andrey Kolmogorov (Kolmogoroff (1933)) symbolisiert die Grundlage der modernen Wahrscheinlichkeitsrechnung. Neben der hier diskutierten axiomatischen Einführung des Wahrscheinlichkeitsraummodells betrachtet Kolmogoroff (1933) noch viele weitere Aspekte der Wahrscheinlichkeitrechnung und bietet so einen gut lesbaren Einstieg in das gesamte Gebiet der Wahrscheinlichkeitstheorie. Natürlich ist der von Kolmogoroff (1933) formulierte Zugang nur ein vorläufiges Endprodukt der langen geschichtlichen Entwicklung

der Wahrscheinlichkeitstheorie. Schließlich ist die Entwicklung der mathematischen Modellierung von Zufallsvorgängen auch mit Kolmogoroff (1933) keinesfalls an einem Ende angelangt. Spätere Arbeiten im 20. Jahrhundert betrafen insbesondere die Interpretation des Wahrscheinlichkeitsbegriffs (vgl. De Finetti (1975)) oder führen verallgemeinerte quantitative Maße subjektiver Unsicherheit ein (vgl. Walley (1991)). Einen aktuellen Überblick zur Interpretation des Wahrscheinlichkeitsbegriffs und seiner formalen Grundlagen gibt Hájek (2019).

Selbstkontrollfragen

1. Erläutern Sie den Begriff des Zufallsvorgangs.
2. Geben Sie die Definition des Begriffs der σ -Algebra wieder.
3. Geben Sie die Definition des Begriffs des Wahrscheinlichkeitsmaßes wieder.
4. Geben Sie die Definition des Begriffs des Wahrscheinlichkeitsraums wieder.
5. Erläutern Sie den Begriff der Ergebnismenge Ω .
6. Erläutern Sie die stillschweigende Mechanik des Wahrscheinlichkeitsraummodells.
7. Erläutern Sie den Begriff eines Ereignisses $A \in \mathcal{A}$.
8. Erläutern Sie den Begriff des Ereignissystems $\mathcal{A}$.
9. Welche σ -Algebra wählt man sinnvollerweise für einen Wahrscheinlichkeitsraum mit endlicher Ergebnismenge?
10. Erläutern Sie den Begriff des Wahrscheinlichkeitsmaßes $\mathbb{P}$.
11. Geben Sie die Definition des Begriffs der Wahrscheinlichkeitsfunktion wieder.
12. Warum ist der Begriff der Wahrscheinlichkeitsfunktion bei der Modellierung eines Zufallsvorgangs durch einen Wahrscheinlichkeitsraum mit endlicher Ergebnismenge hilfreich?
13. Erläutern Sie die Modellierung des Werfens eines Würfels mithilfe eines Wahrscheinlichkeitsraums.
14. Erläutern Sie die Modellierung des gleichzeitigen Werfens eines roten und eines blauen Würfels mithilfe eines Wahrscheinlichkeitsraums.

Lösungen

1. Ein Zufallsvorgang ist ein Phänomen der Wirklichkeit, das nicht mit absoluter Sicherheit vorhersagbar ist bzw. für Menschen mit Unsicherheit behaftet ist. Siehe Einleitung zur Wahrscheinlichkeitstheorie.
2. Siehe Definition 2.1 bezüglich $\mathcal{A}$.
3. Siehe Definition 2.1 bezüglich $\mathbb{P}$.
4. Siehe Definition 2.1.
5. Die Ergebnismenge enthält die in einem Durchgang des modellierten Zufallsvorgangs möglichen Elementarereignisse, siehe die Erläuterungen zu **Ergebnismenge und Mechanik**.
6. Siehe die Erläuterungen zu **Ergebnismenge und Mechanik**.
7. Siehe die Erläuterungen zu **Ereignisse und Ereignissysteme**.
8. Siehe die Erläuterungen zu **Ereignisse und Ereignissysteme**.
9. Die Potenzmenge der Ergebnismenge, sie enthält alle prinzipiell möglichen Ereignisse, siehe auch Theorem 2.1.
10. Siehe die Erläuterungen zu **Wahrscheinlichkeitsmaß $\mathbb{P}$** .
11. Siehe Definition 2.2.
12. Durch Definition der Funktionswerte einer Wahrscheinlichkeitsfunktion kann ein Wahrscheinlichkeitsmaß festgelegt werden, siehe auch Kapitel 2.3.
13. Siehe die Erläuterungen zum **Würfeln mit einem Würfel**.
14. Siehe die Erläuterungen zum **Gleichzeitigen Würfeln mit einem blauen und einem roten Würfel**.

3 Elementare Wahrscheinlichkeiten

In diesem Abschnitt führen wir mit den Begriffen der *gemeinsamen Wahrscheinlichkeit* zweier Ereignisse und der *bedingten Wahrscheinlichkeit* eines Ereignisses zwei elementare Formen von Wahrscheinlichkeiten ein. Intuitiv bezieht sich der Begriff der gemeinsamen Wahrscheinlichkeit auf die Wahrscheinlichkeit des “gleichzeitigen” Eintretens zweier Ereignisse A und B und der Begriff der bedingten Wahrscheinlichkeit auf die Wahrscheinlichkeit des Eintretens eines Ereignisses A , “wenn man um das Eintreten eines anderen Ereignisses B weiß”. Ist es für die Wahrscheinlichkeit eines Ereignisses A unerheblich, ob ein Ereignis B eingetreten ist oder nicht, so nennt man A und B *unabhängige Ereignisse*. Intuitiv modellieren unabhängige Ereignisse die Abwesenheit gegenseitiger Einflüsse.

3.1 Gemeinsame Wahrscheinlichkeiten

Der Begriff der gemeinsamen Wahrscheinlichkeit zweier Ereignisse ist wie folgt definiert.

Definition 3.1 (Gemeinsame Wahrscheinlichkeit). $(\Omega, \mathcal{A}, \mathbb{P})$ sei ein Wahrscheinlichkeitsraum und es seien $A, B \in \mathcal{A}$. Dann heißt

$$\mathbb{P}(A \cap B) \tag{3.1}$$

die *gemeinsame Wahrscheinlichkeit von A und B* .

•

Wie oben angemerkt entspricht $\mathbb{P}(A \cap B)$ der Wahrscheinlichkeit dafür, dass die Ereignisse A und B “gleichzeitig” eintreten. Dies verdeutlicht man sich am besten vor dem Hintergrund der Mechanik des Wahrscheinlichkeitsraummodells. Danach ist $\mathbb{P}(A \cap B)$ eben die Wahrscheinlichkeit, dass in einem Durchgang eines Zufallsvorgangs ein ω realisiert wird, für das sowohl $\omega \in A$ als auch $\omega \in B$ gelten.

Beispiel 3.1 (Gemeinsame Wahrscheinlichkeit beim fairen Würfel). Als erstes Beispiel für eine gemeinsame Wahrscheinlichkeit zweier Ereignisse wollen wir wieder das Wahrscheinlichkeitsraummodell des Werfens eines fairen Würfels betrachten. Seien dazu A das Ereignis “Es fällt eine gerade Augenzahl”, also $A := \{2, 4, 6\}$ und B das Ereignis “Es fällt eine Augenzahl größer als drei”, also $B := \{4, 5, 6\}$. Mengentheoretisch gilt dann

$$A \cap B = \{2, 4, 6\} \cap \{4, 5, 6\} = \{4, 6\}. \tag{3.2}$$

Die Interpretation von $A \cap B = \{4, 6\}$ ist dabei gerade “Es fällt eine gerade Augenzahl *und* diese Augenzahl ist größer als Drei”. Bei Annahme der Fairness des Würfels, also für $\mathbb{P}(\{4\}) = \mathbb{P}(\{6\}) :=$

1/6 können wir mithilfe der σ -Additivität von $\mathbb{P}$ die Wahrscheinlichkeit dieses Ereignisses leicht berechnen. Es ergibt sich

$$\begin{aligned}
 \mathbb{P}(A \cap B) &= \mathbb{P}(\{2, 4, 6\} \cap \{4, 5, 6\}) \\
 &= \mathbb{P}(\{4, 6\}) \\
 &= \mathbb{P}(\{4\}) + \mathbb{P}(\{6\}) \\
 &= \frac{1}{6} + \frac{1}{6} \\
 &= \frac{1}{3}.
 \end{aligned} \tag{3.3}$$

Beim Nachdenken über gemeinsame Wahrscheinlichkeiten ist es natürlich wichtig, die gemeinsame Wahrscheinlichkeit $\mathbb{P}(A \cap B)$ nicht mit der Wahrscheinlichkeit $\mathbb{P}(A \cup B)$ des Ereignisses $A \cup B$ zu verwechseln. Es sei daran erinnert, dass die Vereinigung zweier Mengen $\cup$ dem *inklusive oder*, also einem *und/oder* entspricht (vgl. [Aussagenlogik \(PDWP\)](#) und [Verknüpfungen \(PDWP\)](#)). Das Ereignis $A \cup B$ entspricht also dem Ereignis, dass das Ereignis A und/oder das Ereignis B eintritt. Insbesondere ist $\omega \in A \cup B$ also auch schon dann erfüllt, wenn für das Ergebnis eines Durchgangs eines Zufallsvorgangs *nur* $\omega \in A$ oder *nur* $\omega \in B$ gilt. Konkret ergibt sich etwa für die Ereignisse $A := \{2, 4, 6\}$ und $B := \{4, 5, 6\}$ aus obigem Würfelbeispiel

$$A \cup B = \{2, 4, 6\} \cup \{4, 5, 6\} = \{2, 4, 5, 6\} \tag{3.4}$$

mit der Interpretation “Es fällt eine gerade Augenzahl und/oder es fällt eine Augenzahl größer als drei”. Für die entsprechende Wahrscheinlichkeit ergibt sich

$$\mathbb{P}(\{2, 4, 5, 6\}) = \frac{2}{3}, \tag{3.5}$$

sodass in diesem Fall offenbar $\mathbb{P}(A \cap B) \neq \mathbb{P}(A \cup B)$ gilt.

△

Mithilfe folgenden Theorems wollen wir in diesem Abschnitt schließlich noch einige nützliche Eigenschaften zum Rechnen mit Wahrscheinlichkeiten festhalten, die sich direkt aus der Verbindung von Mengenverknüpfungen und der σ -Additivität von Wahrscheinlichkeitsmaßen ergeben. Wir visualisieren die entsprechenden Aussagen in Abbildung 3.1 mithilfe von Venn-Diagrammen.

Theorem 3.1 (Weitere Eigenschaften von Wahrscheinlichkeiten). *$(\Omega, \mathcal{A}, \mathbb{P})$ sei ein Wahrscheinlichkeitsraum und es seien $A, B \in \mathcal{A}$ Ereignisse. Dann gelten*

1. $\mathbb{P}(A^c) = 1 - \mathbb{P}(A)$.
2. $A \subset B \Rightarrow \mathbb{P}(A) \leq \mathbb{P}(B)$.
3. $\mathbb{P}(A \cap B^c) = \mathbb{P}(A) - \mathbb{P}(A \cap B)$
4. $\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B)$.

◦

Beweis. Die zweite, dritte, und vierte Aussage dieses Theorems basieren auf elementaren mengentheoretischen Aussagen und der σ -Additivität von $\mathbb{P}$. Wir wollen diese elementaren mengentheoretischen Aussagen hier nicht beweisen, sondern verweisen jeweils auf die Intuition, die durch die Venn-Diagramme in Abbildung 3.2 vermittelt wird.

Zu 1.: Wir halten zunächst fest, dass aus $A^c := \Omega \setminus A$ folgt, dass $A^c \cup A = \Omega$ und dass $A^c \cap A = \emptyset$. Mit der Normiertheit und der σ -Additivität von $\mathbb{P}$ folgt dann

$$\mathbb{P}(\Omega) = 1 \Leftrightarrow \mathbb{P}(A^c \cup A) = 1 \Leftrightarrow \mathbb{P}(A^c) + \mathbb{P}(A) = 1 \Leftrightarrow \mathbb{P}(A^c) = 1 - \mathbb{P}(A). \tag{3.6}$$




Abbildung 3.1 Venn-Diagramme zu Theorem 3.1. Die hellblau unterlegten Flächen entsprechen jeweils den Wahrscheinlichkeiten von Interesse

Zu 2.: Zunächst gilt (vgl. Abbildung A)

$$A \subset B \Rightarrow B = A \cup (B \cap A^c) \text{ mit } A \cap (B \cap A^c) = \emptyset. \quad (3.7)$$

Mit der σ -Additivität von $\mathbb{P}$ folgt dann aber

$$\mathbb{P}(B) = \mathbb{P}(A) + \mathbb{P}(B \cap A^c). \quad (3.8)$$

Mit $\mathbb{P}(B \cap A^c) \geq 0$ folgt dann $\mathbb{P}(A) \leq \mathbb{P}(B)$.

Zu 3.: Zunächst gilt (vgl. Abbildung B)

$$(A \cap B) \cap (A \cap B^c) = \emptyset \text{ und } A = (A \cap B) \cup (A \cap B^c). \quad (3.9)$$

Mit der σ -Additivität von $\mathbb{P}$ folgt dann

$$\mathbb{P}(A) = \mathbb{P}(A \cap B) + \mathbb{P}(A \cap B^c) \Leftrightarrow \mathbb{P}(A \cap B) = \mathbb{P}(A) - \mathbb{P}(A \cap B^c) \quad (3.10)$$

Zu 4.: Zunächst gilt (vgl. Abbildung C)

$$B \cap (A \cap B^c) = \emptyset \text{ und } A \cup B = B \cup (A \cap B^c). \quad (3.11)$$

Mit der σ -Additivität von $\mathbb{P}$ folgt dann

$$\mathbb{P}(A \cup B) = \mathbb{P}(B) + \mathbb{P}(A \cap B^c). \quad (3.12)$$

Mit 3. folgt dann

$$\mathbb{P}(A \cup B) = \mathbb{P}(B) + \mathbb{P}(A) - \mathbb{P}(A \cap B). \quad (3.13)$$

□




Abbildung 3.2 Venn-Diagramme zum Beweis von Theorem 3.1

3.2 Bedingte Wahrscheinlichkeiten

Wir wenden uns nun dem Begriff der bedingten Wahrscheinlichkeit zu.

Definition 3.2 (Bedingte Wahrscheinlichkeit). $(\Omega, \mathcal{A}, \mathbb{P})$ sei ein Wahrscheinlichkeitsraum und $A, B \in \mathcal{A}$ seien Ereignisse mit $\mathbb{P}(B) > 0$. Die *bedingte Wahrscheinlichkeit des Ereignisses A gegeben das Ereignis B* ist definiert als

$$\mathbb{P}(A|B) := \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}. \quad (3.14)$$

•

Wir halten fest: Die bedingte Wahrscheinlichkeit $\mathbb{P}(A|B)$ eines Ereignisses A gegeben ein Ereignis B ist die mit $1/\mathbb{P}(B)$ skalierte gemeinsame Wahrscheinlichkeit $\mathbb{P}(A \cap B)$ der Ereignisse A und B . Legt man in der Formulierung eines probabilistischen Modells also die gemeinsame Wahrscheinlichkeit $\mathbb{P}(A \cap B)$ sowie die Wahrscheinlichkeit $\mathbb{P}(B) > 0$ des Ereignisses B fest, so legt man insbesondere auch die bedingte Wahrscheinlichkeit $\mathbb{P}(A|B)$ des Ereignisses A gegeben das Ereignis B fest. Wir weisen ferner darauf hin, dass es keinen Grund gibt, die bedingten Wahrscheinlichkeiten

$$\mathbb{P}(A|B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} \text{ und } \mathbb{P}(B|A) = \frac{\mathbb{P}(B \cap A)}{\mathbb{P}(A)} = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(A)} \quad (3.15)$$

zu verwechseln (vgl. Herzog & Ostwald (2013)). Insbesondere folgt aus $\mathbb{P}(A) \neq \mathbb{P}(B)$ immer direkt $\mathbb{P}(A|B) \neq \mathbb{P}(B|A)$. Schließlich sei angemerkt, dass eine Verallgemeinerung der bedingten Wahrscheinlichkeit in Definition 3.2 auf den Fall $\mathbb{P}(B) = 0$ möglich, aber technisch aufwändig ist. Wir verweisen dafür auf die weiterführende Literatur, z.B. Meintrup & Schäffler (2005) und Schmidt (2009).

Beispiele

Würfeln mit einem Würfel

Als erstes Beispiel für eine bedingte Wahrscheinlichkeit betrachten wir erneut das Modell $(\Omega, \mathcal{A}, \mathbb{P})$ des fairen Würfels. Wir wollen die bedingte Wahrscheinlichkeit für das Ereignis “Es fällt eine gerade Augenzahl” gegeben das Ereignis “Es fällt eine Zahl größer als drei”

berechnen. Wir haben oben bereits gesehen, dass das Ereignis “Es fällt eine gerade Augenzahl” der Teilmenge $A := \{2, 4, 6\}$ von Ω entspricht, und dass das Ereignis “Es fällt eine Zahl größer als drei” der Teilmenge $B := \{4, 5, 6\}$ von Ω entspricht. Weiterhin haben wir gesehen, dass unter der Annahme, dass der modellierte Würfel fair ist, gilt, dass

$$\mathbb{P}(\{2, 4, 6\}) = \mathbb{P}(\{2\}) + \mathbb{P}(\{4\}) + \mathbb{P}(\{6\}) = \frac{1}{6} + \frac{1}{6} + \frac{1}{6} = \frac{3}{6} \quad (3.16)$$

und dass

$$\mathbb{P}(\{4, 5, 6\}) = \mathbb{P}(\{4\}) + \mathbb{P}(\{5\}) + \mathbb{P}(\{6\}) = \frac{1}{6} + \frac{1}{6} + \frac{1}{6} = \frac{3}{6}. \quad (3.17)$$

Schließlich hatten wir auch gesehen, dass das Ereignis $A \cap B$, also das Ereignis “Es fällt eine gerade Augenzahl, die größer als drei ist”, die Wahrscheinlichkeit

$$\mathbb{P}(A \cap B) = \mathbb{P}(\{2, 4, 6\} \cap \{4, 5, 6\}) = \mathbb{P}(\{4, 6\}) = \mathbb{P}(\{4\}) + \mathbb{P}(\{6\}) = \frac{1}{6} + \frac{1}{6} = \frac{2}{6} \quad (3.18)$$

hat. Nach Definition der bedingten Wahrscheinlichkeit ergibt sich dann direkt

$$\mathbb{P}(A|B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} = \frac{\mathbb{P}(\{4, 6\})}{\mathbb{P}(\{4, 5, 6\})} = \frac{2}{6} \cdot \frac{6}{3} = \frac{2}{3}. \quad (3.19)$$

In diesem Zusammenhang bietet sich eine Interpretation der bedingten Wahrscheinlichkeit $\mathbb{P}(A|B)$ als eine Abnahme subjektiver Unsicherheit bzw. als Zugewinn an subjektiver Information gegenüber der unbedingten Wahrscheinlichkeit $\mathbb{P}(A)$ an: Wenn man weiß, dass eine Augenzahl größer als drei gefallen ist, dass also das Ereignis $\omega \in B$ vorliegt ist, ist die Wahrscheinlichkeit, dass es sich bei ω um eine gerade Augenzahl handelt $2/3$. Wenn man dagegen nicht weiß, dass das Ereignis $\omega \in B$ vorliegt (und auch sonst keine Information über ω hat) ist die Wahrscheinlichkeit für das Fallen einer geraden Augenzahl nur $1/2$. Bedingen auf dem Vorliegen eines Ereignisses entspricht also der Einbeziehung von Information und damit der Abnahme von Unsicherheit in wahrscheinlichkeitstheoretische Modellen. Dies ist die Grundlage der Bayesianischen Statistik. Eine ähnliche Interpretation bietet sich auch im Rahmen folgenden, vielleicht lebensnäheren Beispiels an.

Wert eines BDI-II Items

Wir betrachten erneut das Beispiel für den Wert einer Patient:in für das Item “Traurigkeit” der deutschen Version des BDI-II. Wir haben oben den möglichen Itemantworten (0), (1), (2), (3) die Wahrscheinlichkeiten

$$\mathbb{P}(\{0\}) := \frac{2}{10}, \quad \mathbb{P}(\{1\}) := \frac{3}{10}, \quad \mathbb{P}(\{2\}) := \frac{4}{10}, \quad \mathbb{P}(\{3\}) := \frac{1}{10}, \quad (3.20)$$

zugeordnet. Wir nehmen nun an, dass wir von einer Patient:in wissen, dass sie einen Wert größer als (1) gewählt hat und fragen nach den Wahrscheinlichkeiten, dass die Patient:in den Wert (2) oder (3) gewählt hat. Dazu betrachten wir zunächst die Wahrscheinlichkeit des Ereignisses “Die Patient:in hat einen Wert größer als (1) gewählt”. Offenbar entspricht dies der Teilmenge $B := \{2, 3\}$ von Ω . Mit der σ -Additivität ergibt sich für die Wahrscheinlichkeit für dieses Ereignis wie oben gesehen $\mathbb{P}(\{2, 3\}) = 1/2$. Wir betrachten also die in Tabelle 3.1 aufgeführten Ereignisse.

Tabelle 3.1 Ereignisse bei Bearbeitung eines BDI-II Items

Beschreibung	Mengenform
Die Patient:in hat einen Wert größer als (1) gewählt	$\omega \in B := \{2, 3\}$
Die Patient:in hat Antwort (2) gewählt	$\omega \in A_1 := \{2\}$
Die Patient:in hat Antwort (3) gewählt	$\omega \in A_2 := \{3\}$

Es ergeben sich

$$\mathbb{P}(A_1|B) = \frac{\mathbb{P}(A_1 \cap B)}{\mathbb{P}(B)} = \frac{\mathbb{P}(\{2\} \cap \{2, 3\})}{\mathbb{P}(\{2, 3\})} = \frac{\mathbb{P}(\{2\})}{\mathbb{P}(\{2, 3\})} = \frac{4}{10} \cdot \frac{2}{1} = \frac{8}{10} \quad (3.21)$$

und

$$\mathbb{P}(A_2|B) = \frac{\mathbb{P}(A_2 \cap B)}{\mathbb{P}(B)} = \frac{\mathbb{P}(\{3\} \cap \{2, 3\})}{\mathbb{P}(\{2, 3\})} = \frac{\mathbb{P}(\{3\})}{\mathbb{P}(\{2, 3\})} = \frac{1}{10} \cdot \frac{2}{1} = \frac{2}{10}. \quad (3.22)$$

Man beachte, dass

$$\mathbb{P}(A_1|B) + \mathbb{P}(A_2|B) = \frac{8}{10} + \frac{2}{10} = 1. \quad (3.23)$$

Basierend auf der Definition der bedingten Wahrscheinlichkeit eines Ereignisses unter der Bedingung des Eintretens eines festen Ereignisses B kann man ein Wahrscheinlichkeitsmaß definieren, das die Wahrscheinlichkeiten *aller* Ereignisse des Ereignissystems unter der Bedingung des Eintretens eines festen Ereignisses B angibt. Man nennt dieses Wahrscheinlichkeitsmaß die *bedingte Wahrscheinlichkeit gegeben Ereignis B* .

Theorem 3.2 (Bedingte Wahrscheinlichkeit). *Für ein festes $B \in \mathcal{A}$ mit $\mathbb{P}(B) > 0$ sei*

$$\mathbb{P}(\cdot|B) : \mathcal{A} \rightarrow [0, 1], A \mapsto \mathbb{P}(A|B) := \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} \quad (3.24)$$

Dann ist $\mathbb{P}(\cdot|B)$ ein Wahrscheinlichkeitsmaß und heißt die bedingte Wahrscheinlichkeit gegeben Ereignis B .

◦

Beweis. Wir weisen die definierenden Eigenschaften eines Wahrscheinlichkeitsmaßes nach.

(1) $\mathbb{P}(A|B) \geq 0$ für alle $A \in \mathcal{A}$

Nach Definition der bedingten Wahrscheinlichkeit gilt $\mathbb{P}(A|B) = \mathbb{P}(A \cap B)/\mathbb{P}(B)$ mit $\mathbb{P}(B) > 0$. Mit dem Theorem zur Abgeschlossenheit von σ -Algebren bezüglich Durchschnitten und der Definition von $\mathbb{P}$ gilt $\mathbb{P}(A \cap B) \geq 0$ und damit folgt die Aussage.

(2) $\mathbb{P}(\Omega|B) = 1$.

Es gilt

$$\mathbb{P}(\Omega|B) = \frac{\mathbb{P}(\Omega \cap B)}{\mathbb{P}(B)} = \frac{\mathbb{P}(B)}{\mathbb{P}(B)} = 1. \quad (3.25)$$

(3) $\mathbb{P}(\cup_{i=1}^{\infty} A_i|B) = \sum_{i=1}^{\infty} \mathbb{P}(A_i|B)$ für paarweise disjunkte $A_1, A_2, \dots \in \mathcal{A}$.

Mit den Assoziativ- und Distributivgesetzen von Vereinigung und Durchschnitt gilt zunächst, dass

$$(\cup_{i=1}^{\infty} A_i) \cap B = (A_1 \cup A_2 \cup \dots) \cap B = (A_1 \cap B) \cup (A_2 \cap B) \cup \dots = \cup_{i=1}^{\infty} (A_i \cap B). \quad (3.26)$$

Weiterhin gilt mit $A_i \cap A_j = \emptyset$ und den Assoziativ- und Distributivgesetzen von Vereinigung und Durchschnitt, dass auch die $A_i \cap B$ für $i = 1, 2, \dots$ paarweise disjunkt sind, denn

$$(A_i \cap B) \cap (A_j \cap B) = (A_i \cap A_j) \cap (B \cap B) = \emptyset \cap B = \emptyset. \quad (3.27)$$

Mit der σ -Additivität von $\mathbb{P}$ folgt damit dann, dass

$$\begin{aligned} \mathbb{P}(\cup_{i=1}^{\infty} A_i | B) &= \frac{\mathbb{P}((\cup_{i=1}^{\infty} A_i) \cap B)}{\mathbb{P}(B)} \\ &= \frac{\mathbb{P}(\cup_{i=1}^{\infty} (A_i \cap B))}{\mathbb{P}(B)} \\ &= \frac{\sum_{i=1}^{\infty} \mathbb{P}(A_i \cap B)}{\mathbb{P}(B)} \\ &= \sum_{i=1}^{\infty} \frac{\mathbb{P}(A_i \cap B)}{\mathbb{P}(B)} \\ &= \sum_{i=1}^{\infty} \mathbb{P}(A_i | B). \end{aligned} \quad (3.28)$$

□

Man beachte, dass bei der bedingten Wahrscheinlichkeit $\mathbb{P}(\cdot|B)$ die Rechenregeln der Wahrscheinlichkeitstheorie für die Ereignisse links des Strichs gelten. Insbesondere definiert $\mathbb{P}(\cdot|B)$ im Gegensatz zu $\mathbb{P}(\cdot \cap B)$ ein Wahrscheinlichkeitsmaß für alle $A \in \mathcal{A}$. So gelten beispielsweise für $0 < \mathbb{P}(B) < 1$, dass $\mathbb{P}(\Omega|B) = 1$ ist, aber dass $\mathbb{P}(\Omega \cap B) = \mathbb{P}(B) < 1$ ist. Man sagt deshalb auch, dass $\mathbb{P}(\cdot|B)$ *normalisiert* ist, $\mathbb{P}(\cdot \cap B)$ dagegen nicht.

Zum Schluss dieses Abschnittes wollen wir noch drei technische Konsequenzen der Definition der bedingten Wahrscheinlichkeit betrachten, die wir als Theoreme formulieren.

Das erste Theorem betrifft den Zusammenhang von gemeinsamen und bedingten Wahrscheinlichkeiten und reiteriert, wie gemeinsame Wahrscheinlichkeiten aus bedingten und totalen Wahrscheinlichkeiten berechnet werden können.

Theorem 3.3 (Gemeinsame und bedingte Wahrscheinlichkeiten). *Es seien $(\Omega, \mathcal{A}, \mathbb{P})$ ein Wahrscheinlichkeitsraum und $A, B \in \mathcal{A}$ mit $\mathbb{P}(A) > 0$ und $\mathbb{P}(B) > 0$. Dann gilt*

$$\mathbb{P}(A \cap B) = \mathbb{P}(A|B)\mathbb{P}(B) = \mathbb{P}(B|A)\mathbb{P}(A). \quad (3.29)$$

◦

Beweis. Mit der Definition der jeweiligen bedingten Wahrscheinlichkeit folgen direkt

$$\mathbb{P}(A|B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} \Leftrightarrow \mathbb{P}(A \cap B) = \mathbb{P}(A|B)\mathbb{P}(B) \quad (3.30)$$

und

$$\mathbb{P}(B|A) = \frac{\mathbb{P}(B \cap A)}{\mathbb{P}(A)} \Leftrightarrow \mathbb{P}(A \cap B) = \mathbb{P}(B|A)\mathbb{P}(A). \quad (3.31)$$

□

Ebenso wie das Festlegen von $\mathbb{P}(A \cap B)$ und $\mathbb{P}(A)$ die bedingte Wahrscheinlichkeit $\mathbb{P}(B|A)$ festlegt, legt das Festlegen von $\mathbb{P}(A)$ und $\mathbb{P}(B|A)$ also die gemeinsame Wahrscheinlichkeit $\mathbb{P}(A \cap B)$ fest.

Das nachfolgende sogenannte *Gesetz der totalen Wahrscheinlichkeit* besagt, wie basierend auf gemeinsamen Wahrscheinlichkeiten unbedingte, sogenannte *totale Wahrscheinlichkeiten* berechnet werden können.

Theorem 3.4 (Gesetz der totalen Wahrscheinlichkeit). $(\Omega, \mathcal{A}, \mathbb{P})$ sei ein Wahrscheinlichkeitsraum und $A_1, \dots, A_k$ mit $\mathbb{P}(A_i) > 0$ sei eine Partition von Ω . Dann gilt für jedes $B \in \mathcal{A}$, dass

$$\mathbb{P}(B) = \sum_{i=1}^k \mathbb{P}(B \cap A_i) = \sum_{i=1}^k \mathbb{P}(B|A_i)\mathbb{P}(A_i). \quad (3.32)$$

◦

Beweis. Für $i = 1, \dots, k$ sei $C_i := B \cap A_i$, sodass $\cup_{i=1}^k C_i = B$ und $C_i \cap C_j = \emptyset$ für $1 \leq i, j \leq k, i \neq j$. Wir verdeutlichen diese Festlegungen in Abbildung 3.3 mithilfe eines Venn-Diagramms.




Abbildung 3.3 Venn-Diagramm zum Beweis von Theorem 3.4.

Also gilt mit der Definition der bedingten Wahrscheinlichkeit für $\mathbb{P}(A_i) > 0$, dass

$$\mathbb{P}(B) = \sum_{i=1}^k \mathbb{P}(C_i) = \sum_{i=1}^k \mathbb{P}(B \cap A_i) = \sum_{i=1}^k \mathbb{P}(B|A_i)\mathbb{P}(A_i). \quad (3.33)$$

□

Intuitiv entspricht $\mathbb{P}(B)$ also der gewichteten Summe der bedingten Wahrscheinlichkeiten $\mathbb{P}(B|A_i)$ wobei die Wichtungsfaktoren gerade die unbedingten Wahrscheinlichkeiten $\mathbb{P}(A_i)$ für $i = 1, \dots, k$ sind. Die Forderung $\mathbb{P}(A_i) > 0$ für alle $i = 1, \dots, k$ ist hier notwendig, um die Darstellung von $\mathbb{P}(B \cap A_i)$ mithilfe von Definition 3.2 zu gewährleisten.

Beispiel 3.2 (Gesetz der totalen Wahrscheinlichkeit beim fairen Würfel). Als Beispiel für die Darstellung der Wahrscheinlichkeit eines Ereignisses mithilfe des Gesetzes der totalen Wahrscheinlichkeit betrachten wir das Wahrscheinlichkeitsraummodell des fairen Würfels. Für den Ergebnisraum $\Omega := \{1, 2, 3, 4, 5, 6\}$ betrachten wir das Ereignis $B := \{2, 4, 6\}$ („Es fällt eine gerade Zahl“) mit Wahrscheinlichkeit $\mathbb{P}(B) = \frac{1}{2}$ sowie die Partition $A_1 := \{1, 2\}$, $A_2 := \{3\}$, $A_3 := \{4, 5\}$, $A_4 := \{6\}$ von Ω . Dann gelten offenbar

$$\begin{aligned} \mathbb{P}(B \cap A_1) &= \mathbb{P}(\{2, 4, 6\} \cap \{1, 2\}) = \mathbb{P}(\{2\}) = \frac{1}{6} \\ \mathbb{P}(B \cap A_2) &= \mathbb{P}(\{2, 4, 6\} \cap \{3\}) = \mathbb{P}(\emptyset) = 0 \\ \mathbb{P}(B \cap A_3) &= \mathbb{P}(\{2, 4, 6\} \cap \{4, 5\}) = \mathbb{P}(\{4\}) = \frac{1}{6} \\ \mathbb{P}(B \cap A_4) &= \mathbb{P}(\{2, 4, 6\} \cap \{6\}) = \mathbb{P}(\{6\}) = \frac{1}{6} \end{aligned} \quad (3.34)$$

Damit ergibt sich dann

$$\begin{aligned} \sum_{i=1}^4 \mathbb{P}(B \cap A_i) &= \mathbb{P}(B \cap A_1) + \mathbb{P}(B \cap A_2) + \mathbb{P}(B \cap A_3) + \mathbb{P}(B \cap A_4) \\ &= \frac{1}{6} + 0 + \frac{1}{6} + \frac{1}{6} \\ &= \frac{1}{2} \end{aligned} \quad (3.35)$$

und somit

$$\mathbb{P}(B) = \sum_{i=1}^4 \mathbb{P}(B \cap A_i). \quad (3.36)$$

Man beachte, dass die Partitionseigenschaft von A_1, A_2, A_3, A_4 essenziell für die Validität des Theorems in diesem Beispiel ist. Wäre beispielsweise $A_4 = \{4, 6\}$ und damit A_3 und A_4 nicht disjunkt, so ergäbe die rechte Seite des Gesetzes von der totalen Wahrscheinlichkeit einen Wert größer $\mathbb{P}(B)$. Ergäbe die Vereinigung der A_1, A_2, A_3, A_4 dagegen nicht Ω , weil zum Beispiel $A_4 = \emptyset$, so ergäbe sich umgekehrt ein Wert kleiner $\mathbb{P}(B)$.

△

Schließlich betrachten wir mit dem *Bayesschen Theorem* eine Formel zur alternativen Berechnung von bedingten Wahrscheinlichkeiten.

Theorem 3.5 (Bayessches Theorem). $(\Omega, \mathcal{A}, \mathbb{P})$ sei ein Wahrscheinlichkeitsraum und $A_1, \dots, A_k$ sei eine Partition von Ω mit $\mathbb{P}(A_i) > 0$ für alle $i = 1, \dots, k$. Wenn $\mathbb{P}(B) > 0$ gilt, dann gilt für jedes $i = 1, \dots, k$, dass

$$\mathbb{P}(A_i|B) = \frac{\mathbb{P}(B|A_i)\mathbb{P}(A_i)}{\sum_{i=1}^k \mathbb{P}(B|A_i)\mathbb{P}(A_i)}. \quad (3.37)$$

◦

Beweis. Mit der Definition der bedingten Wahrscheinlichkeit und dem Gesetz der totalen Wahrscheinlichkeit gilt

$$\mathbb{P}(A_i|B) = \frac{\mathbb{P}(A_i \cap B)}{\mathbb{P}(B)} = \frac{\mathbb{P}(B|A_i)\mathbb{P}(A_i)}{\mathbb{P}(B)} = \frac{\mathbb{P}(B|A_i)\mathbb{P}(A_i)}{\sum_{i=1}^k \mathbb{P}(B|A_i)\mathbb{P}(A_i)}. \quad (3.38)$$

□

Man beachte, dass das Theorem von Bayes unabhängig von der Frequentistischen oder Bayesianischen Interpretation der Wahrscheinlichkeit ist und lediglich eine Aussage zum Rechnen mit bedingten Wahrscheinlichkeiten macht. Im Rahmen der Frequentistischen Inferenz wird das Theorem von Bayes allerdings recht selten benutzt. Im Rahmen der Bayesianischen Inferenz dagegen ist das Theorem von Bayes zentral. In diesem Kontext wird $\mathbb{P}(A_i)$ dann oft die *Prior-Wahrscheinlichkeit des Ereignisses* A_i und $\mathbb{P}(A_i|B)$ die *Posterior-Wahrscheinlichkeit des Ereignisses* A_i genannt. Wie oben erläutert entspricht $\mathbb{P}(A_i|B)$ der Wahrscheinlichkeit von A_i , wenn man um das Eintreten von B weiß.

In der Anwendung werden die hier als *Gesetz der totalen Wahrscheinlichkeit* (Theorem 3.4), *Theorem zu Gemeinsamen und bedingten Wahrscheinlichkeiten* (Theorem 3.3) und *Bayessches Theorem* (Theorem 3.5) formulierten Resultate oft als die zentrale Rechenregeln der Wahrscheinlichkeitstheorie genutzt. In der Praxis werden sie dabei meist als *Summationsregel*, *Multiplikationsregel* und *Bayesregel* bezeichnet (vgl. Tabelle 3.2).

Tabelle 3.2 Zentrale Rechenregeln der Wahrscheinlichkeitstheorie

Rechenregel	Wahrscheinlichkeitsraumform
Multiplikationsregel	$\mathbb{P}(A \cap B) = \mathbb{P}(B A) \mathbb{P}(A)$
Summenregel	$\mathbb{P}(B) = \sum_{i=1}^k \mathbb{P}(B \cap A_i)$, wenn $\Omega = \cup_{i=1}^k A_i$ und $A_i \cap A_j = \emptyset$
Bayesregel	$\mathbb{P}(A B) = \frac{\mathbb{P}(B A)\mathbb{P}(A)}{\mathbb{P}(B)}$, wenn $\mathbb{P}(B) > 0$

3.3 Unabhängige Ereignisse

Die Unabhängigkeit von Ereignissen dient der Modellierung der Abwesenheit von gegenseitigen Einflüssen von Ereignissen. Ihre Definition besagt, dass sich die gemeinsame Wahrscheinlichkeit zweier Ereignisse aus dem Produkt der Wahrscheinlichkeiten der einzelnen Ereignisse ergeben soll. Man spricht in diesem Kontext auch von der *Faktorisierung der gemeinsamen Wahrscheinlichkeit* der Ereignisse. Der Sinn dieser Definition erschließt sich dann im Lichte des Begriffs der bedingten Wahrscheinlichkeit in Theorem 3.6. Wir betrachten zunächst die Definition.

Definition 3.3 (Unabhängige Ereignisse). Zwei Ereignisse $A \in \mathcal{A}$ und $B \in \mathcal{A}$ heißen *unabhängig*, wenn

$$\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B). \quad (3.39)$$

Eine Menge von Ereignissen $\{A_i | i \in I\} \subset \mathcal{A}$ mit beliebiger Indexmenge I heißt *unabhängig*, wenn für jede endliche Untermenge $J \subseteq I$ gilt, dass

$$\mathbb{P}\left(\bigcap_{j \in J} A_j\right) = \prod_{j \in J} \mathbb{P}(A_j). \quad (3.40)$$

•

Man beachte, dass die Unabhängigkeit bestimmter Ereignissen in der Definition eines probabilistischen Modells vorausgesetzt werden kann oder auch aus der Definition eines probabilistischen Modells folgen kann. Sind zwei Ereignisse nicht unabhängig, so sagt man auch, dass diese Ereignisse *abhängig* sind. Der Sinn der Produkteigenschaft bei Unabhängigkeit erschließt sich, wie wir unten zeigen, im Kontext bedingter Wahrscheinlichkeiten. Zunächst geben wir ein Beispiel, das den Zusammenhang zwischen Unabhängigkeit und paarweiser Unabhängigkeit von Ereignissen verdeutlicht.

Beispiel 3.3 (Paarweise und gemeinsame Unabhängigkeit). Unabhängige Ereignisse sind nach Definition immer auch paarweise unabhängig. Beispielsweise gilt für die Menge $\{A_i | i \in \{1, 2, 3\}\}$ von Ereignissen und die möglichen Untermengen $J_1 := \{1, 2\}$, $J_2 := \{1, 3\}$, $J_3 := \{2, 3\}$, $J := \{1, 2, 3\}$ von $I = \{1, 2, 3\}$, dass die Definitionsbedingung der Unabhängigkeit von A_1, A_2, A_3 die Aussagen

$$\begin{aligned} \mathbb{P}(A_1 \cap A_2) &= \mathbb{P}(A_1)\mathbb{P}(A_2) \\ \mathbb{P}(A_1 \cap A_3) &= \mathbb{P}(A_1)\mathbb{P}(A_3) \\ \mathbb{P}(A_2 \cap A_3) &= \mathbb{P}(A_2)\mathbb{P}(A_3) \\ \mathbb{P}(A_1 \cap A_2 \cap A_3) &= \mathbb{P}(A_1)\mathbb{P}(A_2)\mathbb{P}(A_3) \end{aligned} \quad (3.41)$$

impliziert. Andersherum kann aus der paarweisen Unabhängigkeit von Ereignissen nicht auf die Unabhängigkeit von Ereignissen geschlossen werden, wie folgendes Beispiel zeigt (vgl. DeGroot & Schervish (2012)). Betrachten wir das Modell des zweifachen Werfens einer fairen Münze mit dem Ergebnisraum

$$\Omega := \{HH, HT, TH, TT\} \quad (3.42)$$

mit den Elementarereigniswahrscheinlichkeiten

$$\mathbb{P}\{HH\} = \mathbb{P}\{HT\} = \mathbb{P}\{TH\} = \mathbb{P}\{TT\} = \frac{1}{4} \quad (3.43)$$

Dann sind die in Tabelle 3.3 aufgelisteten Ereignisse zwar paarweise unabhängig, aber nicht unabhängig.

Tabelle 3.3 Münzwurfbeispiel zur Unabhängigkeit

Verbale Beschreibung	Mengenform
Im ersten Wurf fällt Kopf	$A_1 := \{HH, HT\}$
Im zweiten Wurf fällt Kopf	$A_2 := \{HH, TH\}$
In beiden Würfeln fällt das gleiche Ergebnis	$A_3 := \{HH, TT\}$

Es gelten hier offenbar

$$\mathbb{P}(A_1) = \mathbb{P}(A_2) = \mathbb{P}(A_3) = \frac{1}{2}, \quad (3.44)$$

sowie

$$\begin{aligned} \mathbb{P}(A_1 \cap A_2) &= \mathbb{P}(\{HH\}) = \frac{1}{4} = \frac{1}{2} \cdot \frac{1}{2} = \mathbb{P}(A_1) \mathbb{P}(A_2), \\ \mathbb{P}(A_1 \cap A_3) &= \mathbb{P}(\{HH\}) = \frac{1}{4} = \frac{1}{2} \cdot \frac{1}{2} = \mathbb{P}(A_1) \mathbb{P}(A_3), \\ \mathbb{P}(A_2 \cap A_3) &= \mathbb{P}(\{HH\}) = \frac{1}{4} = \frac{1}{2} \cdot \frac{1}{2} = \mathbb{P}(A_2) \mathbb{P}(A_3). \end{aligned} \quad (3.45)$$

Die Ereignisse sind also paarweise unabhängig. Allerdings gilt auch

$$\mathbb{P}(A_1 \cap A_2 \cap A_3) = \mathbb{P}(\{HH\}) = \frac{1}{4} \neq \frac{1}{8} = \frac{1}{2} \cdot \frac{1}{2} \cdot \frac{1}{2} = \mathbb{P}(A_1) \mathbb{P}(A_2) \mathbb{P}(A_3) \quad (3.46)$$

und die Ereignisse A_1, A_2, A_3 sind damit nicht unabhängig.

△

Abschließend wollen wir mit dem Zusammenhang zwischen Unabhängigkeit und bedingter Wahrscheinlichkeit den Sinn der Produkteigenschaft bei Unabhängigkeit erläutern.

Theorem 3.6 (Bedingte Wahrscheinlichkeit unter Unabhängigkeit). *($\Omega, \mathcal{A}, \mathbb{P}$) sei ein Wahrscheinlichkeitsraum und $A, B \in \mathcal{A}$ seien unabhängige Ereignisse mit $\mathbb{P}(B) > 0$. Dann gilt*

$$\mathbb{P}(A|B) = \mathbb{P}(A). \quad (3.47)$$

◦

Beweis. Unter den Annahmen des Theorems gilt

$$\mathbb{P}(A|B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} = \frac{\mathbb{P}(A)\mathbb{P}(B)}{\mathbb{P}(B)} = \mathbb{P}(A). \quad (3.48)$$

□

Bei gegebener Unabhängigkeit zweier Ereignisse A und B ist es für die Wahrscheinlichkeit des Ereignisses A also unerheblich, ob auch B eintritt oder nicht, die Wahrscheinlichkeit $\mathbb{P}(A)$ bleibt gleich. Damit wird die Unabhängigkeit von Ereignissen also gerade als Faktorisierung der gemeinsamen Wahrscheinlichkeit von A und B modelliert, damit $\mathbb{P}(A|B) = \mathbb{P}(A)$ folgt. Aus Sicht der Modellierung subjektiver Unsicherheit durch Wahrscheinlichkeiten bedeutet die Unabhängigkeit zweier Ereignisse also, dass das Wissen um das Vorliegen eines der beiden Ereignisse die Wahrscheinlichkeit für das Vorliegen des anderen Ereignisses nicht ändert. Andersherum bedeutet die Abhängigkeit zweier Ereignisse, dass das Wissen um das Vorliegen eines der beiden Ereignisse die Wahrscheinlichkeit für das Vorliegen des anderen Ereignisses verändert, also entweder erhöht oder verringert.

Beispiel 3.4 (Bedingte Wahrscheinlichkeit unter Unabhängigkeit beim fairen Würfel). Wir wollen den Zusammenhang von Unabhängigkeit, bedingter Wahrscheinlichkeit und Faktorisierung der gemeinsamen Wahrscheinlichkeit am Beispiel des Modells des fairen Würfels verdeutlichen. Dazu betrachten wir das Ereignis $A := \{2, 4, 6\}$ (“Es fällt eine gerade Zahl”) und das Ereignis $B := \{3, 4, 5, 6\}$ (“Es fällt eine Zahl größer als zwei”). Intuitiv verändert sich die Wahrscheinlichkeit dafür, dass eine gerade Zahl gefallen ist, nicht, wenn man weiß, dass eine Zahl größer als zwei gefallen ist: Hat man die Information, dass eine Zahl größer als zwei gefallen ist, so entsprechen drei von sechs Fällen dem Ereignis des Fallens einer geraden Zahl; hat man die Information, so entsprechen zwei von vier Fällen dem Ereignis des Fallens einer geraden Zahl. Der relative Anteil der dem Ereignis “Es fällt eine gerade Zahl” entsprechenden Fälle bleibt also angesichts des Nichtvorliegens oder des Vorliegens der Information “Es fällt eine Zahl größer als zwei” gleich.

Formal stellen wir zunächst die Faktorisierung der gemeinsamen Wahrscheinlichkeit der beiden Ereignisse, also des Ereignisses “Es fällt eine gerade Zahl und diese ist größer als zwei” in das Produkt der Wahrscheinlichkeiten der beiden Ereignisse fest. Es gilt hier mit der σ -Additivität von $\mathbb{P}$

$$\begin{aligned}
 \mathbb{P}(A \cap B) &= \mathbb{P}(\{2, 4, 6\} \cap \{3, 4, 5, 6\}) \\
 &= \mathbb{P}(\{4, 6\}) \\
 &= \frac{2}{6} \\
 &= \frac{1}{2} \cdot \frac{2}{3} \\
 &= \mathbb{P}(\{2, 4, 6\}) \cdot \mathbb{P}(\{3, 4, 5, 6\}) \\
 &= \mathbb{P}(A)\mathbb{P}(B)
 \end{aligned} \tag{3.49}$$

Die gemeinsame Wahrscheinlichkeit von A und B lässt sich also als das Produkt der Wahrscheinlichkeiten von A und B schreiben. Für die bedingte Wahrscheinlichkeit von A gegeben B gilt ferner

$$\begin{aligned}
 \mathbb{P}(A|B) &= \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} \\
 &= \frac{\mathbb{P}(\{4, 6\})}{\mathbb{P}(\{3, 4, 5, 6\})} \\
 &= \frac{1}{3} \cdot \frac{3}{2} \\
 &= \frac{1}{2} \\
 &= \mathbb{P}(\{2, 4, 6\}) \\
 &= \mathbb{P}(A)
 \end{aligned} \tag{3.50}$$

Also sind in diesem Beispiel sowohl Definition 3.3 als auch Theorem 3.6 erfüllt.

△

Die Eigenschaft von Ereignissen, unabhängig zu sein, sollte nicht damit verwechselt werden, dass Ereignisse disjunkt sein können. Tatsächlich gilt folgendes Theorem.

Theorem 3.7 (Disjunktheit und Abhängigkeit von Ereignissen). *$A \in \mathcal{A}$ und $B \in \mathcal{A}$ seien zwei disjunkte Ereignisse mit $\mathbb{P}(A) > 0$ und $\mathbb{P}(B) > 0$. Dann sind A und B abhängige Ereignisse.*

◦

Beweis. Zum einen aufgrund der Disjunktheit von A und B , dass

$$\mathbb{P}(A \cap B) = \mathbb{P}(\emptyset) = 0 \quad (3.51)$$

Zum anderen gilt

$$\mathbb{P}(A)\mathbb{P}(B) > 0, \quad (3.52)$$

da nach Annahme sowohl $\mathbb{P}(A) > 0$ als auch $\mathbb{P}(B) > 0$ gelten. Also gilt

$$\mathbb{P}(A \cap B) \neq \mathbb{P}(A)\mathbb{P}(B) \quad (3.53)$$

und nach Definition 3.3 sind A und B damit nicht unabhängig, also abhängig. $\square$

Beispiel 3.5 (Disjunkte Ereignisse sind abhängig). Wir wollen Theorem 3.7 am Beispiel des fairen Würfels verdeutlichen. Dazu sei $A = \{2, 4, 6\}$ das Ereignis “Es fällt eine gerade Zahl” und $B = \{1, 3, 5\}$ das Ereignis “Es fällt eine ungerade Zahl”. Intuitiv sind die Ereignisse abhängig, da die Information das eine gerade Zahl gefallen ist die subjektive Wahrscheinlichkeit dafür, dass eine ungerade Zahl gefallen ist auf null absenkt. Formal gilt einerseits

$$\mathbb{P}(A)\mathbb{P}(B) = \frac{1}{2} \cdot \frac{1}{2} = \frac{1}{4}, \quad (3.54)$$

aber

$$\mathbb{P}(A \cap B) = \mathbb{P}(\{2, 4, 6\} \cap \{1, 3, 5\}) = \mathbb{P}(\emptyset) = 0. \quad (3.55)$$

Zum anderen gilt auch

$$\mathbb{P}(A|B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} = \frac{\mathbb{P}(\emptyset)}{\mathbb{P}(B)} = \frac{0}{\mathbb{P}(B)} = 0 \neq \frac{1}{2} = \mathbb{P}(\{2, 4, 6\}) = \mathbb{P}(A). \quad (3.56)$$

$\triangle$

3.4 Literaturhinweise

Viele der in diesem Abschnitt eingeführten Begrifflichkeiten sind auf engste mit der geschichtlichen Genese der Wahrscheinlichkeitstheorie verwoben, sodass keine einzelnen Referenzen angegeben werden sollen. Einen Einstieg in die Geschichte der Wahrscheinlichkeitstheorie der letzten zwei Jahrhunderte bietet Hald (1990), einen Überblick über modernere Entwicklungen gibt Von Plato (1994). Das Theorem von Bayes wird allgemein auf Bayes (1763) zurückgeführt, auch wenn es nicht das eigentliche Hauptthema dieser Arbeit ist.

Selbstkontrollfragen

1. Geben Sie die Definition der gemeinsamen Wahrscheinlichkeit zweier Ereignisse wieder.
2. Erläutern Sie die intuitive Bedeutung der gemeinsamen Wahrscheinlichkeit zweier Ereignisse.
3. Geben Sie das Theorem zu weiteren Eigenschaften von Wahrscheinlichkeiten wieder.
4. Geben Sie die Definition der bedingten Wahrscheinlichkeit eines Ereignisses wieder.
5. Geben Sie das Theorem zur bedingten Wahrscheinlichkeit wieder.
6. Geben Sie das Theorem zu gemeinsamen und bedingten Wahrscheinlichkeiten wieder.
7. Geben Sie das Gesetz der totalen Wahrscheinlichkeit wieder.
8. Geben Sie das Theorem von Bayes wieder.
9. Geben Sie den Beweis des Theorems von Bayes wieder.
10. Geben Sie die Definition der Unabhängigkeit zweier Ereignisse wieder.
11. Geben Sie das Theorem zur bedingten Wahrscheinlichkeit unter Unabhängigkeit wieder.
12. Geben Sie den Beweis des Theorems zur bedingten Wahrscheinlichkeit unter Unabhängigkeit wieder.
13. Erläutern Sie das Theorem zur bedingten Wahrscheinlichkeit unter Unabhängigkeit.

Lösungen

1. Siehe Definition 3.1.
2. Siehe Bemerkungen zu Definition 3.1.
3. Siehe Theorem 3.1.
4. Siehe Definition 3.2.
5. Siehe Theorem 3.2.
6. Siehe Theorem 3.3.
7. Siehe Theorem 3.4.
8. Siehe Theorem 3.5.
9. Siehe Beweis zu Theorem 3.5.
10. Siehe Definition 3.3.
11. Siehe Theorem 3.6.
12. Siehe Beweis zu Theorem 3.6.
13. Siehe Bemerkungen Theorem 3.6.

4 Zufallsvariablen

Mit dem Begriff der *Zufallsvariable* führen wir in diesem Kapitel das probabilistische Standardmodell für einen univariaten Datenpunkt ein. Zentral ist dabei die Möglichkeit im Rahmen der probabilistischen Modellformulierung, die Verteilungen von Zufallsvariablen mithilfe von Wahrscheinlichkeitsmassefunktion und Wahrscheinlichkeitsdichtefunktionen festzulegen. Weiterhin impliziert die Konstruktion von Zufallsvariablen als Abbildungen zufälliger Ergebnisse mit der Untersuchung der Verteilungen der so transformierten zufälligen Ergebnisse das Kernthema frequentistischer Inferenz.

4.1 Definition

Wir skizzieren zunächst die Konstruktion einer Zufallsvariable und ihrer Verteilung anhand von Abbildung 4.1. Dazu sei $(\Omega, \mathcal{A}, \mathbb{P})$ ein Wahrscheinlichkeitsraum und

$$\xi : \Omega \rightarrow \mathcal{X}, \omega \mapsto \xi(\omega) \quad (4.1)$$

eine Abbildung. Weiterhin sei $\mathcal{S}$ eine σ -Algebra auf der Zielmenge $\mathcal{X}$ dieser Abbildung. Für jedes $S \in \mathcal{S}$ sei die Urbildmenge von S gegeben durch (vgl. [Bildmenge](#), [Wertebereich](#), [Urbildmenge und Urbild \(PDWP\)](#))

$$\xi^{-1}(S) := \{\omega \in \Omega \mid \xi(\omega) \in S\}. \quad (4.2)$$

Wenn nun $\xi^{-1}(S) \in \mathcal{A}$ für alle $S \in \mathcal{S}$ gilt, dann nennt man die Abbildung ξ *messbar*. Nehmen wir also an ξ sei messbar. Dann kann allen $S \in \mathcal{S}$ die Wahrscheinlichkeit


$$\mathbb{P}_\xi : \mathcal{S} \rightarrow [0, 1], S \mapsto \mathbb{P}_\xi(S) := \mathbb{P}(\xi^{-1}(S)) = \mathbb{P}(\{\omega \in \Omega \mid \xi(\omega) \in S\}) \quad (4.3)$$

zugeordnet werden. In diesem Kontext nennt man ξ nun eine *Zufallsvariable* und $\mathbb{P}_\xi$ heißt das *Bildmaß* oder die *Verteilung* von ξ . Insgesamt wurde damit ausgehend von dem Wahrscheinlichkeitsraum $(\Omega, \mathcal{A}, \mathbb{P})$ mithilfe der Zufallsvariable ξ der Wahrscheinlichkeitsraum $(\mathcal{X}, \mathcal{S}, \mathbb{P}_\xi)$ konstruiert. Formal ist eine Zufallsvariable damit wie folgt definiert.

Definition 4.1 (Zufallsvariable). Es sei $(\Omega, \mathcal{A}, \mathbb{P})$ ein Wahrscheinlichkeitsraum und $(\mathcal{X}, \mathcal{S})$ ein *Messraum*. Dann ist eine *Zufallsvariable* definiert als eine Abbildung $\xi : \Omega \rightarrow \mathcal{X}$ mit der *Messbarkeitseigenschaft*

$$\{\omega \in \Omega \mid \xi(\omega) \in S\} \in \mathcal{A} \text{ für alle } S \in \mathcal{S}. \quad (4.4)$$

•



$$\mathbb{P}(\xi^{-1}(S)) = \mathbb{P}(\{\omega \in \Omega \mid \xi(\omega) \in S\}) =: \mathbb{P}_\xi(S)$$

Abbildung 4.1 Konstruktion von Zufallsvariable und Verteilung.

Nach Definition 4.1 sind Zufallsvariablen weder “zufällig” noch “Variablen”, sondern messbare Abbildungen. Fragt man nach der Bedeutung des Zufalls für die Werte $\xi(\omega)$ von Zufallsvariablen, so vermittelt weiterhin die implizite frequentistische Mechanik des Wahrscheinlichkeitsraums $(\Omega, \mathcal{A}, \mathbb{P})$ eine entsprechende Intuition: In jedem Durchgang des modellierten Zufallsvorgangs wird dabei ein ω anhand von $\mathbb{P}$ realisiert und dann (deterministisch) auf $\xi(\omega)$ abgebildet. Wir definieren dementsprechend die Begriffe des *Ergebnisraums* und der *Realisierung* einer Zufallsvariable.

Definition 4.2 (Realisierung einer Zufallsvariable). $(\Omega, \mathcal{A}, \mathbb{P})$ sei ein Wahrscheinlichkeitsraum, $(\mathcal{X}, \mathcal{S})$ sei ein Messraum und $\xi : \Omega \rightarrow \mathcal{X}$ sei eine Zufallsvariable. Dann heißt $\mathcal{X}$ der *Ergebnisraum der Zufallsvariable* ξ und ein $\xi(\omega) \in \mathcal{X}$ heißt eine *Realisierung der Zufallsvariable* ξ .

•

Beispiel 4.1 (Augensumme zweier Würfel als Zufallsvariable). Aufbauend auf dem in Kapitel 2.3 betrachteten Beispiel eines Wahrscheinlichkeitsraums zur Modellierung des gleichzeitigen Würfeln mit einem blauen und einem roten Würfel wollen wir mit der Summe der Würfelaugen Zahlen ein erstes Beispiel für eine Zufallsvariable und ihre Verteilung betrachten. Wir haben in Kapitel 2.3 gesehen, dass ein sinnvolles Wahrscheinlichkeitsraummodell für das gleichzeitige Würfeln mit einem blauen und einem roten Würfel durch $(\Omega, \mathcal{A}, \mathbb{P})$ mit

- $\Omega := \{(r, b) \mid r \in \mathbb{N}_6, b \in \mathbb{N}_6\}$,
- $\mathcal{A} := \mathcal{P}(\Omega)$ und
- $\mathbb{P} : \mathcal{A} \rightarrow [0, 1]$ mit $\mathbb{P}(\{(r, b)\}) = \frac{1}{36}$ für alle $(r, b) \in \Omega$.

gegeben ist. Die Auswertung der Summe der beiden Würfelaugennummern wird dann sinnvollerweise durch die Abbildung

$$\xi : \Omega \rightarrow \mathcal{X}, (r, b) \mapsto \xi((r, b)) := r + b \quad (4.5)$$

beschrieben, wobei offenbar $\mathcal{X} := \{2, 3, \dots, 12\}$ gelten muss. Der Ergebnisraum der Zufallsvariable ist also wiederum endlich und $\mathcal{S} := \mathcal{P}(\mathcal{X})$ ist eine sinnvolle σ -Algebra auf $\mathcal{X}$. Mithilfe der σ -Additivität von $\mathbb{P}$ können wir nun die Verteilung $\mathbb{P}_\xi$ von ξ für alle Elementarereignisse $\{x\} \in \mathcal{S}$ berechnen und damit insbesondere auch die Messbarkeit von ξ nachweisen, wie in Tabelle 4.1 gezeigt.

Tabelle 4.1 Wahrscheinlichkeitsverteilung der Augensumme beim Wurf zweier Würfel

$\mathbb{P}_\xi(\{x\})$	$\mathbb{P}(\xi^{-1}(\{x\}))$	$\mathbb{P}(\{\omega \xi(\omega) \in \{x\}\})$	
$\mathbb{P}_\xi(\{2\})$	$\mathbb{P}(\xi^{-1}(\{2\}))$	$\mathbb{P}(\{(1, 1)\})$	$\frac{1}{36}$
$\mathbb{P}_\xi(\{3\})$	$\mathbb{P}(\xi^{-1}(\{3\}))$	$\mathbb{P}(\{(1, 2), (2, 1)\})$	$\frac{2}{36}$
$\mathbb{P}_\xi(\{4\})$	$\mathbb{P}(\xi^{-1}(\{4\}))$	$\mathbb{P}(\{(1, 3), (3, 1), (2, 2)\})$	$\frac{3}{36}$
$\mathbb{P}_\xi(\{5\})$	$\mathbb{P}(\xi^{-1}(\{5\}))$	$\mathbb{P}(\{(1, 4), (4, 1), (2, 3), (3, 2)\})$	$\frac{4}{36}$
$\mathbb{P}_\xi(\{6\})$	$\mathbb{P}(\xi^{-1}(\{6\}))$	$\mathbb{P}(\{(1, 5), (5, 1), (2, 4), (4, 2), (3, 3)\})$	$\frac{5}{36}$
$\mathbb{P}_\xi(\{7\})$	$\mathbb{P}(\xi^{-1}(\{7\}))$	$\mathbb{P}(\{(1, 6), (6, 1), (2, 5), (5, 2), (3, 4), (4, 3)\})$	$\frac{6}{36}$
$\mathbb{P}_\xi(\{8\})$	$\mathbb{P}(\xi^{-1}(\{8\}))$	$\mathbb{P}(\{(2, 6), (6, 2), (3, 5), (5, 3), (4, 4)\})$	$\frac{5}{36}$
$\mathbb{P}_\xi(\{9\})$	$\mathbb{P}(\xi^{-1}(\{9\}))$	$\mathbb{P}(\{(3, 6), (6, 3), (4, 5), (5, 4)\})$	$\frac{4}{36}$
$\mathbb{P}_\xi(\{10\})$	$\mathbb{P}(\xi^{-1}(\{10\}))$	$\mathbb{P}(\{(4, 6), (6, 4), (5, 5)\})$	$\frac{3}{36}$
$\mathbb{P}_\xi(\{11\})$	$\mathbb{P}(\xi^{-1}(\{11\}))$	$\mathbb{P}(\{(5, 6), (6, 5)\})$	$\frac{2}{36}$
$\mathbb{P}_\xi(\{12\})$	$\mathbb{P}(\xi^{-1}(\{12\}))$	$\mathbb{P}(\{(6, 6)\})$	$\frac{1}{36}$

Die Wahrscheinlichkeiten der Elementarereignisse in $\mathcal{S}$ wiederum erlauben das Berechnen beliebiger Ereigniswahrscheinlichkeiten hinsichtlich der Würfelaugennummernsumme (vgl. Kapitel 2.2). Insgesamt haben wir basierend auf $(\Omega, \mathcal{A}, \mathbb{P})$ und ξ also ein weiteres Wahrscheinlichkeitsraummodell $(\mathcal{X}, \mathcal{S}, \mathbb{P}_\xi)$ konstruiert.

Folgender **R** Code demonstriert, wie mithilfe der computerbasierten Erzeugung zufälliger Ergebnisse die Konstruktion des hier betrachteten Beispiels für einen Durchgang eines Zufallsvorgangs simuliert werden kann.

```
# Wahrscheinlichkeitsraummodellformulierung
Omega = list()
idx = 1
for(r in 1:6){
  for(b in 1:6){
    Omega[[idx]] = c(r,b)
    idx = idx + 1
  }
}
K = length(Omega)
pi = rep(1/K, 1, K)

# Ergebnisrauminitialisierung
# Ergebnisindexinitialisierung
# Ergebnisse roter Würfel
# Ergebnisse blauer Würfel
# \omega \in \Omega
# Ergebnisindexupdate
# Kardinalität von \Omega
# Wahrscheinlichkeitsfunktion \pi

# Durchgang des Zufallsvorgangs
omega = Omega[[which(rmultinom(1, 1, pi) == 1)]] # Auswahl von \omega anhand \mathbb{P}(\{\omega\})

# Realisierung der Zufallsvariable
xi_omega = sum(omega) # \xi(\omega)
```

```
omega : 6 1
xi(omega) : 7
```

Im Kontext des Vermessens zufällig ausgewählter experimenteller Einheiten dienen Zufallsvariablen oft als Modelle für Messvorgänge. Betrachten wie beispielsweise die Bestimmung des Wertes eines psychologischen Fragebogens (BDI-II) an zufällig ausgewählten Proband:innen (Abbildung 4.2), so ergibt sich folgende Interpretation: Der Ergebnisraum des zugrundeliegenden Wahrscheinlichkeitsraums (Ω) soll die Gesamtheit aller infrage kommender Proband:innen darstellen und die Auswahl einer Proband:in aus diesem Raum die Auswahl eines Ergebnisses ω , welche mit Wahrscheinlichkeit $\mathbb{P}(\{\omega\})$ geschehen soll.

Wird nun eine bestimmte Eigenschaft dieser Proband:in in idealisierter Weise gemessen, so handelt es sich dabei um eine deterministische Abbildung auf einen dieser Proband:in zugeordneten Messwert $\xi(\omega)$ im Raum der Messwerte $\mathcal{X}$. Die Messwerte selbst unterliegen dann einer Wahrscheinlichkeitsverteilung, die durch die zugrundeliegende Verteilung und die Art des Messvorgangs bestimmt wird.




Abbildung 4.2 Zufallsvariable als Modell eines Messvorgangs.

△

Notation

Die Konventionen zur Notation der mit Zufallsvariablen assoziierten Wahrscheinlichkeiten und Verteilungen sind etwas gewöhnungsbedürftig, sodass wir sie in folgender Definition festhalten wollen.

Definition 4.3 (Notation für Zufallsvariablen). Es seien $(\Omega, \mathcal{A}, \mathbb{P})$ und $(\mathcal{X}, \mathcal{S}, \mathbb{P}_\xi)$ Wahrscheinlichkeitsräume und $\xi : \Omega \rightarrow \mathcal{X}$ sei eine Zufallsvariable. Dann gelten mit $S \in \mathcal{S}$

und $x \in \mathcal{X}$ folgende Notationskonventionen für Ereignisse in $\mathcal{A}$:

$$\begin{aligned}\{\xi \in S\} &:= \{\omega \in \Omega \mid \xi(\omega) \in S\} \\ \{\xi = x\} &:= \{\omega \in \Omega \mid \xi(\omega) = x\} \\ \{\xi \leq x\} &:= \{\omega \in \Omega \mid \xi(\omega) \leq x\} \\ \{\xi < x\} &:= \{\omega \in \Omega \mid \xi(\omega) < x\} \\ \{\xi \geq x\} &:= \{\omega \in \Omega \mid \xi(\omega) \geq x\} \\ \{\xi > x\} &:= \{\omega \in \Omega \mid \xi(\omega) > x\}\end{aligned}$$

Aus diesen Konventionen ergeben sich folgende Konventionen für Wahrscheinlichkeiten von Verteilungen

$$\begin{aligned}\mathbb{P}_\xi(\xi \in S) &= \mathbb{P}(\{\xi \in S\}) = \mathbb{P}(\{\omega \in \Omega \mid \xi(\omega) \in S\}) \\ \mathbb{P}_\xi(\xi = x) &= \mathbb{P}(\{\xi = x\}) = \mathbb{P}(\{\omega \in \Omega \mid \xi(\omega) = x\}) \\ \mathbb{P}_\xi(\xi \leq x) &= \mathbb{P}(\{\xi \leq x\}) = \mathbb{P}(\{\omega \in \Omega \mid \xi(\omega) \leq x\}) \\ \mathbb{P}_\xi(\xi < x) &= \mathbb{P}(\{\xi < x\}) = \mathbb{P}(\{\omega \in \Omega \mid \xi(\omega) < x\}) \\ \mathbb{P}_\xi(\xi \geq x) &= \mathbb{P}(\{\xi \geq x\}) = \mathbb{P}(\{\omega \in \Omega \mid \xi(\omega) \geq x\}) \\ \mathbb{P}_\xi(\xi > x) &= \mathbb{P}(\{\xi > x\}) = \mathbb{P}(\{\omega \in \Omega \mid \xi(\omega) > x\}).\end{aligned}$$

Oft wird zudem auf das Subskript bei Verteilungssymbolen verzichtet und zum Beispiel $\mathbb{P}_\xi(\xi \in S)$ nur als $\mathbb{P}(\xi \in S)$ geschrieben, solange sich aus dem Kontext keine Verwechslungsmöglichkeit der beiden Wahrscheinlichkeitsmaße ergeben kann.

•

Der Verzicht auf die explizite Bezeichnung von Funktionen eindeutig bestimmter Zufallsvariablen, wie er in Definition 4.3 bezüglich $\mathbb{P}_\xi$ und $\mathbb{P}$ angerissen wird, ist ein grundlegendes Phänomen moderner, anwendungsorientierter Wahrscheinlichkeitstheorie. Speziell werden in den meisten Fällen Funktionen von Zufallsvariablen mithilfe ihrer Argumente identifiziert. So sollte der verständigen Leser:in anhand von “ $\mathbb{P}(\xi \in S)$ ” klar sein, dass es bei $\mathbb{P}$ um das Bildmaß der Zufallsvariable ξ geht, bei “ $\mathbb{P}(\{\omega \in \Omega \mid \xi(\omega) \in S\})$ ” dagegen um das Wahrscheinlichkeitsmaß auf dem Messraum $(\Omega, \mathcal{A})$. Die Identifikation von Funktionen anhand ihrer Argumente, die insbesondere auch bei den in folgenden Abschnitten diskutierten *Wahrscheinlichkeitsmassefunktionen*, *Wahrscheinlichkeitsdichtefunktionen* und *kumulativen Verteilungsfunktionen* zum Tragen kommt, bezeichnet man in der informatischen Anwendung auch als *Multimethode* (*multiple dispatch*).

Zum Abschluss dieses Abschnittes halten wir in Theorem 4.1 fest, dass arithmetische Operationen mit reellwertigen Zufallsvariablen wiederum auf reellwertige Zufallsvariablen führen.

Theorem 4.1 (Arithmetik reeller Zufallsvariablen). *$(\Omega, \mathcal{A}, \mathbb{P})$ sei ein Wahrscheinlichkeitsraum, $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ sei der reelle Messraum, $\xi_1 : \Omega \rightarrow \mathbb{R}$ und $\xi_2 : \Omega \rightarrow \mathbb{R}$ seien reellwertige Zufallsvariablen und $c \in \mathbb{R}$ sei eine Konstante. Weiterhin seien*

$$\begin{aligned}\xi_1 + c : \Omega &\rightarrow \mathbb{R}, \omega \mapsto (\xi_1 + c)(\omega) := \xi_1(\omega) + c \text{ für } c \in \mathbb{R} \\ c\xi_1 : \Omega &\rightarrow \mathbb{R}, \omega \mapsto (c\xi_1)(\omega) := c\xi_1(\omega) \text{ für } c \in \mathbb{R} \\ \xi_1 + \xi_2 : \Omega &\rightarrow \mathbb{R}, \omega \mapsto (\xi_1 + \xi_2)(\omega) := \xi_1(\omega) + \xi_2(\omega) \\ \xi_1\xi_2 : \Omega &\rightarrow \mathbb{R}, \omega \mapsto (\xi_1\xi_2)(\omega) := \xi_1(\omega)\xi_2(\omega)\end{aligned}\tag{4.6}$$

die Addition einer Konstante zu einer reellwertigen Zufallsvariable, die Multiplikation einer reellwertigen Zufallsvariable mit einer Konstante, die Addition zweier reellwertiger Zufallsvariablen und die Multiplikation zweier reellwertigen Zufallsvariablen, respektive. Dann sind auch $\xi_1 + c$, $c\xi_1$, $\xi_1 + \xi_2$ und $\xi_1\xi_2$ reellwertige Zufallsvariablen.

◦

Für einen Beweis dieses Theorems verweisen wir auf die weiterführende Literatur, beispielsweise Hesse (2009). Intuitiv besagt Theorem 4.1, dass die Addition einer zufälligen Größe zu einer konstanten Größe, die Multiplikation einer zufälligen Größe mit einer Konstante, die Addition zweier zufälliger Größen und die Multiplikation zweier zufälliger Größen immer wieder zufällige Größen mit ihren dann eigenen Verteilungen ergeben.

4.2 Wahrscheinlichkeitsmassefunktionen

In diesem Abschnitt führen wir mit den *Wahrscheinlichkeitsmassefunktionen* (WMFen) ein Hilfsmittel ein, um Verteilungen von Zufallsvariablen mit *diskretem* (genauer *endlichem* oder *abzählbarem*) Ergebnisraum zu definieren. Wir illustrieren den Begriff anhand dreier wichtiger Beispiele, den Bernoulli- und Binomialzufallsvariablen sowie den diskret-gleichverteilten Zufallsvariablen. Wir definieren zunächst den Begriff der WMF wie folgt.

Definition 4.4 (Diskrete Zufallsvariable und Wahrscheinlichkeitsmassefunktion). Eine Zufallsvariable ξ heißt *diskret*, wenn ihr Ergebnisraum $\mathcal{X}$ endlich oder abzählbar ist und eine Funktion der Form

$$p : \mathcal{X} \rightarrow \mathbb{R}_{\geq 0}, x \mapsto p(x) \quad (4.7)$$

existiert, für die gilt

- (1) $\sum_{x \in \mathcal{X}} p(x) = 1$
- (2) $\mathbb{P}(\xi = x) = p(x)$ für alle $x \in \mathcal{X}$.

Eine entsprechende Funktion p heißt *Wahrscheinlichkeitsmassefunktion* (WMF) von ξ .

•

Wir erinnern daran, dass eine Menge *abzählbar* heißt, wenn sie bijektiv auf $\mathbb{N}$ abgebildet werden kann. Im Deutschen nennt man WMFen auch *Zähldichten*. Im Englischen nennt man WMFen *probability mass functions* (PMFs), an diesem Begriff orientieren wir uns hier. Ohne Beweis halten wir fest, dass jede Funktion $p : \mathcal{X} \rightarrow \mathbb{R}_{\geq 0}$, die die Normiertheitseigenschaft $\sum_{x \in \mathcal{X}} p(x) = 1$ besitzt als WMF einer Zufallsvariable interpretiert werden kann.

Beispiele

Wir wollen mit den *Bernoulli-Zufallsvariablen*, den *Binomial-Zufallsvariablen* und den *diskret-gleichverteilten Zufallsvariablen* drei erste Beispiele für die Definition von Verteilungen mithilfe von WMFen betrachten.

Definition 4.5 (Bernoulli-Zufallsvariable). Es sei ξ eine Zufallsvariable mit Ergebnisraum $\mathcal{X} = \{0, 1\}$ und WMF

$$p : \mathcal{X} \rightarrow [0, 1], x \mapsto p(x) := \mu^x(1 - \mu)^{1-x} \text{ mit } \mu \in [0, 1]. \quad (4.8)$$

Dann sagen wir, dass ξ einer *Bernoulli-Verteilung mit Parameter* $\mu \in [0, 1]$ unterliegt und nennen ξ eine *Bernoulli-Zufallsvariable*. Wir kürzen dies mit $\xi \sim \text{Bern}(\mu)$ ab. Die WMF einer Bernoulli-Zufallsvariable bezeichnen wir mit

$$\text{Bern}(x; \mu) := \mu^x(1 - \mu)^{1-x}. \quad (4.9)$$

•

Bernoulli-Zufallsvariablen können immer dann zur probabilistischen Modellierung genutzt werden, wenn das betrachtete Phänomen binär ist und die möglichen Werte der Zufallsvariable bijektiv auf $\{0, 1\}$ abgebildet werden können. Man beachte, dass die funktionale Form der Bernoulli-Zufallsvariable $\text{Bern}(x; \mu)$ nur für $x \in \{0, 1\}$ Sinn ergibt und nicht etwa für $x \in \{H, T\}$. Bildet man aber die möglichen Ergebnisse eines Münzwurfs auf $\{0, 1\}$ ab, also definiert etwa $0 := H$ und $1 := T$, so kann eine Bernoulli-Zufallsvariable durchaus als Modell eines Münzwurfs dienen.

Der Parameter $\mu \in [0, 1]$ einer Bernoulli-Zufallsvariable ist die Wahrscheinlichkeit dafür, dass die Zufallsvariable ξ den Wert 1 annimmt, dies erkennt man anhand von

$$\mathbb{P}(\xi = 1) = p(1) = \mu^1(1 - \mu)^{1-1} = \mu. \quad (4.10)$$

Wir visualisieren die WMFen von Bernoulli-Zufallsvariablen für $\mu := 0.1$, $\mu := 0.5$ und $\mu := 0.7$ in Abbildung 4.3.




Abbildung 4.3 WMFen von Bernoulli-Zufallsvariablen.

Definition 4.6 (Binomialzufallsvariable). Es sei ξ eine Zufallsvariable mit Ergebnisraum $\mathcal{X} := \mathbb{N}_n^0$ und WMF

$$p : \mathcal{X} \rightarrow [0, 1], x \mapsto p(x) := \binom{n}{x} \mu^x (1 - \mu)^{n-x} \text{ für } \mu \in [0, 1]. \quad (4.11)$$

Dann sagen wir, dass ξ einer *Binomialverteilung mit Parametern* $n \in \mathbb{N}$ und $\mu \in [0, 1]$ unterliegt und nennen ξ eine *Binomial-Zufallsvariable*. Wir kürzen dies mit $\xi \sim \text{Bin}(n, \mu)$ ab. Die WMF einer Binomial-Zufallsvariable bezeichnen wir mit

$$\text{Bin}(x; n, \mu) := \binom{n}{x} \mu^x (1 - \mu)^{n-x}. \quad (4.12)$$

•

Ohne Beweis halten wir fest, dass eine Binomial-Zufallsvariable als Modell der Summe von n unabhängig und identisch verteilten Bernoulli-Zufallsvariablen genutzt werden kann. Insbesondere gilt also $\text{Bin}(x; 1, \mu) = \text{Bern}(x; \mu)$. Binomial-Zufallsvariablen haben die Eigenschaft, dass mit n einer ihrer Parameter nicht nur die funktionale Form ihrer WMF, sondern auch ihren Ergebnisraum $\mathcal{X}$ festlegt. Wir visualisieren die WMFen von Binomial-Zufallsvariablen für $(n, \mu) := (5, 0.1)$, $(n, \mu) := (10, 0.5)$ und $(n, \mu) := (15, 0.7)$ in Abbildung 4.4.




Abbildung 4.4 WMFen von Binomial-Zufallsvariablen.

Definition 4.7 (Diskret-gleichverteilte Zufallsvariable). Es sei ξ eine diskrete Zufallsvariable mit endlichem Ergebnisraum $\mathcal{X}$ und WMF

$$p : \mathcal{X} \rightarrow \mathbb{R}_{\geq 0}, x \mapsto p(x) := \frac{1}{|\mathcal{X}|}. \quad (4.13)$$

Dann sagen wir, dass ξ einer *diskreten Gleichverteilung* unterliegt und nennen ξ eine *diskret-gleichverteilte Zufallsvariable*. Wir kürzen dies mit $\xi \sim U(|\mathcal{X}|)$ ab. Die WMF einer diskret-gleichverteilten Zufallsvariable bezeichnen wir mit

$$U(x; |\mathcal{X}|) := \frac{1}{|\mathcal{X}|}. \quad (4.14)$$

•

Diskrete-gleichverteilte Zufallsvariable können offenbar immer dann zur probabilistischen Modellierung genutzt werden, wenn die möglichen diskreten Ergebnisse des modellierten Phänomens die gleiche Wahrscheinlichkeit haben. Im Fall der diskret-gleichverteilten Zufallsvariablen braucht es zur Definition ihrer funktionalen Form nach Festlegung des Ergebnisraums keinen weiteren Parameter. Offenbar gilt für $\mathcal{X} := \{0, 1\}$

$$U(x; |\mathcal{X}|) = \text{Bern}(x; 0.5) = \text{Bin}(x; 1, 0.5). \quad (4.15)$$

Wir visualisieren die WMFen von diskret-gleichverteilten Zufallsvariablen für $\mathcal{X} := \{0, 1\}$, $\mathcal{X} := \{-3, -2, -1, 0, 1\}$ und $\mathcal{X} := \{-4, -3, -2, -1, 0, 1, 2, 3, 4\}$ in Abbildung 4.5. Man beachte, dass Definition 4.7 formal die Sequentialität der Elemente von $\mathcal{X}$ nicht erfordert, man kann also genauso eine diskret-gleichverteilte Zufallsvariable mit Ergebnisraum $\mathcal{X} := \{1, 5, 7\}$ oder auch nicht numerischen Ergebnisraum $\mathcal{X} := \{a, b, x, y\}$ definieren.




Abbildung 4.5 WMFen von diskret-gleichverteilten Zufallsvariablen.

4.3 Wahrscheinlichkeitsdichtefunktionen

In diesem Abschnitt führen wir mit den *Wahrscheinlichkeitsdichtefunktionen* (WDFen) ein Hilfsmittel ein, um Verteilungen von Zufallsvariablen mit *kontinuierlichem* (genauer *überabzählbarem*) Ergebnisraum zu definieren. Wir illustrieren den Begriff zunächst an der grundlegendsten aller Zufallsvariablen, der normalverteilten Zufallsvariable. Mit der Gamma-Zufallsvariable, der Beta-Zufallsvariable und der gleichverteilten Zufallsvariable wollen wir dann noch drei Beispiele von Zufallsvariablen betrachten, die sowohl in der Modellformulierung der Frequentistischen als auch der Bayesianischen Inferenz an vielen Stellen eingesetzt werden. Wir definieren den Begriff der WDF wie folgt.

Definition 4.8 (Kontinuierliche Zufallsvariable und Wahrscheinlichkeitsdichtefunktion). Eine Zufallsvariable ξ heißt *kontinuierlich*, wenn $\mathbb{R}$ der Ergebnisraum von ξ ist und eine Funktion

$$p : \mathbb{R} \rightarrow \mathbb{R}_{\geq 0}, x \mapsto p(x) \quad (4.16)$$

existiert, für die gilt

$$(1) \int_{-\infty}^{\infty} p(x) dx = 1 \text{ und}$$

$$(2) \quad \mathbb{P}(\xi \in [a, b]) = \int_a^b p(x) dx \text{ für alle } a, b \in \mathbb{R} \text{ mit } a \leq b.$$

Eine entsprechende Funktion p heißt *Wahrscheinlichkeitsdichtefunktion (WDF)* von ξ .

•

Im Englischen nennt man WDFen *probability density functions (PDFs)*. Ohne Beweis halten wir fest, dass jede Funktion $p : \mathbb{R} \rightarrow \mathbb{R}_{\geq 0}$, für deren uneigentliches Integral $\int_{-\infty}^{\infty} p(x) dx = 1$ gilt, die also normiert ist, als WDF einer Zufallsvariable interpretiert werden kann.

Im Umgang mit WDFen und in Abgrenzung zu WMFen sollte man sich die *Dichteigenschaft* einer WDF immer bewusst machen: Die Werte einer WDF stellen keine Wahrscheinlichkeiten, sondern Wahrscheinlichkeitsdichten dar, Wahrscheinlichkeiten werden aus WDFen anhand von Definition 4.8 (2) durch Integration berechnet. Wie im physikalischen Sinn ergibt sich die einem reellen Intervall zugeordnete Wahrscheinlichkeitsmasse also erst durch “Multiplikation” mit dem entsprechenden “Intervallvolumen”. Man denke hierzu auch an die Approximation des bestimmten Integrals $\int_a^b p(x) dx$ durch einen Riemannschen Summenterm (vgl. [Riemannsche Summen \(PDWP\)](#)). Intuitiv gilt also

$$(\text{Wahrscheinlichkeits})\text{Masse} = (\text{Wahrscheinlichkeits})\text{Dichte} \cdot (\text{Mengen})\text{Volumen}, \quad (4.17)$$

wobei sich das Volumen im Sinne des Lebesgue-Maßes auf die Breite des Intervalls $[a, b]$ bezieht. Wie in der physikalischen Analogie ist die Wahrscheinlichkeitsmasse eines Intervalls ohne Volumen gleich null,

$$\mathbb{P}(\xi = a) = \int_a^a p(x) dx = 0. \quad (4.18)$$

Ferner gilt, dass bei entsprechend kleinen Intervallen WDFen auch Werte größer als 1 annehmen können, auch wenn dies für die Wahrscheinlichkeit, die sich dann durch entsprechende Integration ergibt, nicht der Fall sein kann. Schließlich sei trotz dieser technischen Feinheiten folgende Intuition betont: Betrachtet man die grafische Darstellung der WDF einer Zufallsvariable und stellt sich eine Zerlegung von $\mathbb{R}$ in gleich große Intervalle vor, so besitzt die Zufallsvariable natürlich eine höhere Wahrscheinlichkeit dafür, Werte in einem Intervall mit assoziierter höherer Wahrscheinlichkeitsdichte anzunehmen als Werte in einem Intervall mit assoziierter relativ niedrigerer Wahrscheinlichkeitsdichte.

Normalverteilte Zufallsvariablen

Mit der normalverteilten Zufallsvariable wollen wir als erstes Beispiel für die Definition einer kontinuierlichen Zufallsvariable mithilfe einer WDF nun die wichtigste Zufallsvariable der probabilistischen Modellbildung einführen.

Definition 4.9 (Normalverteilte Zufallsvariable). Es sei ξ eine Zufallsvariable mit Ergebnisraum $\mathbb{R}$ und WDF

$$p : \mathbb{R} \rightarrow \mathbb{R}_{>0}, x \mapsto p(x) := \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2\sigma^2}(x - \mu)^2\right). \quad (4.19)$$

Dann sagen wir, dass ξ einer *Normalverteilung mit Parametern* $\mu \in \mathbb{R}$ und $\sigma^2 > 0$ unterliegt und nennen ξ eine *normalverteilte Zufallsvariable*. Wir kürzen dies mit $\xi \sim N(\mu, \sigma^2)$ ab. Die WDF einer normalverteilten Zufallsvariable bezeichnen wir mit

$$N(x; \mu, \sigma^2) := \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2\sigma^2}(x - \mu)^2\right). \quad (4.20)$$

Eine normalverteilte Zufallsvariable mit $\mu = 0$ und $\sigma^2 = 1$ nennt man eine *standardnormalverteilte Zufallsvariable*

•

Wir visualisieren die WDFen von normalverteilten Zufallsvariablen für $(\mu, \sigma^2) := (0, 1)$, $(\mu, \sigma^2) := (-2.5, 10)$ und $(\mu, \sigma^2) := (3, 0.5)$ in Abbildung 4.6. Man macht sich an dieser Abbildung grafisch klar, dass die WDFen von normalverteilten Zufallsvariablen immer genau einen Wert höchster Wahrscheinlichkeitsdichte besitzen - und zwar an der Stelle des Parameters $\mu \in \mathbb{R}$. Dies ergibt sich durch die Tatsache, dass das Argument der Exponentialfunktion in der funktionalen Form von $N(x; \mu, \sigma^2)$ aufgrund des negativen Vorzeichens des Quadrates von $x - \mu$ und der Positivität von σ^2 immer nicht-positiv ist und die Exponentialfunktion auf den nicht-positiven reellen Zahlen ihr Maximum bei $x = \mu$, also $x - \mu = 0$ annimmt. Weiterhin macht man sich grafisch klar, dass der Parameter $\sigma^2 > 0$ die Breite der WDF einer normalverteilten Zufallsvariable enkodiert.




Abbildung 4.6 WDFen von normalverteilten Zufallsvariablen.

Weitere Beispiele

Wir wollen mit den *Gamma-Zufallsvariablen*, den *Beta-Zufallsvariablen* und den *gleichverteilten Zufallsvariablen* drei weitere Beispiele für die Definition von Verteilungen mithilfe von WDFen betrachten.

Definition 4.10 (Gamma-Zufallsvariable). Es sei ξ eine Zufallsvariable mit Ergebnisraum $\mathcal{X} := \mathbb{R}_{>0}$ und WDF

$$p : \mathbb{R}_{>0} \rightarrow \mathbb{R}_{>0}, x \mapsto p(x) := \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} \exp\left(-\frac{x}{\beta}\right), \quad (4.21)$$

wobei Γ die Gammafunktion bezeichne. Dann sagen wir, dass ξ einer *Gammaverteilung* mit *Formparameter* $\alpha > 0$ und *Skalenparameter* $\beta > 0$ unterliegt und nennen ξ eine *gammaverteilte Zufallsvariable*. Wir kürzen dies mit $\xi \sim G(\alpha, \beta)$ ab. Die WDF einer gammaverteilten Zufallsvariable bezeichnen wir mit

$$G(x; \alpha, \beta) := \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} \exp\left(-\frac{x}{\beta}\right). \quad (4.22)$$

•

Die spezielle Gamma-Zufallsvariable mit WDF $G(x; \frac{n}{2}, 2)$ wird *Chi-Quadrat* (χ^2) *Verteilung mit n Freiheitsgraden* genannt. Wir visualisieren die WDFen von Gamma-Zufallsvariablen für $(\alpha, \beta) := (1, 1)$, $(\alpha, \beta) := (2, 2)$ und $(\alpha, \beta) := (5, 1)$ in Abbildung 4.7.




Abbildung 4.7 WDFen von Gamma-Zufallsvariablen.

Definition 4.11 (Beta-Zufallsvariable). Es sei ξ eine Zufallsvariable mit Ergebnisraum $\mathcal{X} := [0, 1]$ und WDF

$$p : \mathcal{X} \rightarrow [0, 1], x \mapsto p(x) := \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} x^{\alpha-1} (1-x)^{\beta-1} \text{ mit } \alpha, \beta \in \mathbb{R}_{>0}, \quad (4.23)$$

wobei Γ die Gammafunktion bezeichne. Dann sagen wir, dass ξ einer *Beta-Verteilung* mit Parametern $\alpha > 0$ und $\beta > 0$ unterliegt, und nennen ξ eine *Beta-Zufallsvariable*. Wir kürzen dies mit $\xi \sim \text{Beta}(\alpha, \beta)$ ab. Die WDF einer Beta-Zufallsvariable bezeichnen wir mit

$$\text{Beta}(x; \alpha, \beta) := \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} x^{\alpha-1} (1-x)^{\beta-1}. \quad (4.24)$$

•

Dadurch, dass der Ergebnisraum einer Beta-Zufallsvariable auf das Intervall $\mathcal{X} := [0, 1]$ (für $\alpha < 1, \beta < 1$ genauer $\mathcal{X} :=]0, 1[$) beschränkt ist, bietet sich eine Beta-Zufallsvariable unter anderem dafür an, Wahrscheinlichkeiten von Wahrscheinlichkeiten (also Werten zwischen 0 und 1) zu beschreiben. Wir visualisieren die WDFen von Beta-Zufallsvariablen für $(\alpha, \beta) := (1, 1)$, $(\alpha, \beta) := (3, 2)$ und $(\alpha, \beta) := (10, 5)$ in Abbildung 4.8.

Mit den gleichverteilten Zufallsvariablen betrachten wir abschließend noch das Analogon zu diskret-gleichverteilten Zufallsvariablen für den Fall kontinuierlicher Zufallsvariablen.




Abbildung 4.8 WDFen von Beta-Zufallsvariablen.

Definition 4.12 (Gleichverteilte Zufallsvariable). Es sei ξ eine kontinuierliche Zufallsvariable mit Ergebnisraum $\mathbb{R}$ und WDF

$$p : \mathbb{R} \rightarrow \mathbb{R}_{\geq 0}, x \mapsto p(x) := \begin{cases} \frac{1}{b-a} & x \in [a, b] \\ 0 & x \notin [a, b] \end{cases}. \quad (4.25)$$

Dann sagen wir, dass ξ einer *Gleichverteilung mit Parametern a und b* unterliegt und nennen ξ eine *gleichverteilte Zufallsvariable*. Wir kürzen dies mit $\xi \sim U(a, b)$ ab. Die WDF einer gleichverteilten Zufallsvariablen bezeichnen wir mit

$$U(x; a, b) := \frac{1}{b-a}. \quad (4.26)$$

•

Wir visualisieren die WDFen von gleichverteilten Zufallsvariablen für $(a, b) := (0, 1)$, $(a, b) := (-3, 1)$ und $(a, b) := (-4, 4)$ in Abbildung 4.9.




Abbildung 4.9 WDFen von gleichverteilten-Zufallsvariablen.

4.4 Kumulative Verteilungsfunktionen

Im letzten Abschnitt dieses Kapitels wollen wir mit den *kumulativen Verteilungsfunktionen* (KVFen) eine weitere Möglichkeit einführen, die Verteilungen von diskreten oder kontinuierlichen Zufallsvariablen festzulegen. Es ist allgemein allerdings eher üblich, dies mithilfe von WMFen oder WDFen zu tun. Trotzdem sind KVFen an vielen Stellen nützlich, da sie sowohl für diskrete als auch kontinuierliche Zufallsvariablen einen direkten Zusammenhang zwischen Werten der Zufallsvariable und bestimmten Wahrscheinlichkeiten herstellen, der in der Anwendung ohne Summation oder Integration auskommt. Wir betrachten zunächst die allgemeine Definition von KVFen für sowohl diskrete als auch kontinuierliche Zufallsvariablen und wenden uns dann den KVFen von diskreten und den KVFen von kontinuierlichen Zufallsvariablen im Einzelnen zu. Für eine beliebige Zufallsvariable definieren wir den Begriff der KVF wie folgt.

Definition 4.13 (Kumulative Verteilungsfunktion). Die *kumulative Verteilungsfunktion* (KVF) einer Zufallsvariable ξ ist definiert als

$$P : \mathbb{R} \rightarrow [0, 1], x \mapsto P(x) := \mathbb{P}(\xi \leq x). \quad (4.27)$$

•

Man beachte, dass $P(x)$ für jedes $x \in \mathbb{R}$ definiert ist, auch wenn für ein gegebenes $x \in \mathbb{R}$ gilt, dass $x \notin \mathcal{X}$. Mithilfe von KVFen können zum Beispiel *Überschreitungswahrscheinlichkeiten* und *Intervallwahrscheinlichkeiten* von Zufallsvariablen direkt ausgewertet werden. Dies ist der Inhalt folgender Theoreme.

Theorem 4.2 (Überschreitungswahrscheinlichkeit). *Es sei ξ eine Zufallsvariable mit Ergebnisraum $\mathcal{X}$ und P ihre kumulative Verteilungsfunktion. Dann gilt für die Überschreitungswahrscheinlichkeit $\mathbb{P}(\xi > x)$, dass*

$$\mathbb{P}(\xi > x) = 1 - P(x) \text{ für alle } x \in \mathcal{X}. \quad (4.28)$$

◦

Beweis. Die Ereignisse $\{\xi > x\}$ und $\{\xi \leq x\}$ sind disjunkt und

$$\Omega = \{\omega \in \Omega | \xi(\omega) > x\} \cup \{\omega \in \Omega | \xi(\omega) \leq x\} = \{\xi > x\} \cup \{\xi \leq x\}. \quad (4.29)$$

Mit der σ -Additivität von $\mathbb{P}$ folgt dann

$$\begin{aligned} \mathbb{P}(\Omega) &= 1 \\ \Leftrightarrow \mathbb{P}(\{\xi > x\} \cup \{\xi \leq x\}) &= 1 \\ \Leftrightarrow \mathbb{P}(\{\xi > x\}) + \mathbb{P}(\{\xi \leq x\}) &= 1 \\ \Leftrightarrow \mathbb{P}(\{\xi > x\}) &= 1 - \mathbb{P}(\{\xi \leq x\}) \\ \Leftrightarrow \mathbb{P}(\{\xi > x\}) &= 1 - P(x). \end{aligned} \quad (4.30)$$

□

Theorem 4.3 (Intervallwahrscheinlichkeiten). *Es sei ξ eine Zufallsvariable mit Ergebnisraum $\mathcal{X}$ und P ihre KVF. Dann gilt für die Intervallwahrscheinlichkeit $\mathbb{P}(\xi \in]x_1, x_2])$, dass*

$$\mathbb{P}(\xi \in]x_1, x_2]) = P(x_2) - P(x_1) \text{ für alle } x_1, x_2 \in \mathcal{X} \text{ mit } x_1 < x_2. \quad (4.31)$$

◦

Beweis. Wir betrachten die Ereignisse $\{\xi \leq x_1\}$, $\{x_1 < \xi \leq x_2\}$ und $\{\xi \leq x_2\}$, wobei

$$\{\xi \leq x_1\} \cap \{x_1 < \xi \leq x_2\} = \emptyset \text{ und } \{\xi \leq x_1\} \cup \{x_1 < \xi \leq x_2\} = \{\xi \leq x_2\}. \quad (4.32)$$

gelten. Mit der σ -Additivität von $\mathbb{P}$ gilt dann

$$\begin{aligned} \mathbb{P}(\{\xi \leq x_1\} \cup \{x_1 < \xi \leq x_2\}) &= \mathbb{P}(\{\xi \leq x_2\}) \\ \Leftrightarrow \mathbb{P}(\{\xi \leq x_1\}) + \mathbb{P}(\{x_1 < \xi \leq x_2\}) &= \mathbb{P}(\{\xi \leq x_2\}) \\ \Leftrightarrow \mathbb{P}(\{x_1 < \xi \leq x_2\}) &= \mathbb{P}(\{\xi \leq x_2\}) - \mathbb{P}(\{\xi \leq x_1\}) \\ \Leftrightarrow \mathbb{P}(\{x_1 < \xi \leq x_2\}) &= P(x_2) - P(x_1) \\ \Leftrightarrow \mathbb{P}(\xi \in]x_1, x_2]) &= P(x_2) - P(x_1). \end{aligned} \quad (4.33)$$

□

Folgendes Theorem gibt drei zentrale Eigenschaften von KVFe an. Dabei besagt die dritte Eigenschaft, dass eine KVF keine Sprünge hat, wenn man sich Grenzpunkten von rechts nähert. Tatsächlich sind die diskutierten Eigenschaften auch gerade die definierenden Eigenschaften von KVFe, das heißt, jede Funktion P , die die Eigenschaften von Theorem 4.4 erfüllt, kann als eine KVF einer Zufallsvariablen interpretiert werden. Für einen Beweis dieser Tatsache verweisen wir auf die weiterführende Literatur.

Theorem 4.4 (Eigenschaften von kumulative Verteilungsfunktionen). *Es sei ξ eine Zufallsvariable und P ihre kumulative Verteilungsfunktion. Dann hat P die folgenden Eigenschaften*

- (1) P ist monoton steigend, das heißt, wenn $x_1 < x_2$, dann gilt $P(x_1) \leq P(x_2)$.
- (2) $\lim_{x \rightarrow -\infty} P(x) = 0$ und $\lim_{x \rightarrow \infty} P(x) = 1$.
- (3) P ist rechtsseitig stetig, d.h., $P(x) = \lim_{y \rightarrow x, y > x} P(y)$ für alle $x \in \mathbb{R}$

◦

Beweis. Wir betrachten die Eigenschaften nacheinander.

- (1) Wir halten zunächst fest, dass für Ereignisse $A \subset B$ gilt, dass $\mathbb{P}(A) \leq \mathbb{P}(B)$. Wir halten dann fest, dass für $x_1 < x_2$,

$$\{\xi \leq x_1\} = \{\omega \in \Omega \mid \xi(\omega) \leq x_1\} \subset \{\omega \in \Omega \mid \xi(\omega) \leq x_2\} = \{\xi \leq x_2\}. \quad (4.34)$$

Also gilt

$$\mathbb{P}(\{\xi \leq x_1\}) \leq \mathbb{P}(\{\xi \leq x_2\}) \Rightarrow P(x_1) \leq P(x_2). \quad (4.35)$$

- (2) Für einen Beweis verweisen wir auf die weiterführende Literatur.

(3) Wir definieren

$$P(x^+) = \lim_{y \rightarrow x, y > x} P(y). \quad (4.36)$$

Seien nun $y_1 > y_2 > \dots$ so, dass $\lim_{n \rightarrow \infty} y_n = x$. Dann gilt

$$\{\xi \leq x\} = \cap_{n=1}^{\infty} \{\xi \leq y_n\}. \quad (4.37)$$

Es gilt also

$$P(x) = \mathbb{P}(\{\xi \leq x\}) = \mathbb{P}(\cap_{n=1}^{\infty} \{\xi \leq y_n\}) = \lim_{n \rightarrow \infty} \mathbb{P}(\{\xi \leq y_n\}) = P(x^+), \quad (4.38)$$

wobei wir die dritte Gleichung unbegründet stehen lassen.

□

KVFen von diskreten Zufallsvariablen

Anhand von Abbildung 4.10 und Abbildung 4.11 wollen wir uns obige Eigenschaften von KVFen diskreter Zufallsvariablen visuell verdeutlichen. Dabei sollte man immer vor Augen haben, dass der Wert $P(x)$ einer KVF für den Ergebniswert x der Zufallsvariable ξ der Wahrscheinlichkeit $\mathbb{P}(\xi \leq x)$ entspricht, also der Wahrscheinlichkeit dafür ist, dass die Zufallsvariable ξ Werte kleiner oder gleich x annimmt. Liest man diese Wahrscheinlichkeiten entsprechend aus den Darstellungen der korrespondierenden WMF ab, so ergeben sich die funktionale Form der KVFen im Vergleich mit den entsprechenden WMFen intuitiv. Weiterhin erschließen sich auch folgende Eigenschaften der KVFen von diskreten Zufallsvariablen intuitiv: Wenn $a < b$ und $\mathbb{P}(a < \xi < b) = 0$ ist, dann ist die KVF von ξ konstant horizontal auf $]a, b[$. Weiterhin gilt, dass an jedem Punkt x mit $\mathbb{P}(\xi = x) > 0$ die KVF um den Betrag $\mathbb{P}(\xi = x)$ springt, an dieser Stelle also linksseitig nicht stetig ist. Allgemein ist die KVF einer diskreten Zufallsvariablen mit Ergebnisraum $\mathbb{N}_0$ durch

$$P : \mathbb{R} \rightarrow [0, 1], x \mapsto P(x) := \sum_{k=0}^{\lfloor x \rfloor} \mathbb{P}(\xi = k) \quad (4.39)$$

gegeben, wobei $\lfloor x \rfloor$ die Abrundungsfunktion bezeichnet.

KVFen von kontinuierlichen Zufallsvariablen

Die KVFen von kontinuierlichen Zufallsvariablen sind analytisch etwas zugänglicher als die KVFen von diskreten Zufallsvariablen, da sie keine Unstetigkeitsstellen aufweisen. Wir haben zunächst folgendes, vielleicht etwas überraschendes Theorem.

Theorem 4.5 (Kumulative Verteilungsfunktionen von kontinuierlichen Zufallsvariablen). *ξ sei eine kontinuierliche Zufallsvariable mit WDF p und KVF P . Dann gelten*

$$P(x) = \int_{-\infty}^x p(s) ds \text{ und } p(x) = P'(x). \quad (4.40)$$

◦

Beweis. Wir halten zunächst fest, dass weil $\mathbb{P}(\xi = x) = 0$ für alle $x \in \mathbb{R}$ gilt, die KVF von ξ keine Sprünge hat, P also stetig ist. Mit den Definitionen von WDF und KVF, folgt, dass P die Form einer Stammfunktion von p hat. Dass p die Ableitung von P ist, folgt dann direkt aus dem ersten Hauptsatz der Differenzial- und Integralrechnung ([Erster Hauptsatz der Differenzial- und Integralrechnung \(PDWP\)](#)). □




Abbildung 4.10 WMFen und KVFen von Bernoulli-Zufallsvariablen.




Abbildung 4.11 WMFen und KVFen von Binomial-Zufallsvariablen.

Für kontinuierliche Zufallsvariablen gilt also, dass die KVF der Zufallsvariable eine Stammfunktion der entsprechenden WDF ist, und umgekehrt, dass die WDF die Ableitung der KVF ist. Im Kontext des *Theorems von Radon-Nikodym* wird diese Einsicht auf generelle Maße generalisiert (vgl. Schmidt (2009)). KVFe kontinuierlicher Zufallsvariablen werden auch oft als kumulative Dichtefunktionen (KDFen) bezeichnet.

Als Beispiel betrachten wir die KVF einer normalverteilten Zufallsvariablen. Es sei $\xi \sim N(\mu, \sigma^2)$. Dann ist die WDF von ξ bekanntlich durch

$$p : \mathbb{R} \rightarrow \mathbb{R}_{>0}, x \mapsto p(x) := \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2\sigma^2}(x - \mu)^2\right). \quad (4.41)$$

gegeben. Für die KVF von ξ folgt entsprechend, dass

$$P : \mathbb{R} \rightarrow]0, 1[, x \mapsto P(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \int_{-\infty}^x \exp\left(-\frac{1}{2\sigma^2}(s - \mu)^2\right) ds. \quad (4.42)$$

Interessanterweise kann das definierende Integral der KVF einer normalverteilten Zufallsvariablen nur numerisch, nicht aber analytisch berechnet werden. Wir visualisieren ausgewählte WDFen und KVFe von normalverteilten Zufallsvariablen in Abbildung 4.12.




Abbildung 4.12 WDFen und KVFe von normalverteilten Zufallsvariablen.

Inverse kumulative Verteilungsfunktion

Wir beschließen diesen Abschnitt mit dem Begriff der *inversen kumulativen Verteilungsfunktion*, einem technischen Hilfsmittel, dass insbesondere bei Konfidenzintervallen und

Hypothesentests der frequentistischen Inferenz zur Bestimmung kritischer Werte benutzt wird. Wir definieren die inverse KVF wie folgt.

Definition 4.14 (Inverse kumulative Verteilungsfunktion). ξ sei eine kontinuierliche Zufallsvariable mit KVF P . Dann heißt die Funktion

$$P^{-1}:]0, 1[\rightarrow \mathbb{R}, q \mapsto P^{-1}(q) := \{x \in \mathbb{R} | P(x) = q\} \quad (4.43)$$

die *inverse kumulative Verteilungsfunktion* von ξ .

•

Nach Definition 4.14 gilt offenbar, dass die Funktion P^{-1} die Umkehrfunktion von P ist, also

$$P^{-1}(P(x)) = x. \quad (4.44)$$

Da bekanntlich gilt, dass

$$P(x) = q \Leftrightarrow \mathbb{P}(\xi \leq x) = q \text{ für } q \in]0, 1[, \quad (4.45)$$

ist $P^{-1}(q)$ also der Wert x von ξ , so dass $\mathbb{P}(\xi \leq x) = q$. Wir visualisieren die KVFen und inversen KVFen normalverteilter Zufallsvariablen in Abbildung 4.13. Im Falle einer normalverteilten Zufallsvariable $\xi \sim N(0, 1)$ gelten beispielsweise, dass

$$P(1.645) = 0.950 \Leftrightarrow P^{-1}(0.950) = 1.645, \quad (4.46)$$

und

$$P(1.906) = 0.975 \Leftrightarrow P^{-1}(0.975) = 1.960. \quad (4.47)$$

4.5 Zufallsergebnisse und Zufallsvariablen

Mit den in Kapitel 2 diskutierten *Ergebnissen* ω und den in diesem Kapitel diskutierten Werten von *Zufallsvariablen* ξ haben wir nun zwei Konzepte kennengelernt, die die Unsicherheit über einen zumeist numerischen Wert eines Zufallsvorgangs beschreiben können. So kann man sich zum Beispiel die Augenzahl, die ein Würfel beim einmaligen Werfen annimmt, als Realisierung eines Ergebnisses oder einer Zufallsvariablen vorstellen. Tatsächlich gibt es auch keine standardisierte Antwort auf die Frage, ob man einen Zufallsvorgang lediglich mit einem Wahrscheinlichkeitsraum oder mit dem zugrundeliegenden Wahrscheinlichkeitsraum einer Zufallsvariablen und dem durch beide induzierten Wahrscheinlichkeitsraum modellieren sollte. In der Anwendung wird meist der Begriff der Zufallsvariablen bevorzugt und entsprechende WMFen oder WDFen angegeben, ohne dass ein zugrundeliegender Wahrscheinlichkeitsraum oder die Abbildungsform der Zufallsvariablen spezifiziert würde. Folgende Formulierung ist beispielsweise typisch:

ξ sei eine normalverteilte Zufallsvariable mit Erwartungswertparameter μ und Varianzparameter σ^2 .

Implizit werden in dieser Aussage basierend auf der Definition der normalverteilten Zufallsvariable (vgl. Definition 4.9) für ξ der Ergebnisraum $\mathcal{X} := \mathbb{R}$, die σ -Algebra $\mathcal{S} := \mathcal{B}(\mathbb{R})$, und die Verteilung $\mathbb{P}_\xi := N(\mu, \sigma^2)$ festgelegt, also der “induzierte” Wahrscheinlichkeitsraum $(\mathbb{R}, \mathcal{B}(\mathbb{R}), N(\mu, \sigma^2))$ betrachtet. Allerdings bleibt unklar, durch welchen Wahrscheinlichkeitsraum und welche Abbildungsform genau $(\mathbb{R}, \mathcal{B}(\mathbb{R}), N(\mu, \sigma^2))$ nun induziert wurde.




Abbildung 4.13 KVFe und inverse KVFe von normalverteilten Zufallsvariablen.

Dies kann allerdings immer durch die Annahme, dass ξ die Identitätsfunktion ist, ergänzt werden. Konkret könnte man für den zugrundeliegenden Wahrscheinlichkeitsraum hier $(\mathbb{R}, \mathcal{B}(\mathbb{R}), N(\mu, \sigma^2))$ und für ξ dann

$$\xi : \mathbb{R} \rightarrow \mathbb{R}, \omega \mapsto \xi(\omega) := \omega := x \quad (4.48)$$

wählen. Da ξ dann an dem im Rahmen des zugrundeliegenden Wahrscheinlichkeitsraums zufällig realisiertem Ergebnis ω nichts ändert und dieses lediglich in x umbenannt wird, entspricht die Verteilung von ξ hier direkt dem Wahrscheinlichkeitsmaß des zugrundeliegenden Wahrscheinlichkeitsraums.

Allgemein mag man festhalten, dass das Modellieren von Zufallsvorgängen mithilfe von Zufallsvariablen das elementare Wahrscheinlichkeitsraummodell also als Spezialfall enthält, über dies hinausgehend aber die Möglichkeit eröffnet, durch von der Identitätsabbildung verschiedene Zufallsvariablen die Transformation von Wahrscheinlichkeitsmaßen auf unterschiedlichen Messräumen zu formalisieren und zu studieren.

4.6 Literaturhinweise

Die Genese des Begriffs der Zufallsvariablen ist eng mit der Entwicklung der Wahrscheinlichkeitstheorie in den letzten drei Jahrhunderten verflochten, sodass keine für den Begriff entscheidene Publikation angegeben werden kann. Die mathematische Entwicklung des Begriffs der Normalverteilung durch Abraham De Moivre (1667-1754), Pierre Simon Laplace

(1749-1827), Johann Carl Friedrich Gauss (1777-1855) und viele andere, ihre deskriptiv-statistischen Entsprechungen in der empirischen Forschung des 19. Jahrhunderts, sowie ihre multivariate Generalisierung im ausgehenden 19. Jahrhundert werden ausführlich in Stigler (1986) dargestellt.

Selbstkontrollfragen

1. Geben Sie die Definition des Begriffs der Zufallsvariable wieder.
2. Erläutern Sie die Gleichung $\mathbb{P}_\xi(\xi = x) = \mathbb{P}(\{\xi = x\})$.
3. Erläutern Sie die intuitive Bedeutung von $\mathbb{P}(\xi = x)$.
4. Geben Sie die Definition des Begriffs der Wahrscheinlichkeitsmassefunktion wieder.
5. Geben Sie die Definition des Begriffs der Wahrscheinlichkeitsdichtefunktion wieder.
6. Geben Sie die Definition der WDF einer normalverteilten Zufallsvariable wieder.
7. Geben Sie die Definition des Begriffs der kumulativen Verteilungsfunktion wieder.
8. Schreiben Sie die Überschreitungswahrscheinlichkeit $\mathbb{P}(\xi > x)$ einer Zufallsvariable mithilfe ihrer KVF.
9. Schreiben Sie die Intervallwahrscheinlichkeit $\mathbb{P}(\xi \in]x_1, x_2])$ einer Zufallsvariable mithilfe ihrer KVF.
10. Schreiben Sie den Wert $P(x)$ der KVF einer kontinuierlichen Zufallsvariable mithilfe ihrer WDF p .
11. Schreiben Sie den Wert $p(x)$ der WDF einer kontinuierlichen Zufallsvariable mithilfe ihrer KVF P .
12. Geben Sie die Definition des Begriffs der inversen Verteilungsfunktion wieder.

Lösungen

1. Siehe Definition 4.1.
2. Die Gleichung besagt, dass der von der Verteilung $\mathbb{P}_\xi$ der Zufallsvariable ξ zugeordnete Wahrscheinlichkeitswert für das Ereignis $\xi = x$ in $\mathcal{X}$ definitionsgemäß gleich dem Wert des von dem Wahrscheinlichkeitsmaß $\mathbb{P}$ dem Urbild des Ereignisses $\xi = x$, also der Menge $\{\xi = x\} = \{\omega \in \Omega | \xi(\omega) = x\}$ in $\mathcal{A}$, ist. Siehe Definition 4.3.
3. Intuitiv ist $\mathbb{P}(\xi = x)$ die Wahrscheinlichkeit dafür, dass die Zufallsvariable ξ den Wert x annimmt.
4. Siehe Definition 4.4.
5. Siehe Definition 4.8.
6. Siehe Definition 4.9.
7. Siehe Definition 4.13.
8. Siehe Theorem 4.2.
9. Siehe Theorem 4.3.
10. Siehe Theorem 4.5. Es gilt

$$P(x) = \int_{-\infty}^x p(s) ds. \quad (4.49)$$

11. Siehe Theorem 4.5. Es gilt

$$p(x) = \frac{d}{dx} P(x) = P'(x). \quad (4.50)$$

12. Siehe Definition 4.14.

5 Zufallsvektoren

Zufallsvektoren sind Tupel von Zufallsvariablen. Da jede Zufallsvariable einer Wahrscheinlichkeitsverteilung unterliegt, unterliegt auch ein Zufallsvektor einer Wahrscheinlichkeitsverteilung. Da ein Zufallsvektor aus zwei oder mehr Zufallsvariablen besteht, beschreibt die Verteilung eines Zufallsvektors die *gemeinsame Verteilung* von zwei oder mehr Zufallsvariablen. In diesem Kapitel wollen wir zunächst den Begriff des Zufallsvektors und seiner assoziierten Wahrscheinlichkeitsverteilung, die oft einfach als eine *multivariate Verteilung* bezeichnet wird, einführen. Wir wollen dann diskutieren, wie die Begriffe der WMF, WDF und KVF von Zufallsvariablen auf Zufallsvektoren übertragen werden können (Kapitel 5.1). Mit den *marginalen Verteilungen* und den *bedingten Verteilungen* führen wir dann nachfolgend Begriffe ein, die in der Betrachtung von Zufallsvariablen nicht auftreten. Schließlich führen wir mit dem Begriff der *unabhängigen Zufallsvariablen* das probabilistische Standardmodell für univariate Datensätze ein. Dies stellt einen Spezialfall der gemeinsamen Verteilung der Zufallsvariablen eines Zufallsvektors dar.

5.1 Definition und multivariate Verteilungen

Die Konstruktion und Definition eines Zufallsvektors ist analog zu der einer Zufallsvariable, mit dem Unterschied, dass es sich bei einer Zufallsvariable um eine skalarwertige, bei einem Zufallsvektor dagegen um eine vektorwertige Abbildung auf dem Ergebnisraum eines Wahrscheinlichkeitsraums handelt.

Definition 5.1 (Zufallsvektor). $(\Omega, \mathcal{A}, \mathbb{P})$ sei ein Wahrscheinlichkeitsraum und $(\mathcal{X}, \mathcal{S})$ sei ein n -dimensionaler Messraum. Ein n -dimensionaler *Zufallsvektor* ist definiert als eine Abbildung

$$\xi : \Omega \rightarrow \mathcal{X}, \omega \mapsto \xi(\omega) := \begin{pmatrix} \xi_1(\omega) \\ \vdots \\ \xi_n(\omega) \end{pmatrix} \quad (5.1)$$

mit der *Messbarkeitseigenschaft*

$$\{\omega \in \Omega \mid \xi(\omega) \in S\} \in \mathcal{A} \text{ für alle } S \in \mathcal{S}. \quad (5.2)$$

•


Das Standardbeispiel für den Ergebnisraum eines Zufallsvektors ist $\mathbb{R}^n$, das Standardbeispiel für die auf ihm definierte σ -Algebra ist die n -dimensionale Borelsche σ -Algebra $\mathcal{B}(\mathbb{R}^n)$. Für eine explizite und formale Einführung der n -dimensionalen Borelschen σ -Algebra verweisen wir auf die weiterführende Literatur (z.B. Schmidt (2009)). Wir begnügen uns hier wieder mit der (weiterhin formal falschen) Intuition der n -dimensionalen Borelschen σ -Algebra als Menge aller Teilmengen des $\mathbb{R}^n$. Das Standardbeispiel für einen n -dimensionalen Messraum ist damit $(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n))$.

Wie bei allen vektorwertigen Funktionen nennen wir die den Zufallsvektor konstituierenden Funktionen ξ_i die *Komponentenfunktionen* von ξ . Legen wir den n -dimensionalen Messraum $(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n))$ dem Zufallsvektor zugrunde, so haben diese die Form

$$\xi_i : \Omega \rightarrow \mathbb{R}, \omega \mapsto \xi_i(\omega). \quad (5.3)$$

Ohne Beweis halten wir fest, dass der Zufallsvektor ξ messbar ist, wenn für alle $i = 1, \dots, n$ die Funktionen ξ_i messbar sind und umgekehrt. Damit sind die Komponentenfunktionen eines Zufallsvektors (letztlich nach Definition) Zufallsvariablen. Ein n -dimensionaler Zufallsvektor wird also als eine Konkatenation von n Zufallsvariablen betrachtet, für $n := 1$ entspricht ein Zufallsvektor einer Zufallsvariable.

Zufallsvektoren werden manchmal auch als “multivariate Zufallsvariablen” bezeichnet. Tatsächlich stehen bei der Betrachtung von Zufallsvektoren auch zunächst primär wahrscheinlichkeitstheoretische Aspekte und nicht etwa Aspekte der geometrischen Vektorraumtheorie im Vordergrund. Die Betrachtung von Vektorraumstrukturen ist im Kontext probabilistischer Standardmodelle wie dem Allgemeinen linearen Modell aber durchaus üblich, sodass wir hier den Begriff des Zufallsvektors bevorzugen (vgl. Christensen (2011)). Trotzdem werden wir Zufallsvektoren, wie in vielen Texten der Probabilistik üblich, auch oft in Zeilenform, also etwa als $\xi := (\xi_1, \dots, \xi_n)$, notieren.



$$\mathbb{P}(\xi^{-1}(S)) = \mathbb{P}(\{\omega \in \Omega \mid \xi(\omega) \in S\}) =: \mathbb{P}_\xi(S)$$

Abbildung 5.1 Konstruktion von Zufallsvektor und multivariater Verteilung.

Das durch die Konstruktion eines Zufallsvektors definierte Bildmaß heißt die *multivariate Verteilung des Zufallsvektors*, wie in folgender Definition ausgeführt (vgl. Abbildung 5.1).

Definition 5.2 (Multivariate Verteilung). $(\Omega, \mathcal{A}, \mathbb{P})$ sei ein Wahrscheinlichkeitsraum, $(\mathcal{X}, \mathcal{S})$ sei ein n -dimensionaler Messraum und

$$\xi : \Omega \rightarrow \mathcal{X}, \omega \mapsto \xi(\omega) \quad (5.4)$$

sei ein Zufallsvektor. Dann heißt das Wahrscheinlichkeitsmaß $\mathbb{P}_\xi$, definiert durch

$$\mathbb{P}_\xi : \mathcal{S} \rightarrow [0, 1], S \mapsto \mathbb{P}_\xi(S) := \mathbb{P}(\xi^{-1}(S)) = \mathbb{P}(\{\omega \in \Omega \mid \xi(\omega) \in S\}) \quad (5.5)$$

die *multivariate Verteilung des Zufallsvektor* ξ .

•

Der Einfachheit halber spricht man oft auch nur von *der Verteilung des Zufallsvektors* ξ oder einer *multivariaten Verteilung*. Die Notationskonventionen für Zufallsvariablen Definition 4.3 gelten für Zufallsvektoren analog. Zum Beispiel gelten

$$\begin{aligned}\mathbb{P}_\xi(\xi \in S) &:= \mathbb{P}(\{\xi \in S\}) = \mathbb{P}(\{\omega \in \Omega | \xi(\omega) \in S\}) \\ \mathbb{P}_\xi(\xi = x) &:= \mathbb{P}(\{\xi = x\}) = \mathbb{P}(\{\omega \in \Omega | \xi(\omega) = x\}) \\ \mathbb{P}_\xi(\xi \leq x) &:= \mathbb{P}(\{\xi \leq x\}) = \mathbb{P}(\{\omega \in \Omega | \xi(\omega) \leq x\}) \\ \mathbb{P}_\xi(x_1 \leq \xi \leq x_2) &:= \mathbb{P}(\{x_1 \leq \xi \leq x_2\}) = \mathbb{P}(\{\omega \in \Omega | x_1 \leq \xi(\omega) \leq x_2\})\end{aligned}\tag{5.6}$$

wobei die Relationsoperatoren $<, \leq, >, \geq$ hier *komponentenweise* verstanden werden. So heißt beispielsweise $x \leq y$ für $x, y \in \mathbb{R}^n$, dass für alle Komponenten $x_i, y_i, i = 1, \dots, n$ gilt, dass $x_i \leq y_i$. Eben dieser Konvention folgt auch die Definition der *multivariaten kumulativen Verteilungsfunktion* in Generalisierung von Definition 4.13. Wie bei den Zufallsvariablen werden die qualifizierenden Subskripte bezüglich eines speziellen Zufallsvektors im Sinne der Multimethode meist weggelassen. Wir nutzen diese Konvention schon in folgender Definition der multivariaten kumulativen Verteilungsfunktion eines Zufallsvektors ξ .

Definition 5.3 (Multivariate kumulative Verteilungsfunktionen). ξ sei ein Zufallsvektor mit Ergebnisraum $\mathcal{X}$. Dann heißt eine Funktion der Form

$$P : \mathcal{X} \rightarrow [0, 1], x \mapsto P(x) := \mathbb{P}(\xi \leq x)\tag{5.7}$$

multivariate kumulative Verteilungsfunktion von ξ .

•

Wie kumulative Verteilungsfunktionen können auch multivariate kumulative Verteilungsfunktionen zur Definition von multivariaten Verteilungen genutzt werden. Häufiger ist allerdings, wie im univariaten Fall, die Definition multivariater Verteilungen durch *multivariate Wahrscheinlichkeitsmasse-* oder *Wahrscheinlichkeitsdichtefunktionen*. Wir generalisieren die Definitionen diskreter und kontinuierlicher Zufallsvariablen und ihren assoziierten Wahrscheinlichkeitsmasse- und Wahrscheinlichkeitsdichtefunktionen wie folgt (vgl. Definition 4.4 und Definition 4.8).

Definition 5.4 (Diskreter Zufallsvektor und multivariate Wahrscheinlichkeitsmassefunktion). Ein Zufallsvektor ξ heißt *diskret*, wenn sein Ergebnisraum $\mathcal{X}$ endlich oder abzählbar ist und eine Funktion

$$p : \mathcal{X} \rightarrow [0, 1], x \mapsto p(x)\tag{5.8}$$

existiert, für die gilt

- (1) $\sum_{x \in \mathcal{X}} p(x) = 1$
- (2) $\mathbb{P}(\xi = x) = p(x)$ für alle $x \in \mathcal{X}$.

Eine entsprechende Funktion p heißt *multivariate Wahrscheinlichkeitsmassefunktion (WMF)* von ξ .

•

Der Begriff der multivariaten WMF ist offenbar direkt analog zum Begriff der WMF. Wie univariate WMFen sind multivariate WMFen nicht-negativ und normiert. Der Einfachheit halber spricht man oft einfach von *der WMF eines Zufallsvektors* und verzichtet bei ihrer Bezeichnung, wenn der betreffende Zufallsvektor aus dem Kontext klar ist, auf das ξ Subskript, schreibt also oft einfach p anstelle von p_ξ .

Beispiel 5.1 (Diskreter Zufallsvektor). Zur Illustration des Begriffs des diskreten Zufallsvektors und seiner WMF wollen wir ein Beispiel betrachten. Dazu sei $\xi := (\xi_1, \xi_2)$ ein Zufallsvektor, der Werte in $\mathcal{X} := \mathcal{X}_1 \times \mathcal{X}_2$ annimmt, wobei $\mathcal{X}_1 := \{1, 2, 3\}$ und $\mathcal{X}_2 = \{1, 2, 3, 4\}$ seien. Dann entspricht der Ergebnisraum von ξ der in Tabelle 5.1 spezifizierten Menge an Tupeln (x_1, x_2) .

Tabelle 5.1 Ergebnisraum

(x_1, x_2)	$x_2 = 1$	$x_2 = 2$	$x_2 = 3$	$x_2 = 4$
$x_1 = 1$	(1, 1)	(1, 2)	(1, 3)	(1, 4)
$x_1 = 2$	(2, 1)	(2, 2)	(2, 3)	(2, 4)
$x_1 = 3$	(3, 1)	(3, 2)	(3, 3)	(3, 4)

Eine exemplarische bivariate WMF der Form

$$p : \{1, 2, 3\} \times \{1, 2, 3, 4\} \rightarrow [0, 1], (x_1, x_2) \mapsto p(x_1, x_2) \quad (5.9)$$

ist dann durch Tabelle 5.2 definiert.

Tabelle 5.2 Bivariate WMF $p(x_1, x_2)$

$p(x_1, x_2)$	$x_2 = 1$	$x_2 = 2$	$x_2 = 3$	$x_2 = 4$
$x_1 = 1$	0.1	0.0	0.2	0.1
$x_1 = 2$	0.1	0.2	0.0	0.0
$x_1 = 3$	0.0	0.1	0.1	0.1

Man beachte, dass die so spezifizierte Funktion p den Normiertheits- und Nichtnegativitätsansprüchen an eine WMF genügt. Insbesondere gilt hier

$$\sum_{x \in \mathcal{X}} p(x) = \sum_{x_1=1}^3 \sum_{x_2=1}^4 p(x_1, x_2) = 1. \quad (5.10)$$

△

Den Begriff des kontinuierlichen Zufallsvektors und der multivariaten Wahrscheinlichkeitsdichtefunktion definieren wir wie folgt.

Definition 5.5 (Kontinuierlicher Zufallsvektor und multivariate Wahrscheinlichkeitsdichtefunktion). Ein Zufallsvektor ξ heißt *kontinuierlich*, wenn sein Ergebnisraum durch $\mathbb{R}^n$ gegeben ist und eine Funktion

$$p : \mathbb{R}^n \rightarrow \mathbb{R}_{\geq 0}, x \mapsto p(x), \quad (5.11)$$

existiert, für die gilt, dass

$$(1) \int_{\mathbb{R}^n} p(x) dx = 1 \text{ und}$$

$$(2) \mathbb{P}(x_1 \leq \xi \leq x_2) = \int_{x_{1_1}}^{x_{2_1}} \cdots \int_{x_{1_n}}^{x_{2_n}} p(s_1, \dots, s_n) ds_1 \cdots ds_n.$$

Eine entsprechende Funktion p heißt *multivariate Wahrscheinlichkeitsdichtefunktion (WDF)* von ξ .

•

Offenbar ist der Begriff der multivariaten WDF eines kontinuierlichen Zufallsvektors analog zum Begriff der WDF einer kontinuierlichen Zufallsvariable und wie univariate WDFen sind multivariate WDFen nicht-negativ und normiert. Der Einfachheit halber spricht man auch hier oft einfach von *multivariaten WDFen* und verzichtet auf die den Zufallsvektor identifizierenden Subskripte. Wie für kontinuierliche Zufallsvariablen gilt für kontinuierliche Zufallsvektoren

$$\mathbb{P}(\xi = x) = \mathbb{P}(x \leq \xi \leq x) = \int_{x_1}^{x_1} \cdots \int_{x_n}^{x_n} p(s_1, \dots, s_n) ds_1 \cdots ds_n = 0. \quad (5.12)$$

Das Standardbeispiel für eine multivariate WDF ist die *multivariate Normalverteilung*, die wir in Kapitel 12 ausführlich diskutieren.

5.2 Marginalverteilungen

Hat man die Verteilung eines Zufallsvektors spezifiziert, so kann man sich fragen, welche Verteilungen daraus für die einzelnen Komponenten des Zufallsvektors, also die Zufallsvariablen, die zusammen den Zufallsvektor bilden, folgen. Im Kontext eines Zufallsvektors nennt man diese die *univariaten Marginalverteilungen* des Zufallsvektors. Folgende Definition ist grundlegend.

Definition 5.6 (Univariate Marginalverteilung). $(\Omega, \mathcal{A}, \mathbb{P})$ sei ein Wahrscheinlichkeitsraum, $(\mathcal{X}, \mathcal{S})$ sei ein n -dimensionaler Messraum, $\xi : \Omega \rightarrow \mathcal{X}$ sei ein Zufallsvektor, $\mathbb{P}$ sei die Verteilung von ξ , $\mathcal{X}_i \subset \mathcal{X}$ sei der Ergebnisraum der i ten Komponente ξ_i von ξ , und $\mathcal{S}_i$ sei eine σ -Algebra auf $\mathcal{X}_i$. Dann heißt die durch

$$\mathbb{P}_{\xi_i} : \mathcal{S}_i \rightarrow [0, 1], S \mapsto \mathbb{P}(\mathcal{X}_1 \times \cdots \times \mathcal{X}_{i-1} \times S \times \mathcal{X}_{i+1} \times \cdots \times \mathcal{X}_n) \text{ für } S \in \mathcal{S}_i \quad (5.13)$$

definierte Verteilung die *ite univariate Marginalverteilung* von ξ .

•

Konkret kann man sowohl für diskrete als auch für kontinuierliche Zufallsvektoren die WMFen bzw. WDFen ihrer Komponenten direkt aus der entsprechenden multivariaten WMF bzw. WDF bestimmen. Dies ist die Aussage folgenden Theorems.

Theorem 5.1 (Marginale Wahrscheinlichkeitsmasse- und Wahrscheinlichkeitsdichtefunktionen). (1) $\xi = (\xi_1, \dots, \xi_n)$ sei ein n -dimensionaler diskreter Zufallsvektor mit WMF p und Komponentenergebnisräumen $\mathcal{X}_1, \dots, \mathcal{X}_n$. Dann ergibt sich die WMF der i ten Komponente ξ_i von ξ als

$$p : \mathcal{X}_i \rightarrow [0, 1], x_i \mapsto p(x_i) := \sum_{x_1} \cdots \sum_{x_{i-1}} \sum_{x_{i+1}} \cdots \sum_{x_n} p(x_1, \dots, x_{i-1}, x_i, x_{i+1}, \dots, x_n). \quad (5.14)$$

(2) $\xi = (\xi_1, \dots, \xi_n)$ sei ein n -dimensionaler kontinuierlicher Zufallsvektor mit WDF p und Komponentenergebnisraum $\mathbb{R}$. Dann ergibt sich die WDF der i -ten Komponente ξ_i von ξ als

$$p : \mathbb{R} \rightarrow \mathbb{R}_{\geq 0}, x_i \mapsto p(x_i) := \int_{x_1} \dots \int_{x_{i-1}} \int_{x_{i+1}} \dots \int_{x_n} p(x_1, \dots, x_{i-1}, x_i, x_{i+1}, \dots, x_n) dx_1 \dots dx_{i-1} dx_{i+1} \dots dx_n. \quad (5.15)$$

◦

Die WMFen der univariaten Marginalverteilungen diskreter Zufallsvektoren ergeben sich also durch Summation über alle Werte der zu der jeweils betrachteten Zufallsvariable komplementären Zufallsvariablen und die WDFen der univariaten Marginalverteilungen kontinuierlicher Zufallsvektoren ergeben sich analog durch Integration über alle Werte der zu der jeweils betrachteten Zufallsvariable komplementären Zufallsvariablen. Für einen Beweis von Theorem 5.1 verweisen wir auf die weiterführende Literatur.

Beispiel 5.2 (Marginale Wahrscheinlichkeitsmassefunktionen). In Fortführung von Beispiel 5.1 ergeben sich für die dort definierte WMF des Zufallsvektors $\xi := (\xi_1, \xi_2)$ für die marginalen WMFen die an den Rändern der von Tabelle 5.3 aufgelisteten WMFen anhand von

$$p(x_1) = \sum_{x_2=1}^4 p(x_1, x_2) \text{ und } p(x_2) = \sum_{x_1=1}^3 p(x_1, x_2). \quad (5.16)$$

Tabelle 5.3 Bivariate WMF $p(x_1, x_2)$ mit marginalen WMFen

$p(x_1, x_2)$	$x_2 = 1$	$x_2 = 2$	$x_2 = 3$	$x_2 = 4$	$p(x_1)$
$x_1 = 1$	0.1	0.0	0.2	0.1	0.4
$x_1 = 2$	0.1	0.2	0.0	0.0	0.3
$x_1 = 3$	0.0	0.1	0.1	0.1	0.3
$p(x_2)$	0.2	0.3	0.3	0.2	

Für die Werte $p(x_1)$ werden die entsprechenden Werte von $p(x_1, x_2)$ also zeilenweise und für die Werte von $p(x_2)$ spaltenweise addiert. Man beachte, dass aus der Normiertheit von $p(x_1, x_2)$ die Normiertheit von $p(x_1)$ und $p(x_2)$ direkt folgt, da sich die Gesamtsumme an Wahrscheinlichkeitsmasse nicht ändert:

$$1 = \sum_{x_1=1}^3 \sum_{x_2=1}^4 p(x_1, x_2) = \sum_{x_1=1}^3 p(x_1) = \sum_{x_2=1}^4 p(x_2). \quad (5.17)$$

Ein Realisierungsbeispiel mithilfe relativer Häufigkeiten mag den Begriff der marginalen WMF intuitiv verdeutlichen. Nehmen wir an, wir hätten $n = 100$ unabhängige Realisierungen von ξ vorliegen. Um die Wahrscheinlichkeiten $p(x_1, x_2)$ zu schätzen, würden wir die Anzahl der Realisierungen von (x_1, x_2) zählen und durch n teilen. Hätten wir beispielsweise 12 Realisierungen von $(3, 2)$ vorliegen, so würden wir $p(3, 2) \approx 12/100 = 0.12$ schätzen. Die Frage nach der marginalen Wahrscheinlichkeit von $x_2 = 2$ entspräche dann der Frage, wie oft unter den Realisierungen solche zu finden sind, bei denen $x_2 = 2$ ist, irrespektive des Wertes von x_1 . Dies wäre gerade die Anzahl der Realisierungen der Form $(1, 2)$, $(2, 2)$ und $(3, 2)$. Gäbe es von diesen beispielsweise 0, 22 und 12 respektive, so würde man die Wahrscheinlichkeit $p(2)$ natürlicherweise durch

$$\frac{0 + 22 + 12}{100} = \frac{0}{100} + \frac{22}{100} + \frac{12}{100} = 0.00 + 0.22 + 0.12 = 0.34 \quad (5.18)$$

schätzen. Anstelle der Wahrscheinlichkeiten $p(1,2)$, $p(2,2)$, $p(3,2)$ addiert man hier also die entsprechenden relativen Häufigkeiten.

△

Marginale Verteilungen im Fall von kontinuierlichen Zufallsvektoren behandeln wir am Standardbeispiel der multivariaten Normalverteilung in Kapitel 12.

5.3 Bedingte Verteilungen

Hat man die Verteilung eines Zufallsvektors spezifiziert, so kann man sich fragen, welche Verteilung daraus für eine einzelne Komponente des Zufallsvektors folgt, wenn man den Wert einer anderen Komponente als bekannt annimmt. Dies führt auf den Begriff der *bedingten Verteilung*, welcher sich natürlicherweise aus dem Begriff der bedingten Wahrscheinlichkeit (vgl. Kapitel 3.2) ergibt. Wir erinnern uns zunächst, dass für einen Wahrscheinlichkeitsraum $(\Omega, \mathcal{A}, \mathbb{P})$ und zwei Ereignisse $A, B \in \mathcal{A}$ mit $\mathbb{P}(B) > 0$ die bedingte Wahrscheinlichkeit von A gegeben B definiert ist als

$$\mathbb{P}(A|B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}. \quad (5.19)$$

Analog wird für zwei Zufallsvariablen ξ_1, ξ_2 mit Ereignisräumen $\mathcal{X}_1, \mathcal{X}_2$ und (messbaren) Mengen $S_1 \in \mathcal{X}_1, S_2 \in \mathcal{X}_2$ die bedingte Verteilung von ξ_1 gegeben ξ_2 mithilfe der Ereignisse

$$A := \{\xi_1 \in S_1\} \text{ und } B := \{\xi_2 \in S_2\} \quad (5.20)$$

definiert. So ergibt sich zum Beispiel die bedingte Wahrscheinlichkeit, dass $\xi_1 \in S_1$ gegeben, dass $\xi_2 \in S_2$ und unter der Annahme, dass $\mathbb{P}(\{\xi_2 \in S_2\}) > 0$, zu

$$\mathbb{P}(\{\xi_1 \in S_1\}|\{\xi_2 \in S_2\}) = \frac{\mathbb{P}(\{\xi_1 \in S_1\} \cap \{\xi_2 \in S_2\})}{\mathbb{P}(\{\xi_2 \in S_2\})}. \quad (5.21)$$

Wir betrachten zunächst die Definition der bedingten Verteilungen von diskreten Zufallsvektoren, die lediglich aus zwei Zufallsvariablen bestehen.

Definition 5.7 (Bedingte Wahrscheinlichkeitsmassefunktion und diskrete bedingte Verteilung). $\xi := (\xi_1, \xi_2)$ sei ein diskreter Zufallsvektor mit Ergebnisraum $\mathcal{X} := \mathcal{X}_1 \times \mathcal{X}_2$, WMF $p(x_1, x_2)$ und marginalen WMFen $p(x_1)$ und $p(x_2)$. Die bedingte WMF von ξ_1 gegeben $\xi_2 = x_2$ ist dann für $p(x_2) > 0$ definiert als

$$p : \mathcal{X}_1 \rightarrow [0, 1], x_1 \mapsto p(x_1|x_2) := \frac{p(x_1, x_2)}{p(x_2)} \quad (5.22)$$

Analog ist für $p(x_1) > 0$ die bedingte WMF von ξ_2 gegeben $\xi_1 = x_1$ definiert als

$$p : \mathcal{X}_2 \rightarrow [0, 1], x_2 \mapsto p(x_2|x_1) := \frac{p(x_1, x_2)}{p(x_1)} \quad (5.23)$$

Die bedingten Verteilungen mit WMFen $p(x_1|x_2)$ und $p(x_2|x_1)$ heißen dann die *diskreten bedingten Verteilungen* von ξ_1 gegeben $\xi_2 = x_2$ bzw. ξ_2 gegeben $\xi_1 = x_1$.

•

In Analogie zur Definition der bedingten Wahrscheinlichkeit von Ereignissen gilt also

$$p(x_1|x_2) = \frac{p(x_1, x_2)}{p(x_2)} = \frac{\mathbb{P}(\{\xi_1 = x_1\} \cap \{\xi_2 = x_2\})}{\mathbb{P}(\{\xi_2 = x_2\})}. \quad (5.24)$$

Es ist dabei entscheidend zu erkennen, dass bedingte Verteilungen lediglich normalisierte gemeinsame Verteilungen sind.

Beispiel 5.3 (Bedingte Wahrscheinlichkeitsmassefunktionen). In Fortführung des in Beispiel 5.1 betrachteten Beispiels eines zweidimensionalen Zufallsvektors $\xi := (\xi_1, \xi_2)$ und seiner in Beispiel 5.2 bestimmten Marginalverteilungen ergeben sich die in Tabelle 5.4 dargestellten bedingte WMFen für $p(x_1|x_2)$ und die in Tabelle 5.5 dargestellten bedingte WMFen für $p(x_2|x_1)$.

Tabelle 5.4 Bedingte WMFen $p(x_1|x_2)$

$p(x_1 x_2)$	$x_2 = 1$	$x_2 = 2$	$x_2 = 3$	$x_2 = 4$
$p(1 x_2)$	$\frac{0.1}{0.2} = 0.5$	$\frac{0.0}{0.3} = 0.0$	$\frac{0.2}{0.3} = 0.6\bar{6}$	$\frac{0.1}{0.2} = 0.5$
$p(2 x_2)$	$\frac{0.1}{0.2} = 0.5$	$\frac{0.2}{0.3} = 0.6\bar{6}$	$\frac{0.0}{0.3} = 0.0$	$\frac{0.0}{0.2} = 0.0$
$p(3 x_2)$	$\frac{0.0}{0.2} = 0.0$	$\frac{0.1}{0.3} = 0.3\bar{3}$	$\frac{0.1}{0.3} = 0.3\bar{3}$	$\frac{0.1}{0.2} = 0.5$

Tabelle 5.5 Bedingte WMFen $p(x_2|x_1)$

$p(x_2 x_1)$	$p(1 x_1)$	$p(2 x_1)$	$p(3 x_1)$	$p(4 x_1)$
$x_1 = 1$	$\frac{0.1}{0.4} = 0.25$	$\frac{0.0}{0.4} = 0.00$	$\frac{0.2}{0.4} = 0.50$	$\frac{0.1}{0.4} = 0.25$
$x_1 = 2$	$\frac{0.1}{0.3} = 0.3\bar{3}$	$\frac{0.2}{0.3} = 0.6\bar{6}$	$\frac{0.0}{0.3} = 0.00$	$\frac{0.0}{0.3} = 0.00$
$x_1 = 3$	$\frac{0.0}{0.3} = 0.00$	$\frac{0.1}{0.3} = 0.3\bar{3}$	$\frac{0.1}{0.3} = 0.3\bar{3}$	$\frac{0.1}{0.3} = 0.3\bar{3}$

Man beachte, dass zum einen gilt, dass

$$\sum_{x_1=1}^3 p(x_1|x_2) = 1 \text{ für alle } x_2 \in \mathcal{X}_2 \text{ und } \sum_{x_2=1}^4 p(x_2|x_1) = 1 \text{ für alle } x_1 \in \mathcal{X}_1, \quad (5.25)$$

die bedingten WMFen sind also normiert. Zum anderen beachte man die qualitative Ähnlichkeit der WMFen $p(x_1, x_2)$ und $p(x_1|x_2)$ bzw. $p(x_2|x_1)$, die sich einfach daraus ergibt, dass einerseits $p(x_1, x_2)$ und $p(x_1|x_2)$ für alle $x_2 \in \mathcal{X}_2$ bis auf den gemeinsamen Skalierungsfaktor $1/p(x_2)$ und andererseits $p(x_1, x_2)$ und $p(x_2|x_1)$ für alle $x_1 \in \mathcal{X}_1$ bis auf den gemeinsamen Skalierungsfaktor $1/p(x_1)$ identisch sind.

△

Im Fall eines kontinuierlichen Zufallsvektors sind die analogen bedingten WDFen definiert wie folgt.

Definition 5.8 (Bedingte Wahrscheinlichkeitsdichtefunktion und kontinuierliche bedingte Verteilung). $\xi := (\xi_1, \xi_2)$ sei ein kontinuierlicher Zufallsvektor mit Ergebnisraum $\mathbb{R}^2$, WDF $p(x_1, x_2)$ und marginalen WDFen $p(x_1)$ und $p(x_2)$. Die bedingte WDF von ξ_1 gegeben $\xi_2 = x_2$ ist dann für $p(x_2) > 0$ definiert als

$$p : \mathbb{R} \rightarrow \mathbb{R}_{\geq 0}, x_1 \mapsto p(x_1|x_2) := \frac{p(x_1, x_2)}{p(x_2)} \quad (5.26)$$

Analog ist für $p(x_1) > 0$ die bedingte WMF von ξ_2 gegeben $\xi_1 = x_1$ definiert als

$$p : \mathbb{R} \rightarrow \mathbb{R}_{\geq 0}, x_2 \mapsto p(x_2|x_1) := \frac{p(x_1, x_2)}{p(x_1)} \quad (5.27)$$

Die Verteilungen mit WDFen p und p heißen dann die *kontinuierlichen bedingten Verteilungen von ξ_1 gegeben $\xi_2 = x_2$ und ξ_2 gegeben $\xi_1 = x_1$* , respektive.

•

Man beachte, dass im kontinuierlichen Fall zwar $\mathbb{P}(\xi = x) = 0$, aber nicht notwendig auch $p(x) = 0$ gilt. Die bedingten Verteilungen multivariater Normalverteilungen diskutieren wir in einem eigenen Kapitel.

5.4 Unabhängige Zufallsvariablen

Ähnlich wie die bedingten Wahrscheinlichkeiten von Ereignissen lässt sich auch das Konzept der unabhängigen Ereignisse auf Zufallsvektoren übertragen. Wir definieren zunächst den Begriff der unabhängigen Zufallsvariablen.

Definition 5.9 (Unabhängige Zufallsvariablen). $(\Omega, \mathcal{A}, \mathbb{P})$ sei ein Wahrscheinlichkeitsraum und $\xi := (\xi_1, \xi_2)$ ein zweidimensionaler Zufallsvektor. Die Zufallsvariablen ξ_1, ξ_2 mit Ergebnisräumen $\mathcal{X}_1, \mathcal{X}_2$ heißen *unabhängig*, wenn für alle $S_1 \subseteq \mathcal{X}_1$ und $S_2 \subseteq \mathcal{X}_2$ gilt, dass

$$\mathbb{P}(\xi_1 \in S_1, \xi_2 \in S_2) = \mathbb{P}(\xi_1 \in S_1)\mathbb{P}(\xi_2 \in S_2). \quad (5.28)$$

•

Definition 5.9 besagt, dass die Ereignisse $\{\xi_1 \in S_1\}$ und $\{\xi_2 \in S_2\}$ unabhängig sind. Es gilt also auch, dass

$$\mathbb{P}(\{\xi_1 \in S_1\} | \{\xi_2 \in S_2\}) = \mathbb{P}(\{\xi_1 \in S_1\}) \quad (5.29)$$

und das Wissen um das Eintreten des Ereignisses $\{\xi_2 \in S_2\}$ verändert die Wahrscheinlichkeit des Ereignisses $\{\xi_1 \in S_1\}$ nicht. Das Faktorisierungsprinzip zur Modellierung probabilistischer Unabhängigkeit überträgt sich auf WMFen und WDFen von Zufallsvektoren. Dies ist die Aussage folgenden Theorems.

Theorem 5.2 (Unabhängigkeit und Faktorisierung).

(1) $\xi := (\xi_1, \xi_2)$ sei ein diskreter Zufallsvektor mit Ergebnisraum $\mathcal{X}_1 \times \mathcal{X}_2$, WMF $p(x_1, x_2)$ und marginalen WMFen $p(x_1), p(x_2)$. Dann gilt

$$\begin{aligned} \xi_1 \text{ und } \xi_2 \text{ sind unabhängige Zufallsvariablen} &\Leftrightarrow \\ p(x_1, x_2) &= p(x_1)p(x_2) \text{ für alle } (x_1, x_2) \in \mathcal{X}_1 \times \mathcal{X}_2. \end{aligned} \quad (5.30)$$

(2) $\xi := (\xi_1, \xi_2)$ sei ein kontinuierlicher Zufallsvektor mit Ergebnisraum $\mathbb{R}^2$, WDF p und marginalen WDFen p, p . Dann gilt

$$\begin{aligned} \xi_1 \text{ und } \xi_2 \text{ sind unabhängige Zufallsvariablen} &\Leftrightarrow \\ p(x_1, x_2) &= p(x_1)p(x_2) \text{ für alle } (x_1, x_2) \in \mathbb{R}^2. \end{aligned} \quad (5.31)$$

◦

Generell ist die Unabhängigkeit zweier Zufallsvariablen also äquivalent zur Faktorisierung ihrer gemeinsamen WMF oder WDF. Für einen Beweis von Theorem 5.2 verweisen wir auf die weiterführende Literatur. Theorem 5.2 ist für weite Aspekte der probabilistischen Modellierung grundlegend.

Beispiel 5.4 (Unabhängige Wahrscheinlichkeitsmassefunktionen). Wir betrachten erneut den zweidimensionalen Zufallsvektor $\xi := (\xi_1, \xi_2)$ aus Beispiel 5.1, dessen gemeinsame und marginale WMFen die in Tabelle 5.3 spezifizierten Formen haben. Wir fragen zunächst, ob ξ_1 und ξ_2 unabhängig sind. Dies ist nicht der Fall, da hier gilt, dass

$$p(1, 1) = 0.10 \neq 0.08 = 0.40 \cdot 0.20 = p(1)p(1). \quad (5.32)$$

Möchten wir basierend auf den Marginalverteilungen von ξ eine gemeinsame Verteilung erzeugen, in der ξ_1 und ξ_2 unabhängig sind, so muss sich jeder Eintrag der gemeinsamen Verteilung $p(\xi_1, \xi_2)$ aus dem jeweiligen Produkt der Marginalwahrscheinlichkeiten ergeben. Die gemeinsame Verteilung von ξ_1 und ξ_2 unter dieser Annahme der Unabhängigkeit von ξ_1 und ξ_2 bei gleichen Marginalverteilungen wie in Tabelle 5.3 ergibt sich zu der in Tabelle 5.6 gemeinsamen WMF.

Tabelle 5.6 Bivariate WMF bei Annahme der Unabhängigkeit von ξ_1 und ξ_2

$p(x_1, x_2)$	$x_2 = 1$	$x_2 = 2$	$x_2 = 3$	$x_2 = 4$	$p(x_1)$
$x_1 = 1$	0.08	0.12	0.12	0.08	0.40
$x_1 = 2$	0.06	0.09	0.09	0.06	0.30
$x_1 = 3$	0.06	0.09	0.09	0.06	0.30
$p(x_2)$	0.20	0.30	0.30	0.20	

Weiterhin ergeben sich im Falle der Unabhängigkeit von ξ_1 und ξ_2 beispielsweise die bedingten WMFen $p(x_2|x_1)$ wie in Tabelle 5.7 dargestellt. Im Falle der Unabhängigkeit von ξ_1 und ξ_2 ändert sich die Verteilung von ξ_2 gegeben (oder im Wissen um) den Wert von ξ_1 also nicht und entspricht jeweils der Marginalverteilung von ξ_2 . Dies entspricht natürlich der Intuition der Unabhängigkeit von Ereignissen im Kontext elementarer Wahrscheinlichkeiten.

Tabelle 5.7 Bedingte WMF bei Annahme der Unabhängigkeit von ξ_1 und ξ_2

$p(x_2 x_1)$	$p(1 x_1)$	$p(2 x_1)$	$p(3 x_1)$	$p(4 x_1)$
$x_1 = 1$	$\frac{0.08}{0.40} = 0.2$	$\frac{0.12}{0.40} = 0.3$	$\frac{0.12}{0.40} = 0.3$	$\frac{0.08}{0.40} = 0.2$
$x_1 = 2$	$\frac{0.06}{0.30} = 0.2$	$\frac{0.09}{0.30} = 0.3$	$\frac{0.09}{0.30} = 0.3$	$\frac{0.06}{0.30} = 0.2$
$x_1 = 3$	$\frac{0.06}{0.30} = 0.2$	$\frac{0.09}{0.30} = 0.3$	$\frac{0.09}{0.30} = 0.3$	$\frac{0.06}{0.30} = 0.2$

△

Wir wollen abschließend den Begriff der unabhängigen Zufallsvariablen für mehr als zwei Zufallsvariablen definieren.

Definition 5.10 (n unabhängige Zufallsvariablen). $\xi := (\xi_1, \dots, \xi_n)$ sei ein n -dimensionaler Zufallsvektor mit Ergebnisraum $\mathcal{X} = \times_{i=1}^n \mathcal{X}_i$. Die n Zufallsvariablen $\xi_1, \dots, \xi_n$ heißen *unabhängig*, wenn für alle $S_i \subseteq \mathcal{X}_i, i = 1, \dots, n$ gilt, dass

$$\mathbb{P}(\xi_1 \in S_1, \dots, \xi_n \in S_n) = \prod_{i=1}^n \mathbb{P}(\xi_i \in S_i). \quad (5.33)$$

Wenn der Zufallsvektor eine n -dimensionale WMF oder WDF p mit marginalen WMFen oder WDFen $p_{\xi_i}, i = 1, \dots, n$ besitzt, dann ist die Unabhängigkeit von $\xi_1, \dots, \xi_n$ gleichbedeutend mit der Faktorisierung der gemeinsamen WMF oder WDF, also mit

$$p(\xi_1, \dots, \xi_n) = \prod_{i=1}^n p(x_i). \quad (5.34)$$

•

Es handelt bei Definition 5.10 also um eine direkte Generalisierung des zweidimensionalen Falls. Sind n Zufallsvariablen nicht nur unabhängig, sondern haben sie auch alle die gleiche Verteilung, so nennt man sie *unabhängig und identisch verteilt (u.i.v.)*.

Definition 5.11 (Unabhängig und identisch verteilte Zufallsvariablen). n Zufallsvariablen $\xi_1, \dots, \xi_n$ heißen *unabhängig und identisch verteilt (u.i.v.)*, wenn

- (1) $\xi_1, \dots, \xi_n$ unabhängige Zufallsvariablen sind, und
- (2) die Marginalverteilungen der ξ_i übereinstimmen, also gilt, dass

$$\mathbb{P}(\xi_i) = \mathbb{P}(\xi_j) \text{ für alle } 1 \leq i, j \leq n. \quad (5.35)$$

Wenn die Zufallsvariablen $\xi_1, \dots, \xi_n$ unabhängig und identisch verteilt sind und die i te Marginalverteilung $\mathbb{P}$ ist, so schreibt man auch

$$\xi_1, \dots, \xi_n \sim \mathbb{P}. \quad (5.36)$$

•

Man sagt kurz, dass $\xi_1, \dots, \xi_n$ *u.i.v.* sind. Im Englischen spricht man von *independent and identically distributed (i.i.d)* Zufallsvariablen. U.i.v. Zufallsvariablen spielen an vielen Stellen der probabilistischen Modellierung eine wichtige Rolle. So werden, wie wir an späterer Stelle sehen werden, additive Fehlerterme in probabilistischen Modellen meist durch u.i.v. Zufallsvariablen modelliert. Schließlich halten wir fest, dass n u.i.v. normalverteilte Zufallsvariablen als

$$\xi_1, \dots, \xi_n \sim N(\mu, \sigma^2) \quad (5.37)$$

geschrieben werden. In Kapitel 12 zeigen wir, wie die gemeinsame Verteilung von n u.i.v. normalverteilten Zufallsvariablen im Sinne eines Zufallsvektors beschaffen ist.

Selbstkontrollfragen

1. Geben Sie die Definition des Begriffs des Zufallsvektors wieder.
2. Geben Sie die Definition des Begriffs der multivariaten Verteilung eines Zufallsvektors wieder.
3. Geben Sie die Definition des Begriffs der multivariaten WMF wieder.
4. Geben Sie die Definition des Begriffs der multivariaten WDF wieder.
5. Geben Sie die Definition des Begriffs der univariaten Marginalverteilung eines Zufallsvektors wieder.
6. Wie berechnet man die WMF der i ten Komponente eines diskreten Zufallsvektors?
7. Wie berechnet man die WDF der i ten Komponente eines kontinuierlichen Zufallsvektors?
8. Geben Sie die Definition des Begriffs der Unabhängigkeit zweier Zufallsvariablen wieder.
9. Wie erkennt man an der gemeinsamen WMF oder WDF eines zweidimensionalen Zufallsvektors $\xi := (\xi_1, \xi_2)$, ob die Komponenten des Zufallsvektors unabhängig sind oder nicht?
10. Geben Sie die Definition des Begriffs der Unabhängigkeit von n Zufallsvariablen wieder.
11. Geben Sie die Definition des Begriffs der unabhängig und identisch verteilten Zufallsvariablen wieder.

Lösungen

1. Siehe Definition 5.1.
2. Siehe Definition 5.2
3. Siehe Definition 5.4.
4. Siehe Definition 5.5.
5. Siehe Definition 5.6.
6. Siehe Theorem 5.1. Man erhält die WMF der i ten Komponente eines diskreten Zufallsvektors durch Summation der Werte der WMF des Zufallsvektors über alle Komponenten des Zufallsvektors *außer* der i ten Komponente.
7. Siehe Theorem 5.1. Man erhält die WDF der i ten Komponente eines kontinuierlichen Zufallsvektors durch Integration der Werte der WDF des Zufallsvektors über alle Komponenten des Zufallsvektors *außer* der i ten Komponente.
8. Siehe Definition 5.9.
9. Man prüft, ob sich alle Werte der gemeinsamen WMF oder WDF $p(x_1, x_2)$ des Zufallsvektors durch Multiplikation der entsprechenden marginalen WMF oder WDF Werte $p(x_1)$ und $p(x_2)$ ergeben. Ist dies für alle $(x_1, x_2) \in \mathcal{X}_1 \times \mathcal{X}_2$ der Fall, so sind ξ_1 und ξ_2 unabhängig, ist dies nicht für alle $(x_1, x_2) \in \mathcal{X}_1 \times \mathcal{X}_2$, so sind ξ_1 und ξ_2 nicht unabhängig.
10. Siehe Definition 5.9.
11. Siehe Definition 5.11.

6 Erwartungswerte

In diesem Kapitel führen wir den Begriff des *Erwartungswerts* einer Zufallsvariable ein. Der Erwartungswert dient als eine einzige, skalare Kennzahl, die eine Wahrscheinlichkeitsverteilung zusammenfassend beschreibt und häufig als zentrale charakteristische Größe von Zufallsvariablen verwendet wird. Der Erwartungswert dient dabei als ein Maß der “durchschnittlichen Realisierung” einer Zufallsvariable und bildet die Grundlage für weitere Begriffsbildungen wie die der *Varianz* einer Zufallsvariable und die der *Kovarianz* zweier Zufallsvariablen im Folgenden. Wir ergänzen den Begriff des Erwartungswerts um seine Analoga in Bezug auf Zufallsvektoren und bedingte Verteilungen sowie um sein deskriptiv-statistisches Äquivalent, das sogenannte *Stichprobenmittel*.

6.1 Definitionen

Definition 6.1 (Erwartungswert einer Zufallsvariable). $(\Omega, \mathcal{A}, \mathbb{P})$ sei ein Wahrscheinlichkeitsraum und ξ sei eine Zufallsvariable. Dann ist der *Erwartungswert* von ξ definiert als

- $\mathbb{E}(\xi) := \sum_{x \in \mathcal{X}} x p(x)$, wenn $\xi : \Omega \rightarrow \mathcal{X}$ diskret mit WMF p ist.
- $\mathbb{E}(\xi) := \int_{-\infty}^{\infty} x p(x) dx$, wenn $\xi : \Omega \rightarrow \mathbb{R}$ kontinuierlich mit WDF p ist.

•

Der Erwartungswert ist also eine skalare Zusammenfassung der Verteilung einer Zufallsvariable. Eine Definition des Erwartungswertes, die ohne eine Fallunterscheidung in kontinuierliche und diskrete Zufallsvariablen auskommt, ist möglich, erfordert aber mit der Einführung des Lebesgue-Integrals einigen technischen Aufwand. Wir verweisen dafür auf die weiterführende Literatur (vgl. Schmidt (2009), Meintrup & Schäffler (2005)). Es ist wichtig anzuerkennen, dass ein Erwartungswert alleine aufgrund der Festlegung des Ergebnisraums und der Verteilung einer Zufallsvariable mithilfe einer WMF oder WDF bestimmt wird. Nichtsdestotrotz entspricht der Erwartungswert einer Zufallsvariable dem im langfristigen Mittel durchschnittlich zu erwartenden Wert der Zufallsvariable. Dieser Umstand wird unter dem Begriff des *Gesetzes der großen Zahlen* (vgl. Kapitel 10.1) formalisiert. Wir betrachten zunächst drei Beispiele für Definition 6.1.

Beispiel 6.1 (Erwartungswert einer diskreten Zufallsvariable). ξ sei eine Zufallsvariable mit Ergebnisraum $\mathcal{X} := \{-1, 0, 1\}$ und WMF

$$p(-1) := \frac{1}{4}, \quad p(0) := \frac{1}{2}, \quad p(1) := \frac{1}{4}. \quad (6.1)$$

Dann gilt

$$\mathbb{E}(\xi) = 0. \quad (6.2)$$

△

Beweis. Nach Definition 6.1 ergibt sich

$$\begin{aligned}
 \mathbb{E}(\xi) &= \sum_{x \in \mathcal{X}} xp(x) \\
 &= -1 \cdot p(-1) + 0 \cdot p(0) + 1 \cdot p(1) \\
 &= -1 \cdot \frac{1}{4} + 0 \cdot \frac{1}{2} + 1 \cdot \frac{1}{4} \\
 &= 0.
 \end{aligned} \tag{6.3}$$

□

Beispiel 6.2 (Erwartungswert einer Bernoulli Zufallsvariable). Es sei $\xi \sim \text{Bern}(\mu)$. Dann gilt $\mathbb{E}(\xi) = \mu$.

△

Beweis. ξ ist diskret mit $\mathcal{X} = \{0, 1\}$. Also gilt nach Definition 6.1

$$\begin{aligned}
 &= \sum_{x \in \{0, 1\}} x \text{Bern}(x; \mu) \\
 &= 0 \cdot \mu^0 (1 - \mu)^{1-0} + 1 \cdot \mu^1 (1 - \mu)^{1-1} \\
 &= 1 \cdot \mu^1 (1 - \mu)^0 \\
 &= \mu.
 \end{aligned} \tag{6.4}$$

□

Beispiel 6.3 (Erwartungswert einer normalverteilten Zufallsvariable). Es sei $\xi \sim N(\mu, \sigma^2)$. Dann gilt $\mathbb{E}(\xi) = \mu$.

△

Beweis. Wir verzichten auf einen Beweis.

□

Intuitiv mag man sich Definition 6.1 wie in Beispiel 6.4 dargestellt erklären.

Beispiel 6.4 (Erwartungswert und Mittelwert). Wir betrachten eine diskrete Zufallsvariable ξ mit Ergebnisraum $\{1, 2, 3\}$ und WMF definiert durch

$$p(1) := \frac{1}{4}, \quad p(2) := \frac{1}{4}, \quad p(3) := \frac{1}{2}. \tag{6.5}$$

Es gilt also

$$\begin{aligned}
 \mathbb{E}(\xi) &= \sum_{x \in \{1, 2, 3\}} xp(x) \\
 &= 1 \cdot p(1) + 2 \cdot p(2) + 3 \cdot p(3) \\
 &= 1 \cdot \frac{1}{4} + 2 \cdot \frac{1}{4} + 3 \cdot \frac{1}{2} \\
 &= \frac{9}{4}.
 \end{aligned} \tag{6.6}$$

Stellen wir uns nun $n = 100$ unabhängige Realisierungen $x_1, \dots, x_{100}$ der Zufallsvariable vor. Gemäß ihrer WMF würden wir in etwa 25 Einsen, 25 Zweien und 50 Dreien erwarten. Nehmen wir konkret

an, wir hätten 27 Einsen, 22 Zweien und 51 Dreien vorliegen. Der Mittelwert dieser Zahlen ergibt sich dann zu (vgl. [Summen](#), [Produkte](#), [Potenzen \(PDWP\)](#))

$$\begin{aligned}
 \bar{x} &= \frac{1}{100} \sum_{i=1}^n x_i \\
 &= \frac{1}{100} (27 \cdot 1 + 22 \cdot 2 + 51 \cdot 3) \\
 &= \frac{1}{100} (1 \cdot 27 + 2 \cdot 22 + 3 \cdot 51) \\
 &= 1 \cdot \frac{27}{100} + 2 \cdot \frac{22}{100} + 3 \cdot \frac{51}{100} \\
 &= 1 \cdot 0.27 + 2 \cdot 0.22 + 3 \cdot 0.51 \\
 &= 2.24.
 \end{aligned} \tag{6.7}$$

Versteht man in dieser Rechnung die Faktoren $0.27 \approx \frac{1}{4}$, $0.22 \approx \frac{1}{4}$ und $0.51 \approx \frac{1}{2}$ als Schätzungen $\hat{p}(1)$, $\hat{p}(2)$ und $\hat{p}(3)$ für die WMF Werte $p(1)$, $p(2)$ und $p(3)$, so fällt mit

$$\bar{x} = \sum_{x \in \{1,2,3\}} x \hat{p}(x) \approx \sum_{x \in \{1,2,3\}} x p(x) = \mathbb{E}(\xi) \tag{6.8}$$

die formale Ähnlichkeit der Bildung eines Mittelwerts von Realisierungen einer diskreten Zufallsvariablen und zwischen der Definition des Erwartungswerts einer eben solchen direkt ins Auge.

△

In Abgrenzung zu Definition 6.1 definieren wir aufbauend auf Beispiel 6.4 das sogenannte *Stichprobenmittel*.

Definition 6.2 (Stichprobenmittel). $\xi_1, \dots, \xi_n$ seien Zufallsvariablen. Dann nennt man $\xi_1, \dots, \xi_n$ auch eine *Stichprobe*. Das *Stichprobenmittel* von $\xi_1, \dots, \xi_n$ ist definiert als der arithmetische Mittelwert

$$\bar{\xi} := \frac{1}{n} \sum_{i=1}^n \xi_i. \tag{6.9}$$

•

Es ist zentral zu erkennen, dass $\mathbb{E}(\xi)$ eine feste Kennzahl einer Zufallsvariable ξ ist und insbesondere selbst keine Zufallsvariable ist. $\bar{\xi}$ hingegen ist eine Kennzahl einer Stichprobe $\xi_1, \dots, \xi_n$ und als Funktion von Zufallsvariablen damit selbst eine Zufallsvariable. In Beispiel 6.4 modelliert man beispielsweise jede Realisierung x_i für $i = 1, \dots, n$ als eine Realisierung der Zufallsvariable $\xi_i := \xi$ für $i = 1, \dots, n$. Da $\bar{\xi}$ eine skalierte Summe von Zufallsvariablen ist, ist $\bar{\xi}$ auch selbst eine Zufallsvariable. Realisierungen der Zufallsvariable $\bar{\xi}$ bezeichnen wir wie im Folgenden mit $\bar{x}$.

Beispiel 6.5 (Stichprobenmittel). Als Beispiel für die Realisation eines Stichprobenmittels betrachten wir die in Tabelle 6.1 gezeigten Realisationen der Zufallsvariablen $\xi_1, \dots, \xi_{10} \sim N(1, 2)$.

Tabelle 6.1 Stichprobenrealisation

x_1	x_2	x_3	x_4	x_5	x_6	x_7	x_8	x_9	x_{10}
0.54	1.01	-3.28	0.35	2.75	-0.51	2.32	1.49	0.96	1.25

Die Stichprobenmittelrealisation ist

$$\bar{x} = \frac{1}{10} \sum_{i=1}^{10} x_i = \frac{6.88}{10} = 0.68. \quad (6.10)$$

△

In Verallgemeinerung von Definition 6.1 gilt folgende Definition für den Erwartungswert einer Funktion einer Zufallsvariable.

Definition 6.3 (Erwartungswert einer Funktion einer Zufallsvariable). $(\Omega, \mathcal{A}, \mathbb{P})$ sei ein Wahrscheinlichkeitsraum, ξ sei eine Zufallsvariable mit Ergebnisraum $\mathcal{X}$ und $f : \mathcal{X} \rightarrow \mathcal{Z}$ sei eine Funktion mit Zielmenge $\mathcal{Z}$. Dann ist der *Erwartungswert der Funktion f der Zufallsvariable ξ* definiert als

- $\mathbb{E}(f(\xi)) := \sum_{x \in \mathcal{X}} f(x) p(x)$, wenn $\xi : \Omega \rightarrow \mathcal{X}$ diskret mit WMF p ist,
- $\mathbb{E}(f(\xi)) := \int_{-\infty}^{\infty} f(x) p(x) dx$, wenn $\xi : \Omega \rightarrow \mathbb{R}$ kontinuierlich mit WDF p ist.

•

Der Erwartungswert einer Zufallsvariable ergibt sich anhand von Definition 6.3 als der Spezialfall, in dem gilt, dass

$$f : \mathcal{X} \rightarrow \mathcal{Z}, x \mapsto f(x) := x. \quad (6.11)$$

In der englischsprachigen Literatur ist Definition 6.3 auch als “Law of the unconscious statistician” bekannt und wird oft auch direkt zur Definition des Erwartungswertes herangezogen. Folgendes Theorem gibt ein erstes Beispiel für den Erwartungswert einer Funktion einer Zufallsvariable.

Theorem 6.1 (Erwartungswert bei linear-affiner Transformation einer Zufallsvariable). ξ sei eine Zufallsvariable mit Ergebnisraum $\mathcal{X}$ und es sei

$$f : \mathcal{X} \rightarrow \mathcal{Z}, x \mapsto f(x) := ax + b \text{ für } a, b \in \mathbb{R} \quad (6.12)$$

eine linear-affine Funktion. Dann gilt

$$\mathbb{E}(f(\xi)) = \mathbb{E}(a\xi + b) = a\mathbb{E}(\xi) + b. \quad (6.13)$$

◦

Beweis. Die Aussage des Theorems folgt mit den Linearitätseigenschaften von Summen und Integralen. Wir betrachten den Fall einer diskreten Zufallsvariable ξ mit endlichem Ergebnisraum $\mathcal{X}$ und WMF p . Es gilt

$$\begin{aligned} \mathbb{E}(f(\xi)) &= \mathbb{E}(a\xi + b) \\ &= \sum_{x \in \mathcal{X}} (ax + b)p(x) \\ &= \sum_{x \in \mathcal{X}} axp(x) + bp(x) \\ &= a \sum_{x \in \mathcal{X}} xp(x) + b \sum_{x \in \mathcal{X}} p(x) \\ &= a\mathbb{E}(\xi) + b. \end{aligned} \quad (6.14)$$

□

Betrachtet man anstelle einer Zufallsvariable einen Zufallsvektor, so erweitert sich die Definition des Erwartungswerts wie folgt.

Definition 6.4 (Erwartungswert eines Zufallsvektors). ξ sei ein n -dimensionaler Zufallsvektor. Dann ist der *Erwartungswert von ξ* definiert als der n -dimensionale reelle Vektor

$$\mathbb{E}(\xi) := \begin{pmatrix} \mathbb{E}(\xi_1) \\ \vdots \\ \mathbb{E}(\xi_n) \end{pmatrix}. \quad (6.15)$$

•

Der Erwartungswert eines Zufallsvektors ist also der Vektor der Erwartungswerte seiner Komponenten. Die Berechnung eines Erwartungswerts eines Zufallsvektors ist damit auf die Bestimmung der Erwartungswerte der den Zufallsvektor konstituierenden Zufallsvektoren bezüglich ihrer marginalen Verteilungen zurückgeführt. In Analogie zu Definition 6.3 definiert man für die Funktion eines Zufallsvektors den Erwartungswert dieser Transformation wie folgt.

Definition 6.5 (Erwartungswert einer Funktion eines Zufallsvektors). $(\Omega, \mathcal{A}, \mathbb{P})$ sei ein Wahrscheinlichkeitsraum, ξ sei ein Zufallsvektor mit Ergebnisraum $\mathcal{X}$ und $f : \mathcal{X} \rightarrow \mathcal{Z}$ sei eine Funktion mit Zielmenge $\mathcal{Z}$. Dann ist der *Erwartungswert der Funktion f des Zufallsvektors ξ* definiert als

- $\mathbb{E}(f(\xi)) := \sum_{x \in \mathcal{X}} f(x) p(x)$, wenn $\xi : \Omega \rightarrow \mathcal{X}$ diskret mit WMF p ist,
- $\mathbb{E}(f(\xi)) := \int_{-\infty}^{\infty} f(x) p(x) dx$, wenn $\xi : \Omega \rightarrow \mathbb{R}$ kontinuierlich mit WDF p ist.

•

6.2 Eigenschaften

Folgende Aussagen sind insbesondere beim Rechnen mit Stichproben relevant.

Theorem 6.2 (Erwartungswert bei linear-affiner Kombination von Zufallsvariablen). ξ sei ein n -dimensionaler Zufallsvektor mit Komponenten $\xi_1, \dots, \xi_n$ und Ergebnisraum $\mathcal{X} := \mathcal{X}_1 \times \dots \times \mathcal{X}_n$. Weiterhin sei

$$f : \mathcal{X} \rightarrow \mathcal{Z}, x \mapsto f(x) := a_0 + \sum_{i=1}^n a_i x_i \text{ für } a_0, \dots, a_n \in \mathbb{R}. \quad (6.16)$$

eine linear-affine Kombination der Komponenten von ξ . Dann gilt

$$\mathbb{E}(f(\xi)) = \mathbb{E} \left(a_0 + \sum_{i=1}^n a_i \xi_i \right) = a_0 + \sum_{i=1}^n a_i \mathbb{E}(\xi_i). \quad (6.17)$$

◦

Beweis. Wie unten gezeigt, folgt das Theorem mit den Linearitätseigenschaften von Summen und Integralen, sowie Fubini's Theorem zur Vertauschung von Summations- bzw. Integrationsreihenfolge. Wir beschränken uns auf den diskreten Fall, wobei wir zur Vereinfachung der Notation $\sum_{x_i \in \mathcal{X}_i}$ als $\sum_{x_i}$ schreiben. Es gilt dann

$$\begin{aligned}
\mathbb{E}(f(\xi)) &= \mathbb{E}\left(a_0 + \sum_{i=1}^n a_i \xi_i\right) \\
&= \mathbb{E}(a_0 + a_1 \xi_1 + \dots + a_n \xi_n) \\
&= \sum_{x_1} \dots \sum_{x_n} (a_0 + a_1 x_1 + \dots + a_n x_n) p(x_1, \dots, x_n) \\
&= \sum_{x_1} \dots \sum_{x_n} a_0 p(x_1, \dots, x_n) + a_1 x_1 p(x_1, \dots, x_n) + \dots + a_n x_n p(x_1, \dots, x_n) \\
&= \sum_{x_1} \dots \sum_{x_n} a_0 p(x_1, \dots, x_n) + \sum_{x_1} \dots \sum_{x_n} a_1 x_1 p(x_1, \dots, x_n) + \dots + \sum_{x_1} \dots \sum_{x_n} a_n x_n p(x_1, \dots, x_n) \\
&= a_0 \sum_{x_1} \dots \sum_{x_n} p(x_1, \dots, x_n) + a_1 \sum_{x_1} \dots \sum_{x_n} x_1 p(x_1, \dots, x_n) + \dots + a_n \sum_{x_1} \dots \sum_{x_n} x_n p(x_1, \dots, x_n) \\
&= a_0 + a_1 \sum_{x_1} x_1 \sum_{x_2} \dots \sum_{x_n} p(x_1, \dots, x_n) + \dots + a_n \sum_{x_n} x_n \sum_{x_{n-1}} \dots \sum_{x_1} p(x_1, \dots, x_n) \\
&= a_0 + a_1 \sum_{x_1} x_1 p(x_1) + \dots + a_n \sum_{x_n} x_n p(x_n) \\
&= a_0 + a_1 \mathbb{E}(\xi_1) + \dots + a_n \mathbb{E}(\xi_n) \\
&= a_0 + \sum_{i=1}^n a_i \mathbb{E}(\xi_i)
\end{aligned} \tag{6.18}$$

Analog folgt das Resultat für einen kontinuierlichen Zufallsvektor. $\square$

Theorem 6.3 (Erwartungswert des Produkts unabhängiger Zufallsvariablen). ξ sei ein n -dimensionaler Zufallsvektor mit unabhängigen Komponenten $\xi_1, \dots, \xi_n$ und Ergebnisraum $\mathcal{X} := \mathcal{X}_1 \times \dots \times \mathcal{X}_n$. Weiterhin sei

$$f : \mathcal{X} \rightarrow \mathcal{Z}, x \mapsto f(x) := \prod_{i=1}^n x_i. \tag{6.19}$$

das Produkt der Komponenten von ξ . Dann gilt

$$\mathbb{E}(f(\xi)) = \prod_{i=1}^n \mathbb{E}(\xi_i). \tag{6.20}$$

◦

Beweis. Wie unten gezeigt, folgt das Theorem mit den Linearitätseigenschaften von Summen und Integralen, sowie Fubini's Theorem zur Vertauschung von Summations- bzw. Integrationsreihenfolge. Wir beschränken uns auf den diskreten Fall, wobei wir zur Vereinfachung der Notation $\sum_{x_i \in \mathcal{X}_i}$ als $\sum_{x_i}$ schreiben. Weil die Komponenten von $\xi_1, \dots, \xi_n$ als unabhängig vorausgesetzt sind, gilt zunächst für die WMF des Zufallsvektors

$$p(x_1, \dots, x_n) = \prod_{i=1}^n p(x_i). \tag{6.21}$$

Weiterhin gilt also

$$\begin{aligned}
 \mathbb{E} \left(\prod_{i=1}^n \xi_i \right) &= \sum_{x_1} \cdots \sum_{x_n} \left(\prod_{i=1}^n x_i \right) p(x_1, \dots, x_n) \\
 &= \sum_{x_1} \cdots \sum_{x_n} \prod_{i=1}^n x_i \prod_{i=1}^n p(x_i) \\
 &= \sum_{x_1} \cdots \sum_{x_n} \prod_{i=1}^n x_i p(x_i) \\
 &= \prod_{i=1}^n \sum_{x_i} x_i p(x_i) \\
 &= \prod_{i=1}^n \mathbb{E}(\xi_i).
 \end{aligned} \tag{6.22}$$

□

6.3 Bedingter Erwartungswert

Betrachtet man bei der Bildung eines Erwartungswertes nun anstelle der Verteilung einer Zufallsvariable die bedingte Verteilung einer Zufallsvariable, so ist man entsprechend auf den Begriff des bedingten Erwartungswerts geführt.

Definition 6.6 (Bedingter Erwartungswert). Gegeben sei ein Zufallsvektor $\xi := (\xi_1, \xi_2)$ mit Ergebnisraum $\mathcal{X} := \mathcal{X}_1 \times \mathcal{X}_2$, WMF oder WDF $p(x_1, x_2)$ und bedingter WMF oder WDF $p(x_1|x_2)$ für alle $x_2 \in \mathcal{X}_2$. Dann ist der *bedingte Erwartungswert* von ξ_1 gegeben $\xi_2 = x_2$ definiert als

- $\mathbb{E}(\xi_1|\xi_2 = x_2) := \sum_{x_1 \in \mathcal{X}_1} x_1 p(x_1|x_2)$, wenn ξ ein diskreter Zufallsvektor ist.
- $\mathbb{E}(\xi_1|\xi_2 = x_2) := \int_{\mathcal{X}_1} x_1 p(x_1|x_2) dx_1$, wenn ξ ein kontinuierlicher Zufallsvektor ist.

•

Der bedingte Erwartungswert einer Zufallsvariable ist also der Erwartungswert einer Zufallsvariable in einer bedingten Verteilung. Man beachte, dass wir in Definition 6.6 den bedingten Erwartungswert für einen festen Wert x_2 von ξ_2 definiert haben. Bei einem festen Wert x_2 von ξ_2 ist $\mathbb{E}(\xi_1|\xi_2 = x_2)$ damit ein fester Wert und durch Austauschen der Subskripte erhält man entsprechend $\mathbb{E}(\xi_2|\xi_1 = x_1)$.

Allgemein ist $\mathbb{E}(\xi_1|\xi_2)$ allerdings eine Zufallsvariable, da ξ_2 eine Zufallsvariable ist und nur mit einer gewissen Wahrscheinlichkeit einen Wert $\xi_2 = x_2$ annimmt. Wir werden später sehen, dass analog zu Definition 6.6 bedingte Varianzen, bedingte Kovarianzen und bedingte Korrelationen definiert werden. In der Psychologie ist der Begriff des bedingten Erwartungswerts zentral, denn in der klassischen Testtheorie sind die wahren Werte von Personen bei Testmessungen als bedingte Erwartungswerte definiert. Zur Verdeutlichung von Definition 6.6 betrachten wir ein Beispiel für einen diskreten Zufallsvektor.

Beispiel 6.6 (Bedingter Erwartungswert eines diskreten Zufallsvektors). Für einen zweidimensionalen Zufallsvektor $\xi := (\xi_1, \xi_2)$, der Werte in $\mathcal{X} := \mathcal{X}_1 \times \mathcal{X}_2$ mit $\mathcal{X}_1 := \{1, 2, 3, 4\}$ und $\mathcal{X}_2 = \{1, 2, 3\}$ annahme, seien bedingte WMFen für $p(x_1|x_2)$ für alle $x_1 \in \mathcal{X}_1$ wie in Tabelle 6.2 spezifiziert

Tabelle 6.2 Bedingte Wahrscheinlichkeitsverteilung von x_1 gegeben x_2

$p(x_1 x_2)$	$x_2 = 1$	$x_2 = 2$	$x_2 = 3$
$p(x_1 = 1 x_2)$	$\frac{1}{4}$	$\frac{1}{3}$	0
$p(x_1 = 2 x_2)$	0	$\frac{2}{3}$	$\frac{1}{3}$
$p(x_1 = 3 x_2)$	$\frac{1}{2}$	0	$\frac{1}{3}$
$p(x_1 = 4 x_2)$	$\frac{1}{4}$	0	$\frac{1}{3}$

Dann ergeben sich die bedingten Erwartungswerte

$$\begin{aligned}
\mathbb{E}(\xi_1|\xi_2 = 1) &= \sum_{x_1 \in \mathcal{X}_1} x_1 p(x_1|x_2 = 1) = 1 \cdot \frac{1}{4} + 2 \cdot 0 + 3 \cdot \frac{1}{2} + 4 \cdot \frac{1}{4} = \frac{11}{4} \\
\mathbb{E}(\xi_1|\xi_2 = 2) &= \sum_{x_1 \in \mathcal{X}_1} x_1 p(x_1|x_2 = 2) = 1 \cdot \frac{1}{3} + 2 \cdot \frac{2}{3} + 3 \cdot 0 + 4 \cdot 0 = \frac{5}{3} \\
\mathbb{E}(\xi_1|\xi_2 = 3) &= \sum_{x_1 \in \mathcal{X}_1} x_1 p(x_1|x_2 = 3) = 1 \cdot 0 + 2 \cdot \frac{1}{3} + 3 \cdot \frac{1}{3} + 4 \cdot \frac{1}{3} = \frac{8}{3}.
\end{aligned} \tag{6.23}$$

△

Das folgende Theorem, der sogenannte *Satz vom iterierten Erwartungswert*, stellt einen Zusammenhang zwischen dem (marginalen) Erwartungswert einer Zufallsvariable und dem bedingten Erwartungswert dieser Zufallsvariable her. Das Theorem wird manchmal auch als *Satz vom totalen Erwartungswert* bezeichnet.

Theorem 6.4 (Satz vom iterierten Erwartungswert). *Gegeben sei ein Zufallsvektor $\xi := (\xi_1, \xi_2)$. Dann gilt*

$$\mathbb{E}(\xi_1) = \mathbb{E}(\mathbb{E}(\xi_1|\xi_2)). \tag{6.24}$$

◦

Beweis. Wir beschränken uns auf den Beweis für einen diskreten Zufallsvektor, der Beweis für einen kontinuierlichen Zufallsvektor folgt analog. Es gilt

$$\begin{aligned}
\mathbb{E}(\xi_1) &= \sum_{x_1 \in \mathcal{X}_1} x_1 p(x_1) \\
&= \sum_{x_1 \in \mathcal{X}_1} x_1 \sum_{x_2 \in \mathcal{X}_2} p(x_1, x_2) \\
&= \sum_{x_1 \in \mathcal{X}_1} x_1 \sum_{x_2 \in \mathcal{X}_2} p(x_1|x_2)p(x_2) \\
&= \sum_{x_1 \in \mathcal{X}_1} \sum_{x_2 \in \mathcal{X}_2} x_1 p(x_1|x_2)p(x_2) \\
&= \sum_{x_2 \in \mathcal{X}_2} \sum_{x_1 \in \mathcal{X}_1} x_1 p(x_1|x_2)p(x_2) \\
&= \sum_{x_2 \in \mathcal{X}_2} \mathbb{E}(\xi_1|\xi_2 = x_2)p(x_2) \\
&= \mathbb{E}(\mathbb{E}(\xi_1|\xi_2)).
\end{aligned} \tag{6.25}$$

□

Offenbar bezeichnen die verschiedenen Erwartungswerte in Theorem 6.4 Erwartungswert bezüglich unterschiedlicher Verteilungen: der Erwartungswert auf der linken Seite der Gleichung bezeichnet den Erwartungswert bezüglich der marginalen Verteilung von ξ_1 , der äußere Erwartungswert auf der rechten Seite der Gleichung bezeichnet den Erwartungswert bezüglich der marginalen Verteilung von ξ_2 und der innere Erwartungswert auf der rechten Seite der Gleichung bezeichnet den bedingten Erwartungswert von ξ_1 gegeben ξ_2 .

Selbstkontrollfragen

1. Geben Sie die Definition des Erwartungswerts einer Zufallsvariable wieder.
2. Erläutern Sie den Begriff des Erwartungswerts einer Zufallsvariable.
3. Berechnen Sie den Erwartungswert einer Bernoulli-Zufallsvariable.
4. Geben Sie die Definition des Begriffs der Stichprobe wieder.
5. Geben Sie die Definition des Stichprobenmittels wieder.
6. Erläutern Sie die Unterschiede zwischen einem Erwartungswert und einem Stichprobenmittel.
7. Geben Sie die Definition des Erwartungswerts einer Funktion einer Zufallsvariable wieder.
8. Geben Sie das Theorem zum Erwartungswert bei linear-affiner Transformation einer Zufallsvariable wieder.
9. Geben Sie die Definition des Erwartungswerts eines Zufallsvektors wieder.
10. Geben Sie die Definition des Erwartungswerts einer Funktion eines Zufallsvektors wieder.
11. Geben Sie das Theorem zum Erwartungswert bei linear-affiner Kombination von Zufallsvariablen wieder.
12. Geben Sie das Theorem zum Erwartungswert des Produkts unabhängiger Zufallsvariablen wieder.

Lösungen

1. Siehe Definition 6.1.
2. Siehe Erläuterungen in der Nachfolge von Definition 6.1, insbesondere auch Beispiel 6.4.
3. Siehe Beispiel 6.2.
4. Siehe Definition 6.2.
5. Siehe Definition 6.2.
6. Siehe Erläuterungen zu Beispiel 6.4, Definition 6.2 und Beispiel 6.5.
7. Siehe Definition 6.3.
8. Siehe Theorem 6.1.
9. Siehe Definition 6.4.
10. Siehe Definition 6.5.
11. Siehe Theorem 6.2.
12. Siehe Theorem 6.3.

7 Varianzen

In diesem Kapitel führen wir den Begriff der *Varianz* einer Zufallsvariable ein. Wie der Erwartungswert dient die Varianz als eine einzige, skalare Kennzahl, die eine Wahrscheinlichkeitsverteilung zusammenfassend beschreibt und häufig als zentrale charakteristische Größe von Zufallsvariablen verwendet wird. Die Varianz dient dabei als ein Maß für die “Variabilität” einer Zufallsvariable. Letztlich handelt es sich bei der Varianz einer Zufallsvariable um eine spezielle Kovarianz (vgl. Kapitel 8), nämlich die Kovarianz einer Zufallsvariable mit sich selbst. Eng verwandt mit dem Begriff der Varianz ist der Begriff der Standardabweichung, den wir parallel einführen wollen. Wir ergänzen diese Begriffe vorliegenden Kapitel durch ihre deskriptiv-statistischen Äquivalente, die sogenannte *Stichprobenvarianz* und *Stichprobenstandardabweichung* sowie ihr Auftreten in bedingten Verteilungen.

7.1 Definition

Definition 7.1 (Varianz und Standardabweichung). ξ sei eine Zufallsvariable mit endlichem Erwartungswert $\mathbb{E}(\xi)$. Dann ist die *Varianz von ξ* definiert als

$$\mathbb{V}(\xi) := \mathbb{E}((\xi - \mathbb{E}(\xi))^2) \quad (7.1)$$

und die *Standardabweichung von ξ* ist definiert als

$$\mathbb{S}(\xi) := \sqrt{\mathbb{V}(\xi)}. \quad (7.2)$$

•

Die Varianz einer Zufallsvariable ξ mit Ergebnisraum $\mathcal{X}$ ist nach Definition 6.3 also der Erwartungswert der Funktion

$$f : \mathcal{X} \rightarrow \mathbb{R}, x \mapsto f(x) := (x - \mathbb{E}(\xi))^2 \quad (7.3)$$

und damit die erwartete quadrierte Abweichung einer Zufallsvariable von ihrem Erwartungswert. Die Quadrierung der Abweichung der Zufallsvariable von ihrem Erwartungswert ist dabei nötig, da andernfalls mit Theorem 6.1 immer gelten würde, dass

$$\mathbb{E}(\xi - \mathbb{E}(\xi)) = \mathbb{E}(\xi) - \mathbb{E}(\xi) = 0. \quad (7.4)$$

Intuitiv misst die Varianz also die *Streuung* oder *Variabilität* einer Zufallsvariable. Insbesondere besagt die in Kapitel 9 genauer diskutierte *Chebyshev Ungleichung*, dass

$$\mathbb{P}(|\xi - \mathbb{E}(\xi)| \geq x) \leq \frac{\mathbb{V}(\xi)}{x^2}. \quad (7.5)$$

Mit der Chebyshev Ungleichung gelten beispielsweise, dass

$$\mathbb{P}(|\xi - \mathbb{E}(\xi)| \geq 2\sqrt{\mathbb{V}(\xi)}) \leq \frac{\mathbb{V}(\xi)}{(2\sqrt{\mathbb{V}(\xi)})^2} = \frac{1}{4} \quad (7.6)$$

und

$$\mathbb{P}(|\xi - \mathbb{E}(\xi)| \geq 3\sqrt{\mathbb{V}(\xi)}) \leq \frac{\mathbb{V}(\xi)}{(3\sqrt{\mathbb{V}(\xi)})^2} = \frac{1}{9}. \quad (7.7)$$

Für eine Zufallsvariable gilt also immer, dass die Wahrscheinlichkeit für eine absolute Abweichung vom doppelten ihrer Standardabweichung höchstens $1/4$ ist, also frequentistisch betrachtet nur für etwa ein Viertel ihrer Realisierungen zutrifft, und die Wahrscheinlichkeit für eine absolute Abweichung vom dreifachen ihrer Standardabweichung höchstens $1/9$ ist, also frequentistisch betrachtet nur für etwa ein Zehntel ihrer Realisierungen zutrifft, jeweils unabhängig davon, von welcher genauen Form die Verteilung der Zufallsvariable ist. Neben der Varianz gibt es allerdings viele weitere Maße für die Variabilität von Zufallsvariablen. Hier seien die *erwartete absolute Abweichung* einer Zufallsvariable von ihrem Erwartungswert

$$\mathbb{A}(\xi) := \mathbb{E}(|\xi - \mathbb{E}(\xi)|) \quad (7.8)$$

und die sogenannte *Entropie* einer Zufallsvariable

$$\mathbb{H}(\xi) := -\mathbb{E}(\ln p(x)) \quad (7.9)$$

genannt. Wir verdeutlichen die Definition der Varianz in Definition 7.1 zunächst an einigen Beispielen.

Beispiel 7.1 (Varianz einer diskreten Zufallsvariable). ξ sei eine Zufallsvariable mit Ergebnisraum $\mathcal{X} := \{-1, 0, 1\}$ und WMF

$$p(-1) = \frac{1}{4}, \quad p(0) = \frac{1}{2}, \quad p(1) = \frac{1}{4}. \quad (7.10)$$

Dann gilt

$$\mathbb{V}(\xi) = \frac{1}{2}. \quad (7.11)$$

△

Beweis. Nach Definition 7.1 ergibt sich mit dem in Beispiel 6.1 bestimmten Erwartungswert derselben Zufallsvariable

$$\begin{aligned} \mathbb{V}(\xi) &= \mathbb{E}((\xi - \mathbb{E}(\xi))^2) \\ &= \mathbb{E}((\xi - 0)^2) \\ &= \mathbb{E}(\xi^2) \\ &= \sum_{x \in \mathcal{X}} x^2 p(x) \\ &= (-1)^2 \cdot p(-1) + 0^2 \cdot p(0) + 1^2 \cdot p(1) \\ &= 1 \cdot \frac{1}{4} + 0 \cdot \frac{1}{2} + 1 \cdot \frac{1}{4} \\ &= \frac{1}{2}. \end{aligned} \quad (7.12)$$

□

Beispiel 7.2 (Varianz einer Bernoulli-Zufallsvariable). Es sei $\xi \sim \text{Bern}(\mu)$. Dann ist die Varianz von ξ gegeben durch

$$\mathbb{V}(\xi) = \mu(1 - \mu). \quad (7.13)$$

△

Beweis. ξ ist eine diskrete Zufallsvariable und es gilt $\mathbb{E}(\xi) = \mu$. Also gilt

$$\begin{aligned} \mathbb{V}(\xi) &= \mathbb{E}((\xi - \mu)^2) \\ &= \sum_{x \in \{0,1\}} (x - \mu)^2 \text{Bern}(x; \mu) \\ &= (0 - \mu)^2 \mu^0 (1 - \mu)^{1-0} + (1 - \mu)^2 \mu^1 (1 - \mu)^{1-1} \\ &= \mu^2 (1 - \mu) + (1 - \mu)^2 \mu \\ &= (\mu^2 + (1 - \mu)\mu) (1 - \mu) \\ &= (\mu^2 + \mu - \mu^2) (1 - \mu) \\ &= \mu(1 - \mu). \end{aligned} \quad (7.14)$$

□

Beispiel 7.3 (Varianz einer normalverteilten Zufallsvariable). Es sei $\xi \sim N(\mu, \sigma^2)$. Dann ist die Varianz von ξ gegeben durch

$$\mathbb{V}(\xi) = \sigma^2. \quad (7.15)$$

△

Beweis. Wir verzichten auf einen Beweis. □

Analog zum Begriff des Stichprobenmittels definiert man die deskriptiv-statistischen Äquivalente von zu Definition 7.1 wie folgt.

Definition 7.2 (Stichprobenvarianz und Stichprobenstandardabweichung). $\xi_1, \dots, \xi_n$ seien Zufallsvariablen und $\bar{\xi}$ sei ihr Stichprobenmittel. Die *Stichprobenvarianz* von $\xi_1, \dots, \xi_n$ ist definiert als

$$S^2 := \frac{1}{n-1} \sum_{i=1}^n (\xi_i - \bar{\xi})^2 \quad (7.16)$$

und die *Stichprobenstandardabweichung* von $\xi_1, \dots, \xi_n$ ist definiert als

$$S := \sqrt{S^2}. \quad (7.17)$$

•

Wie im Kontext des Stichprobenmittels ist es zentral zu erkennen, dass $\mathbb{V}(\xi)$ und $\mathbb{S}(\xi)$ Kennzahlen einer Zufallsvariable ξ sind, wohingegen S^2 bzw. S Kennzahlen einer Stichprobe $\xi_1, \dots, \xi_n$ sind. Da S^2 und S Funktionen von Zufallsvariablen sind, sind S^2 bzw. S auch selbst Zufallsvariablen. Realisierungen von S^2 und S bezeichnen wir s^2 bzw. s .

Beispiel 7.4 (Stichprobenvarianz und Stichprobenstandardabweichung). Als Beispiel für die Realisationen einer Stichprobenvarianz bzw. einer Stichprobenstandardabweichung betrachten wir erneut die in Tabelle 7.1 gezeigten Realisationen der Zufallsvariablen $\xi_1, \dots, \xi_{10} \sim N(1, 2)$ mit Stichprobenmittelrealisation $\bar{x} = 0.68$.

Tabelle 7.1 Stichprobenrealisation

x_1	x_2	x_3	x_4	x_5	x_6	x_7	x_8	x_9	x_{10}
0.54	1.01	-3.28	0.35	2.75	-0.51	2.32	1.49	0.96	1.25

Die Stichprobenvarianzrealisation ist dann

$$s^2 = \frac{1}{9} \sum_{i=1}^{10} (x_i - \bar{x})^2 = \frac{1}{9} \sum_{i=1}^{10} (x_i - 0.68)^2 = \frac{25.37}{9} = 2.82 \quad (7.18)$$

und die Stichprobenstandardabweichungsrealisation entsprechend

$$s = \sqrt{s^2} = \sqrt{2.82} = 1.68. \quad (7.19)$$

△

Die Begriffe der Varianz und Standardabweichung sind nach Definition 7.1 offenbar äquivalent zueinander, da die eine direkt aus der anderen durch Wurzelziehen bzw. Quadrieren hervorgeht. Die Varianz ist historisch eng sowohl mit dem Exponentialargument der Normalverteilung als auch mit den Quadratsummen der Varianzanalyse verwoben und deshalb in der Modellbildung oft leichter zu handhaben als die Standardabweichung.

Sowohl die Varianz als auch die Stichprobenvarianz messen die Variabilität einer Zufallsvariable allerdings in quadrierten Einheiten. Ein Beispiel hierfür ist die Berechnung der Stichprobenvarianz in Beispiel 7.4, wenn man sich die Realisierungen in Tabelle 7.1 als Längenmessungen in Metern (m) denkt. Nach der Definition 7.2 wird die Einheit bei Berechnung der Stichprobenvarianz dann quadriert,

$$s^2 = \frac{1}{9} \sum_{i=1}^{10} (x_i \text{ m} - 0.68 \text{ m})^2 = \frac{1}{9} \cdot 25.37 \text{ m}^2 = 2.82 \text{ m}^2. \quad (7.20)$$

Das resultierende Maß für die Variabilität hätte somit die Einheit einer Fläche (m^2), obwohl die ursprünglichen Daten Längen in Meter (m) darstellen. Das Wurzelziehen korrigiert die Einheiten zurück auf die Einheit der Daten und liefert als Standardabweichung dann ein Variabilitätsmaß in der ursprünglichen Einheit,

$$s = \sqrt{2.82 \text{ m}^2} = \sqrt{2.82} \sqrt{\text{m}^2} = 1.68 \text{ m}. \quad (7.21)$$

Allerdings ist man in den meisten Anwendungskontexten eher an den Verhältnissen von Variabilitäten verschiedener Stichproben interessiert, wofür sich dann sowohl (Stichproben)Varianz als auch (Stichproben)Standardabweichung gleichermaßen eignen.

7.2 Eigenschaften

Die Varianz hat die Eigenschaft, keine negativen Werte anzunehmen.

Theorem 7.1 (Nichtnegativität der Varianz). ξ sei eine Zufallsvariable. Dann gilt

$$\mathbb{V}(\xi) \geq 0. \quad (7.22)$$

◦

Beweis. Wir betrachten den Fall einer diskreten Zufallsvariable. Dann gilt zunächst

$$(x - \mathbb{E}(\xi))^2 \geq 0 \text{ für alle } x \in \mathcal{X}. \quad (7.23)$$

Weiterhin gilt für die WMF p von ξ , dass

$$p(x) \geq 0 \text{ für alle } x \in \mathcal{X}. \quad (7.24)$$

Also folgt

$$p(x)(x - \mathbb{E}(\xi))^2 \geq 0 \text{ für alle } x \in \mathcal{X}. \quad (7.25)$$

Damit gilt dann aber

$$\mathbb{V}(\xi) = \sum_{x \in \mathcal{X}} p(x)(x - \mathbb{E}(\xi))^2 \geq 0, \quad (7.26)$$

Analog zeigt man die Nichtnegativität der Varianz bei kontinuierlichen Zufallsvariablen. $\square$

Das Berechnen von Varianzen wird durch folgendes Theorem, den sogenannten *Varianzverschiebungssatz* oft erleichtert, insbesondere, wenn der Erwartungswert der quadrierten Zufallsvariable leicht zu bestimmen oder bekannt ist.

Theorem 7.2 (Varianzverschiebungssatz). ξ sei eine Zufallsvariable. Dann gilt

$$\mathbb{V}(\xi) = \mathbb{E}(\xi^2) - \mathbb{E}(\xi)^2. \quad (7.27)$$

◦

Beweis. Mit der Definition der Varianz und der Linearität des Erwartungswerts gilt

$$\begin{aligned} \mathbb{V}(\xi) &= \mathbb{E}((\xi - \mathbb{E}(\xi))^2) \\ &= \mathbb{E}(\xi^2 - 2\xi\mathbb{E}(\xi) + \mathbb{E}(\xi)^2) \\ &= \mathbb{E}(\xi^2) - 2\mathbb{E}(\xi)\mathbb{E}(\xi) + \mathbb{E}(\mathbb{E}(\xi)^2) \\ &= \mathbb{E}(\xi^2) - 2\mathbb{E}(\xi)^2 + \mathbb{E}(\xi)^2 \\ &= \mathbb{E}(\xi^2) - \mathbb{E}(\xi)^2. \end{aligned} \quad (7.28)$$

 $\square$

In Analogie zu Theorem 6.1 gilt für die Varianz folgendes Resultat.

Theorem 7.3 (Varianz und Standardabweichung bei linear-affiner Transformation einer Zufallsvariable). ξ sei eine Zufallsvariable und es sei

$$f : \mathcal{X} \rightarrow \mathcal{Z}, x \mapsto f(x) := ax + b \text{ für } a, b \in \mathbb{R} \quad (7.29)$$

eine linear-affine Funktion. Dann gelten

$$\mathbb{V}(f(\xi)) = \mathbb{V}(a\xi + b) = a^2\mathbb{V}(\xi) \quad (7.30)$$

und

$$\mathbb{S}(f(\xi)) = \mathbb{S}(a\xi + b) = |a|\mathbb{S}(\xi) \quad (7.31)$$

◦

Beweis. Es ergibt sich

$$\begin{aligned} \mathbb{V}(f(\xi)) &= \mathbb{V}(a\xi + b) \\ &= \mathbb{E}((a\xi + b - \mathbb{E}(a\xi + b))^2) \\ &= \mathbb{E}((a\xi + b - a\mathbb{E}(\xi) - b)^2) \\ &= \mathbb{E}((a\xi - a\mathbb{E}(\xi))^2) \\ &= \mathbb{E}(a(\xi - \mathbb{E}(\xi))^2) \\ &= \mathbb{E}(a^2(\xi - \mathbb{E}(\xi))^2) \\ &= a^2\mathbb{E}((\xi - \mathbb{E}(\xi))^2) \\ &= a^2\mathbb{V}(\xi). \end{aligned} \quad (7.32)$$

Wurzelziehen unter Beachtung von

$$a \geq 0 \Rightarrow a^2 \geq 0 \Rightarrow \sqrt{a^2} = a \geq 0 \Leftrightarrow \sqrt{a^2} = |a| \text{ für } a \geq 0 \quad (7.33)$$

sowie

$$a < 0 \Rightarrow a^2 > 0 \Rightarrow \sqrt{a^2} = -a > 0 \Leftrightarrow \sqrt{a^2} = |a| \text{ für } a < 0 \quad (7.34)$$

zeigt dann das Resultat für die Standardabweichung. $\square$

Die Varianz der Linearkombination zweier unabhängiger Zufallsvariablen lässt sich als modifizierte Linearkombination der Varianzen der Zufallsvariablen schreiben.

Theorem 7.4 (Varianz bei Linearkombination zweier unabhängiger Zufallsvariablen). ξ_1 und ξ_2 seien zwei unabhängige Zufallsvariablen und es seien $a_1, a_2 \in \mathbb{R}$. Dann gilt

$$\mathbb{V}(a_1\xi_1 + a_2\xi_2) = a_1^2\mathbb{V}(\xi_1) + a_2^2\mathbb{V}(\xi_2). \quad (7.35)$$

◦

Beweis. Wir halten zunächst fest, dass mit Theorem 6.2 gilt, dass

$$\mathbb{E}(a_1\xi_1 + a_2\xi_2) = a_1\mathbb{E}(\xi_1) + a_2\mathbb{E}(\xi_2). \quad (7.36)$$

Weiterhin gilt mit Theorem 6.3, dass

$$\begin{aligned} \mathbb{E}((\xi_1 - \mathbb{E}(\xi_1))(\xi_2 - \mathbb{E}(\xi_2))) &= \mathbb{E}(\xi_1\xi_2 - \mathbb{E}(\xi_1)\xi_2 - \xi_1\mathbb{E}(\xi_2) + \mathbb{E}(\xi_1)\mathbb{E}(\xi_2)) \\ &= \mathbb{E}(\xi_1\xi_2) - \mathbb{E}(\xi_1)\mathbb{E}(\xi_2) - \mathbb{E}(\xi_1)\mathbb{E}(\xi_2) + \mathbb{E}(\xi_1)\mathbb{E}(\xi_2) \\ &= \mathbb{E}(\xi_1)\mathbb{E}(\xi_2) - \mathbb{E}(\xi_1)\mathbb{E}(\xi_2) \\ &= 0. \end{aligned} \quad (7.37)$$

Es folgt also

$$\begin{aligned}
\mathbb{V}(a_1\xi_1 + a_2\xi_2) &= \mathbb{E}((a_1\xi_1 + a_2\xi_2 - \mathbb{E}(a_1\xi_1 + a_2\xi_2))^2) \\
&= \mathbb{E}((a_1\xi_1 + a_2\xi_2 - a_1\mathbb{E}(\xi_1) - a_2\mathbb{E}(\xi_2))^2) \\
&= \mathbb{E}((a_1\xi_1 - a_1\mathbb{E}(\xi_1) + a_2\xi_2 - a_2\mathbb{E}(\xi_2))^2) \\
&= \mathbb{E}(a_1(\xi_1 - \mathbb{E}(\xi_1)) + a_2(\xi_2 - \mathbb{E}(\xi_2)))^2 \\
&= \mathbb{E}(a_1(\xi_1 - \mathbb{E}(\xi_1)))^2 + 2a_1(\xi_1 - \mathbb{E}(\xi_1))(a_2(\xi_2 - \mathbb{E}(\xi_2))) + (a_2(\xi_2 - \mathbb{E}(\xi_2)))^2) \\
&= \mathbb{E}(a_1^2(\xi_1 - \mathbb{E}(\xi_1))^2 + 2a_1a_2(\xi_1 - \mathbb{E}(\xi_1))(\xi_2 - \mathbb{E}(\xi_2)) + a_2^2(\xi_2 - \mathbb{E}(\xi_2))^2) \\
&= a_1^2\mathbb{E}((\xi_1 - \mathbb{E}(\xi_1))^2) + 2a_1a_2\mathbb{E}((\xi_1 - \mathbb{E}(\xi_1))(\xi_2 - \mathbb{E}(\xi_2))) + a_2^2\mathbb{E}((\xi_2 - \mathbb{E}(\xi_2))^2) \\
&= a_1^2\mathbb{V}(\xi_1) + 2a_1a_2\mathbb{E}((\xi_1 - \mathbb{E}(\xi_1))(\xi_2 - \mathbb{E}(\xi_2))) + a_2^2\mathbb{V}(\xi_2) \\
&= a_1^2\mathbb{V}(\xi_1) + 2a_1a_2 \cdot 0 + a_2^2\mathbb{V}(\xi_2) \\
&= a_1^2\mathbb{V}(\xi_1) + a_2^2\mathbb{V}(\xi_2).
\end{aligned} \tag{7.38}$$

□

Weitergreifendere Aussage zur Varianz der Summe nicht unabhängiger Zufallsvariablen lassen sich erst mithilfe des in Kapitel 8 eingeführten Begriffs der Kovarianz treffen.

7.3 Bedingte Varianz

Definition 7.3 (Bedingte Varianz). Gegeben sei ein Zufallsvektor $\xi := (\xi_1, \xi_2)$ mit Ergebnisraum $\mathcal{X} := \mathcal{X}_1 \times \mathcal{X}_2$. Dann ist die *bedingte Varianz von ξ_1 gegeben $\xi_2 = x_2$* definiert als

$$\mathbb{V}(\xi_1|\xi_2 = x_2) = \mathbb{E}((\xi_1 - \mathbb{E}(\xi_1|\xi_2 = x_2))^2 | \xi_2 = x_2) \tag{7.39}$$

und die *bedingte Standardabweichung von ξ_1 gegeben $\xi_2 = x_2$* ist definiert als

$$\mathbb{S}(\xi_1|\xi_2 = x_2) = \sqrt{\mathbb{V}(\xi_1|\xi_2 = x_2)}. \tag{7.40}$$

•

Die bedingte Varianz ist im Sinne des bedingten Erwartungswerts definiert, ebenso wie ein bedingter Erwartungswert ist eine bedingte Varianz also eine Zufallsvariable. Auch für die bedingte Varianz gilt der Verschiebungssatz, wie folgendes Theorem besagt.

Theorem 7.5 (Kovarianzverschiebungssatz der bedingten Varianz). Gegeben sei ein Zufallsvektor $\xi := (\xi_1, \xi_2)$. Dann gilt

$$\mathbb{V}(\xi_1|\xi_2 = x_2) = \mathbb{E}(\xi_1^2|\xi_2 = x_2) - \mathbb{E}(\xi_1|\xi_2 = x_2)^2 \tag{7.41}$$

◦

Beweis. Wir beschränken uns auf den Beweis für einen diskreten Zufallsvektor. Der Beweis für einen kontinuierlichen Zufallsvektor folgt analog. Mit der Definition des bedingten Erwartungswerts (Definition 6.6)

gilt

$$\begin{aligned}
\mathbb{V}(\xi_1 | \xi_2 = x_2) &= \mathbb{E}((\xi_1 - \mathbb{E}(\xi_1 | \xi_2 = x_2))^2 | \xi_2 = x_2) \\
&= \mathbb{E}(\xi_1^2 - 2\xi_1 \mathbb{E}(\xi_1 | \xi_2 = x_2) + \mathbb{E}(\xi_1 | \xi_2 = x_2)^2 | \xi_2 = x_2) \\
&= \sum_{x_1 \in \mathcal{X}_1} p(x_1 | x_2) (x_1^2 - 2x_1 \mathbb{E}(\xi_1 | \xi_2 = x_2) + \mathbb{E}(\xi_1 | \xi_2 = x_2)^2) \\
&= \sum_{x_1 \in \mathcal{X}_1} x_1^2 p(x_1 | x_2) - \sum_{x_1 \in \mathcal{X}_1} 2x_1 \mathbb{E}(\xi_1 | \xi_2 = x_2) p(x_1 | x_2) + \sum_{x_1 \in \mathcal{X}_1} \mathbb{E}(\xi_1 | \xi_2 = x_2)^2 p(x_1 | x_2) \\
&= \mathbb{E}(\xi_1^2 | \xi_2 = x_2) - 2\mathbb{E}(\xi_1 | \xi_2 = x_2) \sum_{x_1 \in \mathcal{X}_1} x_1 p(x_1 | x_2) + \mathbb{E}(\xi_1 | \xi_2 = x_2)^2 \sum_{x_1 \in \mathcal{X}_1} p(x_1 | x_2) \\
&= \mathbb{E}(\xi_1^2 | \xi_2 = x_2) - 2\mathbb{E}(\xi_1 | \xi_2 = x_2) \mathbb{E}(\xi_1 | \xi_2 = x_2) + \mathbb{E}(\xi_1 | \xi_2 = x_2)^2 \cdot 1 \\
&= \mathbb{E}(\xi_1^2 | \xi_2 = x_2) - 2\mathbb{E}(\xi_1 | \xi_2 = x_2)^2 + \mathbb{E}(\xi_1 | \xi_2 = x_2)^2 \\
&= \mathbb{E}(\xi_1^2 | \xi_2 = x_2) - \mathbb{E}(\xi_1 | \xi_2 = x_2)^2
\end{aligned} \tag{7.42}$$

□

Folgendes Theorem, der sogenannte *Satz von der iterierten Varianz* stellt einen Zusammenhang zwischen der Varianz einer Zufallsvariable, ihrer bedingten Varianz und der Varianz ihres bedingten Erwartungswerts her.

Theorem 7.6 (Satz von der iterierten Varianz). *Gegeben sei ein Zufallsvektor $\xi := (\xi_1, \xi_2)$. Dann gilt*

$$\mathbb{V}(\xi_1) = \mathbb{E}(\mathbb{V}(\xi_1 | \xi_2)) + \mathbb{V}(\mathbb{E}(\xi_1 | \xi_2)) \tag{7.43}$$

◦

Beweis. Wir beschränken uns auf den Beweis für einen diskreten Zufallsvektor. Der Beweis für einen kontinuierlichen Zufallsvektor folgt analog. Mit dem Kovarianzverschiebungssatz (Theorem 8.2), dem Satz vom iterierten Erwartungswert (Theorem 6.4) und dem Kovarianzverschiebungssatz der bedingten Varianz (Theorem 7.5) gilt

$$\begin{aligned}
\mathbb{V}(\xi_1) &= \mathbb{E}(\xi_1^2) - \mathbb{E}(\xi_1)^2 \\
&= \mathbb{E}(\mathbb{E}(\xi_1^2 | \xi_2)) - \mathbb{E}(\mathbb{E}(\xi_1 | \xi_2))^2 \\
&= \sum_{x_2 \in \mathcal{X}_2} p(x_2) \mathbb{E}(\xi_1^2 | \xi_2 = x_2) - \mathbb{E}(\mathbb{E}(\xi_1 | \xi_2))^2 \\
&= \sum_{x_2 \in \mathcal{X}_2} p(x_2) (\mathbb{V}(\xi_1 | \xi_2 = x_2) + \mathbb{E}(\xi_1 | \xi_2 = x_2)^2) - \mathbb{E}(\mathbb{E}(\xi_1 | \xi_2))^2 \\
&= \sum_{x_2 \in \mathcal{X}_2} p(x_2) \mathbb{V}(\xi_1 | \xi_2 = x_2) + \sum_{x_2 \in \mathcal{X}_2} p(x_2) \mathbb{E}(\xi_1 | \xi_2 = x_2)^2 - \mathbb{E}(\mathbb{E}(\xi_1 | \xi_2))^2 \\
&= \mathbb{E}(\mathbb{V}(\xi_1 | \xi_2)) + (\mathbb{E}(\mathbb{E}(\xi_1 | \xi_2)^2) - \mathbb{E}(\mathbb{E}(\xi_1 | \xi_2))^2) \\
&= \mathbb{E}(\mathbb{V}(\xi_1 | \xi_2)) + \mathbb{V}(\mathbb{E}(\xi_1 | \xi_2))
\end{aligned} \tag{7.44}$$

□

Selbstkontrollfragen

1. Geben Sie die Definition der Varianz und der Standardabweichung einer Zufallsvariable wieder.
2. Erläutern Sie die Definition der Varianz und der Standardabweichung einer Zufallsvariable.
3. Berechnen Sie die Varianz einer Bernoulli-Zufallsvariable.
4. Geben Sie die Definition von Stichprobenvarianz und Stichprobenstandardabweichung wieder.
5. Erläutern Sie die Definitionen der Stichprobenvarianz und der Stichprobenstandardabweichung.

6. Geben Sie das Theorem zur Nichtnegativität der Varianz wieder.
7. Geben Sie das Theorem zum Varianzverschiebungssatz wieder.
8. Geben Sie das Theorem zur Varianz und Standardabweichung bei linear-affiner Transformation einer Zufallsvariable wieder.
9. Geben Sie das Theorem zur Varianz bei Linearkombination zweier unabhängiger Zufallsvariablen wieder.

Lösungen

1. Siehe Definition [7.1](#).
2. Siehe Erläuterungen zu Definition [7.1](#).
3. Siehe Beispiel [7.2](#).
4. Siehe Definition [7.2](#).
5. Siehe Erläuterungen zu Definition [7.2](#) sowie Beispiel [7.4](#).
6. Siehe Theorem [7.1](#).
7. Siehe Theorem [7.2](#).
8. Siehe Theorem [7.3](#).
9. Siehe Theorem [7.4](#).

8 Kovarianzen

Mit der *Kovarianz* zweier Zufallsvariablen und ihrer standardisierten Form, der *Korrelation*, führen wir in diesem Kapitel skalare Maßzahlen für die linear-affine Abhängigkeit von Zufallsvariablen ein.

8.1 Definitionen

Definition 8.1 (Kovarianz und Korrelation zweier Zufallsvariablen). Die *Kovarianz* zweier Zufallsvariablen ξ_1 und ξ_2 ist definiert als

$$\mathbb{C}(\xi_1, \xi_2) := \mathbb{E}((\xi_1 - \mathbb{E}(\xi_1))(\xi_2 - \mathbb{E}(\xi_2))). \quad (8.1)$$

Die *Korrelation* zweier Zufallsvariablen ξ_1 und ξ_2 mit $\mathbb{S}(\xi_1) > 0$ und $\mathbb{S}(\xi_2) > 0$ ist definiert als

$$\rho(\xi_1, \xi_2) := \frac{\mathbb{C}(\xi_1, \xi_2)}{\mathbb{S}(\xi_1)\mathbb{S}(\xi_2)}. \quad (8.2)$$

•

Die Kovarianz einer Zufallsvariable mit sich selbst ist ihre Varianz, denn es gilt

$$\mathbb{C}(\xi_1, \xi_1) = \mathbb{E}((\xi_1 - \mathbb{E}(\xi_1))(\xi_1 - \mathbb{E}(\xi_1))) = \mathbb{E}((\xi_1 - \mathbb{E}(\xi_1))^2) = \mathbb{V}(\xi_1). \quad (8.3)$$

Die Zahl $\rho(\xi_1, \xi_2)$ wird auch *Korrelationskoeffizient* von ξ_1 und ξ_2 genannt. Wenn $\rho(\xi_1, \xi_2) = 0$ gilt, so werden ξ_1 und ξ_2 *unkorreliert* genannt. In Kapitel 9 zeigen wir in Theorem 9.4, dass

$$-1 \leq \rho(\xi_1, \xi_2) \leq 1. \quad (8.4)$$

Die Definition der Kovarianz nach Definition 8.1 lässt implizit, dass die in ihr auftauchenden Erwartungswerte unterschiedlicher Natur sind. Dabei geht die Definition der Kovarianz zunächst einmal davon aus, dass ξ_1 und ξ_2 die Komponenten eines Zufallsvektors $\xi := (\xi_1, \xi_2)$ mit Ergebnisraum $\mathcal{X}_1 \times \mathcal{X}_2$, gemeinsamer Verteilung $\mathbb{P}(\xi_1, \xi_2)$ und marginalen Verteilungen $\mathbb{P}(\xi_1)$ und $\mathbb{P}(\xi_2)$ sind. Bei den Erwartungswerten $\mathbb{E}(\xi_1)$ und $\mathbb{E}(\xi_2)$ handelt es sich um die Erwartungswerte der Komponenten ξ_1 und ξ_2 bezüglich dieser Marginalverteilungen. Die Kovarianz selbst ist dann der Erwartungswert der Funktion

$$f : \mathcal{X}_1 \times \mathcal{X}_2 \rightarrow \mathbb{R}, (x_1, x_2) \mapsto f(x_1, x_2) := (x_1 - \mathbb{E}(\xi_1))(x_2 - \mathbb{E}(\xi_2)) \quad (8.5)$$

bezüglich der gemeinsamen Verteilung $\mathbb{P}(\xi_1, \xi_2)$. Wir wollen dies am Beispiel eines diskreten Zufallsvektors verdeutlichen.

Beispiel 8.1 (Kovarianz zweier diskreter Zufallsvariablen.). Es $\xi := (\xi_1, \xi_2)$ ein diskreter Zufallsvektor mit Ergebnisraum $\mathcal{X} := \{1, 2\} \times \{1, 2, 3\}$ und der in Tabelle 8.1 dargestellten gemeinsamen WMF $p(x_1, x_2)$ und marginalen WMFen $p(x_1)$ und $p(x_2)$.

Tabelle 8.1 Gemeinsame und marginale WMFen des Zufallsvektors ξ

$p(x_1, x_2)$	$x_2 = 1$	$x_2 = 2$	$x_2 = 3$	$p(x_1)$
$x_1 = 1$	0.10	0.05	0.15	0.30
$x_1 = 2$	0.60	0.05	0.05	0.70
$p(x_2)$	0.70	0.10	0.20	

Mit der Definition der Kovarianz von ξ_1 und ξ_2 gilt dann unter Beachtung von Gleichung 8.5

$$\begin{aligned}
 \mathbb{C}(\xi_1, \xi_2) &= \mathbb{E}(f(\xi_1, \xi_2)) \\
 &= \sum_{x_1=1}^2 \sum_{x_2=1}^3 f(x_1, x_2) p(x_1, x_2) \\
 &= \sum_{x_1=1}^2 \sum_{x_2=1}^3 (x_1 - \mathbb{E}(\xi_1))(x_2 - \mathbb{E}(\xi_2)) p(x_1, x_2)
 \end{aligned} \tag{8.6}$$

Einsetzen der Werte aus Tabelle 8.1 ergibt dann zunächst

$$\mathbb{E}(\xi_1) = \sum_{x_1=1}^2 x_1 p(x_1) = 1 \cdot 0.3 + 2 \cdot 0.7 = 1.7 \tag{8.7}$$

und

$$\mathbb{E}(\xi_2) = \sum_{x_2=1}^3 x_2 p(x_2) = 1 \cdot 0.7 + 2 \cdot 0.1 + 3 \cdot 0.2 = 1.5. \tag{8.8}$$

und damit dann schließlich

$$\begin{aligned}
 \mathbb{C}(\xi_1, \xi_2) &= \sum_{x_1=1}^2 \sum_{x_2=1}^3 (x_1 - 1.7)(x_2 - 1.5) p(x_1, x_2) \\
 &= \sum_{x_1=1}^2 (x_1 - 1.7)(1 - 1.5)p(x_1, 1) + (x_1 - 1.7)(2 - 1.5)p(x_1, 2) + (x_1 - 1.7)(3 - 1.5)p(x_1, 3) \\
 &= (1 - 1.7)(1 - 1.5)p(1, 1) + (1 - 1.7)(2 - 1.5)p(1, 2) + (1 - 1.7)(3 - 1.5)p(1, 3) \\
 &\quad + (2 - 1.7)(1 - 1.5)p(2, 1) + (2 - 1.7)(2 - 1.5)p(2, 2) + (2 - 1.7)(3 - 1.5)p(2, 3) \\
 &= (-0.7) \cdot (-0.5) \cdot 0.10 + (-0.7) \cdot 0.5 \cdot 0.05 + (-0.7) \cdot 1.5 \cdot 0.15 \\
 &\quad + 0.3 \cdot (-0.5) \cdot 0.60 + 0.3 \cdot 0.5 \cdot 0.05 + 0.3 \cdot 1.5 \cdot 0.05 \\
 &= 0.035 - 0.0175 - 0.1575 - 0.09 + 0.0075 + 0.0225 \\
 &= -0.2.
 \end{aligned} \tag{8.9}$$

Die Kovarianz der Zufallsvariablen ξ_1 und ξ_2 mit der in obiger Tabelle festgelegter Verteilung ist also $\mathbb{C}(\xi_1, \xi_2) = -0.2$. Im Gegensatz zur Varianz kann die Kovarianz also offenbar auch negative Werte annehmen.

△

8.2 Eigenschaften

Wir betrachten im Folgenden einige grundlegende Eigenschaften der Kovarianz.

Theorem 8.1 (Symmetrie von Kovarianz und Korrelation). ξ_1 und ξ_2 seien zwei Zufallsvariablen. Dann gelten

$$\mathbb{C}(\xi_1, \xi_2) = \mathbb{C}(\xi_2, \xi_1) \text{ und } \rho(\xi_1, \xi_2) = \rho(\xi_2, \xi_1). \quad (8.10)$$

◦

Beweis. Mit der Kommutativität der Multiplikation gilt zunächst

$$\mathbb{C}(\xi_1, \xi_2) = \mathbb{E}((\xi_1 - \mathbb{E}(\xi_1))(\xi_2 - \mathbb{E}(\xi_2))) = \mathbb{E}((\xi_2 - \mathbb{E}(\xi_2))(\xi_1 - \mathbb{E}(\xi_1))) = \mathbb{C}(\xi_2, \xi_1) \quad (8.11)$$

Weiterhin gilt dann

$$\rho(\xi_1, \xi_2) = \frac{\mathbb{C}(\xi_1, \xi_2)}{\mathbb{S}(\xi_1)\mathbb{S}(\xi_2)} = \frac{\mathbb{C}(\xi_2, \xi_1)}{\mathbb{S}(\xi_2)\mathbb{S}(\xi_1)} = \rho(\xi_2, \xi_1) \quad (8.12)$$

□

Wie das Berechnen von Varianzen wird auch das Berechnen von Kovarianzen manchmal durch folgendes Theorem erleichtert.

Theorem 8.2 (Kovarianzverschiebungssatz). ξ_1 und ξ_2 seien Zufallsvariablen. Dann gilt

$$\mathbb{C}(\xi_1, \xi_2) = \mathbb{E}(\xi_1 \xi_2) - \mathbb{E}(\xi_1)\mathbb{E}(\xi_2). \quad (8.13)$$

◦

Beweis. Mit Definition 8.1 gilt

$$\begin{aligned} \mathbb{C}(\xi_1, \xi_2) &= \mathbb{E}((\xi_1 - \mathbb{E}(\xi_1))(\xi_2 - \mathbb{E}(\xi_2))) \\ &= \mathbb{E}(\xi_1 \xi_2 - \xi_1 \mathbb{E}(\xi_2) - \mathbb{E}(\xi_1) \xi_2 + \mathbb{E}(\xi_1)\mathbb{E}(\xi_2)) \\ &= \mathbb{E}(\xi_1 \xi_2) - \mathbb{E}(\xi_1)\mathbb{E}(\xi_2) - \mathbb{E}(\xi_1)\mathbb{E}(\xi_2) + \mathbb{E}(\xi_1)\mathbb{E}(\xi_2) \\ &= \mathbb{E}(\xi_1 \xi_2) - \mathbb{E}(\xi_1)\mathbb{E}(\xi_2). \end{aligned} \quad (8.14)$$

□

Natürlich ist Theorem 8.2 nur dann wirklich nützlich, wenn $\mathbb{E}(\xi_1 \xi_2)$ leicht zu berechnen sind. Der Varianzverschiebungssatz nach Theorem 7.2 ergibt sich aus Theorem 8.2 für den Fall $\xi_1 = \xi_2 := \xi$ anhand von

$$\mathbb{V}(\xi) = \mathbb{C}(\xi, \xi) = \mathbb{E}(\xi \xi) - \mathbb{E}(\xi)\mathbb{E}(\xi) = \mathbb{E}(\xi^2) - \mathbb{E}(\xi)\mathbb{E}(\xi). \quad (8.15)$$

Auch in Hinblick auf die Kovarianz $\mathbb{C}(\xi_1, \xi_2)$ ist man daran interessiert, wie sich diese unter Anwendung linear-affiner Transformationen auf ξ_1 und ξ_2 verhält. Folgendes Resultat zeigt, dass die Kovarianz zweier Zufallsvariablen von ihrem Maßstab abhängt, die Korrelation dagegen nicht. Dies motiviert den häufigen Einsatz der Korrelation als allgemeines, zwischen verschiedenen Anwendungsszenarien vergleichbares Zusammenhangsmaß.

Theorem 8.3 (Kovarianz und Korrelation bei linear-affinen Transformation). ξ_1 und ξ_2 seien Zufallsvariablen mit gemeinsamen Ergebnisraum $\mathcal{X}_1 \times \mathcal{X}_2$ und es seien

$$\begin{aligned} f_1 : \mathcal{X}_1 &\rightarrow \mathcal{Z}_1, x_1 \mapsto f(x_1) := ax_1 + b \\ f_2 : \mathcal{X}_2 &\rightarrow \mathcal{Z}_2, x_2 \mapsto f(x_2) := cx_2 + d \end{aligned} \quad (8.16)$$

für $a, b, c, d \in \mathbb{R}$ zwei linear-affine Funktionen. Dann gelten

$$\mathbb{C}(f_1(\xi_1), f(\xi_2)) = \mathbb{C}(a\xi_1 + b, c\xi_2 + d) = ac\mathbb{C}(\xi_1, \xi_2). \quad (8.17)$$

und

$$\rho(f_1(\xi_1), f(\xi_2)) = \rho(a\xi_1 + b, c\xi_2 + d) = \rho(\xi_1, \xi_2). \quad (8.18)$$

◦

Beweis. Es gilt zunächst

$$\begin{aligned} \mathbb{C}(a\xi_1 + b, c\xi_2 + d) &= \mathbb{E}((a\xi_1 + b - \mathbb{E}(a\xi_1 + b))(c\xi_2 + d - \mathbb{E}(c\xi_2 + d))) \\ &= \mathbb{E}((a\xi_1 + b - a\mathbb{E}(\xi_1) - b)(c\xi_2 + d - c\mathbb{E}(\xi_2) - d)) \\ &= \mathbb{E}(a(\xi_1 - \mathbb{E}(\xi_1))(c(\xi_2 - \mathbb{E}(\xi_2)))) \\ &= \mathbb{E}(ac((\xi_1 - \mathbb{E}(\xi_1))(\xi_2 - \mathbb{E}(\xi_2)))) \\ &= ac\mathbb{C}(\xi_1, \xi_2). \end{aligned} \quad (8.19)$$

Also folgt

$$\begin{aligned} \rho(a\xi_1 + b, c\xi_2 + d) &= \frac{\mathbb{C}(a\xi_1 + b, c\xi_2 + d)}{\sqrt{\mathbb{V}(a\xi_1 + b)}\sqrt{\mathbb{V}(c\xi_2 + d)}} \\ &= \frac{ac\mathbb{C}(\xi_1, \xi_2)}{\sqrt{a^2\mathbb{V}(\xi_1)}\sqrt{c^2\mathbb{V}(\xi_2)}} \\ &= \frac{ac\mathbb{C}(\xi_1, \xi_2)}{a\mathbb{S}(\xi_1)c\mathbb{S}(\xi_2)} \\ &= \frac{\mathbb{C}(\xi_1, \xi_2)}{\mathbb{S}(\xi_1)\mathbb{S}(\xi_2)} \\ &= \rho(\xi_1, \xi_2). \end{aligned} \quad (8.20)$$

□

Mithilfe des Begriffes des Kovarianz ist es möglich, weitgreifenderer Aussagen über die Varianzen von Summen und Differenzen von Zufallsvariablen zu treffen als es in Kapitel 7 der Fall war, wo lediglich die Varianzen von Summen unabhängiger Zufallsvariablen betrachtet wurden. Mit dem folgenden Theorem untersuchen wir zunächst den sehr allgemeinen Fall der Kovarianz zweier Zufallsvariablen, die sich als Linearkombinationen von n Zufallsvariablen $\xi_1, \dots, \xi_n$ und m Zufallsvariablen $\zeta_1, \dots, \zeta_m$ unter Addition reeller Konstanten ergeben. Hieraus ergeben sich dann eine Reihe von in der Anwendung, insbesondere in der Klassischen Testtheorie, wichtiger Spezialfälle.

Theorem 8.4 (Kovarianz von Linearkombinationen von Zufallsvariablen). *Gegeben seien n Zufallsvariablen $\xi_1, \dots, \xi_n$ und $n + 1$ reelle Konstanten $a_0, a_1, \dots, a_n$ sowie m Zufallsvariablen $\zeta_1, \dots, \zeta_m$ und $m + 1$ reelle Konstanten $b_0, b_1, \dots, b_m$. Dann gilt*

$$\mathbb{C}\left(a_0 + \sum_{i=1}^n a_i \xi_i, b_0 + \sum_{j=1}^m b_j \zeta_j\right) = \sum_{i=1}^n \sum_{j=1}^m a_i b_j \mathbb{C}(\xi_i, \zeta_j). \quad (8.21)$$

◦

Beweis.

$$\begin{aligned}
& \mathbb{C} \left(a_0 + \sum_{i=1}^n a_i \xi_i, b_0 + \sum_{j=1}^m b_j \zeta_j \right) \\
&= \mathbb{E} \left(\left(a_0 + \sum_{i=1}^n a_i \xi_i - \mathbb{E} \left(a_0 + \sum_{i=1}^n a_i \xi_i \right) \right) \left(b_0 + \sum_{j=1}^m b_j \zeta_j - \mathbb{E} \left(b_0 + \sum_{j=1}^m b_j \zeta_j \right) \right) \right) \\
&= \mathbb{E} \left(\left(a_0 + \sum_{i=1}^n a_i \xi_i - a_0 - \mathbb{E} \left(\sum_{i=1}^n a_i \xi_i \right) \right) \left(b_0 + \sum_{j=1}^m b_j \zeta_j - b_0 - \mathbb{E} \left(\sum_{j=1}^m b_j \zeta_j \right) \right) \right) \\
&= \mathbb{E} \left(\left(\sum_{i=1}^n a_i \xi_i - \sum_{i=1}^n a_i \mathbb{E}(\xi_i) \right) \left(\sum_{j=1}^m b_j \zeta_j - \sum_{j=1}^m b_j \mathbb{E}(\zeta_j) \right) \right) \\
&= \mathbb{E} \left(\sum_{i=1}^n a_i \xi_i \sum_{j=1}^m b_j \zeta_j - \sum_{i=1}^n a_i \xi_i \sum_{j=1}^m b_j \mathbb{E}(\zeta_j) - \sum_{i=1}^n a_i \mathbb{E}(\xi_i) \sum_{j=1}^m b_j \zeta_j + \sum_{i=1}^n a_i \mathbb{E}(\xi_i) \sum_{j=1}^m b_j \mathbb{E}(\zeta_j) \right) \\
&= \mathbb{E} \left(\sum_{i=1}^n a_i \xi_i \sum_{j=1}^m b_j \zeta_j \right) - \mathbb{E} \left(\sum_{i=1}^n a_i \xi_i \sum_{j=1}^m b_j \mathbb{E}(\zeta_j) \right) - \mathbb{E} \left(\sum_{i=1}^n a_i \mathbb{E}(\xi_i) \sum_{j=1}^m b_j \zeta_j \right) + \mathbb{E} \left(\sum_{i=1}^n a_i \mathbb{E}(\xi_i) \sum_{j=1}^m b_j \mathbb{E}(\zeta_j) \right) \\
&= \sum_{i=1}^n \sum_{j=1}^m a_i b_j \mathbb{E}(\xi_i \zeta_j) - 2 \sum_{i=1}^n \sum_{j=1}^m a_i b_j \mathbb{E}(\xi_i) \mathbb{E}(\zeta_j) + \sum_{i=1}^n \sum_{j=1}^m a_i b_j \mathbb{E}(\xi_i) \mathbb{E}(\zeta_j) \\
&= \sum_{i=1}^n \sum_{j=1}^m a_i b_j (\mathbb{E}(\xi_i \zeta_j) - 2\mathbb{E}(\xi_i) \mathbb{E}(\zeta_j) + \mathbb{E}(\xi_i) \mathbb{E}(\zeta_j)) \\
&= \sum_{i=1}^n \sum_{j=1}^m a_i b_j \mathbb{E}((\xi_i - \mathbb{E}(\xi_i))(\zeta_j - \mathbb{E}(\zeta_j))) \\
&= \sum_{i=1}^n \sum_{j=1}^m a_i b_j \mathbb{C}(\xi_i, \zeta_j)
\end{aligned}$$

□

Mit folgenden Theorem betrachten wir nun einen ersten Spezialfall von Theorem 8.4.

Theorem 8.5 (Kovarianz bei paarweiser Addition von Zufallsvariablen). $\xi_1, \xi_2, \zeta_1, \zeta_2$ seien vier Zufallsvariablen. Dann gilt

$$\mathbb{C}(\xi_1 + \xi_2, \zeta_1 + \zeta_2) = \mathbb{C}(\xi_1, \zeta_1) + \mathbb{C}(\xi_1, \zeta_2) + \mathbb{C}(\xi_2, \zeta_1) + \mathbb{C}(\xi_2, \zeta_2). \quad (8.22)$$

◦

Beweis. Es seien $n := 2, m := 2, a_0 = b_0 := 0$ und $a_i = b_i := 1$ für $i = 1, 2$. Dann gilt mit Theorem 8.4

$$\begin{aligned}
\mathbb{C}(\xi_1 + \xi_2, \zeta_1 + \zeta_2) &= \mathbb{C} \left(a_0 + \sum_{i=1}^2 a_i \xi_i, b_0 + \sum_{j=1}^2 b_j \zeta_j \right) \\
&= \sum_{i=1}^2 \sum_{j=1}^2 a_i b_j \mathbb{C}(\xi_i, \zeta_j) \\
&= \sum_{i=1}^2 \sum_{j=1}^2 \mathbb{C}(\xi_i, \zeta_j) \\
&= \mathbb{C}(\xi_1, \zeta_1) + \mathbb{C}(\xi_1, \zeta_2) + \mathbb{C}(\xi_2, \zeta_1) + \mathbb{C}(\xi_2, \zeta_2).
\end{aligned} \quad (8.23)$$

□

Folgendes Theorem besagt nun, wie man im Allgemeinen die Varianz einer Linearkombinationen von Zufallsvariablen unter Addition einer Konstante bestimmt werden kann.

Theorem 8.6 (Varianz einer Linearkombination von Zufallsvariablen). *Gegeben seien n Zufallsvariablen $\xi_1, \dots, \xi_n$ und $n + 1$ reelle Konstanten $a_0, a_1, \dots, a_n$. Dann gilt*

$$\mathbb{V} \left(a_0 + \sum_{i=1}^n a_i \xi_i \right) = \sum_{i=1}^n a_i^2 \mathbb{V}(\xi_i) + 2 \sum_{i=1}^{n-1} \sum_{j=i+1}^n a_i a_j \mathbb{C}(\xi_i, \xi_j). \quad (8.24)$$

◦

Beweis. Mit $\mathbb{V}(\xi) = \mathbb{C}(\xi, \xi)$ und Theorem 8.4 gilt zunächst

$$\begin{aligned} \mathbb{V} \left(a_0 + \sum_{i=1}^n a_i \xi_i \right) &= \mathbb{C} \left(a_0 + \sum_{i=1}^n a_i \xi_i, a_0 + \sum_{i=1}^n a_i \xi_i \right) \\ &= \mathbb{C} \left(a_0 + \sum_{i=1}^n a_i \xi_i, a_0 + \sum_{j=1}^n a_j \xi_j \right) \\ &= \sum_{i=1}^n \sum_{j=1}^n a_i a_j \mathbb{C}(\xi_i, \xi_j) \\ &= \sum_{i=1}^n \sum_{\substack{j=1 \\ j \neq i}}^n a_i a_j \mathbb{C}(\xi_i, \xi_j) + \sum_{i=1}^n \sum_{\substack{j=1 \\ j=i}}^n a_i a_j \mathbb{C}(\xi_i, \xi_j) \\ &= \sum_{i=1}^n a_i a_i \mathbb{C}(\xi_i, \xi_i) + \sum_{i=1}^n \sum_{\substack{j=1 \\ j \neq i}}^n a_i a_j \mathbb{C}(\xi_i, \xi_j) \\ &= \sum_{i=1}^n a_i^2 \mathbb{V}(\xi_i) + \sum_{i=1}^n \sum_{\substack{j=1 \\ j \neq i}}^n a_i a_j \mathbb{C}(\xi_i, \xi_j) \\ &= \sum_{i=1}^n a_i^2 \mathbb{V}(\xi_i) + 2 \sum_{i=1}^{n-1} \sum_{j=i+1}^n a_i a_j \mathbb{C}(\xi_i, \xi_j), \end{aligned} \quad (8.25)$$

Dabei wurde in der vierten Gleichung die Doppelsumme in solche Terme aufgespalten für die $i = j$ und für die $i \neq j$ und in siebten Gleichung ausgenutzt, dass

$$a_i a_j \mathbb{C}(\xi_i, \xi_j) = a_j a_i \mathbb{C}(\xi_j, \xi_i). \quad (8.26)$$

Wir verdeutlichen die daraus folgende Identität

$$\sum_{i=1}^n \sum_{\substack{j=1 \\ j \neq i}}^n a_i a_j \mathbb{C}(\xi_i, \xi_j) = 2 \sum_{i=1}^{n-1} \sum_{j=i+1}^n a_i a_j \mathbb{C}(\xi_i, \xi_j), \quad (8.27)$$

am Beispiel $n = 3$ untenstehend. Analog mag man sich vorstellen, über alle Elemente außer der Diagonalelemente der $i = 1, \dots, n$ Zeilen und $j = 1, \dots, n$ Spalten einer symmetrischen Matrix mit Einträgen $a_i a_j \mathbb{C}(\xi_i, \xi_j)$ zu summieren. Die linke Seite oberer Gleichung entspricht dann dem zeilenweisen Vorgehen der Summationsbildung für alle Spalteneinträge außer dem, der in der Spalte der jeweils betrachteten Zeile steht, d.h. dem Diagonaleintrag. Die rechte Seite der obigen Gleichung entspricht dann dem Vorgehen, die Symmetrie der Matrix auszunutzen, also die Tatsache zu berücksichtigen, dass die Einträge der Matrix rechts oberhalb und links unterhalb der Diagonalen identisch sind, so dass es genügt, die Einträge der oberen linken Hälfte aufzuaddieren und zu verdoppeln. Dabei werden für jede Zeile $i = 1, \dots, n$ nur gerade die Spalten $j = i + 1, \dots, n$ betrachtet, die rechts von der Diagonale stehen und ihre Einträge aufsummiert. In der letzten Zeile steht dabei nur ein Diagonalelement, das nicht zur Summe gehört, weshalb der Index

der äußeren Summe nur bis $n - 1$ läuft. Konkret ergibt sich für $n := 3$

$$\begin{aligned}
& \sum_{i=1}^3 \sum_{\substack{j=1 \\ j \neq i}}^3 a_i a_j \mathbb{C}(\xi_i, \xi_j) \\
&= \sum_{\substack{j=1 \\ j \neq 1}}^3 a_1 a_j \mathbb{C}(\xi_1, \xi_j) + \sum_{\substack{j=1 \\ j \neq 2}}^3 a_2 a_j \mathbb{C}(\xi_2, \xi_j) + \sum_{\substack{j=1 \\ j \neq 3}}^3 a_3 a_j \mathbb{C}(\xi_3, \xi_j) \\
&= a_1 a_2 \mathbb{C}(\xi_1, \xi_2) + a_1 a_3 \mathbb{C}(\xi_1, \xi_3) + a_2 a_1 \mathbb{C}(\xi_2, \xi_1) + a_2 a_3 \mathbb{C}(\xi_2, \xi_3) + a_3 a_1 \mathbb{C}(\xi_3, \xi_1) + a_3 a_2 \mathbb{C}(\xi_3, \xi_2) \\
&= a_1 a_2 \mathbb{C}(\xi_1, \xi_2) + a_2 a_1 \mathbb{C}(\xi_2, \xi_1) + a_1 a_3 \mathbb{C}(\xi_1, \xi_3) + a_3 a_1 \mathbb{C}(\xi_3, \xi_1) + a_2 a_3 \mathbb{C}(\xi_2, \xi_3) + a_3 a_2 \mathbb{C}(\xi_3, \xi_2) \\
&= 2a_1 a_2 \mathbb{C}(\xi_1, \xi_2) + 2a_1 a_3 \mathbb{C}(\xi_1, \xi_3) + 2a_2 a_3 \mathbb{C}(\xi_2, \xi_3) \\
&= 2(a_1 a_2 \mathbb{C}(\xi_1, \xi_2) + a_1 a_3 \mathbb{C}(\xi_1, \xi_3) + a_2 a_3 \mathbb{C}(\xi_2, \xi_3)) \\
&= 2 \left(\sum_{j=2}^3 a_1 a_j \mathbb{C}(\xi_1, \xi_j) + \sum_{j=3}^3 a_2 a_j \mathbb{C}(\xi_2, \xi_j) \right) \\
&= 2 \left(\sum_{j=1+1}^3 a_1 a_j \mathbb{C}(\xi_1, \xi_j) + \sum_{j=2+1}^3 a_2 a_j \mathbb{C}(\xi_2, \xi_j) \right) \\
&= 2 \sum_{i=1}^2 \sum_{j=i+1}^3 a_i a_j \mathbb{C}(\xi_i, \xi_j).
\end{aligned} \tag{8.28}$$

□

Theorem 8.7 (Varianzen spezieller Linearkombinationen von Zufallsvariablen).

(1) (Varianz bei Addition zweier Zufallsvariablen). Gegeben seien zwei Zufallsvariablen ξ und ζ . Dann gilt

$$\mathbb{V}(\xi + \zeta) = \mathbb{V}(\xi) + \mathbb{V}(\zeta) + 2\mathbb{C}(\xi, \zeta) \tag{8.29}$$

(2) (Varianz bei Subtraktion zweier Zufallsvariablen). Gegeben seien zwei Zufallsvariablen ξ und ζ . Dann gilt

$$\mathbb{V}(\xi - \zeta) = \mathbb{V}(\xi) + \mathbb{V}(\zeta) - 2\mathbb{C}(\xi, \zeta) \tag{8.30}$$

◦

Beweis. Es seien $n := 2$, $\xi_1 := \xi$, $\xi_2 := \zeta$, $a_0 := 0$, $a_1 := 1$ und $a_2 := 1$. Dann gilt mit Theorem 8.6

$$\begin{aligned}
\mathbb{V}(\xi + \zeta) &= \mathbb{V}(a_0 + a_1 \xi_1 + a_2 \xi_2) \\
&= \mathbb{V} \left(a_0 + \sum_{i=1}^2 a_i \xi_i \right) \\
&= \sum_{i=1}^2 a_i^2 \mathbb{V}(\xi_i) + 2 \sum_{i=1}^{2-1} \sum_{j=i+1}^2 a_i a_j \mathbb{C}(\xi_i, \xi_j) \\
&= \sum_{i=1}^2 a_i^2 \mathbb{V}(\xi_i) + 2 \sum_{i=1}^1 \sum_{j=i+1}^2 a_i a_j \mathbb{C}(\xi_i, \xi_j) \\
&= \sum_{i=1}^2 a_i^2 \mathbb{V}(\xi_i) + 2 \sum_{j=1+1}^2 a_1 a_j \mathbb{C}(\xi_1, \xi_j) \\
&= \sum_{i=1}^2 a_i^2 \mathbb{V}(\xi_i) + 2 \sum_{j=2}^2 a_1 a_j \mathbb{C}(\xi_1, \xi_j) \\
&= a_1^2 \mathbb{V}(\xi_1) + a_2^2 \mathbb{V}(\xi_2) + 2a_1 a_2 \mathbb{C}(\xi_1, \xi_2) \\
&= 1^2 \cdot \mathbb{V}(\xi) + 1^2 \cdot \mathbb{V}(\zeta) + 2 \cdot 1 \cdot 1 \cdot \mathbb{C}(\xi, \zeta) \\
&= \mathbb{V}(\xi) + \mathbb{V}(\zeta) + 2\mathbb{C}(\xi, \zeta).
\end{aligned} \tag{8.31}$$

Es seien nun $n := 2$, $\xi_1 := \xi$, $\xi_2 := \zeta$, $a_0 := 0$, $a_1 := 1$ und $a_2 := -1$. Dann gilt mit dem Theorem 8.6

$$\begin{aligned}
 \mathbb{V}(\xi - \zeta) &= \mathbb{V}(a_0 + a_1\xi_1 + a_2\xi_2) \\
 &= \mathbb{V}\left(a_0 + \sum_{i=1}^2 a_i\xi_i\right) \\
 &= \sum_{i=1}^2 a_i^2 \mathbb{V}(\xi_i) + 2 \sum_{i=1}^{2-1} \sum_{j=i+1}^2 a_i a_j \mathbb{C}(\xi_i, \xi_j) \\
 &= \sum_{i=1}^2 a_i^2 \mathbb{V}(\xi_i) + 2 \sum_{i=1}^1 \sum_{j=i+1}^2 a_i a_j \mathbb{C}(\xi_i, \xi_j) \\
 &= \sum_{i=1}^2 a_i^2 \mathbb{V}(\xi_i) + 2 \sum_{j=1+1}^2 a_1 a_j \mathbb{C}(\xi_1, \xi_j) \\
 &= \sum_{i=1}^2 a_i^2 \mathbb{V}(\xi_i) + 2 \sum_{j=2}^2 a_1 a_j \mathbb{C}(\xi_1, \xi_j) \\
 &= a_1^2 \mathbb{V}(\xi_1) + a_2^2 \mathbb{V}(\xi_2) + 2a_1 a_2 \mathbb{C}(\xi_1, \xi_2) \\
 &= 1^2 \cdot \mathbb{V}(\xi) + (-1)^2 \cdot \mathbb{V}(\zeta) + 2 \cdot 1 \cdot (-1) \cdot \mathbb{C}(\xi, \zeta) \\
 &= \mathbb{V}(\xi) + \mathbb{V}(\zeta) - 2\mathbb{C}(\xi, \zeta).
 \end{aligned} \tag{8.32}$$

Alternativ gilt ohne Rückgriff auf Theorem 8.6 und mit Theorem 6.2, dass

$$\begin{aligned}
 &\mathbb{V}(a\xi + b\zeta + c) \\
 &= \mathbb{E}((a\xi + b\zeta + c - a\mathbb{E}(\xi) - b\mathbb{E}(\zeta) - c)^2) \\
 &= \mathbb{E}((a(\xi - \mathbb{E}(\xi)) + b(\zeta - \mathbb{E}(\zeta)))^2) \\
 &= \mathbb{E}(a^2(\xi - \mathbb{E}(\xi))^2 + 2ab(\xi - \mathbb{E}(\xi))(\zeta - \mathbb{E}(\zeta)) + b^2(\zeta - \mathbb{E}(\zeta))^2) \\
 &= a^2\mathbb{E}((\xi - \mathbb{E}(\xi))^2) + b^2\mathbb{E}((\zeta - \mathbb{E}(\zeta))^2) + 2ab\mathbb{E}((\xi - \mathbb{E}(\xi))(\zeta - \mathbb{E}(\zeta))) \\
 &= a^2\mathbb{V}(\xi) + b^2\mathbb{V}(\zeta) + 2ab\mathbb{C}(\xi, \zeta).
 \end{aligned} \tag{8.33}$$

Die Spezialfälle folgen dann direkt mit $a := b := 1$ und $a := 1, b := -1$, respektive. $\square$

Schließlich wollen wir mit Theorem 13.12 einen ersten Eindruck zum Zusammenhang von Kovarianz und Korrelation mit dem Begriff der Unabhängigkeit von Zufallsvariablen erlangen. Es zeigt sich, dass Kovarianz und Korrelation lediglich für bestimmte Formen der Abhängigkeit von Zufallsvariablen sensitiv sind und insbesondere, dass von einer Kovarianz von null nicht auf die Unabhängigkeit der Zufallsvariablen geschlossen werden kann. Andererseits impliziert die Unabhängigkeit zweier Zufallsvariablen immer, dass ihre Kovarianz null und sie damit unkorreliert sind. Abhängigkeit und Unabhängigkeit von Zufallsvariablen sind also sehr viel allgemeinere Begrifflichkeiten zur Beschreibung des Zusammenhangs von Zufallsvariablen als Kovarianz und Korrelation.

Theorem 8.8 (Korrelation und Unabhängigkeit von Zufallsvariablen). *ξ_1 und ξ_2 seien zwei Zufallsvariablen. Wenn ξ_1 und ξ_2 unabhängig sind, dann ist $\mathbb{C}(\xi_1, \xi_2) = 0$ und ξ_1 und ξ_2 sind folglich unkorreliert. Ist dagegen $\mathbb{C}(\xi_1, \xi_2) = 0$ und sind ξ_1 und ξ_2 somit unkorreliert, dann sind ξ_1 und ξ_2 nicht notwendigerweise unabhängig.*

◦

Beweis. Wir zeigen in einem ersten Schritt, dass aus der Unabhängigkeit von ξ_1 und ξ_2 $\mathbb{C}(\xi_1, \xi_2) = 0$ folgt. Wir zeigen dann durch Angabe eines Beispiels, dass die Kovarianz von abhängigen Zufallsvariablen ξ_1 und ξ_2 durchaus null sein kann.

(1) Wir zeigen, dass aus der Unabhängigkeit von ξ_1 und ξ_2 $\mathbb{C}(\xi_1, \xi_2) = 0$ folgt. Hierzu halten wir als erstes fest, dass für unabhängige Zufallsvariablen gilt, dass

$$\mathbb{E}(\xi_1 \xi_2) = \mathbb{E}(\xi_1) \mathbb{E}(\xi_2). \tag{8.34}$$

Mit dem Kovarianzverschiebungssatz folgt dann

$$\mathbb{C}(\xi_1, \xi_2) = \mathbb{E}(\xi_1 \xi_2) - \mathbb{E}(\xi_1)\mathbb{E}(\xi_2) = \mathbb{E}(\xi_1)\mathbb{E}(\xi_2) - \mathbb{E}(\xi_1)\mathbb{E}(\xi_2) = 0. \quad (8.35)$$

Mit der Definition des Korrelationskoeffizienten folgt dann, dass $\rho(\xi_1, \xi_2) = 0$ ist und ξ_1 und ξ_2 somit unkorreliert sind.

(2) Wir zeigen nun durch Angabe eines Beispiels, dass die Kovarianz von abhängigen Zufallsvariablen ξ_1 und ξ_2 null sein kann. Zu diesem Zweck betrachten wir den Fall zweier diskreter Zufallsvariablen ξ_1 und ξ_2 mit Ergebnisräumen $\mathcal{X}_1 = \{-1, 0, 1\}$ und $\mathcal{X}_2 = \{0, 1\}$, marginaler WMF von ξ_1 gegeben durch $p(x_1) := \frac{1}{3}$ für alle $x_1 \in \mathcal{X}_1$ und der Definition von

$$\xi_2 := \xi_1^2. \quad (8.36)$$

Die Definition von ξ_2 impliziert dann die in Tabelle 8.2 gezeigte bedingte WMF.

Tabelle 8.2 Bedingte WMF zum Beweis von Theorem 8.8

$p(x_2 x_1)$	$x_1 = -1$	$x_1 = 0$	$x_1 = 1$
$x_2 = 0$	0	1	0
$x_2 = 1$	1	0	1

Die marginale WMF $p(x_1)$ und die bedingte WMF $p(x_2|x_1)$ implizieren dann die in Tabelle 8.3 gezeigte gemeinsame WMF.

Tabelle 8.3 Gemeinsame WMF zum Beweis von Theorem 8.8

$p(x_1, x_2)$	$x_1 = -1$	$x_1 = 0$	$x_1 = 1$	$p(x_2)$
$x_2 = 0$	0	1/3	0	1/3
$x_2 = 1$	1/3	0	1/3	2/3
$p(x_1)$	1/3	1/3	1/3	

Anhand von Tabelle 8.3 gilt also zum Beispiel

$$p(-1, 0) = 0 \neq \frac{1}{9} = \frac{1}{3} \cdot \frac{1}{3} = p(-1)p(0). \quad (8.37)$$

Die gemeinsame WMF von ξ_1 und ξ_2 faktorisiert also nicht und ξ_1 und ξ_2 sind damit nicht unabhängig. Allerdings folgt mit

$$\mathbb{E}(\xi_1) = \sum_{x_1 \in \mathcal{X}_1} x_1 p(x_1) = -1 \cdot \frac{1}{3} + 0 \cdot \frac{1}{3} + 1 \cdot \frac{1}{3} = 0 \quad (8.38)$$

und

$$\mathbb{E}(\xi_1 \xi_2) = \mathbb{E}(\xi_1 \xi_1^2) = \mathbb{E}(\xi_1^3) = \sum_{x_1 \in \mathcal{X}_1} x_1^3 p(x_1) = -1^3 \cdot \frac{1}{3} + 0^3 \cdot \frac{1}{3} + 1^3 \cdot \frac{1}{3} = 0, \quad (8.39)$$

sowie dem Kovarianzverschiebungssatz, dass

$$\mathbb{C}(\xi_1, \xi_2) = \mathbb{E}(\xi_1 \xi_2) - \mathbb{E}(\xi_1)\mathbb{E}(\xi_2) = \mathbb{E}(\xi_1^3) - \mathbb{E}(\xi_1)\mathbb{E}(\xi_2) = 0 - 0 \cdot \mathbb{E}(\xi_2) = 0. \quad (8.40)$$

Die Kovarianz von ξ_1 und ξ_2 ist also null und ξ_1 und ξ_2 damit unkorreliert, obwohl ξ_1 und ξ_2 nicht unabhängig sind. $\square$

8.3 Bedingte Kovarianz

Wie den Erwartungswert und die Varianz kann man auch die Kovarianz in einer bedingten gemeinsamen Verteilung zweier Zufallsvariablen betrachten. Dies führt auf den Begriff der *bedingten Kovarianz*.

Definition 8.2 (Bedingte Kovarianz). Gegeben sei ein Zufallsvektor $\xi := (\xi_1, \xi_2, \xi_3)$ mit Ergebnisraum $\mathcal{X} := \mathcal{X}_1 \times \mathcal{X}_2 \times \mathcal{X}_3$ und WMF oder WDF $p(x_1, x_2, x_3)$ und bedingter WMF oder WDF $p(x_1, x_2 | x_3)$ für alle $x_3 \in \mathcal{X}_3$. Dann ist die bedingte Kovarianz von ξ_1 und ξ_2 gegeben $\xi_3 = x_3$ definiert als

$$\mathbb{C}(\xi_1, \xi_2 | \xi_3 = x_3) = \mathbb{E}((\xi_1 - \mathbb{E}(\xi_1 | \xi_3 = x_3))(\xi_2 - \mathbb{E}(\xi_2 | \xi_3 = x_3)) | \xi_3 = x_3) \quad (8.41)$$

•

Die bedingte Kovarianz ist also im Sinne des bedingten Erwartungswerts des Zufallsvektors (ξ_1, ξ_2) definiert und ist, wie der bedingte Erwartungswert und die bedingte Varianz im Allgemeinen eine Zufallsvariable dar. Schließlich halten wir fest, dass auch für die bedingte Kovarianz der Kovarianzverschiebungssatz gilt.

Theorem 8.9 (Verschiebungssatz der bedingten Kovarianz). Gegeben sei ein Zufallsvektor $\xi := (\xi_1, \xi_2, \xi_3)$. Dann gilt

$$\mathbb{C}(\xi_1, \xi_2 | \xi_3) = \mathbb{E}(\xi_1 \xi_2 | \xi_3) - \mathbb{E}(\xi_1 | \xi_3) \mathbb{E}(\xi_2 | \xi_3). \quad (8.42)$$

◦

Beweis. Ein Beweis ergibt sich durch die Ersetzung der entsprechenden Erwartungswerte im Beweis von Theorem 8.2 durch die entsprechenden bedingten Erwartungswerte. $\square$

8.4 Kovarianzmatrizen

Das multivariate Analogon der Varianz einer Zufallsvariable ist die *Kovarianzmatrix eines Zufallsvektors*. Diese enkodiert neben den Varianzen der Komponenten des Zufallsvektors auch ihre paarweisen Kovarianzen und ist wie folgt definiert.

Definition 8.3 (Kovarianzmatrix eines Zufallsvektors). ξ sei ein n -dimensionaler Zufallsvektor. Dann ist die *Kovarianzmatrix* von ξ definiert als die $n \times n$ Matrix

$$\mathbb{C}(\xi) := \mathbb{E}((\xi - \mathbb{E}(\xi))(\xi - \mathbb{E}(\xi))^T). \quad (8.43)$$

•

Die Kovarianzmatrix ist in Definition 8.3 formal analog zur Kovarianz zweier Zufallsvariablen definiert. Eine direkte Rückführung des Begriffs der Kovarianzmatrix eines Zufallsvektors auf den Begriff aus dem univariaten Kontext bekannten Begriff der Kovarianz zweier Zufallsvariablen erlaubt folgendes Theorem.

Theorem 8.10 (Eigenschaften der Kovarianzmatrix). ξ sei ein m -dimensionaler Zufallsvektor und $\mathbb{C}(\xi)$ sei seine Kovarianzmatrix. Dann gelten

(1) (Elemente) Die Elemente von $\mathbb{C}(\xi)$ sind die Kovarianzen der Komponenten von ξ ,

$$\mathbb{C}(\xi) = (\mathbb{C}(\xi_i, \xi_j))_{1 \leq i, j \leq m}. \quad (8.44)$$

(2) (Kovarianzmatrixverschiebungssatz) Es gilt

$$\mathbb{C}(\xi) = \mathbb{E}(\xi \xi^T) - \mathbb{E}(\xi) \mathbb{E}(\xi)^T. \quad (8.45)$$

(3) (Linear-affine Transformation) Für $A \in \mathbb{R}^{n \times m}$ und $b \in \mathbb{R}^n$ gilt

$$\mathbb{C}(A\xi + b) = A\mathbb{C}(\xi)A^T. \quad (8.46)$$

(4) (Matrizeigenschaften) $\mathbb{C}(\xi)$ ist symmetrisch und positiv-semidefinit.

◦

Beweis. (1) Es gilt

$$\begin{aligned} \mathbb{C}(\xi) &:= \mathbb{E}((\xi - \mathbb{E}(\xi))(\xi - \mathbb{E}(\xi))^T) \\ &= \mathbb{E}\left(\left(\begin{pmatrix} \xi_1 \\ \vdots \\ \xi_n \end{pmatrix} - \begin{pmatrix} \mathbb{E}(\xi_1) \\ \vdots \\ \mathbb{E}(\xi_n) \end{pmatrix}\right)\left(\begin{pmatrix} \xi_1 \\ \vdots \\ \xi_n \end{pmatrix} - \begin{pmatrix} \mathbb{E}(\xi_1) \\ \vdots \\ \mathbb{E}(\xi_n) \end{pmatrix}\right)^T\right) \\ &= \mathbb{E}\left(\begin{pmatrix} \xi_1 - \mathbb{E}(\xi_1) \\ \vdots \\ \xi_n - \mathbb{E}(\xi_n) \end{pmatrix}\begin{pmatrix} \xi_1 - \mathbb{E}(\xi_1) \\ \vdots \\ \xi_n - \mathbb{E}(\xi_n) \end{pmatrix}^T\right) \\ &= \mathbb{E}\left(\begin{pmatrix} \xi_1 - \mathbb{E}(\xi_1) \\ \vdots \\ \xi_n - \mathbb{E}(\xi_n) \end{pmatrix}(\xi_1 - \mathbb{E}(\xi_1) \quad \dots \quad \xi_n - \mathbb{E}(\xi_n))\right) \\ &= \mathbb{E}\begin{pmatrix} (\xi_1 - \mathbb{E}(\xi_1))(\xi_1 - \mathbb{E}(\xi_1)) & \dots & (\xi_1 - \mathbb{E}(\xi_1))(\xi_n - \mathbb{E}(\xi_n)) \\ \vdots & \ddots & \vdots \\ (\xi_n - \mathbb{E}(\xi_n))(\xi_1 - \mathbb{E}(\xi_1)) & \dots & (\xi_n - \mathbb{E}(\xi_n))(\xi_n - \mathbb{E}(\xi_n)) \end{pmatrix} \\ &= (\mathbb{E}((\xi_i - \mathbb{E}(\xi_i))(\xi_j - \mathbb{E}(\xi_j))))_{1 \leq i, j \leq n} \\ &= (\mathbb{C}(\xi_i, \xi_j))_{1 \leq i, j \leq n}. \end{aligned} \quad (8.47)$$

(2) Mit den Eigenschaften von Erwartungswerten gilt

$$\begin{aligned} \mathbb{C}(\xi) &= \mathbb{E}((\xi - \mathbb{E}(\xi))(\xi - \mathbb{E}(\xi))^T) \\ &= \mathbb{E}(\xi \xi^T - \xi \mathbb{E}(\xi)^T - \mathbb{E}(\xi) \xi^T + \mathbb{E}(\xi) \mathbb{E}(\xi)^T) \\ &= \mathbb{E}(\xi \xi^T) - \mathbb{E}(\xi) \mathbb{E}(\xi)^T - \mathbb{E}(\xi) \mathbb{E}(\xi)^T + \mathbb{E}(\xi) \mathbb{E}(\xi)^T \\ &= \mathbb{E}(\xi \xi^T) - \mathbb{E}(\xi) \mathbb{E}(\xi)^T. \end{aligned} \quad (8.48)$$

(3) Mit den Eigenschaften von Erwartungswerten gilt

$$\begin{aligned} \mathbb{C}(A\xi + b) &= \mathbb{E}((A\xi + b - \mathbb{E}(A\xi + b))(A\xi + b - \mathbb{E}(A\xi + b))^T) \\ &= \mathbb{E}((A\xi + b - A\mathbb{E}(\xi) - b)(A\xi + b - A\mathbb{E}(\xi) - b)^T) \\ &= \mathbb{E}((A(\xi - \mathbb{E}(\xi)))(A(\xi - \mathbb{E}(\xi)))^T) \\ &= \mathbb{E}(A(\xi - \mathbb{E}(\xi))(\xi - \mathbb{E}(\xi))^T A^T) \\ &= A\mathbb{E}((\xi - \mathbb{E}(\xi))(\xi - \mathbb{E}(\xi))^T) A^T \\ &= A\mathbb{C}(\xi)A^T. \end{aligned} \quad (8.49)$$

(4) Die Symmetrie von $\mathbb{C}(\xi)$ folgt aus der Symmetrie der Kovarianz einer Zufallsvariable mit

$$\mathbb{C}(\xi_i, \xi_j) = \mathbb{C}(\xi_j, \xi_i) \text{ für alle } i = 1, \dots, m, j = 1, \dots, m. \quad (8.50)$$

Um die positive Semidefinitheit von $\mathbb{C}(\xi)$ nachzuweisen, ist zu zeigen, dass $a^T \mathbb{C}(\xi) a \geq 0$ für alle $a \in \mathbb{R}^m$ mit $a \neq 0_m$. Sei also $a \in \mathbb{R}^m$ mit $a \neq 0$. Dann gilt mit Aussage (3) für $A := a^T \in \mathbb{R}^{1 \times m}$, dass

$$a^T \mathbb{C}(\xi) a = \mathbb{C}(a^T \xi). \quad (8.51)$$

Weiterhin gilt mit der Definition der Kovarianzmatrix aber, dass

$$\mathbb{C}(a^T \xi) = \mathbb{E} \left((a^T \xi - \mathbb{E}(a^T \xi))^2 \right) = \mathbb{V}(a^T \xi). \quad (8.52)$$

Da mit den Eigenschaften der Varianz die Varianz der Zufallsvariable $a^T \xi$ aber immer nichtnegativ ist, folgt

$$a^T \mathbb{C}(\xi) a = \mathbb{V}(a^T \xi) \geq 0 \quad (8.53)$$

und damit die positive Semidefinitheit von $\mathbb{C}(\xi)$. $\square$

Die Diagonalelemente von $\mathbb{C}(\xi)$ sind die Varianzen der Komponenten von ξ , da

$$\mathbb{V}(\xi_i) = \mathbb{C}(\xi_i, \xi_i) \text{ für } i = 1, \dots, m. \quad (8.54)$$

Eigenschaften (2) und (3) sind im Wesentlichen analog zu den Eigenschaften der Varianz.

Die Kovarianzmatrix eines Zufallsvektors ξ ist also die Matrix der Kovarianzen der Komponenten von ξ . Damit ist auch die Kovarianzmatrix direkt im Sinne des Begriffs der Kovarianz von Zufallsvektoren gegeben. Da die Kovarianz einer Zufallsvariable mit sich selbst bekanntlich ihre Varianz ist, enthält die Kovarianzmatrix auf ihrer Diagonalen die Varianzen der Komponenten von ξ .

Folgendes Theorem dokumentiert eine Schreibweise für die Kovarianzmatrix eines partitionierten Zufallsvektors im Sinne von Erwartungswerten von Zufallsvektorprodukten an, die zum Beispiel im Rahmen der Kanonischen Korrelationsanalyse hilfreich ist.

Theorem 8.11 (Kovarianzmatrizen von Zufallsvektoren). *Es seien*

$$\zeta = \begin{pmatrix} \xi \\ v \end{pmatrix} \text{ mit } \mathbb{E}(\zeta) := 0_m \quad (8.55)$$

ein $m_\xi + m_v$ -dimensionaler Zufallsvektor und sein Erwartungswertvektor, respektive. Dann kann die $m \times m$ Kovarianzmatrix von ζ geschrieben werden als

$$\mathbb{C}(\zeta) = \begin{pmatrix} \Sigma_{\xi\xi} & \Sigma_{\xi_1\xi_2} \\ \Sigma_{v\xi} & \Sigma_{vv} \end{pmatrix} \in \mathbb{R}^{m \times m} \quad (8.56)$$

wobei

$$\begin{aligned} \Sigma_{\xi\xi} &:= \mathbb{E}(\xi\xi^T) \in \mathbb{R}^{m_\xi \times m_\xi} \\ \Sigma_{\xi_1\xi_2} &:= \mathbb{E}(\xi_1\xi_2^T) \in \mathbb{R}^{m_\xi \times m_v} \\ \Sigma_{v\xi} &:= \mathbb{E}(v\xi^T) \in \mathbb{R}^{m_v \times m_\xi} \\ \Sigma_{vv} &:= \mathbb{E}(vv^T) \in \mathbb{R}^{m_v \times m_v} \end{aligned} \quad (8.57)$$

◦

Beweis. Nach Definition der Kovarianzmatrix eines Zufallsvektors gilt

$$\begin{aligned} \mathbb{C}(z) &= \mathbb{E}((\zeta - \mathbb{E}(\zeta))(\zeta - \mathbb{E}(\zeta))^T) \\ &= \mathbb{E}((\zeta - 0_m)(\zeta - 0_m)^T) \\ &= \mathbb{E}(\zeta\zeta^T) \\ &= \mathbb{E}\left(\begin{pmatrix} \xi \\ v \end{pmatrix} \begin{pmatrix} \xi^T & v^T \end{pmatrix}\right) \\ &= \mathbb{E}\left(\begin{pmatrix} \xi\xi^T & \xi_1\xi_2^T \\ v\xi^T & vv^T \end{pmatrix}\right) \\ &= \begin{pmatrix} \mathbb{E}(\xi\xi^T) & \mathbb{E}(\xi_1\xi_2^T) \\ \mathbb{E}(v\xi^T) & \mathbb{E}(vv^T) \end{pmatrix} \\ &= \begin{pmatrix} \Sigma_{\xi\xi} & \Sigma_{\xi_1\xi_2} \\ \Sigma_{v\xi} & \Sigma_{vv} \end{pmatrix} \end{aligned} \quad (8.58)$$

□

Schließlich ist man in manchen Anwendungen an einer normalisierten, maßstabsunabhängigen Repräsentation der Kovarianzen eines Zufallsvektors interessiert. Wie im univariaten Fall bietet sich hierfür die Normalisierung der Kovarianz zweier Zufallsvariablen mithilfe ihrer jeweiligen Varianzen im Sinne einer Korrelation an. Diese Überlegung führt auf den Begriff der *Korrelationsmatrix* eines Zufallsvektors.

Definition 8.4 (Korrelationsmatrix). ξ sei ein n -dimensionaler Zufallsvektor. Dann ist die *Korrelationsmatrix* von ξ definiert als die $n \times n$ Matrix

$$\mathbb{R}(\xi) := (\rho_{ij})_{1 \leq i, j \leq n} = \left(\frac{\mathbb{C}(\xi_i, \xi_j)}{\sqrt{\mathbb{V}(\xi_i)} \sqrt{\mathbb{V}(\xi_j)}} \right)_{1 \leq i, j \leq n}. \quad (8.59)$$

•

Da es sich bei den Varianzen der Komponenten von ξ um die Diagonalelemente der Kovarianzmatrix von ξ handelt, ist die Korrelationsmatrix natürlich in der Kovarianzmatrix implizit. Weiterhin gelten, wie immer für Korrelationen, für die Einträge ρ_{ij} , $1 \leq i, j \leq n$ der Korrelationsmatrix, dass

$$\rho_{ij} \in [-1, 1] \text{ für } 1 \leq i, j \in n \text{ und } \rho_{ii} = 1 \text{ für } 1 \leq i \leq n. \quad (8.60)$$

Selbstkontrollfragen

1. Geben Sie die Definition von Kovarianz und Korrelation zweier Zufallsvariablen wieder.
2. Erläutern Sie die Definition von Kovarianz und Korrelation zweier Zufallsvariablen.
3. Geben Sie das Theorem zur Symmetrie von Kovarianz und Korrelation wieder.
4. Geben Sie das Theorem zur Kovarianz und Korrelation bei linear-affinen Transformation wieder.
5. Erläutern Sie das Theorem zur Kovarianz und Korrelation bei linear-affinen Transformation.
6. Geben Sie das Theorem zu den Varianzen spezieller Linearkombinationen von Zufallsvariablen wieder.
7. Geben Sie das Theorem zur Korrelation und Unabhängigkeit von Zufallsvariablen wieder.

Lösungen

1. Siehe Definition 8.1.
2. Siehe Erläuterungen zu Definition 8.1 und Beispiel 8.1.
3. Siehe Theorem 8.1.
4. Siehe Theorem 8.3.
5. Siehe Erläuterungen zu Theorem 8.3.
6. Siehe Theorem 8.7.
7. Siehe Theorem 8.8.

9 Ungleichungen

Das Thema dieses Kapitels sind Ungleichungen, die in der Wahrscheinlichkeitstheorie häufig zur Abschätzung von Wahrscheinlichkeiten und Erwartungswerten genutzt werden. Wir gliedern die Ungleichungen entsprechend in *Wahrscheinlichkeitsungleichungen* (*Markov-Ungleichung* und *Chebyshev Ungleichung*, Kapitel 9.1) und *Erwartungswertungleichungen* (*Cauchy-Schwarz-Ungleichung*, *Korrelationsungleichung* und *Jensensche Ungleichung*, Kapitel 9.2).

9.1 Wahrscheinlichkeitsungleichungen

Die *Markov-Ungleichung* stellt einen Bezug zwischen den Überschreitungswahrscheinlichkeiten (vgl. Theorem 4.2) und dem Erwartungswert einer *nicht-negativen* Zufallsvariablen, also einer Zufallsvariable, für die $\mathbb{P}(\xi \geq 0) = 1$ ist, her. Im Beweis dieser Ungleichung wollen wir nur den Fall einer kontinuierlichen Zufallsvariable betrachten.

Theorem 9.1 (Markov-Ungleichung). ξ sei eine Zufallsvariable mit $\mathbb{P}(\xi \geq 0) = 1$. Dann gilt für alle $x > 0$, dass

$$\mathbb{P}(\xi \geq x) \leq \frac{\mathbb{E}(\xi)}{x}. \quad (9.1)$$

◦

Beweis. Wir betrachten den Fall einer kontinuierlichen Zufallsvariable ξ mit WDF p . Wir halten zunächst fest, dass

$$\mathbb{E}(\xi) = \int_{-\infty}^{\infty} s p(s) ds = \int_0^{\infty} s p(s) ds = \int_0^x s p(s) ds + \int_x^{\infty} s p(s) ds, \quad (9.2)$$

weil ξ nicht-negativ ist. Es folgt dann

$$\mathbb{E}(\xi) \geq \int_x^{\infty} s p(s) ds \geq \int_x^{\infty} x p(s) ds = x \int_x^{\infty} p(s) ds = x \mathbb{P}(\xi \geq x). \quad (9.3)$$

Dabei gilt die erste Ungleichung, weil

$$\int_0^x s p(s) ds \geq 0, \quad (9.4)$$

und die zweite Ungleichung gilt, weil $x \leq \xi$ für $\xi \in [x, \infty[$. Es folgt also, dass

$$\mathbb{E}(\xi) \geq x \mathbb{P}(\xi \geq x) \Leftrightarrow \mathbb{P}(\xi \geq x) \leq \frac{\mathbb{E}(\xi)}{x}. \quad (9.5)$$

□

Gilt beispielweise für eine nichtnegative Zufallsvariable ξ , dass $\mathbb{E}(\xi) = 1$ ist, dann folgt aus der Markov-Ungleichung, dass

$$\mathbb{P}(\xi \geq 100) \leq 0.01. \quad (9.6)$$

Beispiel 9.1 (Markov-Ungleichung). Als Beispiel für die Markov-Ungleichung betrachten wir den Fall einer Gamma-Zufallsvariable $\xi \sim G(\alpha, \beta)$. Gamma-Zufallsvariablen sind bekanntlich definitionsgemäß nicht-negativ (vgl. Definition 4.10). Für den Erwartungswert einer Gamma-Zufallsvariable gilt $\mathbb{E}(\xi) = \alpha\beta$. Wir betrachten konkret den Fall $\alpha := 5$ und $\beta := 2$, sodass ξ auch einer χ^2 -Zufallsvariable mit Freiheitsgradparameter $n = 10$ entspricht. In Abbildung 9.1 A stellen wir die KVF P dieser Zufallsvariable dar, in Abbildung 9.1 B visualisieren wir die in der Markov-Ungleichung betrachteten Größen $\mathbb{E}(\xi)/x$ und die Überschreitungswahrscheinlichkeit $\mathbb{P}(\xi \geq x) = 1 - P(x)$. Offensichtlich trifft die Markov-Ungleichung zu.

△




Abbildung 9.1 Markov-Ungleichung am Beispiel einer Gamma-Zufallsvariable.

Die Chebychev Ungleichung setzt die Wahrscheinlichkeit dafür, dass eine Zufallsvariable Werte weit von ihrem Erwartungswert entfernt annimmt, in Bezug zu ihrer Varianz. Wie in Kapitel 7 erläutert, liefert die Chebychev Ungleichung damit eine Begründung dafür, warum die in Definition 7.1 formulierte Größe als ein Maß für die Variabilität einer Zufallsvariable verstanden werden kann. Im Beweis der Chebyshev -Ungleichung wird an entscheidender Stelle auf die Markov Ungleichung zurückgegriffen.

Theorem 9.2 (Chebyshev -Ungleichung). *Es sei ξ eine Zufallsvariable mit Varianz $\mathbb{V}(\xi)$. Dann gilt für alle $x \in \mathbb{R}$*

$$\mathbb{P}(|\xi - \mathbb{E}(\xi)| \geq x) \leq \frac{\mathbb{V}(\xi)}{x^2}. \quad (9.7)$$

◦

Beweis. Wir halten zunächst fest, dass für $a, b \in \mathbb{R}$ gilt, dass aus $a^2 \geq b^2$ folgt, dass $|a| \geq b$. Dazu betrachten wir die folgenden vier möglichen Fälle.

(1) $a^2 \geq b^2$ für $a \geq 0$ und $b \geq 0$. Dann gilt

$$a^2 \geq b^2 \Rightarrow \sqrt{a^2} \geq \sqrt{b^2} \Rightarrow a \geq b \Rightarrow |a| \geq b. \quad (9.8)$$

(2) $a^2 \geq b^2$ für $a < 0$ und $b \geq 0$. Dann gilt

$$a^2 \geq b^2 \Rightarrow \sqrt{a^2} \geq \sqrt{b^2} \Rightarrow -a \geq b \Rightarrow |a| \geq b. \quad (9.9)$$

(3) $a^2 \geq b^2$ für $a \geq 0$ und $b < 0$. Dann gilt

$$a^2 \geq b^2 \Rightarrow \sqrt{a^2} \geq \sqrt{b^2} \Rightarrow a \geq -b \geq b \Rightarrow |a| \geq b. \quad (9.10)$$

(4) $a^2 \geq b^2$ für $a < 0$ und $b < 0$. Dann gilt

$$a^2 \geq b^2 \Rightarrow \sqrt{a^2} \geq \sqrt{b^2} \Rightarrow -a \geq -b > b \Rightarrow |a| \geq b. \quad (9.11)$$

Als Nächstes definieren wir $v := (\xi - \mathbb{E}(\xi))^2$. Dann gilt offenbar $v \geq 0$ und es folgt aus der Markov-Ungleichung

$$\begin{aligned} \mathbb{P}(v \geq x^2) &\leq \frac{\mathbb{E}(v)}{x^2} \\ \Leftrightarrow \mathbb{P}((\xi - \mathbb{E}(\xi))^2 \geq x^2) &\leq \frac{\mathbb{E}((\xi - \mathbb{E}(\xi))^2)}{x^2} \\ \Leftrightarrow \mathbb{P}(|\xi - \mathbb{E}(\xi)| \geq x) &\leq \frac{\mathbb{V}(\xi)}{x^2}. \end{aligned} \quad (9.12)$$

□

9.2 Erwartungswertungleichungen

Die Cauchy-Schwarz-Ungleichung ist eine zentrale Ungleichung der modernen Mathematik, die in verschiedenen mathematischen Bereichen wie der Analysis, der Vektorraumtheorie und eben auch der Wahrscheinlichkeitstheorie zur Anwendung kommt (vgl. Steele (2006)). In Bezug auf Erwartungswerte von Zufallsvariablen hat sie die folgende Form.

Theorem 9.3 (Cauchy-Schwarz-Ungleichung). ξ und v seien zwei Zufallsvariablen und $\mathbb{E}(\xi v)$ sei endlich. Dann gilt

$$\mathbb{E}(\xi v)^2 \leq \mathbb{E}(\xi^2) \mathbb{E}(v^2). \quad (9.13)$$

◦

Für einen Beweis verweisen wir auf den Beweis von Theorem 4.6.2 in DeGroot & Schervish (2012). Analog zu Theorem 9.3 gilt zum Beispiel für Vektoren $x, y \in \mathbb{R}^n$, dass

$$\langle x, y \rangle^2 \leq \langle x, x \rangle \langle y, y \rangle. \quad (9.14)$$

Im Kontext der probabilistischen Datenanalyse ist die Anwendung der Cauchy-Schwarz Ungleichung vor allem im Beweis der sogenannten *Korrelationsungleichung* von Relevanz.

Theorem 9.4 (Korrelationsungleichung). ξ und v seien Zufallsvariablen mit $\mathbb{V}(\xi) > 0$ und $\mathbb{V}(v) > 0$. Dann gelten

$$\frac{\mathbb{C}(\xi, v)^2}{\mathbb{V}(\xi)\mathbb{V}(v)} \leq 1 \text{ und } -1 \leq \rho(\xi, v) \leq 1. \quad (9.15)$$

◦

Beweis. Mit der Cauchy-Schwarz-Ungleichung für zwei Zufallsvariablen α und β gilt, dass

$$\mathbb{E}(\alpha\beta)^2 \leq \mathbb{E}(\alpha^2) \mathbb{E}(\beta^2). \quad (9.16)$$

Wir definieren nun $\alpha := \xi - \mathbb{E}(\xi)$ und $\beta := v - \mathbb{E}(v)$. Dann besagt die Cauchy-Schwarz-Ungleichung gerade, dass

$$\mathbb{E}((\xi - \mathbb{E}(\xi))(v - \mathbb{E}(v)))^2 \leq \mathbb{E}((\xi - \mathbb{E}(\xi))^2) \mathbb{E}((v - \mathbb{E}(v))^2). \quad (9.17)$$

Also gilt

$$\mathbb{C}(\xi, v)^2 \leq \mathbb{V}(\xi)\mathbb{V}(v) \Leftrightarrow \frac{\mathbb{C}(\xi, v)^2}{\mathbb{V}(\xi)\mathbb{V}(v)} \leq 1. \quad (9.18)$$

Weiterhin folgt aus der Definition der Korrelation dann sofort, dass auch

$$\rho(\xi, v)^2 \leq 1. \quad (9.19)$$

Dann gilt aber auch

$$|\rho(\xi, v)| \leq 1 \Leftrightarrow -1 \leq \rho(\xi, v) \leq 1, \quad (9.20)$$

denn

$$\rho(\xi, v)^2 \leq 1 \Rightarrow \sqrt{\rho(\xi, v)^2} \leq \sqrt{1} \Rightarrow |\rho(\xi, v)| \leq 1 \text{ für } \rho(\xi, v) \geq 0 \quad (9.21)$$

und

$$\rho(\xi, v)^2 \leq 1 \Rightarrow \sqrt{\rho(\xi, v)^2} \leq \sqrt{1} \Rightarrow -\rho(\xi, v) \leq 1 \Rightarrow |\rho(\xi, v)| \leq 1 \text{ für } \rho(\xi, v) < 0. \quad (9.22)$$

□

Die Korrelationsungleichung wird manchmal auch als *Kovarianzungleichung* bezeichnet. Insbesondere besagt sie, dass die Korrelation von Zufallsvariablen normalisiert ist, also immer Werte zwischen -1 und 1 inklusive annimmt (vgl. Kapitel 8).

Die *Jensensche Ungleichung* schließlich liefert Abschätzungen für den Erwartungswert einer durch eine konvexe oder konkave Funktion transformierte Zufallsvariable. Sie kommt in der Betrachtung von Parameterschätzereigenschaften (vgl. [Parameterschätzung \(PDWP\)](#)) und insbesondere als Grundlage der variationalen Bayesianischen Inferenz zum Einsatz. Wir erinnern daran, dass sich eine konvexe Funktion g dadurch auszeichnet, dass der Funktionsgraf von g über einem Intervall $[x_1, x_2]$ immer unter der verbindenden Geraden zwischen den Funktionswerten $g(x_1)$ und $g(x_2)$ liegt, wohingegen bei einer konkaven Funktion g dieser immer über der verbindenden Geraden zwischen den Funktionswerten $g(x_1)$ zu $g(x_2)$ liegt. Wir visualisieren dies für eine konvexe Funktion in Abbildung 9.2.

Theorem 9.5 (Jensensche Ungleichung). ξ sei eine Zufallsvariable und $g : \mathbb{R} \rightarrow \mathbb{R}$ eine konvexe Funktion, d.h.

$$g(\lambda x_1 + (1 - \lambda)x_2) \leq \lambda g(x_1) + (1 - \lambda)g(x_2) \quad (9.23)$$

für alle $x_1, x_2 \in \mathbb{R}, \lambda \in [0, 1]$. Dann gilt

$$\mathbb{E}(g(\xi)) \geq g(\mathbb{E}(\xi)). \quad (9.24)$$

Analog sei $g : \mathbb{R} \rightarrow \mathbb{R}$ eine konkave Funktion, d.h.

$$g(\lambda x_1 + (1 - \lambda)x_2) \geq \lambda g(x_1) + (1 - \lambda)g(x_2) \quad (9.25)$$

für alle $x_1, x_2 \in \mathbb{R}, \lambda \in [0, 1]$. Dann gilt

$$\mathbb{E}(g(\xi)) \leq g(\mathbb{E}(\xi)). \quad (9.26)$$

◦

Beweis. Es sei g eine konvexe Funktion. Dann gilt für die Tangente t von g in $x_0 \in \mathbb{R}$ für alle $x \in \mathbb{R}$, dass

$$g(x) \geq t(x) := g(x_0) + g'(x_0)(x - x_0) \quad (9.27)$$

Wir setzen nun $x := \xi$ und $x_0 := \mathbb{E}(\xi)$. Dann gilt mit obiger Ungleichung, dass

$$g(\xi) \geq g(\mathbb{E}(\xi)) + g'(\mathbb{E}(\xi))(\xi - \mathbb{E}(\xi)) \quad (9.28)$$

Erwartungswertbildung ergibt dann

$$\begin{aligned} \mathbb{E}(g(\xi)) &\geq \mathbb{E}(g(\mathbb{E}(\xi)) + g'(\mathbb{E}(\xi))(\xi - \mathbb{E}(\xi))) \\ &\Leftrightarrow \mathbb{E}(g(\xi)) \geq g(\mathbb{E}(\xi)) + g'(\mathbb{E}(\xi))\mathbb{E}(\xi - \mathbb{E}(\xi)) \\ &\Leftrightarrow \mathbb{E}(g(\xi)) \geq g(\mathbb{E}(\xi)) + g'(\mathbb{E}(\xi))(\mathbb{E}(\xi) - \mathbb{E}(\xi)) \\ &\Leftrightarrow \mathbb{E}(g(\xi)) \geq g(\mathbb{E}(\xi)). \end{aligned} \quad (9.29)$$

Sei nun g eine konkave Funktion. Dann ist $-g$ eine konvexe Funktion. Mit der Jensenschen Ungleichung für konvexe Funktionen folgt dann die Jensensche Ungleichung für konkave Funktionen aus

$$\begin{aligned} \mathbb{E}(-g(\xi)) &\geq -g(\mathbb{E}(\xi)) \\ &\Leftrightarrow -\mathbb{E}(g(\xi)) \geq -g(\mathbb{E}(\xi)) \\ &\Leftrightarrow \mathbb{E}(g(\xi)) \leq g(\mathbb{E}(\xi)). \end{aligned} \quad (9.30)$$

□

Im Kontext der variationalen Bayesianischen Inferenz ist grundlegend, dass der Logarithmus eine konkave Funktion ist und damit für eine beliebige Zufallsvariable ξ gilt, dass

$$\mathbb{E}(\ln \xi) \leq \ln \mathbb{E}(\xi). \quad (9.31)$$

Selbstkontrollfragen

1. Geben Sie die Markov-Ungleichung wieder.
2. Geben Sie die Chebyshev -Ungleichung wieder.
3. Geben Sie die Cauchy-Schwarz-Ungleichung wieder
4. Geben Sie die Korrelationsungleichung wieder.

Lösungen

1. Siehe Theorem [9.1](#).
2. Siehe Theorem [9.2](#).
3. Siehe Theorem [9.3](#).
4. Siehe Theorem [9.4](#).




Abbildung 9.2 Darstellung der konvexen Funktion $g(x) := x^2$ mit $x_1 := -\sqrt{1.5}$, $x_2 := \sqrt{3.5}$, $\lambda \in [0, 1]$ und $x_0 := 1$.

10 Grenzwerte

In diesem Kapitel beschäftigen wir uns mit für die probabilistische Modellbildung und Datenanalyse grundlegenden Grenzwertaussagen zu Folgen von Zufallsvariablen. Dabei liefern die *Gesetze der großen Zahlen* (Kapitel 10.1) zunächst eine grundlegende Begründung für die Mittelwertbildung im Rahmen der probabilistischen Inferenz. Die *zentralen Grenzwertsätze* liefern dann die Begründung für die weite Verbreitung von Normalverteilungsannahmen zu unbekannten Einflüssen im Rahmen der probabilistischen Modellformulierung (Kapitel 10.2). Die mathematische Tiefe dieser Grenzwertaussagen kann in dieser einführenden Betrachtung nicht ausgeschöpft werden, sodass wir uns mit zahlreichen Vereinfachungen begnügen müssen. Ein minimales Vorwissen zu Funktionenfolgen und ihren Grenzfunktionen liefert [Folgen, Grenzwerte, Stetigkeit \(PDWP\)](#).

10.1 Gesetze der großen Zahlen

Es gibt ein *schwaches Gesetz der großen Zahlen* und ein *starkes Gesetz der großen Zahlen*. Intuitiv besagen beide Gesetze, dass sich das Stichprobenmittel von unabhängigen und identisch verteilten Zufallsvariablen für eine große Anzahl an Zufallsvariablen dem Erwartungswert der zugrundeliegenden Verteilung nähert. Das schwache und das starke Gesetz der großen Zahlen unterscheiden sich in Hinblick auf die zu ihrer Formulierung benutzen Formen der *Konvergenz von Zufallsvariablen*. Das schwache Gesetz basiert auf der *Konvergenz in Wahrscheinlichkeit*. Das starke Gesetz basiert auf der *fast sicheren Konvergenz*. Wir begnügen uns hier mit dem Begriff der Konvergenz in Wahrscheinlichkeit und damit dem schwachen Gesetz der großen Zahlen.

Definition 10.1 (Konvergenz in Wahrscheinlichkeit). Eine Folge von Zufallsvariablen $\xi_1, \xi_2, \dots$ *konvergiert gegen eine Zufallsvariable ξ in Wahrscheinlichkeit*, wenn für jedes noch so kleine $\epsilon > 0$ gilt, dass

$$\lim_{n \rightarrow \infty} \mathbb{P}(|\xi_n - \xi| < \epsilon) = 1 \Leftrightarrow \lim_{n \rightarrow \infty} \mathbb{P}(|\xi_n - \xi| \geq \epsilon) = 0. \quad (10.1)$$

Die Konvergenz von $\xi_1, \xi_2, \dots$ gegen ξ in Wahrscheinlichkeit wird geschrieben als

$$\xi_n \xrightarrow[n \rightarrow \infty]{P} \xi. \quad (10.2)$$

•

$\xi_n \xrightarrow[n \rightarrow \infty]{P} \xi$ heißt also, dass sich die Wahrscheinlichkeit dafür, dass ξ_n in dem zufälligen Intervall

$$]\xi - \epsilon, \xi + \epsilon[\quad (10.3)$$

liegt, unabhängig davon, wie klein dieses Intervall sein mag, 1 nähert, wenn n gegen Unendlich geht. Intuitiv heißt das, dass sich für $n \rightarrow \infty$ und eine konstante Zufallsvariable

$\xi := a$ die Verteilung von ξ_n mehr und mehr um a konzentriert, wenn n gegen Unendlich strebt. Mithilfe der Konvergenz in Wahrscheinlichkeit formuliert man das schwache Gesetz der großen Zahlen wie folgt.

Theorem 10.1 (Schwach-Gesetz der großen Zahlen). $\xi_1, \dots, \xi_n$ seien unabhängig und identisch verteilte Zufallsvariablen mit $\mathbb{E}(\xi_i) = \mu$ für alle $i = 1, \dots, n$. Weiterhin bezeichne

$$\bar{\xi}_n := \frac{1}{n} \sum_{i=1}^n \xi_i \quad (10.4)$$

das Stichprobenmittel der $\xi_i, i = 1, \dots, n$. Dann konvergiert $\bar{\xi}_n$ in Wahrscheinlichkeit gegen μ ,

$$\bar{\xi}_n \xrightarrow[n \rightarrow \infty]{P} \mu. \quad (10.5)$$

◦

Beweis. Mit Theorem 6.2 gilt zunächst, dass

$$\mathbb{E}(\bar{\xi}_n) = \mathbb{E}\left(\frac{1}{n} \sum_{i=1}^n \xi_i\right) = \frac{1}{n} \sum_{i=1}^n \mathbb{E}(\xi_i) = \frac{1}{n} n \mathbb{E}(\xi_i) = \mathbb{E}(\xi_i) = \mu. \quad (10.6)$$

Der Erwartungswert μ der i ten Stichprobenvariable ξ_i stimmt also mit dem Erwartungswert des Stichprobenmittels $\bar{\xi}_n$ überein. Weiterhin halten wir fest, dass mit Theorem 8.6 und Theorem 8.8 bei Unabhängigkeit der Zufallsvariablen gilt, dass

$$\mathbb{V}(\bar{\xi}_n) = \mathbb{V}\left(\frac{1}{n} \sum_{i=1}^n \xi_i\right) = \frac{1}{n^2} \sum_{i=1}^n \mathbb{V}(\xi_i) = \frac{1}{n^2} n \mathbb{V}(\xi_i) = \frac{\mathbb{V}(\xi_i)}{n}. \quad (10.7)$$

Die Varianz des Stichprobenmittels ergibt sich also durch Teilen der Varianz der i ten Stichprobenvariable durch n . Mit Theorem 9.2 gilt dann aber

$$\mathbb{P}(|\bar{\xi}_n - \mathbb{E}(\bar{\xi}_n)| \geq \epsilon) \leq \frac{\mathbb{V}(\bar{\xi}_n)}{\epsilon^2} = \frac{\mathbb{V}(\xi_i)}{n\epsilon^2}. \quad (10.8)$$

Dann aber gilt für beliebige $\mathbb{V}(\xi_i) \geq 0$ und $\epsilon > 0$ und mit der Nichtnegativität der Wahrscheinlichkeit

$$\lim_{n \rightarrow \infty} \mathbb{P}(|\bar{\xi}_n - \mathbb{E}(\bar{\xi}_n)| \geq \epsilon) \leq \lim_{n \rightarrow \infty} \frac{\mathbb{V}(\xi_i)}{n\epsilon^2} \Leftrightarrow \lim_{n \rightarrow \infty} \mathbb{P}(|\bar{\xi}_n - \mu| \geq \epsilon) \leq 0 \Leftrightarrow \lim_{n \rightarrow \infty} \mathbb{P}(|\bar{\xi}_n - \mu| \geq \epsilon) = 0 \quad (10.9)$$

und es ist alles gezeigt. $\square$

Intuitiv heißt

$$\bar{\xi}_n \xrightarrow[n \rightarrow \infty]{P} \mu, \quad (10.10)$$

dass die Wahrscheinlichkeit, dass das Stichprobenmittel nahe dem Erwartungswert der zugrundeliegenden Verteilung liegt, sich 1 nähert, wenn n gegen Unendlich strebt.

Beispiel 10.1 (Simulation des schwachen Gesetzes der großen Zahlen). Zur Veranschaulichung von Theorem 10.1 betrachten wir den Fall von u.i.v. normalverteilten Zufallsvariablen $\xi_1, \dots, \xi_n \sim N(0, 1)$. Abbildung 10.1 A zeigt Realisationen der von Stichprobenmitteln $\bar{\xi}_n$ als Funktion von n . Man erkennt, dass für größeres n mehr Realisierungen von $\bar{\xi}_n$ in der Nähe des Erwartungswerts der $\xi_i, i = 1, \dots, n$ liegen. Basierend auf diesen Stichprobenmittelrealisationen zeigt Abbildung 10.1 B Schätzungen der Wahrscheinlichkeit $\mathbb{P}(|\bar{\xi}_n - \mu| \geq \epsilon)$ als Funktionen von n und ϵ . Für ein großes ϵ reicht ein geringes n aus, um die Wahrscheinlichkeit für eine absolute Abweichung des Stichprobenmittels vom Erwartungswert klein werden zu lassen. Für ein kleineres ϵ ist dafür ein größeres n nötig. In jedem Fall sinken die Abweichungswahrscheinlichkeiten jedoch mit größerem n .

△




Abbildung 10.1 Simulation des schwachen Gesetz der großen Zahlen.

10.2 Zentrale Grenzwertsätze

Die zentralen Grenzwertsätze besagen intuitiv, dass die Summe von unabhängigen Zufallsvariablen mit Erwartungswert null *asymptotisch*, also für unendlich viele Zufallsvariablen, normalverteilt mit Erwartungswertparameter null ist. Modelliert man eine beliebige Messgröße y also als Summe eines deterministischen Einflusses μ und der Summe

$$\varepsilon := \sum_{i=1}^n \xi_i \quad (10.11)$$

einer Vielzahl von unabhängigen Zufallsvariablen $\xi_i, i = 1, \dots, n$, die unbekannte Einflüsse modellieren sollen, so ist für großes n die Annahme

$$y = \mu + \varepsilon \text{ mit } \varepsilon \sim N(0, \sigma^2) \quad (10.12)$$

mathematisch gerechtfertigt. Wie wir später sehen werden, liegt die Annahme in Gleichung 10.12 einer großen Vielzahl von probabilistischen Modellen zugrunde.

Formal werden verschiedene Formen von zentralen Grenzwertsätzen, je nach Ausgestaltung der zugrundeliegenden Annahmen und ihrer Beweisführung unterschieden. In der sogenannten *Lindeberg und Lévy Form* des zentralen Grenzwertsatzes werden unabhängige und identische Zufallsvariablen vorausgesetzt. In der *Liapunov Form* dagegen werden nur unabhängige Zufallsvariablen vorausgesetzt. In beiden Formulierungen des zentralen Grenzwertsatzes ist die betrachtete Konvergenz von Zufallsvariablen die *Konvergenz in Verteilung*, welche wir zunächst einführen.

Definition 10.2 (Konvergenz in Verteilung). Eine Folge $\xi_1, \xi_2, \dots$ von Zufallsvariablen konvergiert in Verteilung gegen eine Zufallsvariable ξ , wenn

$$\lim_{n \rightarrow \infty} P_{\xi_n}(x) = P_{\xi}(x) \quad (10.13)$$

für alle ξ an denen P_ξ stetig ist. Die Konvergenz in Verteilung von $\xi_1, \xi_2, \dots$ gegen ξ wird geschrieben als

$$\xi_n \xrightarrow[n \rightarrow \infty]{D} \xi. \quad (10.14)$$

Gilt $\xi_n \xrightarrow[n \rightarrow \infty]{D} \xi$, dann heißt die Verteilung von ξ die *asymptotische Verteilung der Folge* $\xi_1, \xi_2, \dots$

•

Die Konvergenz in Verteilung ist also eine Aussage zur Konvergenz von Funktionenfolgen, speziell von KVFn. Ohne Begründung merken wir an, dass die oben betrachtete Konvergenz in Wahrscheinlichkeit die Konvergenz in Verteilung impliziert. Wir geben nun zunächst den zentralen Grenzwertsatz nach Lindeberg und Lévy an. Für einen Beweis verweisen wir auf Henze (2024).

Theorem 10.2 (Zentraler Grenzwertsatz nach Lindeberg und Lévy). $\xi_1, \dots, \xi_n$ seien unabhängig und identisch verteilte Zufallsvariablen mit

$$\mathbb{E}(\xi_i) := \mu \text{ und } \mathbb{V}(\xi_i) := \sigma^2 > 0 \text{ für alle } i = 1, \dots, n. \quad (10.15)$$

Weiterhin sei ζ_n die Zufallsvariable definiert als

$$\zeta_n := \sqrt{n} \left(\frac{\bar{\xi}_n - \mu}{\sigma} \right). \quad (10.16)$$

Dann gilt für alle $z \in \mathbb{R}$

$$\lim_{n \rightarrow \infty} P_{\zeta_n}(z) = \Phi(z), \quad (10.17)$$

wobei Φ die kumulative Verteilungsfunktion der Standardnormalverteilung bezeichnet.

◦

Wir zeigen an späterer Stelle, dass damit für $n \rightarrow \infty$ auch gilt, dass

$$\sum_{i=1}^n \xi_i \sim N(\mu, n\sigma^2) \text{ und } \bar{\xi}_n \sim N\left(\mu, \frac{\sigma^2}{n}\right). \quad (10.18)$$

Beispiel 10.2 (Simulation des zentralen Grenzwertsatzes nach Lindeberg und Lévy). Wir betrachten den Fall von u.i.v. χ^2 -Zufallsvariablen $\xi_1, \dots, \xi_n \sim \chi^2(3)$. Offenbar ist die funktionale Form der $\chi^2(3)$ -Verteilung von der Standardnormalverteilung recht verschieden, insbesondere nehmen χ^2 -Zufallsvariablen mit von null verschiedener Wahrscheinlichkeit nur nicht-negative Werte an (vgl. Kapitel 4.3). Nichtsdestotrotz resultiert ihre standardisierte Summe asymptotisch in einer Normalverteilung, wie in Abbildung 10.2 visualisiert. Dazu nutzen wir auf Ebene der Implementation die Tatsache, für die χ^2 -Zufallsvariablen $\xi_i, i = 1, \dots, n$ mit Freiheitsgradparameter 3 gilt, dass

$$\mathbb{E}(\xi_i) = 3 \text{ und } \mathbb{V}(\xi_i) = 6. \quad (10.19)$$

Die Abbildungen in Abbildung 10.2 A zeigen Histogrammschätzer der Wahrscheinlichkeitsdichte von

$$\zeta_n := \sqrt{n} \left(\frac{\bar{\xi}_n - \mu}{\sigma} \right) \quad (10.20)$$

basierend auf 1000 Realisationen von ζ_n für $n = 2$ und $n = 200$, sowie die WDF von $N(0, 1)$. Offenbar ist die Verteilung der Realisationen von ζ_2 der Standardnormalverteilung noch sehr unähnlich,

wohingegen sich die Verteilung der Realisationen von ζ_{200} der Standardnormalverteilung schon annähert. Abbildung 10.2 B zeigt die entsprechenden geschätzten KVFen über die Theorem 10.2 formal eine Aussage trifft.

△




Abbildung 10.2 Simulation des Zentralen Grenzwertsatzes nach Lindeberg und Lévy.

Der zentrale Grenzwertsatz nach Liapounov generalisiert Theorem 10.2 auf den Fall nicht notwendig identisch verteilter Zufallsvariablen. Für einen Beweis verweisen wir wiederum auf Henze (2024).

Theorem 10.3 (Zentraler Grenzwertsatz nach Liapounov). $\xi_1, \dots, \xi_n$ seien unabhängige aber nicht notwendigerweise identisch verteilten Zufallsvariablen mit

$$\mathbb{E}(\xi_i) := \mu_i \text{ und } \mathbb{V}(\xi_i) := \sigma_i^2 > 0 \text{ für alle } i = 1, \dots, n. \quad (10.21)$$

Weiterhin sollen für $\xi_1, \dots, \xi_n$ folgende Eigenschaften gelten:

$$\mathbb{E}(|\xi_i - \mu_i|^3) < \infty \text{ und } \lim_{n \rightarrow \infty} \frac{\sum_{i=1}^n \mathbb{E}(|\xi_i - \mu_i|^3)}{(\sum_{i=1}^n \sigma_i^2)^{3/2}} = 0. \quad (10.22)$$

Dann gilt für die Zufallsvariable ζ_n definiert als

$$\zeta_n := \frac{\sum_{i=1}^n \xi_i - \sum_{i=1}^n \mu_i}{\sqrt{\sum_{i=1}^n \sigma_i^2}}, \quad (10.23)$$

für alle $z \in \mathbb{R}$, dass

$$\lim_{n \rightarrow \infty} P_{\zeta_n}(z) = \Phi(z), \quad (10.24)$$

wobei Φ die KVF der Standardnormalverteilung bezeichnet.

◦

Wir zeigen an späterer Stelle, dass damit für $n \rightarrow \infty$ auch gilt, dass

$$\sum_{i=1}^n \xi_i \sim N\left(\sum_{i=1}^n \mu_i, \sum_{i=1}^n \sigma_i^2\right). \quad (10.25)$$

10.3 Literaturhinweise

Zur mathematik-geschichtlichen Genese der Zentralen Grenzwertsätze siehe Fischer (2011) und Ulyanov (2024). Zum zentralen Grenzwertsatz nach Lindeberg-Lévy, siehe Lindeberg (1922) und Lévy (1937), zum zentralen Grenzwertsatz nach Liapunov, siehe Liapounoff (1900) und Liapounoff (1901).

Selbstkontrollfragen

1. Geben Sie das Schwache Gesetz der großen Zahlen wieder.
2. Erläutern Sie den zentralen Grenzwertsatz nach Lindeberg und Lévy.
3. Warum sind die zentralen Grenzwertsätze für die probabilistische Modellbildung wichtig?

Lösungen

1. Siehe Theorem [10.1](#).
2. Der zentrale Grenzwertsatz nach Lindeberg und Lévy besagt, dass die standardisierte Summe unabhängig und identisch verteilter Zufallsvariablen asymptotisch normalverteilt ist.
3. Die zentralen Grenzwertsätze begründen die häufige Annahme normalverteilter unbekannter Einflüsse als Stör-, Fehler-, Abweichungs- oder Unsicherheitsvariablen in probabilistischen Modellen.

11 Transformationen

Die Transformation von Zufallsvektoren und die Analyse ihrer resultierenden Verteilungen ist ein zentrales Thema der probabilistischen Modellierung und in besonderem Maße der Frequentistischen Inferenz. Mit einer *Transformation* soll hier die Anwendung einer Funktion auf einen Zufallsvektor gemeint sein, die seine Komponenten entweder individuell transformiert oder miteinander verknüpft. Die zentrale Fragestellung dabei ist folgende: “Wenn ein Zufallsvektor ξ eine vorgegebene Verteilung hat, wie ist dann der Zufallsvektor v , der sich durch Transformation von ξ ergibt, verteilt?” Für die in diesem Kapitel behandelten Fälle gilt dabei, dass man explizite Lösungen für die Verteilung der transformierten Zufallsvektoren angeben kann. Diese gehören zu den klassischen Resultaten der Frequentistischen Inferenz und sind für das Verständnis von klassischer Frequentistischer Inferenzverfahren wie Konfidenzintervallen und Hypothesentests essenziell.

Für eine erste Intuition hierzu beschränken wir uns auf den Fall einer einzelnen Zufallsvariable. Man kann sich dann die Transformation einer Zufallsvariable anhand der Transformation ihrer unabhängig und identisch verteilten Realisierungen verdeutlichen. Betrachtet man beispielsweise die Zufallsvariable $\xi \sim N(0,1)$ und ihre Transformation $v := \xi^2$ und sind $x_1 = 0.10, x_2 = -0.20, x_3 = 0.80$ drei Realisierungen von drei unabhängigen Kopien von ξ , so entspricht dies den Realisierungen $y_1 = x_1^2 = 0.01, y_2 = x_2^2 = 0.04, y_3 = x_3^2 = 0.64$ von v . In diesem Beispiel fällt auf, dass v keine negativen Werte annimmt, die Verteilung von v ordnet negativen Werten daher eine Wahrscheinlichkeitsdichte von 0 zu. Untenstehender **R** Code simuliert diese Überlegungen. Abbildung 11.1 zeigt das Histogramm der gewonnenen Realisierungen der hier betrachteten Zufallsvariable ξ und Abbildung 11.2 zeigt das Histogramm der quadrierten Realisierungen von ξ , also unabhängig und identisch verteilte Realisierungen von v .

```
# Simulationsspezifikation
n      = 1e4                # Anzahl von u.i.v. Realisierungen (ZVen)
mu     = 1                  # Erwartungswertparameter von \xi
sigsqr = 2                  # Varianzparameter von \xi

# Quadrieren einer Zufallsvariable
x      = rnorm(n, mu, sqrt(sigsqr)) # Realisierungen x_i, i = 1,...,n von \xi
y      = x^2                # Realisierungen y_i = x_i^2 von \upsilon

# Ausgabe der ersten acht Werte der Realisierungen von \xi und von \upsilon
print(x[1:8], digits = 2)
```

```
[1] -0.039 -2.476 3.411 0.459 2.174 1.670 1.620 1.987
```

```
print(y[1:8], digits = 2)
```

```
[1] 0.0015 6.1296 11.6328 0.2107 4.7261 2.7893 2.6239 3.9465
```

Grundlegend für die nachfolgenden Betrachtungen ist folgendes Theorem, das wir nicht beweisen wollen.




Abbildung 11.1 Histogramm von 10.000 Realisierungen unabhängig und identisch normalverteilter Zufallsvariablen.




Abbildung 11.2 Histogramm von 10.000 quadrierten Realisierungen unabhängig und identisch normalverteilter Zufallsvariablen.

Theorem 11.1 (Transformation eines Zufallsvektors). $\xi : \Omega \rightarrow \mathcal{X}$ sei ein Zufallsvektor und $f : \mathcal{X} \rightarrow \mathbb{R}^m$ sei eine multivariate vektorwertige Funktion. Dann ist

$$v : \Omega \rightarrow \mathbb{R}, \omega \mapsto v(\omega) := (f \circ \xi)(\omega) := f(\xi(\omega)) \quad (11.1)$$

ein Zufallsvektor.

◦

Das Theorem formalisiert die oben etablierte Intuition, dass die Anwendung einer Funktion auf eine zufällige Größe im Allgemeinen wieder eine zufällige Größe ergibt. In einem Beweis von Theorem 11.1 müsste die Messbarkeit von v als Folge der Messbarkeit von ξ nachgewiesen werden. Im Folgenden ist oft $\mathcal{X} := \mathbb{R}$ und $f : \mathbb{R} \rightarrow \mathbb{R}$. Wir schreiben in diesem Fall in der Regel einfach $v := f(\xi)$ und nennen v die *transformierte Zufallsvariable*.

In Kapitel 11.1 betrachten wir Theoreme zur Transformation von Zufallsvariablen in Abhängigkeit von der Art der betrachteten Funktion f . In Kapitel 11.2 betrachten wir ein Theorem zur Transformation von Zufallsvektoren bei bijektiver Transformationsfunktion und die Bestimmung von Verteilungen bei der binären Verknüpfungen von Zufallsvariablen.

11.1 Univariate Transformationstheoreme

Theorem 11.2 gibt eine Formel zur Berechnung der WDF p_v von $v := f(\xi)$, wenn ξ eine Zufallsvariable mit WDF p_ξ ist und f eine bijektive Funktion ist.

Theorem 11.2 (Univariate WDF Transformation bei bijektiven Abbildungen). ξ sei eine Zufallsvariable mit WDF p_ξ für die $\mathbb{P}(]a, b[) = 1$ gilt, wobei a und/oder b entweder endlich oder unendlich seien. Weiterhin sei

$$v := f(\xi), \quad (11.2)$$

wobei die univariate reellwertige Funktion $f :]a, b[\rightarrow \mathbb{R}$ differenzierbar und bijektiv auf $]a, b[$ sei. $f(]a, b[)$ sei das Bild von $]a, b[$ unter f . Schließlich sei $f^{-1}(y)$ der Wert der Umkehrfunktion von $f(x)$ für $y \in f(]a, b[)$ und $f'(x)$ sei die Ableitung von f an der Stelle x . Dann ist die WDF von v gegeben durch

$$p_v : \mathbb{R} \rightarrow \mathbb{R}_{\geq 0}, y \mapsto p_v(y) := \begin{cases} \frac{1}{|f'(f^{-1}(y))|} p_\xi(f^{-1}(y)) & \text{für } y \in f(]a, b[) \\ 0 & \text{für } y \in \mathbb{R} \setminus f(]a, b[). \end{cases} \quad (11.3)$$

◦

Beweis. Wir halten zunächst fest, dass weil f eine differenzierbare bijektive Funktion auf $]a, b[$ ist, f entweder strikt wachsend oder strikt fallend ist. Nehmen wir zunächst an, dass f auf $]a, b[$ strikt wachsend ist. Dann ist auch f^{-1} für alle $y \in f(]a, b[)$ wachsend, und es gilt

$$P_v(y) = \mathbb{P}(v \leq y) = \mathbb{P}(f(\xi) \leq y) = \mathbb{P}(f^{-1}(f(\xi)) \leq f^{-1}(y)) = \mathbb{P}(\xi \leq f^{-1}(y)) = P_\xi(f^{-1}(y)).$$

P_v ist also differenzierbar an allen Stellen y , an denen sowohl f^{-1} als auch P_ξ differenzierbar sind. Mit der Kettenregel und dem Satz von der Umkehrabbildung $(f^{-1}(x))' = 1/f'(f^{-1}(x))$, folgt dann, dass die WDF p_v sich ergibt wie folgt:

$$p_v(y) = \frac{d}{dy} P_v(y) = \frac{d}{dy} P_\xi(f^{-1}(y)) = p_\xi(f^{-1}(y)) \frac{d}{dy} f^{-1}(y) = \frac{1}{f'(f^{-1}(y))} p_\xi(f^{-1}(y)),$$

Weil f^{-1} strikt wachsend ist, ist $d/dy(f^{-1}(y))$ positiv und das Theorem trifft zu. Analog gilt, dass wenn f auf $]a, b[$ strikt fallend ist, dann ist auch f^{-1} für alle $y \in f(]a, b[)$ fallend und es gilt

$$P_v(y) = \mathbb{P}(f(\xi) \leq y) = \mathbb{P}(f^{-1}(f(\xi)) \geq f^{-1}(y)) = \mathbb{P}(\xi \geq f^{-1}(y)) = 1 - P_\xi(f^{-1}(y)),$$

Mit der Kettenregel und dem Satz von der Umkehrabbildung folgt dann

$$p_v(y) = \frac{d}{dy}(1 - P_v(y)) = -\frac{d}{dy}P_\xi(f^{-1}(y)) = -p_\xi(f^{-1}(y)) \frac{d}{dy}f^{-1}(y) = -\frac{1}{f'(f^{-1}(y))}p_\xi(f^{-1}(y)).$$

Weil f^{-1} strikt fallend ist, ist $d/dy(f^{-1}(y))$ negativ, so dass $-d/dy(f^{-1}(y))$ gleich $|d/dy(f^{-1}(y))|$ ist und das Theorem trifft zu. $\square$

Ein wichtiger Anwendungsfall von Theorem 11.2 ist Theorem 11.3. Im Vergleich zu Theorem 11.2 gibt Theorem 11.3 eine vereinfachte Formel zur Berechnung der WDF p_v von $v := f(\xi)$ an, wenn f eine linear-affine Funktion ist.

Theorem 11.3 (Univariates WDF Transformationstheorem bei linear-affinen Abbildungen). ξ sei eine Zufallsvariable mit WDF p_ξ und es sei

$$v = f(\xi) \text{ mit } f(\xi) := a\xi + b \text{ für } a \neq 0. \quad (11.4)$$

Dann ist die WDF von v gegeben durch

$$p_v : \mathbb{R} \rightarrow \mathbb{R}_{\geq 0}, y \mapsto p_v(y) := \frac{1}{|a|} p_\xi\left(\frac{y-b}{a}\right). \quad (11.5)$$

◦

Beweis. Wir halten zunächst fest, dass

$$f^{-1} : \mathbb{R} \rightarrow \mathbb{R}, y \mapsto f^{-1}(y) = \frac{y-b}{a} \quad (11.6)$$

ist, weil dann $f \circ f^{-1} = \text{id}_{\mathbb{R}}$ gilt, wie man anhand von

$$f(f^{-1}(x)) = a\left(\frac{x-b}{a}\right) + b = x - b + b = x \text{ für alle } x \in \mathbb{R} \quad (11.7)$$

eingieht. Wir halten weiterhin fest, dass

$$f' : \mathbb{R} \rightarrow \mathbb{R}, x \mapsto f'(x) = \frac{d}{dx}(ax + b) = a. \quad (11.8)$$

Also folgt mit Theorem 11.2, dass

$$\begin{aligned} p_v : \mathbb{R} \rightarrow \mathbb{R}_{\geq 0}, y \mapsto p_v(y) &= \frac{1}{|f'(f^{-1}(y))|} p_\xi(f^{-1}(y)) \\ &= \frac{1}{|a|} p_\xi\left(\frac{y-b}{a}\right). \end{aligned} \quad (11.9)$$

$\square$

Theorem 11.4 gibt eine Formel zur Berechnung der WDF p_v von $v := f(\xi)$ an, wenn f zumindest in Teilen bijektiv ist.

Theorem 11.4 (Univariate WDF Transformation bei stückweise bijektiven Abbildungen). ξ sei eine Zufallsvariable mit Ergebnisraum $\mathcal{X}$ und WDF p_ξ . Weiterhin sei

$$v = f(\xi), \quad (11.10)$$

wobei f so beschaffen sei, dass der Ergebnisraum von ξ in eine endliche Anzahl von Mengen $\mathcal{X}_1, \dots, \mathcal{X}_k$ mit einer entsprechenden Anzahl von Mengen $\mathcal{Y}_1 := f(\mathcal{X}_1), \dots, \mathcal{Y}_k := f(\mathcal{X}_k)$ im Ergebnisraum $\mathcal{Y}$ von v partitioniert werden kann (wobei nicht notwendigerweise $\mathcal{Y}_i \cap \mathcal{Y}_j = \emptyset, 1 \leq i, j \leq k$ gelten muss), sodass die Abbildung f für alle $\mathcal{X}_1, \dots, \mathcal{X}_k$ bijektiv ist (d.h. f ist eine stückweise bijektive Abbildung). Für $i = 1, \dots, k$ bezeichne f_i^{-1} die Umkehrfunktion von f auf $\mathcal{Y}_i$. Schließlich nehmen wir an, dass die Ableitungen f'_i für alle $i = 1, \dots, k$ existieren und stetig sind. Dann ist eine WDF von v durch

$$p_v : \mathcal{Y} \rightarrow \mathbb{R}_{\geq 0}, y \mapsto p_v(y) := \sum_{i=1}^k 1_{\mathcal{Y}_i}(y) \frac{1}{|f'_i(f_i^{-1}(y))|} p_\xi(f_i^{-1}(y)). \quad (11.11)$$

gegeben.

◦

Für einen Beweis verweisen wir auf Casella & Berger (2002).

11.2 Multivariate Transformationstheoreme

Theorem 11.5 liefert eine Formel zur Berechnung der WDF p_v von $v := f(\xi)$, wenn ξ ein Zufallsvektor mit WDF p_ξ ist und f eine bijektive multivariate vektorwertige Funktion ist. Es handelt sich dabei um eine direkte Generalisierung von Theorem 11.2.

Theorem 11.5 (Multivariate WDF Transformation bei bijektiven Abbildungen). ξ sei ein n -dimensionaler Zufallsvektor mit Ergebnisraum $\mathbb{R}^n$ und WDF p_ξ . Weiterhin sei

$$v := f(\xi), \quad (11.12)$$

wobei die multivariate vektorwertige Funktion $f : \mathbb{R}^n \rightarrow \mathbb{R}^n$ differenzierbar und bijektiv auf $]a, b[$ sei. Schließlich seien

$$J^f(x) = \left(\frac{\partial}{\partial x_j} f_i(x) \right)_{1 \leq i \leq n, 1 \leq j \leq n} \in \mathbb{R}^{n \times n} \quad (11.13)$$

die Jacobi-Matrix von f an der Stelle $x \in \mathbb{R}^n$, $|J^f(x)|$ die Determinante von $J^f(x)$, und es sei $|J^f(x)| \neq 0$ für alle $x \in \mathbb{R}^n$. Dann ist eine WDF von v durch

$$p_v : \mathbb{R}^n \rightarrow \mathbb{R}_{\geq 0}, y \mapsto p_v(y) := \begin{cases} \frac{1}{|J^f(f^{-1}(y))|} p_\xi(f^{-1}(y)) & \text{für } y \in f(\mathbb{R}^n) \\ 0 & \text{für } y \in \mathbb{R}^n \setminus f(\mathbb{R}^n) \end{cases} \quad (11.14)$$

gegeben.

◦

Für einen Beweis verweisen wir auf Billingsley (1995).

Das folgende sogenannte *Konvolutionstheorem* liefert eine Formel zur Berechnung der WDF p_v von $v := \xi_1 + \xi_2$, wenn ξ_1 und ξ_2 zwei Zufallsvariablen mit WDFen p_{ξ_1} und p_{ξ_2} sind.

Theorem 11.6 (Summe unabhängiger Zufallsvariablen (Konvolution)). *ξ_1 und ξ_2 seien zwei kontinuierliche unabhängige Zufallsvariablen mit WDF p_{ξ_1} und p_{ξ_2} , respektive. $v := \xi_1 + \xi_2$ sei die Summe von ξ_1 und ξ_2 . Dann ergibt sich eine WDF der Verteilung von v als*

$$p_v(y) = \int_{-\infty}^{\infty} p_{\xi_1}(y - x_2) p_{\xi_2}(x_2) dx_2 = \int_{-\infty}^{\infty} p_{\xi_1}(x_1) p_{\xi_2}(y - x_1) dx_1 \quad (11.15)$$

Die Formel für die WDF p_v heißt Konvolution oder Faltung von p_{ξ_1} und p_{ξ_2} .

◦

Beweis. Wir nutzen das multivariate WDF Transformationstheorem für bijektive Abbildungen. Dazu definieren wir zunächst

$$f : \mathbb{R}^2 \rightarrow \mathbb{R}^2, x \mapsto f(x) := \begin{pmatrix} x_1 + x_2 \\ x_2 \end{pmatrix} := \begin{pmatrix} z_1 \\ z_2 \end{pmatrix} \quad (11.16)$$

Die inverse Funktion von f ist dann gegeben durch

$$f : \mathbb{R}^2 \rightarrow \mathbb{R}^2, z \mapsto f(z) := \begin{pmatrix} z_1 - z_2 \\ z_2 \end{pmatrix} \quad (11.17)$$

weil dann $f \circ f^{-1} = \text{id}_{\mathbb{R}^2}$ gilt, wie man anhand von

$$f^{-1}(f(x)) = f^{-1} \begin{pmatrix} x_1 + x_2 \\ x_2 \end{pmatrix} = \begin{pmatrix} x_1 + x_2 - x_2 \\ x_2 \end{pmatrix} = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} \quad (11.18)$$

einsieht. Die Jacobimatrix von f ergibt sich zu

$$J^f(x) = \begin{pmatrix} \frac{\partial}{\partial x_1} f_1(x) & \frac{\partial}{\partial x_2} f_1(x) \\ \frac{\partial}{\partial x_1} f_2(x) & \frac{\partial}{\partial x_2} f_2(x) \end{pmatrix} = \begin{pmatrix} \frac{\partial}{\partial x_1} (x_1 + x_2) & \frac{\partial}{\partial x_2} (x_1 + x_2) \\ \frac{\partial}{\partial x_1} x_2 & \frac{\partial}{\partial x_2} x_2 \end{pmatrix} = \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix} \quad (11.19)$$

und die Jacobideterminante damit zu $|J^f(x)| = 1$. Wir halten weiterhin fest, dass die Unabhängigkeit von ξ_1 und ξ_2 impliziert, dass

$$p_{\xi_1, \xi_2}(x_1, x_2) = p_{\xi_1}(x_1) p_{\xi_2}(x_2) \quad (11.20)$$

impliziert. Einsetzen und Integration hinsichtlich x_2 ergibt dann für $z \in f(\mathbb{R}^2)$

$$\begin{aligned} p_{\zeta}(z) &= \frac{1}{|J^f(f^{-1}(z))|} p_{\xi}(f^{-1}(z)) \\ &= \frac{1}{1} p_{\xi_1, \xi_2}(z_1 - z_2, z_2) \\ &= p_{\xi_1}(z_1 - z_2) p_{\xi_2}(z_2) \end{aligned} \quad (11.21)$$

Integration über x_2 ergibt dann eine WDF für die marginale Verteilung von ζ_1

$$p_{\zeta_1}(z_1) = \int_{-\infty}^{\infty} p_{\xi_1}(z_1 - x_2) p_{\xi_2}(x_2) dx_2 \quad (11.22)$$

Mit $\zeta_1 = \xi_1 + \xi_2 = v$ ergibt sich dann die erste Form des Konvolutionstheorems zu

$$p_v(y) = \int_{-\infty}^{\infty} p_{\xi_1}(y - x_2) p_{\xi_2}(x_2) dx_2. \quad (11.23)$$

□

Selbstkontrollfragen

1. Erläutern Sie das Konzept der Transformation einer Zufallsvariable am Beispiel von $v := \xi^2$.

Lösungen

1. Siehe Erläuterungen zu Abbildung [11.1](#) und Abbildung [11.2](#).

12 Normalverteilungen

Die multivariate Normalverteilung ist die multivariate Generalisierung der univariaten Normalverteilung. Die Motivation für die verbreiteten Normalverteilungsannahmen in der probabilistischen Modellierung liegt bekanntermaßen im Zentralen Grenzwertsatz: In probabilistischen Modellen repräsentieren probabilistische Terme die Summation sehr vieler Zufallsvorgänge, die durch die deterministischen Bestandteile des jeweiligen Modells, also eine formalisierte wissenschaftliche Theorie, nicht erklärt werden. Nach dem Zentralen Grenzwertsatz ist die Summe dieser nicht erklärten Zufallsvorgänge dann aber gerade normalverteilt.

Über diesen grundlegenden Aspekt hinaus hat die Normalverteilung viele günstige mathematische Eigenschaften, die ihren Einsatz in vielen Bereichen der probabilistischen Modellierung ermöglichen. Anwendungen multivariater Normalverteilungen finden sich damit im Kontext des Allgemeinen linearen Modells, den Generalisierungen des Allgemeinen Modells zu Hierarchischen linearen Modellen oder Multivariaten Allgemeinen linearen Modellen, der Bayesianischen Inferenz bei Normalverteilungsannahmen und nicht zuletzt der Theorie probabilistischer Filter, wie zum Beispiel dem Kalman-Bucy Filter.

12.1 Konstruktion multivariater Normalverteilungen

In diesem Abschnitt wollen wir zeigen, wie ein bivariat normalverteilter Zufallsvektor durch Transformation und Konkatination zweier univariat normalverteilter Zufallsvariablen konstruiert werden kann. Dazu erinnern wir zunächst an den Begriff der normalverteilten Zufallsvariable. Wir wiederholen die entsprechende Definition aus Kapitel 4 hier, um die Terminologie für die multivariaten Normalverteilungen einzuführen.

Definition 12.1 (Normalverteilte Zufallsvariable). ξ sei eine Zufallsvariable mit Ergebnisraum $\mathbb{R}$ und WDF

$$p : \mathbb{R} \rightarrow \mathbb{R}_{>0}, x \mapsto p(x) := \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2\sigma^2}(x - \mu)^2\right). \quad (12.1)$$

Dann sagen wir, dass ξ einer *Normalverteilung* (oder *Gauß-Verteilung*) mit *Erwartungswertparameter* $\mu \in \mathbb{R}$ und *Varianzparameter* $\sigma^2 > 0$ unterliegt und nennen ξ eine *normalverteilte Zufallsvariable*. Wir kürzen dies mit $\xi \sim N(\mu, \sigma^2)$ ab. Die WDF einer normalverteilten Zufallsvariablen bezeichnen wir mit

$$N(x; \mu, \sigma^2) := \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2\sigma^2}(x - \mu)^2\right). \quad (12.2)$$

•




Abbildung 12.1 Wahrscheinlichkeitsdichtefunktionen univariater Normalverteilungen.

Visuell entspricht der Parameter μ einer normalverteilten Zufallsvariablen dem Wert höchster Wahrscheinlichkeitsdichte und der Parameter σ^2 spezifiziert die Breite der WDF (Abbildung 12.1). Weiterhin gelten für den Erwartungswert und die Varianz einer normalverteilten Zufallsvariablen bekanntlich

$$\mathbb{E}(\xi) = \mu \text{ und } \mathbb{V}(\xi) = \sigma^2. \quad (12.3)$$

Eine normalverteilte Zufallsvariable der Form $\xi \sim N(0, 1)$ schließlich heißt auch *standard-normalverteilt*.

Folgendes Theorem zeigt, wie zwei unabhängige, univariat standardnormalverteilte Zufallsvariablen kombiniert werden können, um einen bivariat verteilten Zufallsvektor zu konstruieren. Die Verteilung eines ebensolchen Zufallsvektors wird dann als *bivariate Normalverteilung* bezeichnet.

Theorem 12.1 (Konstruktion bivariater Normalverteilungen). $\zeta_1 \sim N(0, 1)$ und $\zeta_2 \sim N(0, 1)$ seien zwei unabhängige standardnormalverteilte Zufallsvariablen. Weiterhin seien $\mu_1, \mu_2 \in \mathbb{R}$, $\sigma_1, \sigma_2 > 0$ und $\rho \in]-1, 1[$. Schließlich seien

$$\begin{aligned} \xi_1 &:= \sigma_1 \zeta_1 + \mu_1 \\ \xi_2 &:= \sigma_2 (\rho \zeta_1 + (1 - \rho^2)^{1/2} \zeta_2) + \mu_2. \end{aligned} \quad (12.4)$$

Dann hat die WDF des Zufallsvektors $\xi := (\xi_1, \xi_2)^T$, also der gemeinsamen Verteilung von ξ_1 und ξ_2 , die Form

$$p : \mathbb{R}^2 \rightarrow \mathbb{R}_{>0}, x \mapsto p(x) := (2\pi)^{-\frac{n}{2}} |\Sigma|^{-\frac{1}{2}} \exp \left(-\frac{1}{2} (x - \mu)^T \Sigma^{-1} (x - \mu) \right), \quad (12.5)$$

wobei $n := 2$ und $\mu \in \mathbb{R}^2$ und $\Sigma \in \mathbb{R}^{2 \times 2}$ durch

$$\mu = \begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix} \text{ und } \Sigma = \begin{pmatrix} \sigma_1^2 & \rho \sigma_1 \sigma_2 \\ \rho \sigma_2 \sigma_1 & \sigma_2^2 \end{pmatrix} \quad (12.6)$$

gegeben sind.

◦

Für einen Beweis des Theorems verweisen wir auf DeGroot & Schervish (2012).

Beispiel 12.1 (Konstruktion einer bivariaten Normalverteilung). Folgender **R** Code zeichnet das obige Theorem anhand konkreter Beispielwerte für $\mu_1, \mu_2, \sigma_1, \sigma_2$ und ρ nach und gibt die Parameter μ und Σ der resultierenden bivariaten WDF aus.

```
# Parameterdefinitionen
mu_1 = 5.0
mu_2 = 4.0
sig_1 = 1.5
sig_2 = 1.0
rho = 0.9

# Realisierungen der standardnormalverteilten ZVen
n = 100
zeta_1 = rnorm(n)
zeta_2 = rnorm(n)

# Evaluation von Realisierungen von \xi_1 und \xi_2
xi_1 = sig_1*zeta_1 + mu_1
xi_2 = sig_2*(rho*zeta_1 + sqrt(1-rho^2)*zeta_2) + mu_2

# Parameter der gemeinsamen Verteilung von \xi_1 und \xi_2
mu = matrix(c(mu_1, mu_2),
             nrow = 2, byrow = TRUE)
Sigma = matrix(c(sig_1^2, rho*sig_1*sig_2,
                 rho*sig_1*sig_2, sig_2^2),
               nrow = 2, byrow = TRUE)

print(mu)

      [,1]
[1,] 5
[2,] 4

print(Sigma)

      [,1] [,2]
[1,] 2.25 1.35
[2,] 1.35 1.00
```

Die durch obigen **R** Code generierten Realisierungen von $\xi = (\xi_1, \xi_2)^T$, sowie die Isokonturen der durch Theorem 12.1 postulierten WDF sind in Abbildung 12.2 dargestellt.

△

12.2 Definition multivariater Normalverteilungen

Wir wollen die multivariate Normalverteilung nun formal einführen und erste Eigenschaften angeben. Wir nutzen dazu folgende Definition.

Definition 12.2. ξ sei ein n -dimensionaler Zufallsvektor mit Ergebnisraum $\mathbb{R}^n$ und WDF

$$p : \mathbb{R}^n \rightarrow \mathbb{R}_{>0}, x \mapsto p(x) := (2\pi)^{-\frac{n}{2}} |\Sigma|^{-\frac{1}{2}} \exp \left(-\frac{1}{2} (x - \mu)^T \Sigma^{-1} (x - \mu) \right). \quad (12.7)$$

Dann sagen wir, dass ξ einer *multivariaten (oder n -dimensionalen) Normalverteilung* mit *Erwartungswertparameter* $\mu \in \mathbb{R}^n$ und positiv-definitem *Kovarianzmatrixparameter* $\Sigma \in \mathbb{R}^{n \times n}$ unterliegt und nennen ξ einen *(multivariat) normalverteilten Zufallsvektor*. Wir kürzen dies mit $\xi \sim N(\mu, \Sigma)$ ab. Die WDF eines multivariat normalverteilten Zufallsvektors bezeichnen wir mit

$$N(x; \mu, \Sigma) := (2\pi)^{-\frac{n}{2}} |\Sigma|^{-\frac{1}{2}} \exp \left(-\frac{1}{2} (x - \mu)^T \Sigma^{-1} (x - \mu) \right). \quad (12.8)$$

•




Abbildung 12.2 Konstruktion einer bivariaten Normalverteilung.

Beispiel 12.2 (Bivariate Normalverteilungen). Abbildung 12.3 A,B,C zeigen die Isokonturen der WDFen bivariat normalverteilter Zufallsvektoren für $\mu = (1, 1)^T$ und

$$\Sigma_A := \begin{pmatrix} 0.20 & 0.15 \\ 0.15 & 0.20 \end{pmatrix}, \quad \Sigma_B := \begin{pmatrix} 0.20 & 0.00 \\ 0.00 & 0.20 \end{pmatrix}, \quad \Sigma_C := \begin{pmatrix} 0.20 & -0.15 \\ -0.15 & 0.20 \end{pmatrix} \quad (12.9)$$

respektive. Abbildung 12.4 A,B und C zeigen jeweils 200 Realisierungen der entsprechenden Zufallsvektoren.

△




Abbildung 12.3 Wahrscheinlichkeitsdichtefunktionen bivariater Normalverteilungen.

Ohne Beweis halten wir fest, dass wie im Fall einer univariat normalverteilten Zufallsvariable, der Erwartungswert und die Kovarianzmatrix eines normalverteilten Zufallsvektors durch die entsprechenden Parameter gegeben sind.




Abbildung 12.4 Realisierungen bivariat normalverteilter Zufallsvektoren.

Theorem 12.2 (Erwartungswert und Kovarianzmatrix normalverteilter Zufallsvektoren). $\xi \sim N(\mu, \Sigma)$ sei ein multivariat normalverteilter Zufallsvektor mit Erwartungswertparameter $\mu \in \mathbb{R}^n$ und Kovarianzmatrixparameter $\Sigma \in \mathbb{R}^{n \times n}$ pd. Dann gelten

$$\mathbb{E}(\xi) = \mu \text{ und } \mathbb{C}(\xi) = \Sigma. \quad (12.10)$$

◦

Wie im Falle der univariat normalverteilten Zufallsvariablen entspricht der Parameter $\mu \in \mathbb{R}^n$ dem Wert höchster Wahrscheinlichkeitsdichte der multivariaten Normalverteilung. Analog zum Varianzparameter der univariat normalverteilten Zufallsvariable spezifizieren die Diagonalelemente von $\Sigma \in \mathbb{R}^{n \times n}$ pd die Breite der WDF bezüglich der Zufallsvektorkomponenten $\xi_1, \dots, \xi_n$. Allgemein spezifiziert im Falle des multivariat normalverteilten Zufallsvektors das i, j te Element von $\Sigma \in \mathbb{R}^{n \times n}$ pd hier nun die Kovarianz der Zufallsvektorkomponenten ξ_i und ξ_j .

12.3 Sphärizität

Folgendes Theorem ist für die grundlegende Theorie des Allgemeinen linearen Modells zentral.

Theorem 12.3 (Sphärische multivariate Normalverteilung). Für $i = 1, \dots, n$ seien $N(x_i; \mu_i, \sigma^2)$ die WDFen von n unabhängigen univariaten normalverteilten Zufallsvariablen $\xi_1, \dots, \xi_n$ mit $\mu_1, \dots, \mu_n \in \mathbb{R}$ und $\sigma^2 > 0$. Weiterhin sei $N(x; \mu, \sigma^2 I_n)$ die WDF eines n -variaten normalverteilten Zufallsvektors ξ mit Erwartungswertparameter $\mu := (\mu_1, \dots, \mu_n)^T \in \mathbb{R}^n$. Dann gilt

$$p_\xi(x) = p_{\xi_1, \dots, \xi_n}(x_1, \dots, x_n) = \prod_{i=1}^n p_{\xi_i}(x_i) \quad (12.11)$$

und insbesondere

$$N(x; \mu, \sigma^2 I_n) = \prod_{i=1}^n N(x_i; \mu_i, \sigma^2) \quad (12.12)$$

für alle $x = (x_1, \dots, x_n)^T \in \mathbb{R}^n$.

◦

Beweis. Wir zeigen die Identität der multivariaten WDF $N(x; \mu, \sigma^2 I_n)$ mit dem Produkt von n univariaten WDFen $N(x_i; \mu_i, \sigma^2 I_n)$, wobei μ_i der i te Eintrag von $\mu \in \mathbb{R}^n$ ist. Es ergibt sich

$$\begin{aligned}
 N(x; \mu, \sigma^2 I_n) &= (2\pi)^{-\frac{n}{2}} |\sigma^2 I_n|^{-\frac{1}{2}} \exp\left(-\frac{1}{2}(x - \mu)^T (\sigma^2 I_n)^{-1} (x - \mu)\right) \\
 &= \left(\prod_{i=1}^n 2\pi^{-\frac{1}{2}}\right) (\sigma^2)^{-\frac{n}{2}} \exp\left(-\frac{1}{2\sigma^2} (x - \mu)^T (x - \mu)\right) \\
 &= \left(\prod_{i=1}^n (2\pi\sigma^2)^{-\frac{1}{2}}\right) \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu_i)^2\right) \\
 &= \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \prod_{i=1}^n \exp\left(-\frac{1}{2\sigma^2} (x_i - \mu_i)^2\right) \\
 &= \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2\sigma^2} (x_i - \mu_i)^2\right) \\
 &= \prod_{i=1}^n N(x_i; \mu_i, \sigma^2).
 \end{aligned} \tag{12.13}$$

□

Einen Kovarianzmatrixparameter der Form $\Sigma = \sigma^2 I_n$ nennt man auch *sphärisch*, da die Isokonturen der WDF eines normalverteilten Zufallsvektors mit einem solchen Kovarianzmatrixparameter *Sphären* bilden (zum Beispiel Kreise bei $n = 2$ und Kugeln bei $n = 3$). Eine multivariate Normalverteilung mit sphärischem Kovarianzmatrixparameter nennt man entsprechend eine *sphärische Normalverteilung*. Theorem 12.3 besagt, dass die WDF eines n -dimensionalen normalverteilten Zufallsvektors mit sphärischem Kovarianzparameter der gemeinsamen WDF von n unabhängigen univariat normalverteilten Zufallsvariablen entspricht und umgekehrt. Eine Realisierung eines n -dimensionalen normalverteilten Zufallsvektors entspricht also den Realisierungen von n unabhängigen univariat normalverteilten Zufallsvariablen und umgekehrt. Man beachte, dass die Identität der Verteilungen der $\xi_i, i = 1, \dots, n$ hier nicht vorausgesetzt ist, insbesondere können sich ihre Erwartungswertparameter $\mu_i, i = 1, \dots, n$ explizit unterscheiden.

12.4 Marginale, bedingte und gemeinsame Verteilungen

Multivariate Normalverteilungen haben die Eigenschaft, dass auch alle anderen assoziierten Verteilungen Normalverteilungen sind und deren Erwartungswert- und Kovarianzmatrixparameter aus den Parametern der jeweils komplementären Verteilung errechnet werden können. Speziell gilt zum einen, dass die uni- und multivariaten Marginalverteilungen multivariater Normalverteilungen wiederum Normalverteilungen sind. Zum anderen lassen sich wie alle multivariaten Verteilungen multivariate Normalverteilungen multiplikativ in eine marginale und eine bedingte Verteilung zerlegen. Insbesondere sind nun aber bei multivariaten Normalverteilungen diese Verteilungen wiederum (multivariate) Normalverteilungen, deren Parameter aus den Parametern der gemeinsamen Verteilung errechnet werden können und umgekehrt. Wir fassen obige Erkenntnisse formal in den folgenden drei Theoremen zusammen.

Theorem 12.4 (Marginale Normalverteilungen). *Es sei $n := k + l$ und $\xi = (\xi_1, \dots, \xi_n)^T$ sei ein n -dimensionaler normalverteilter Zufallsvektor mit Erwartungswertparameter*

$$\mu = \begin{pmatrix} \mu_v \\ \mu_\zeta \end{pmatrix} \in \mathbb{R}^n, \tag{12.14}$$

mit $\mu_v \in \mathbb{R}^k$ and $\mu_\zeta \in \mathbb{R}^l$ und Kovarianzmatrixparameter

$$\Sigma = \begin{pmatrix} \Sigma_{vv} & \Sigma_{v\zeta} \\ \Sigma_{\zeta v} & \Sigma_{\zeta\zeta} \end{pmatrix} \in \mathbb{R}^{n \times n}, \quad (12.15)$$

mit $\Sigma_{vv} \in \mathbb{R}^{k \times k}$, $\Sigma_{v\zeta} \in \mathbb{R}^{k \times l}$, $\Sigma_{\zeta v} \in \mathbb{R}^{l \times k}$, und $\Sigma_{\zeta\zeta} \in \mathbb{R}^{l \times l}$. Dann sind $v := (\xi_1, \dots, \xi_k)^T$ und $\zeta := (\xi_{k+1}, \dots, \xi_n)^T$ k - und l -dimensionale normalverteilte Zufallsvektoren, respektive, und es gilt

$$v \sim N(\mu_v, \Sigma_{vv}) \text{ und } \zeta \sim N(\mu_\zeta, \Sigma_{\zeta\zeta}). \quad (12.16)$$

◦

Die Marginalverteilungen einer multivariaten Normalverteilung sind also auch Normalverteilungen und die Parameter der Marginalverteilungen ergeben sich aus den Parametern der gemeinsamen Verteilung. Für Beweise dieses Theorems verweisen wir auf Mardia et al. (1979) und Anderson (2003).

12.5 Marginale Normalverteilungen

Abbildung 12.5 visualisiert Theorem 12.4 für den Fall $n := 2, k := 1, l := 1$,

$$\mu := \begin{pmatrix} 1 \\ 2 \end{pmatrix} \in \mathbb{R}^2 \text{ und } \Sigma := \begin{pmatrix} 0.10 & 0.08 \\ 0.08 & 0.15 \end{pmatrix} \in \mathbb{R}^{2 \times 2}. \quad (12.17)$$

Abbildung 12.5 A zeigt dabei die WDF des bivariaten Zufallsvektors ξ und Abbildung 12.5 B und C die WDFen der entsprechenden marginalen Zufallsvariablen v und ζ .




Abbildung 12.5 Marginale Verteilungen eines bivariaten normalverteilten Zufallsvektor.

Mithilfe einer marginalen und einer bedingten multivariaten Normalverteilung lässt sich eine gemeinsame multivariate Normalverteilung konstruieren, deren Parameter sich aus den Parametern der marginalen und bedingten Verteilung ergeben. Dies ist die zentrale Aussage folgenden Theorems.

Theorem 12.5 (Gemeinsame Normalverteilungen). ξ sei ein m -dimensionaler normalverteilter Zufallsvektor mit WDF

$$p_\xi : \mathbb{R}^m \rightarrow \mathbb{R}_{>0}, x \mapsto p_\xi(x) := N(x; \mu_\xi, \Sigma_{\xi\xi}) \text{ mit } \mu_\xi \in \mathbb{R}^m, \Sigma_{\xi\xi} \in \mathbb{R}^{m \times m}, \quad (12.18)$$

$A \in \mathbb{R}^{n \times m}$ sei eine Matrix, $b \in \mathbb{R}^n$ sei ein Vektor und v sei ein n -dimensionaler bedingt normalverteilter Zufallsvektor mit bedingter WDF

$$p_{v|\xi}(\cdot|x) : \mathbb{R}^n \rightarrow \mathbb{R}_{>0}, y \mapsto p_{v|\xi}(y|x) := N(y; A\xi + b, \Sigma_{vv}) \text{ mit } \Sigma_{vv} \in \mathbb{R}^{n \times n}. \quad (12.19)$$

Dann ist der $m + n$ -dimensionale Zufallsvektor $(\xi, v)^T$ normalverteilt mit (gemeinsamer) WDF

$$p_{\xi,v} : \mathbb{R}^{m+n} \rightarrow \mathbb{R}_{>0}, \begin{pmatrix} x \\ y \end{pmatrix} \mapsto p_{\xi,v} \left(\begin{pmatrix} x \\ y \end{pmatrix} \right) = N \left(\begin{pmatrix} x \\ y \end{pmatrix}; \mu_{\xi,v}, \Sigma_{\xi,v} \right), \quad (12.20)$$

mit $\mu_{\xi,v} \in \mathbb{R}^{m+n}$ und $\Sigma_{\xi,v} \in \mathbb{R}^{(m+n) \times (m+n)}$ und insbesondere

$$\mu_{\xi,v} = \begin{pmatrix} \mu_\xi \\ A\mu_\xi + b \end{pmatrix} \text{ und } \Sigma_{\xi,v} = \begin{pmatrix} \Sigma_{\xi\xi} & \Sigma_{\xi\xi}A^T \\ A\Sigma_{\xi\xi} & \Sigma_{vv} + A\Sigma_{\xi\xi}A^T \end{pmatrix}. \quad (12.21)$$

◦

Die Parameter der gemeinsamen Verteilung ergeben sich also als linear-affine Transformationen der Parameter der induzierenden marginalen und bedingten Verteilungen.

Beispiel 12.3 (Gemeinsame Normalverteilungen). Abbildung 12.6 visualisiert Theorem 12.5 für den Fall $m := 1, n := 1, \mu_\xi := 1, \Sigma_{\xi\xi} := 0.2, A := 1, b := 1$ und $\Sigma_{vv} := 0.1$. Abbildung 12.6 A zeigt dabei die WDF der Zufallsvariable ξ , Abbildung 12.6 B zeigt die WDF der bedingten Verteilung der Zufallsvariable v gegeben ξ und Abbildung 12.5 C schließlich zeigt die WDFen des induzierten bivariaten Zufallsvektors (ξ, v) .

△

Die Definition einer multivariaten Normalverteilung erlaubt es weiterhin, die bedingten Verteilungen aller Komponenten des entsprechenden Zufallsvektors direkt mithilfe der Parameter der multivariaten Normalverteilung zu bestimmen. Dies ist die zentrale Aussage folgenden Theorems.

Theorem 12.6 (Bedingte Normalverteilungen). (ξ, v) sei ein $m + n$ -dimensionaler normalverteilter Zufallsvektor mit WDF

$$p_{\xi,v} : \mathbb{R}^{m+n} \rightarrow \mathbb{R}_{>0}, \begin{pmatrix} x \\ y \end{pmatrix} \mapsto p_{\xi,v} \left(\begin{pmatrix} x \\ y \end{pmatrix} \right) := N \left(\begin{pmatrix} x \\ y \end{pmatrix}; \mu_{\xi,v}, \Sigma_{\xi,v} \right), \quad (12.22)$$

mit

$$\mu_{\xi,v} = \begin{pmatrix} \mu_\xi \\ \mu_v \end{pmatrix}, \Sigma_{\xi,v} = \begin{pmatrix} \Sigma_{\xi\xi} & \Sigma_{\xi v} \\ \Sigma_{v\xi} & \Sigma_{vv} \end{pmatrix}, \quad (12.23)$$

mit $x, \mu_\xi \in \mathbb{R}^m, y, \mu_v \in \mathbb{R}^n$ und $\Sigma_{\xi\xi} \in \mathbb{R}^{m \times m}, \Sigma_{\xi v} \in \mathbb{R}^{m \times n}, \Sigma_{vv} \in \mathbb{R}^{n \times n}$. Dann ist die bedingte Verteilung von ξ gegeben v eine m -dimensionale Normalverteilung mit bedingter WDF

$$p_{\xi|v}(\cdot|y) : \mathbb{R}^m \rightarrow \mathbb{R}_{>0}, x \mapsto p_{\xi|v}(x|y) := N(x; \mu_{\xi|v}, \Sigma_{\xi|v}) \quad (12.24)$$




Abbildung 12.6 Gemeinsame Verteilungen einer marginalen und einer auf dieser bedingten normalverteilten Zufallsvariablen.

mit

$$\mu_{\xi|v} = \mu_{\xi} + \Sigma_{\xi v} \Sigma_{vv}^{-1} (y - \mu_v) \in \mathbb{R}^m \quad (12.25)$$

und

$$\Sigma_{\xi|v} = \Sigma_{\xi\xi} - \Sigma_{\xi v} \Sigma_{vv}^{-1} \Sigma_{v\xi} \in \mathbb{R}^{m \times m}. \quad (12.26)$$

◦

Im Zusammenspiel mit Theorem 12.5 und Theorem 12.4 können die Parameter bedingter und marginaler Normalverteilungen also aus den Parametern der komplementären bedingten und marginalen Normalverteilungen bestimmt werden.

Beispiel 12.4 (Bedingte Normalverteilungen). Abbildung 12.7 visualisiert Theorem 12.6 für den Fall $m := 2, n := 1$,

$$\mu := \begin{pmatrix} 1 \\ 2 \end{pmatrix} \text{ und } \Sigma := \begin{pmatrix} 0.12 & 0.09 \\ 0.09 & 0.12 \end{pmatrix} \quad (12.27)$$

Dabei zeigt Abbildung 12.7 A die WDF des bivariaten Zufallsvektors $(\xi, v)^T$ und Abbildung 12.7 B und C zeigen die WDF der bedingten Verteilung der Zufallsvariable ξ gegeben $v = 1.5$ und $v = 2.8$, respektive.

△

12.6 Multivariate Transformationen

In diesem Abschnitt stellen wir einige Resultate zu den Verteilungen transformierter normalverteilter Zufallsvektoren zusammen. Wir verzichten dabei auf Beweise.




Abbildung 12.7 Bedingte Normalverteilungen

Theorem 12.7 (Invertierbare lineare Transformation eines normalverteilten Zufallsvektors). $\xi \sim N(\mu_\xi, \Sigma_\xi)$ sei ein normalverteilter n -dimensionaler Zufallsvektor und es sei $\zeta := A\xi$ mit einer invertierbaren Matrix $A \in \mathbb{R}^{n \times n}$. Dann gilt

$$\zeta \sim N(\mu_\zeta, \Sigma_\zeta) \text{ mit } \mu_\zeta = A\mu_\xi \text{ und } \Sigma_\zeta = A\Sigma_\xi A^T. \quad (12.28)$$

◦

Nach Theorem 12.7 ergibt die invertierbare lineare Transformation eines multivariat normalverteilten Zufallsvektors also wiederum einen multivariat normalverteilten Zufallsvektor und die Parameter der Verteilung dieses normalverteilten Zufallsvektors ergeben sich aus den Parametern der Verteilung des ursprünglichen Zufallsvektors und der Transformationsmatrix.

Beispiel 12.5 (Invertierbare lineare Transformation einer bivariaten Normalverteilung). Als Beispiel betrachten wir die invertierbare lineare Transformation eines bivariaten normalverteilten Zufallsvektors ξ . Es seien

$$\mu_\xi := \begin{pmatrix} 1 \\ 1 \end{pmatrix} \text{ und } \Sigma_\xi := \begin{pmatrix} 0.20 & 0.15 \\ 0.15 & 0.20 \end{pmatrix} \quad (12.29)$$

der Erwartungswert- und Kovarianzmatrixparameter von ξ , respektive, und es sei

$$A := \begin{pmatrix} -2 & 1 \\ -1 & 2 \end{pmatrix} \quad (12.30)$$

die Transformationsmatrix. Da $|A| = -3 \neq 0$ ist A invertierbar und es gilt nach Theorem 12.7, dass

$$\zeta \sim N(\mu_\zeta, \Sigma_\zeta) \text{ mit } \mu_\zeta = A\mu_\xi = \begin{pmatrix} -1 \\ 1 \end{pmatrix} \text{ und } A\Sigma_\xi A^T = \begin{pmatrix} 0.40 & 0.05 \\ 0.05 & 0.40 \end{pmatrix}. \quad (12.31)$$

Abbildung 12.8 A zeigt Isokonturen der WDF von ξ und Realisierungen $x^{(i)} \in \mathbb{R}^2$ von ξ für $i = 1, \dots, 50$. Abbildung 12.8 B zeigt die transformierten Realisierungen $z^{(i)} = Ax^{(i)} \in \mathbb{R}^2$ von ζ sowie die Isokonturen der WDF von ζ nach Theorem 12.7.

△

Die Tatsache, dass ein linear transformierter normalverteilter Zufallsvektor wiederum normalverteilt ist und dass sich die Parameter der Verteilung des transformierten Zufallsvektors aus den Parametern der Verteilung des ursprünglichen Zufallsvektors sowie den Transformationsparametern bestimmen lassen, bleibt auch im Falle einer nicht notwendigerweise




Abbildung 12.8 Invertierbare lineare Transformation eines normalverteilten Zufallsvektors

invertierbaren linearen Transformation und auch im Falle einer nicht notwendigerweise invertierbaren linear-affinen Transformation wahr. Dies ist die Aussage folgenden zentralen Theorems.

Theorem 12.8 (Linear-affine Transformation eines normalverteilten Zufallsvektors). $\xi \sim N(\mu_\xi, \Sigma_\xi)$ sei ein normalverteilter n -dimensionaler Zufallsvektor und es sei

$$\zeta := Ax + b \text{ mit } A \in \mathbb{R}^{m \times n} \text{ und } b \in \mathbb{R}^m. \quad (12.32)$$

Dann gilt

$$\zeta \sim N(\mu_\zeta, \Sigma_\zeta) \text{ mit } \mu_\zeta = A\mu + b \in \mathbb{R}^m \text{ und } \Sigma_\zeta = A\Sigma A^T \in \mathbb{R}^{m \times m}. \quad (12.33)$$

◦

Für einen Beweis verweisen wir auf Anderson (2003).

12.7 Transformationen normalverteilter Zufallsvariablen

In diesem Abschnitt diskutieren wir sechs Transformationen normalverteilter Zufallsvariablen, die in der Frequentistischen Inferenz zentrale Rollen spielen und bei denen es sich um Anwendungen von den in Kapitel 11 eingeführten Transformationstheoremen handelt. Unsere Aussagen sind dabei meist von der allgemeinen Form “Wenn $\xi_i, i = 1, \dots, n$ unabhängig und identisch normalverteilte Zufallsvariablen sind und $v := f(\xi_1, \dots, \xi_n)$ eine Transformation dieser Zufallsvariablen ist, dann ist die WDF von v durch die Formel $p_v := \{\text{Formel}\}$ gegeben und man nennt die Verteilung von v *Verteilungsname*”. Aussagen dieser Form sind für die Frequentistische Inferenz zentral, weil erstens die Zentralen Grenzwertsätze die Annahme additiv unabhängig normalverteilter Störvariablen, und damit normalverteilter Daten, begründet, zweitens, wie wir in [Frequentistische Inferenz \(PDWP\)](#) sehen werden, es sich bei Schätzern und Statistiken um Transformationen

von Zufallsvariablen handelt, und drittens, Parameterschätzergütekriterien, Konfidenzintervalle und Hypothesentests der Frequentistischen Inferenz durch die Verteilungen der jeweiligen Schätzer und Statistiken charakterisiert und begründet sind.

Summationstransformation

In diesem Abschnitt betrachten wir die resultierenden Verteilungen bei Summation und Mittelwertbildung von unabhängig und identisch normalverteilten Zufallsvariablen. Speziell besagt Theorem 12.9, dass die Summe unabhängig normalverteilter Zufallsvariablen wiederum normalverteilt ist und gibt die Parameter dieser Verteilung an, während Theorem 12.10 besagt, dass das Stichprobenmittel unabhängig normalverteilter Zufallsvariablen wiederum normalverteilt ist und gibt die Parameter dieser Verteilung an.

Theorem 12.9 (Summationstransformation). *Für $i = 1, \dots, n$ seien $\xi_i \sim N(\mu_i, \sigma_i^2)$ unabhängige normalverteilte Zufallsvariablen. Dann gilt für die Summe $v := \sum_{i=1}^n \xi_i$, dass*

$$v \sim N\left(\sum_{i=1}^n \mu_i, \sum_{i=1}^n \sigma_i^2\right) \quad (12.34)$$

Für unabhängige und identisch normalverteilte Zufallsvariablen $\xi_i \sim N(\mu, \sigma^2)$ gilt folglich

$$v \sim N(n\mu, n\sigma^2). \quad (12.35)$$

◦

Beweis. Wir skizzieren mithilfe von Theorem 11.6, dass für $\xi_1 \sim N(\mu_1, \sigma_1^2)$, $\xi_2 \sim N(\mu_2, \sigma_2^2)$, und $v := \xi_1 + \xi_2$ gilt, dass $v \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$. Für $n > 2$ folgt das Theorem dann durch Iteration. Mit der Definition der WDF der Normalverteilung erhalten wir zunächst

$$\begin{aligned} p_v(y) &= \int_{-\infty}^{\infty} p_{\xi_1}(x_1) p_{\xi_2}(y - x_1) dx_1 \\ &= \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}\sigma_1} \exp\left(-\frac{1}{2}\left(\frac{x_1 - \mu_1}{\sigma_1}\right)^2\right) \frac{1}{\sqrt{2\pi}\sigma_2} \exp\left(-\frac{1}{2}\left(\frac{y - x_1 - \mu_2}{\sigma_2}\right)^2\right) dx_1 \\ &= \int_{-\infty}^{\infty} \frac{1}{2\pi\sigma_1\sigma_2} \exp\left(-\frac{1}{2}\left(\frac{x_1 - \mu_1}{\sigma_1}\right)^2 - \frac{1}{2}\left(\frac{y - x_1 - \mu_2}{\sigma_2}\right)^2\right) dx_1. \end{aligned} \quad (12.36)$$

Mit einigem algebraischen Aufwand erhält man die Identität

$$-\frac{1}{2}\left(\frac{x_1 - \mu_1}{\sigma_1}\right)^2 - \frac{1}{2}\left(\frac{y - x_1 - \mu_2}{\sigma_2}\right)^2 = -\frac{(y - \mu_1 - \mu_2)^2}{2(\sigma_1^2 + \sigma_2^2)} - \frac{((\sigma_1^2 + \sigma_2^2)x_1 - \sigma_1^2 y + \mu_2 \sigma_1^2 - \mu_1 \sigma_2^2)^2}{2\sigma_1^2 \sigma_2^2 (\sigma_1^2 + \sigma_2^2)}, \quad (12.37)$$

so dass weiterhin gilt, dass

$$\begin{aligned} p_v(y) &= \int_{-\infty}^{\infty} \frac{1}{2\pi\sigma_1\sigma_2} \exp\left(-\frac{(y - \mu_1 - \mu_2)^2}{2(\sigma_1^2 + \sigma_2^2)} - \frac{((\sigma_1^2 + \sigma_2^2)x_1 - \sigma_1^2 y + \mu_2 \sigma_1^2 - \mu_1 \sigma_2^2)^2}{2\sigma_1^2 \sigma_2^2 (\sigma_1^2 + \sigma_2^2)}\right) dx_1 \\ &= \int_{-\infty}^{\infty} \frac{1}{2\pi\sigma_1\sigma_2} \exp\left(-\frac{(y - \mu_1 - \mu_2)^2}{2(\sigma_1^2 + \sigma_2^2)}\right) \exp\left(-\frac{((\sigma_1^2 + \sigma_2^2)x_1 - \sigma_1^2 y + \mu_2 \sigma_1^2 - \mu_1 \sigma_2^2)^2}{2\sigma_1^2 \sigma_2^2 (\sigma_1^2 + \sigma_2^2)}\right) dx_1 \\ &= \frac{1}{2\pi\sigma_1\sigma_2} \exp\left(-\frac{(y - \mu_1 - \mu_2)^2}{2(\sigma_1^2 + \sigma_2^2)}\right) \int_{-\infty}^{\infty} \exp\left(-\frac{((\sigma_1^2 + \sigma_2^2)x_1 - \sigma_1^2 y + \mu_2 \sigma_1^2 - \mu_1 \sigma_2^2)^2}{2\sigma_1^2 \sigma_2^2 (\sigma_1^2 + \sigma_2^2)}\right) dx_1. \end{aligned} \quad (12.38)$$

Für das verbleibende Integral zeigt man mithilfe der Integration durch Substitution, dass

$$\int_{-\infty}^{\infty} \exp\left(-\frac{((\sigma_1^2 + \sigma_2^2)x_1 - \sigma_1^2 y + \mu_2 \sigma_1^2 - \mu_1 \sigma_2^2)^2}{2\sigma_1^2 \sigma_2^2 (\sigma_1^2 + \sigma_2^2)}\right) dx_1 = \frac{\sqrt{2\pi} \sigma_1 \sigma_2}{\sqrt{\sigma_1^2 + \sigma_2^2}}. \quad (12.39)$$

Es ergibt sich also

$$\begin{aligned} p_v(y) &= \frac{1}{2\pi \sigma_1 \sigma_2} \frac{\sqrt{2\pi} \sigma_1 \sigma_2}{\sqrt{\sigma_1^2 + \sigma_2^2}} \exp\left(-\frac{(y - \mu_1 - \mu_2)^2}{2(\sigma_1^2 + \sigma_2^2)}\right) \\ &= \frac{(2\pi)^{-1} (2\pi)^2}{\sqrt{\sigma_1^2 + \sigma_2^2}} \exp\left(-\frac{(y - \mu_1 - \mu_2)^2}{2(\sigma_1^2 + \sigma_2^2)}\right) \\ &= \frac{1}{\sqrt{2\pi} \sqrt{\sigma_1^2 + \sigma_2^2}} \exp\left(-\frac{(y - \mu_1 - \mu_2)^2}{2(\sigma_1^2 + \sigma_2^2)}\right). \end{aligned} \quad (12.40)$$

Schließlich folgt, dass

$$p_v(y) = \frac{1}{\sqrt{2\pi(\sigma_1^2 + \sigma_2^2)}} \exp\left(-\frac{1}{2(\sigma_1^2 + \sigma_2^2)} (y - (\mu_1 + \mu_2))^2\right) = N(y; \mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2) \quad (12.41)$$

Ein einfacheres Vorgehen ergibt sich vermutlich nach Fouriertransformation der WDF im Sinne der sogenannten charakteristischen Funktion einer Zufallsvariable. In diesem Fall würde die Faltung der WDFen der Multiplikation der charakteristischen Funktionen entsprechen. $\square$

Ein wichtiger Anwendungsfall von Theorem 12.9 ist das nachfolgende Theorem 12.10 sowie die in Gleichung 10.18 und Gleichung 10.25 erwähnten Generalisierungen der Zentralen Grenzwertsätze. Wir visualisieren Theorem 12.9 exemplarisch in Abbildung 12.9.




Abbildung 12.9 Summation normalverteilter Zufallsvariablen.

Mittelwerttransformation

Theorem 12.10 (Mittelwertstransformation). *Für $i = 1, \dots, n$ seien $\xi_i \sim N(\mu, \sigma^2)$ unabhängig und identisch normalverteilte Zufallsvariablen. Dann gilt für das Stichprobenmittel $\bar{\xi}_n := \frac{1}{n} \sum_{i=1}^n \xi_i$, dass*

$$\bar{\xi}_n \sim N\left(\mu, \frac{\sigma^2}{n}\right). \quad (12.42)$$

◦

Beweis. Wir halten zunächst fest, dass mit dem Theorem zur Summe von unabhängig normalverteilten Zufallsvariablen gilt, dass $\bar{\xi}_n = \frac{1}{n}v$ mit $v := \sum_{i=1}^n \xi_i \sim N(n\mu, n\sigma^2)$. Einsetzen in Theorem 11.3 ergibt dann

$$\begin{aligned}
 p_{\bar{\xi}_n}(\bar{x}_n) &= \frac{1}{|1/n|} N(n\bar{x}_n; n\mu, n\sigma^2) \\
 &= \frac{n}{\sqrt{2\pi n\sigma^2}} \exp\left(-\frac{1}{2n\sigma^2} (n\bar{x}_n - n\mu)^2\right) \\
 &= \frac{n}{\sqrt{2\pi n\sigma^2}} \exp\left(-\frac{1}{2n\sigma^2} (n\bar{x}_n - n\mu)^2\right) \\
 &= nn^{-\frac{1}{2}} \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(n\bar{x}_n)^2}{2n\sigma^2} + \frac{2(n\bar{x}_n)(n\mu)}{2n\sigma^2} - \frac{(n\mu)^2}{2n\sigma^2}\right) \\
 &= \sqrt{n} \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{n\bar{x}_n^2}{2\sigma^2} + \frac{2n\bar{x}_n\mu}{2\sigma^2} - \frac{n\mu^2}{2\sigma^2}\right) \\
 &= \frac{1}{1/\sqrt{n}} \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{\bar{x}_n^2}{2(\sigma^2/n)} + \frac{2\bar{x}_n\mu}{2(\sigma^2/n)} - \frac{\mu^2}{2(\sigma^2/n)}\right) \\
 &= \frac{1}{\sqrt{2\pi(\sigma^2/n)}} \exp\left(-\frac{1}{2(\sigma^2/n)} (\bar{x}_n - \mu)^2\right) \\
 &= N(\bar{x}_n; \mu, \sigma^2/n)
 \end{aligned} \tag{12.43}$$

□

Wichtige Anwendungsfälle von Theorem 12.10 sind die Analyse von Erwartungswertschätzern in Punktschätzung (PDWP) sowie die in Gleichung 10.18 erwähnte Generalisierung des Zentralen Grenzwertsatzes nach Lindeberg-Lévy. Wir visualisieren Theorem 12.10 exemplarisch in Abbildung 12.10.




Abbildung 12.10 Mittelwertbildung bei normalverteilten Zufallsvariablen.

Z-Transformation

Das Theorem 12.11 besagt, dass Subtraktion des Erwartungswertparameters und gleichzeitige Division mit der Wurzel des Varianzparameters die Verteilung einer normalverteilten Zufallsvariable in eine Standardnormalverteilung transformiert.

Theorem 12.11 (*Z-Transformation*). *Es sei $v \sim N(\mu, \sigma^2)$ eine normalverteilte Zufallsvariable. Dann ist die Zufallsvariable*

$$Z := \frac{v - \mu}{\sigma} \tag{12.44}$$

eine standardnormalverteilte Zufallsvariable, es gilt also $Z \sim N(0, 1)$.

◦

Beweis. Wir nutzen Theorem 11.3. Dazu halten wir zunächst fest, dass die Z -Transformation einer Funktion der Form

$$f(v) := \frac{v - \mu}{\sigma} =: Z \quad (12.45)$$

entspricht. Wir stellen weiterhin fest, dass die Umkehrfunktion von f durch

$$f^{-1}(Z) := \sigma Z + \mu \quad (12.46)$$

gegeben ist, da für alle $z \in \mathbb{R}$ mit $z = y - \mu\sigma$ gilt, dass

$$\zeta^{-1}(z) = \zeta^{-1}\left(\frac{y - \mu}{\sigma}\right) = \frac{\sigma(y - \mu)}{\sigma} + \mu = y - \mu + \mu = y. \quad (12.47)$$

Schließlich stellen wir fest, dass für die Ableitung f' von f gilt, dass

$$f'(y) = \frac{d}{dy}\left(\frac{y - \mu}{\sigma}\right) = \frac{d}{dy}\left(\frac{y}{\sigma} - \frac{\mu}{\sigma}\right) = \frac{1}{\sigma}. \quad (12.48)$$

Einsetzen in Theorem 11.3 ergibt dann

$$\begin{aligned} p_Z(z) &= \frac{1}{|1/\sigma|} N(\sigma z + \mu; \mu, \sigma^2) \\ &= \frac{1}{1/\sqrt{\sigma^2}} \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2\sigma^2}(\sigma z + \mu - \mu)^2\right) \\ &= \frac{\sqrt{\sigma^2}}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2\sigma^2}\sigma^2 z^2\right) \\ &= \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}z^2\right) \\ &= N(z; 0, 1) \end{aligned} \quad (12.49)$$

also, dass $Z \sim N(0, 1)$. □

Wichtige Anwendungsfälle von Theorem 12.11 sind neben der häufig angewandten Standardisierung von normalverteilten Zufallsvariablen im Sinne der sogenannten Z -Werte (Z -Scores) die Z -Konfidenzintervallstatistik und die Z -Teststatistik. Wir visualisieren Theorem 12.11 exemplarisch in Abbildung 12.11.

χ^2 -Transformation

Mit der χ^2 -Transformation führen wir nun eine erste Transformation unabhängig und identisch normalverteilter Zufallsvariablen ein, die *nicht* wiederum auf eine Normalverteilung führt. Speziell besagt Theorem 12.12, dass die Summe quadrierter unabhängiger standardnormalverteilter Zufallsvariablen eine χ^2 -verteilte Zufallsvariable ist. Dazu erinnern wir zunächst an den Begriff der χ^2 -Zufallsvariable als Spezialfall der in Kapitel 4 betrachteten Gammazufallsvariablen (vgl. Definition 4.10).

Definition 12.3 (χ^2 -Zufallsvariable). U sei eine Zufallsvariable mit Ergebnisraum $\mathbb{R}_{>0}$ und WDF

$$p : \mathbb{R}_{>0} \rightarrow \mathbb{R}_{>0}, u \mapsto p(u) := \frac{1}{\Gamma\left(\frac{n}{2}\right) 2^{\frac{n}{2}}} u^{\frac{n}{2}-1} \exp\left(-\frac{1}{2}u\right), \quad (12.50)$$




Abbildung 12.11 Z-Transformation normalverteilter Zufallsvariablen.

wobei Γ die Gammafunktion bezeichne. Dann sagen wir, dass U einer χ^2 -Verteilung mit Freiheitsgradparameter n unterliegt und nennen U eine χ^2 -Zufallsvariable mit Freiheitsgradparameter n . Wir kürzen dies mit $U \sim \chi^2(n)$ ab. Die WDF einer χ^2 -Zufallsvariable bezeichnen wir mit

$$\chi^2(u; n) := \frac{1}{\Gamma\left(\frac{n}{2}\right) 2^{\frac{n}{2}}} u^{\frac{n}{2}-1} \exp\left(-\frac{1}{2}u\right). \quad (12.51)$$

•

Wir erinnern daran, dass die WDF der χ^2 -Verteilung der WDF $G(u; \frac{n}{2}, 2)$ einer Gammaverteilung entspricht. In Abbildung 12.12 visualisieren wir exemplarisch einige WDFen von χ^2 -Zufallsvariablen. Wir beobachten, dass mit ansteigendem n sich $\chi^2(u; n)$ verbreitert und Wahrscheinlichkeitsmasse zu größeren Werten von u verschoben wird.

Theorem 12.12 (χ^2 -Transformation). $Z_1, \dots, Z_n \sim N(0, 1)$ seien unabhängig und identisch standardnormalverteilte Zufallsvariablen. Dann ist die Zufallsvariable

$$U := \sum_{i=1}^n Z_i^2 \quad (12.52)$$

eine χ^2 -verteilte Zufallsvariable mit Freiheitsgradparameter n , es gilt also $U \sim \chi^2(n)$. Insbesondere gilt für $Z \sim N(0, 1)$ und $U := Z^2$, dass $U \sim \chi^2(1)$.

◦

Beweis. Wir zeigen das Theorem nur für den Fall $n := 1$ mithilfe von Theorem 11.4. Danach ist die WDF einer Zufallsvariable $U := f(Z)$, welche aus der Transformation einer Zufallsvariable Z mit WDF p_Z durch eine stückweise bijektive Abbildung hervorgeht, gegeben durch

$$p_U(u) = \sum_{i=1}^k 1_{u_i} \frac{1}{|f'_i(f_i^{-1}(u))|} p_Z(f_i^{-1}(u)). \quad (12.53)$$




Abbildung 12.12 WDFen von χ^2 Zufallsvariablen.

Wir definieren

$$\mathcal{U}_1 :=]-\infty, 0[, \mathcal{U}_2 :=]0, \infty[, \text{ und } \mathcal{U}_i := \mathbb{R}_{>0} \text{ f\"ur } i = 1, 2, \quad (12.54)$$

sowie

$$f_i : \mathcal{Z}_i \rightarrow \mathcal{U}_i, x \mapsto f_i(z) := z^2 =: u \text{ f\"ur } i = 1, 2. \quad (12.55)$$

Die Ableitung und die Umkehrfunktion der f_i ergeben sich zu

$$f'_i : \mathcal{Z}_i \rightarrow \mathcal{Z}_i, x \mapsto f'_i(z) = 2z \text{ f\"ur } i = 1, 2, \quad (12.56)$$

und

$$f_1^{-1} : \mathcal{U}_1 \rightarrow \mathcal{U}_1, u \mapsto f_1^{-1}(u) = -\sqrt{u} \text{ und } f_2^{-1} : \mathcal{U}_2 \rightarrow \mathcal{U}_2, u \mapsto f_2^{-1}(u) = \sqrt{u}, \quad (12.57)$$

respektive. Einsetzen ergibt dann

$$\begin{aligned} p_U(u) &= 1_{\mathcal{U}_1}(u) \frac{1}{|f'_1(f_1^{-1}(u))|} p_\zeta(f_1^{-1}(u)) + 1_{\mathcal{U}_2}(u) \frac{1}{|f'_2(f_2^{-1}(u))|} p_\zeta(f_2^{-1}(u)) \\ &= \frac{1}{|2(-\sqrt{u})|} \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}(-\sqrt{u})^2\right) + \frac{1}{|2(\sqrt{u})|} \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}(\sqrt{u})^2\right) \\ &= \frac{1}{2\sqrt{u}} \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}u\right) + \frac{1}{2\sqrt{u}} \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}u\right) \\ &= \frac{1}{\sqrt{2\pi}} \frac{1}{\sqrt{u}} \exp\left(-\frac{1}{2}u\right). \end{aligned} \quad (12.58)$$

Andererseits gilt, dass mit $\Gamma(\frac{1}{2}) = \sqrt{\pi}$, die PDF einer χ^2 -Zufallsvariable U mit $n = 1$ durch

$$\frac{1}{\Gamma(\frac{1}{2}) 2^{\frac{1}{2}}} u^{\frac{1}{2}-1} \exp\left(-\frac{1}{2}u\right) = \frac{1}{\sqrt{2\pi}} \frac{1}{\sqrt{u}} \exp\left(-\frac{1}{2}u\right) \quad (12.59)$$

gegeben ist. Also gilt, dass wenn $Z \sim N(0, 1)$ ist, dann ist $U := Z^2 \sim \chi^2(1)$. $\square$

Wichtige Anwendungsfälle sind die U -Konfidenzintervallstatistik sowie die im Folgenden eingeführten t - und F -Zufallsvariablen. Wir visualisieren Theorem 12.12 exemplarisch in Abbildung 12.13.




Abbildung 12.13 χ^2 -Transformation normalverteilter Zufallsvariablen.

T -Transformation

Das in diesem Abschnitt betrachtete Theorem geht auf Student (1908) zurück und ist das zentrale und stilprägende Resultat der Entwicklung der Frequentistischen Inferenz in der ersten Hälfte der 20. Jahrhunderts. Hald (2007) und Zabell (2008) geben hierzu einen historischen Überblick. Das zentrale Theorem 12.13 besagt dabei, dass die Zufallsvariable, die sich durch Division einer standardnormalverteilten Zufallsvariable durch die Quadratwurzel einer χ^2 -verteilten Zufallsvariable geteilt durch ein n , ergibt, eine t -verteilte Zufallsvariable ist. Dabei ist eine t -verteilte Zufallsvariable wie folgt definiert.

Definition 12.4 (t -Zufallsvariable). T sei eine Zufallsvariable mit Ergebnisraum $\mathbb{R}$ und WDF


$$p : \mathbb{R} \rightarrow \mathbb{R}_{>0}, t \mapsto p(t) := \frac{\Gamma\left(\frac{n+1}{2}\right)}{\sqrt{n\pi}\Gamma\left(\frac{n}{2}\right)} \left(1 + \frac{t^2}{n}\right)^{-\frac{n+1}{2}}, \quad (12.60)$$

wobei Γ die Gammafunktion bezeichne. Dann sagen wir, dass T einer t -Verteilung mit Freiheitsgradparameter n unterliegt und nennen T eine t -Zufallsvariable mit Freiheitsgradparameter n . Wir kürzen dies mit $T \sim t(n)$ ab. Die WDF einer t -Zufallsvariable bezeichnen wir mit

$$T(t; n) := \frac{\Gamma\left(\frac{n+1}{2}\right)}{\sqrt{n\pi}\Gamma\left(\frac{n}{2}\right)} \left(1 + \frac{t^2}{n}\right)^{-\frac{n+1}{2}}. \quad (12.61)$$

•

In Abbildung 12.14 visualisieren wir exemplarisch einige WDFen von t -Zufallsvariablen. Wir beobachten, dass die t -Verteilung immer um 0 symmetrisch ist und ein steigendes n Wahrscheinlichkeitsmasse aus den Ausläufen zum Zentrum verschiebt. Wir merken an, dass ab etwa $n = 30$ gilt, dass $T(t; n) \approx N(0, 1)$.

Abbildung 12.14 WDFen von T -Zufallsvariablen.

Theorem 12.13 (T -Transformation). $Z \sim N(0, 1)$ sei eine standardnormalverteilte Zufallsvariable, $U \sim \chi^2(n)$ sei eine χ^2 -Zufallsvariable mit Freiheitsgradparameter n , und Z und U seien unabhängig. Dann ist die Zufallsvariable

$$T := \frac{Z}{\sqrt{U/n}} \quad (12.62)$$

eine t -verteilte Zufallsvariable mit Freiheitsgradparameter n , es gilt also $T \sim t(n)$.

◦

Beweis. Wir halten zunächst fest, dass die zweidimensionale WDF der gemeinsamen (unabhängigen) Verteilung von Z und U durch

$$p_{Z,U}(z, u) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}z^2\right) \frac{1}{\Gamma(\frac{n}{2})2^{\frac{n}{2}}} u^{\frac{n}{2}-1} \exp\left(-\frac{1}{2}u\right). \quad (12.63)$$

gegeben ist. Wir betrachten dann die multivariate vektorwertige Abbildung

$$f: \mathbb{R}^2 \rightarrow \mathbb{R}^2, (z, u) \mapsto f(z, u) := \left(\frac{z}{\sqrt{u/n}}, u \right) =: (t, w) \quad (12.64)$$

und benutzen das multivariate WDF Transformationstheorem für bijektive Abbildungen um die WDF von (t, w) herzuleiten. Dazu erinnern wir uns, dass wenn ξ ein n -dimensionaler Zufallsvektor mit WDF p_ξ und $v := f(\xi)$ für eine differenzierbare und bijektive Abbildung $f: \mathbb{R}^n \rightarrow \mathbb{R}^n$ ist, die WDF des Zufallsvektors v durch

$$p_v: \mathbb{R}^n \rightarrow \mathbb{R}_{\geq 0}, y \mapsto p_v(y) := \frac{1}{|Jf(f^{-1}(y))|} p_\xi(f^{-1}(y)) \quad (12.65)$$

gegeben ist. Für die im vorliegenden Fall betrachtete Abbildung halten wir zunächst fest, dass

$$f^{-1}: \mathbb{R}^2 \rightarrow \mathbb{R}^2, (t, w) \mapsto f^{-1}(t, w) := (\sqrt{w/nt}, w). \quad (12.66)$$

Dies ergibt sich direkt aus

$$f^{-1}(f(z, u)) = f^{-1}\left(\frac{z}{\sqrt{u/n}}, u\right) = \left(\frac{\sqrt{u/n}z}{\sqrt{u/n}}, u\right) = (z, u) \text{ für alle } (z, u) \in \mathbb{R}^2. \quad (12.67)$$

Wir halten dann fest, dass die Determinante der Jacobi-Matrix von f an der Stelle (z, u) durch

$$|J^f(z, u)| = \left| \begin{array}{cc} \frac{\partial}{\partial z} \left(\frac{z}{\sqrt{u/n}} \right) & \frac{\partial}{\partial u} \left(\frac{z}{\sqrt{u/n}} \right) \\ \frac{\partial}{\partial z} u & \frac{\partial}{\partial u} u \end{array} \right| = \left(\frac{v}{n} \right)^{-1/2}, \quad (12.68)$$

gegeben ist, sodass folgt, dass

$$\frac{1}{|J^f(f^{-1}(z, u))|} = \left(\frac{w}{n} \right)^{1/2}. \quad (12.69)$$

Einsetzen ergibt dann

$$p_{T,W}(t, w) = \left(\frac{w}{n} \right)^{1/2} p_{Z,V}(\sqrt{w/nt}, w), \quad (12.70)$$

Es folgt also

$$\begin{aligned} p_T(t) &= \int_0^\infty p_{T,W}(t, w) dw \\ &= \int_0^\infty \left(\frac{w}{n} \right)^{1/2} p_{Z,V}(\sqrt{w/nt}, w) dw \\ &= \int_0^\infty \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}(\sqrt{w/nt})^2\right) \frac{1}{\Gamma(\frac{n}{2})2^{\frac{n}{2}}} w^{\frac{n}{2}-1} \exp\left(-\frac{1}{2}w\right) \left(\frac{w}{n}\right)^{1/2} dw \\ &= \frac{1}{\sqrt{2\pi}} \frac{1}{\Gamma(\frac{n}{2})2^{\frac{n}{2}}n^{\frac{1}{2}}} \int_0^\infty \exp\left(-\frac{1}{2}\frac{w}{n}t^2\right) w^{\frac{n}{2}-1} \exp\left(-\frac{1}{2}w\right) w^{1/2} dw \\ &= \frac{1}{\sqrt{2\pi}} \frac{1}{\Gamma(\frac{n}{2})2^{\frac{n}{2}}n^{\frac{1}{2}}} \int_0^\infty \exp\left(-\frac{1}{2}\frac{w}{n}t^2 - \frac{1}{2}w\right) w^{\frac{n}{2}-1} w^{1/2} dw \\ &= \frac{1}{\sqrt{2\pi}} \frac{1}{\Gamma(\frac{n}{2})2^{\frac{n}{2}}n^{\frac{1}{2}}} \int_0^\infty \exp\left(-\frac{1}{2}\left(\frac{w}{n}t^2 + w\right)\right) w^{\frac{n+1}{2}-1} dw \\ &= \frac{1}{\sqrt{2\pi}} \frac{1}{\Gamma(\frac{n}{2})2^{\frac{n}{2}}n^{\frac{1}{2}}} \int_0^\infty \exp\left(-\frac{1}{2}\left(1 + \frac{t^2}{n}\right)w\right) w^{\frac{n+1}{2}-1} dw \end{aligned} \quad (12.71)$$

Wir stellen dann fest, dass der Integrand auf der linken Seite der obigen Gleichung dem Kern einer Gamma WDF mit Parametern $\alpha = \frac{n+1}{2}$ und $\beta = \frac{2}{1+\frac{t^2}{n}}$ entspricht, wie man leicht einsieht:

$$\begin{aligned} \Gamma(w; \alpha, \beta) &= \frac{1}{\Gamma(\alpha)\beta^\alpha} w^{\alpha-1} \exp\left(-\frac{w}{\beta}\right) \\ \Rightarrow \Gamma\left(w; \frac{n+1}{2}, \frac{2}{1+\frac{t^2}{n}}\right) &= \frac{1}{\Gamma(\frac{n+1}{2})\left(\frac{2}{1+\frac{t^2}{n}}\right)^{\frac{n+1}{2}}} w^{\frac{n+1}{2}-1} \exp\left(-\frac{w}{\frac{2}{1+\frac{t^2}{n}}}\right) \\ &= \frac{1}{\Gamma(\frac{n+1}{2})\left(\frac{2}{1+\frac{t^2}{n}}\right)^{\frac{n+1}{2}}} \exp\left(-\frac{1}{2}\left(1 + \frac{t^2}{n}\right)w\right) w^{\frac{n+1}{2}-1}. \end{aligned}$$

Es ergibt sich also


$$p_T(t) = \frac{1}{\sqrt{2\pi}} \frac{1}{\Gamma(\frac{n}{2})2^{\frac{n}{2}}n^{\frac{1}{2}}} \int_0^\infty \Gamma\left(w; \frac{n+1}{2}, \frac{2}{1+\frac{t^2}{n}}\right) dw. \quad (12.72)$$

Schließlich stellen wir fest, dass der Integralterm in obiger Gleichung dem Normalisierungsterm einer Gamma WDF entspricht. Abschließend ergibt sich also

$$p_T(t) = \frac{1}{\sqrt{2\pi}} \frac{1}{\Gamma(\frac{n}{2})2^{\frac{n}{2}}n^{\frac{1}{2}}} \Gamma\left(\frac{n+1}{2}\right) \left(\frac{2}{1+\frac{t^2}{n}}\right)^{\frac{n+1}{2}}. \quad (12.73)$$

Die Verteilung von $Z/\sqrt{U/n}$ hat also die WDF einer t -Zufallsvariable. $\square$

Wichtige Anwendungsfälle sind die T -Konfidenzintervallstatistik sowie die T -Teststatistiken der Theorie von Hypothesentests im Kontext des Allgemeinen Linearen Modells. Wir visualisieren Theorem 12.13 exemplarisch in Abbildung 12.15.

Abbildung 12.15 T -Transformation normalverteilter Zufallsvariablen.

Nichtzentrale T -Transformation

In diesem Abschnitt betrachten wir den Fall, dass der Erwartungswertparameter der Zählervariable der in Theorem 12.13 betrachteten Zufallsvariable T von null verschieden ist, dass es sich bei der Zählervariable also nicht um eine nach $N(0, 1)$, sondern eine nach $N(\mu, 1)$ verteilte Zufallsvariable für ein beliebiges $\mu \in \mathbb{R}$ handelt. Die so entstehende Zufallsvariable T folgt dann einer sogenannten *nichtzentralen- t -Verteilung*. Eine frühe ausführliche Diskussion dieser Verteilung findet sich zum Beispiel in Johnson & Welch (1940). Eine entsprechende nichtzentralen- t -verteilte Zufallsvariable ist wie folgt definiert (vgl. Lehmann (1986)).

Definition 12.5 (Nichtzentrale t -Zufallsvariable). T sei eine Zufallsvariable mit Ergebnisraum $\mathbb{R}$ und WDF

$$p : \mathbb{R} \rightarrow \mathbb{R}_{>0}, t \mapsto p(t) := \frac{1}{2^{\frac{n-1}{2}} \Gamma\left(\frac{n}{2}\right) (n\pi)^{\frac{1}{2}}} \times \int_0^\infty \tau^{\frac{n-1}{2}} \exp\left(-\frac{\tau}{2}\right) \exp\left(-\frac{1}{2} \left(t \left(\frac{\tau}{n}\right)^{\frac{1}{2}} - \delta\right)^2\right) d\tau. \quad (12.74)$$

Dann sagen wir, dass T einer nichtzentralen t -Verteilung mit Nichtzentralitätsparameter δ und Freiheitsgradparameter n unterliegt und nennen T eine *nichtzentrale t -Zufallsvariable mit Nichtzentralitätsparameter δ und Freiheitsgradparameter n* . Wir kürzen dies mit $t(\delta, n)$ ab. Die WDF einer nichtzentralen t -Zufallsvariable bezeichnen wir mit $t(T; \delta, n)$. Die KVF und inverse KVF einer nichtzentralen t -Zufallsvariable bezeichnen wir mit $\Psi(\cdot; \delta, n)$ und $\Psi^{-1}(\cdot; \delta, n)$, respektive.

•

Ohne Beweis merken wir an, dass eine nichtzentrale t -Zufallsvariable mit $\delta = 0$ einer t -Zufallsvariable entspricht, es gelten also

$$t(T; 0, n) = t(T; n) \quad (12.75)$$

sowie

$$\Psi(T; 0, n) = \Psi(T; n) \text{ und } \Psi^{-1}(T; 0, n) = \Psi^{-1}(T; n). \quad (12.76)$$

In Abbildung 12.16 visualisieren wir exemplarisch einige WDFen von nichtzentralen t -Zufallsvariablen. Wir beobachten, dass ein positiver Nichtzentralitätsparameter δ die Verteilung nach rechts verschiebt und die Verteilungen mit steigendem Freiheitsgradparameter n sich entsprechend lokalisierten Normalverteilungen mit Varianzparameter 1 annähern. Man beachte auch die Nichtsymmetrie der WDFen für kleine Freiheitsgradparameter bei von Null verschiedenem positivem Nichtzentralitätsparameter.




Abbildung 12.16 WDFen von Nichtzentralen- T -Zufallsvariablen.

Eine nichtzentrale t -Zufallsvariable ist das Resultat einer nichtzentralen T -Transformation, wie folgendes Theorem besagt.

Theorem 12.14 (Nichtzentrale T -Transformation). $v \sim N(\mu, 1)$ sei eine normalverteilte Zufallsvariable, $U \sim \chi^2(n)$ sei eine χ^2 -Zufallsvariable mit Freiheitsgradparameter n , und v und U seien unabhängige Zufallsvariablen. Dann ist die Zufallsvariable

$$T := \frac{v}{\sqrt{U/n}} \quad (12.77)$$

eine nichtzentrale t -Zufallsvariable mit Nichtzentralitätsparameter μ und Freiheitsgradparameter n , also $T \sim t(\mu, n)$.

◦

Wir verzichten auf einen Beweis. Wichtige Anwendungsfälle sind die Testgütefunktionen der T -Test-Varianten im Kontext des Allgemeinen Linearen Modells. Wir visualisieren Theorem 12.14 exemplarisch in Abbildung 12.17.

F -Transformation

Das in diesem Abschnitt zentrale Theorem 12.15 besagt, dass die Zufallsvariable, die sich durch Division zweier jeweils durch ihre Freiheitsgradparameter geteilter χ^2 -verteilter Zufallsvariablen ergibt, eine F -verteilte Zufallsvariable ist. Dabei ist eine F -verteilte Zufallsvariable wie folgt definiert.




Abbildung 12.17 Nichtzentrale T -Transformation normalverteilter Zufallsvariablen.

Definition 12.6 (F -Zufallsvariable). F sei eine Zufallsvariable mit Ergebnisraum $\mathbb{R}_{>0}$ und WDF

$$p_F : \mathbb{R} \rightarrow \mathbb{R}_{>0}, f \mapsto p_F(f) := \left(\frac{n}{m}\right)^{\frac{n}{2}} \frac{\Gamma\left(\frac{n+m}{2}\right)}{\Gamma\left(\frac{n}{2}\right)\Gamma\left(\frac{m}{2}\right)} \frac{f^{\frac{n}{2}-1}}{\left(1 + \frac{n}{m}f\right)^{\frac{n+m}{2}}}, \quad (12.78)$$

wobei Γ die Gammafunktion bezeichne. Dann sagen wir, dass F einer F -Verteilung mit Freiheitsgradparametern n, m unterliegt und nennen F eine F -Zufallsvariable mit Freiheitsgradparametern n, m . Wir kürzen dies mit $F \sim F(n, m)$ ab. Die WDF einer F -Zufallsvariable bezeichnen wir mit

$$F(f; n, m) := \left(\frac{n}{m}\right)^{\frac{n}{2}} \frac{\Gamma\left(\frac{n+m}{2}\right)}{\Gamma\left(\frac{n}{2}\right)\Gamma\left(\frac{m}{2}\right)} \frac{f^{\frac{n}{2}-1}}{\left(1 + \frac{n}{m}f\right)^{\frac{n+m}{2}}}. \quad (12.79)$$

•

In [Abbildung 12.18](#) visualisieren wir exemplarisch einige WDFen von F -Zufallsvariablen. Wir beobachten, dass die Form der WDFen zunächst primär durch den Freiheitsgradparameter n und dann sekundär durch den Freiheitsgradparameter m bestimmt werden.



Theorem 12.15 (F -Transformation). $V \sim \chi^2(n)$ und $W \sim \chi^2(m)$ seien zwei unabhängige χ^2 -Zufallsvariablen mit Freiheitsgradparametern n und m , respektive. Dann ist die Zufallsvariable

$$F := \frac{V/n}{W/m} \quad (12.80)$$

eine F -verteilte Zufallsvariable mit Freiheitsgradparametern n, m , es gilt also $F \sim F(n, m)$.

◦

Das Theorem kann bewiesen werden, indem man zunächst ein Transformationstheorem für Quotienten von Zufallsvariablen mithilfe von [Theorem 11.1](#) und Marginalisierung herleitet und dieses Theorem dann auf die WDF von χ^2 -verteilten Zufallsvariablen anwendet. Wir visualisieren [Theorem 12.15](#) exemplarisch in [Abbildung 12.19](#). Wichtige Anwendungsfälle von [Theorem 12.15](#) sind die im Rahmen der Theorie des Allgemeinen linearen Modells betrachteten F -Statistiken.

Abbildung 12.18 WDFen von F -verteilten Zufallsvariablen.Abbildung 12.19 F -Transformation normalverteilter Zufallsvariablen.

12.8 Literaturhinweise

Die Entwicklung der bivariaten Normalverteilung hat ihre Ursprünge in der statistischen Literatur zur Mitte des 19. Jahrhunderts, insbesondere in den Arbeiten von Francis Galton (1822-1911). Die mathematische Formalisierung der bivariaten Normalverteilung geht dabei wohl auf Pearson (1896) zurück (Seal (1967)). Die ursprüngliche Formulierung der multivariaten Normalverteilung wird bei Edgeworth (1892) verortet. Tong (1990) gibt einen umfassenden Überblick zur Theorie und Anwendung der multivariaten Normalverteilung.

Selbstkontrollfragen

1. Geben Sie das Summationstransformationstheorem wieder.
2. Geben Sie das Mittelwerttransformationstheorem wieder.
3. Geben Sie das Z -Transformationstheorem wieder.
4. Geben Sie das χ^2 -Transformationstheorem wieder.
5. Beschreiben Sie die WDF der t -Verteilung in Abhängigkeit ihres Freiheitsgradparameters.
6. Geben Sie das T -Transformationstheorem wieder.
7. Geben Sie das F -Transformationstheorem wieder.

Lösungen

1. Siehe Theorem [12.9](#).
2. Siehe Theorem [12.10](#).
3. Siehe Theorem [12.11](#).
4. Siehe Theorem [12.12](#).
5. Siehe Abbildung [12.14](#).
6. Siehe Theorem [12.13](#).
7. Siehe Theorem [12.15](#).

Referenzen

- Anderson, T. W. (2003). *An Introduction to Multivariate Statistical Analysis* (3rd ed). Wiley-Interscience.
- Bayes, T. (1763). An essay towards solving a problem in the doctrine of chances. By the late Rev. Mr. Bayes, F. R. S. communicated by Mr. Price, in a letter to John Canton, A. M. F. R. S. *Philosophical Transactions of the Royal Society of London*, 53, 370–418. <https://doi.org/10.1098/rstl.1763.0053>
- Billingsley, P. (1995). *Probability and Measure* (3rd ed). Wiley.
- Borel, É. (1898). *Leçons Sur La Théorie Des Fonctions*. Paris: Gauthier Villars.
- Casella, G., & Berger, R. (2002). *Statistical Inference* (2. Aufl.). Thomson Learning.
- Christensen, R. (2011). *Plane Answers to Complex Questions*. Springer New York. <https://doi.org/10.1007/978-1-4419-9816-3>
- De Finetti, B. (1975). *Theory of Probability*. John Wiley & Sons.
- DeGroot, M. H., & Schervish, M. J. (2012). *Probability and Statistics* (4th ed). Addison-Wesley.
- Edgeworth, F. Y. (1892). The Law of Error and Correlated Averages. *The London, Edinburgh, and Dublin Philosophical Magazine and Journal of Science*, 34(210), 429–438. <https://doi.org/10.1080/14786449208620355>
- Fischer, H. (2011). *A History of the Central Limit Theorem*. Springer New York. <https://doi.org/10.1007/978-0-387-87857-7>
- Gillies, D. (2000). Varieties of Propensity. *The British Journal for the Philosophy of Science*, 51(4), 807–835. <https://doi.org/10.1093/bjps/51.4.807>
- Hájek, A. (2019). Interpretations of Probability. In E. N. Zalta (Hrsg.), *The Stanford Encyclopedia of Philosophy* (Fall 2019). Metaphysics Research Lab, Stanford University.
- Hald, A. (1990). *A History of Probability and Statistics and Their Applications before 1750*. Wiley.
- Hald, A. (2007). *A History of Parametric Statistical Inference from Bernoulli to Fisher, 1713-1935*. Springer.
- Hautzinger, M., Keller, F., & Kühner, C. (2006). *BDI-II Beck Depressions-Inventar*. Pearson.
- Henze, N. (2024). *Stochastik: Eine Einführung mit Grundzügen der Maßtheorie: Inkl. zahlreicher Erklärvideos*. Springer Berlin Heidelberg. <https://doi.org/10.1007/978-3-662-68649-2>
- Herzog, S., & Ostwald, D. (2013). Sometimes Bayesian Statistics Are Better. *Nature*, 494(7435), 35–35. <https://doi.org/10.1038/494035b>
- Hesse, C. (2009). *Wahrscheinlichkeitstheorie* (2. Aufl.). Vieweg + Teubner.
- Jaynes, E. (1968). Prior Probabilities. *IEEE Transactions on Systems Science and Cybernetics*, 4(3), 227–241. <https://doi.org/10.1109/TSSC.1968.300117>
- Jeffreys, H. (1939). *Theory Of Probability*. Oxford Classic Texts in the Physical Sciences.
- Johnson, N. L., & Welch, B. L. (1940). Applications of the Non-Central t-Distribution. *Biometrika*, 31(3/4), 362. <https://doi.org/10.2307/2332616>
- Kolmogoroff, A. (1933). *Grundbegriffe der Wahrscheinlichkeitsrechnung*. Springer Berlin Heidelberg. <https://doi.org/10.1007/978-3-642-49888-6>

- Laplace, P. S. (1814). *A Philosophical Essay on Probabilities*.
- Lehmann, E. L. (1986). *Testing Statistical Hypotheses*. Wiley Series in Probability and Statistics.
- Lévy, P. (1937). *Théorie de l'addition des variables aléatoires*. Gauthier-Villars.
- Liapounoff, A. M. (1900). Sur Une Proposition de La Théorie Des Probabilités. *Bulletin de l'Académie Impériale des Sciences de Saint-Petersbourg*, 13, 359.
- Liapounoff, A. M. (1901). Nouvelle Forme Du Théorème Sur La Limite de Probabilité. *Mémoires de l'Académie Impériale des Sciences de Saint Pétersbourg*, VIII, 12(5).
- Lindeberg, J. W. (1922). Eine Neue Herleitung Des Exponentialgesetzes in Der Wahrscheinlichkeitsrechnung. *Mathematische Zeitschrift*, 15, 211–225.
- Mardia, K. V., Kent, J. T., & Bibby, J. M. (1979). *Multivariate Analysis*. Academic Press.
- Meintrup, D., & Schäffler, S. (2005). *Stochastik: Theorie und Anwendungen*. Springer.
- Pearson, K. (1896). Mathematical Contributions to the Theory of Evolution. III. Regression, Heredity, and Panmixia. *Philosophical Transactions of the Royal Society of London. Series A, Containing Papers of a Mathematical or Physical Character*, 18, 253–318. <https://www.jstor.org/stable/90707>
- Peirce, C. S. (1957). Notes on the Doctrine of Chances. In *Essays in the Philosophy of Science* (S. 74–84). Bobbs-Merrill.
- Philip, S., Kew, S., Van Oldenborgh, G. J., Otto, F., Vautard, R., Van Der Wiel, K., King, A., Lott, F., Arrighi, J., Singh, R., & Van Aalst, M. (2020). A Protocol for Probabilistic Extreme Event Attribution Analyses. *Advances in Statistical Climatology, Meteorology and Oceanography*, 6(2), 177–203. <https://doi.org/10.5194/ascmo-6-177-2020>
- Popper, K. R. (1959). The Propensity Interpretation of Probability. *The British Journal for the Philosophy of Science*, 10(37), 25–42. <https://doi.org/10.1093/bjps/X.37.25>
- Ramsey, F. P. (1926). Truth and Probability. In *The Foundations of Mathematics and Other Logical Essays, Chp VII* (S. 156–198). Harcourt, Brace and Company.
- Reichenbach, H. (1949). Philosophical Foundations of Probability. *Proceedings of the Berkeley Symposium on Mathematical Statistics and Probability*, 1–20.
- Savage, L. J. (1954). *The Foundations of Statistics* (S. xv, 294). John Wiley & Sons.
- Schmidt, K. D. (2009). *Maß und Wahrscheinlichkeit*. Springer.
- Seal, H. L. (1967). Studies in the History of Probability and Statistics. XV: The Historical Development of the Gauss Linear Model. *Biometrika*, 54(1/2), 1. <https://doi.org/10.2307/2333849>
- Steele, J. M. (2006). *The Cauchy-Schwarz Master Class: An Introduction to the Art of Mathematical Inequalities* (repr). Cambridge University Press [u.a.].
- Stigler, S. M. (1986). *The History of Statistics: The Measurement of Uncertainty before 1900*. Belknap Press of Harvard University Press.
- Student. (1908). The Probable Error of a Mean. *Biometrika*, 6(1), 1–25.
- Tong, Y. L. (1990). *Multivariate Normal Distribution*. Springer.
- Ulyanov, V. V. (2024). From Classical to Modern Central Limit Theorems. *arXiv Preprint arXiv:2405.19282v1*. <https://arxiv.org/abs/2405.19282v1>
- Venn, J. (1876). *The Logic of Chance*. MacMillan.
- von Mises, R. (1951). *Wahrscheinlichkeit, Statistik Und Wahrheit*. Springer International Publishing. https://doi.org/10.1007/978-3-319-29251-9_9
- Von Plato, J. (1994). *Creating Modern Probability: Its Mathematics, Physics, and Philosophy in Historical Perspective*. Cambridge University Press.
- Walley, P. (1991). *Statistical Reasoning with Imprecise Probabilities* (1st ed). Chapman and Hall.
- Zabell, S. L. (2008). On Student's 1908 Article „The Probable Error of a Mean“. *Jour-*

nal of the American Statistical Association, 103(481), 1–7. <https://doi.org/10.1198/016214508000000030>